




國立臺北科技大學

資訊工程系碩士班

碩士學位論文

自我監督式學習應用於醫療影像之研究
Application of Self-Supervised Learning to Medical
Imaging



研究生：張維俊

指導教授：尤信程、劉建宏

中華民國一百一十二年七月

國立臺北科技大學
研究所碩士學位論文口試委員會審定書

本校資訊工程研究所張維俊君

所提論文，經本委員會審定通過，合於碩士資格，特此證明。

學位考試委員會

委

員：

尤信程

陳威廷

劉建宏

指導教授：

尤信程 劉建宏

所

長：

劉建宏

中華民國一百零一十二年七月十九日

摘要

論文名稱：自我監督式學習應用於醫療影像之研究

頁數：八十頁

校所別：國立臺北科技大學 資訊工程系碩士班

畢業時間：一百一十一學年度 第二學期

學位：碩士

研究生：張維俊

指導教授：尤信程、劉建宏 教授

關鍵詞：腦部腫瘤分割、深度學習、卷積神經網路、監督式學習、自我監督式學習、遷移學習

MRI 和 PET-CT 是在腦腫瘤分析和監測中被廣泛使用的可靠診斷工具，自動腦腫瘤分割技術在疾病診斷中也起到輔助的作用。然而醫療影像分割依賴於大量的人工標籤資料集，由於進行人工標記的成本和時間很高，因此通常不容易取得足夠的資料。另外與 MRI 腦部影像上的腫瘤特徵相比，PET-CT 上的腫瘤區域用人工的方式更加難以識別，所以對 PET-CT 進行人工腫瘤標記變得更具有挑戰性。本研究嘗試從 MRI 影像上的人工標籤轉移到同一位患者的 PET-CT 影像上，用來當做 PET-CT 訓練用的標籤，並探討自我監督式學習在有限的資料下分別對 MRI 與 PET-CT 腦腫瘤自動分割的性能表現，同時與傳統監督式學習和遷移學習進行比較。實驗結果顯示，自我監督式學習對 MRI 與 PET-CT 腦腫瘤偵測的性能比傳統監督式學習和遷移學習還要好。經過資料增強後，模型的性能以及泛化能力也有進一步的提升。最後也證實了以 MRI 腫瘤標籤轉移到 PET-CT 的方法用來偵測 PET-CT 上的腫瘤是可行的。

ABSTRACT

Title: Application of Self-Supervised Learning to Medical Imaging

Pages: 80

School: National Taipei University of Technology

Department: Department of Computer Science & Information Engineering

Time: July, 2023

Degree: Master


Researcher: Wei-Jun Zhang

Advisor: Shing-Chen You, Ph.D., Chien-Hung Liu, Ph.D.

Keywords: Brain Tumor Segmentation, Deep Learning, Convolutional Neural Network, Supervised Learning, Self-Supervised Learning, Transfer Learning

MRI and PET-CT are widely used as reliable diagnostic tools in the analysis and monitoring of brain tumor, and automated brain tumor segmentation technology also plays an auxiliary role in disease diagnosis. However, medical image segmentation relies on a large number of manual labeling dataset, and due to the high cost and time of manual labeling, it is usually not easy to obtain sufficient data. In addition, compared with the tumor features on MRI brain images, the tumor areas on PET-CT are more difficult to identify by artificial means, so the manual tumor labeling on PET-CT becomes more challenging. This study attempted to transfer manual tumor labels from MRI images to PET-CT images of the same patient, which were used as PET-CT training labels, and explored the performance of Self-Supervised Learning in automatic segmentation of MRI and PET-CT brain tumor with limited data. At the same time, it is compared with traditional Supervised Learning and Transfer Learning. The results show that the performance of Self-Supervised Learning in MRI and PET-CT brain tumor detection is better than that of traditional Supervised Learning and Transfer Learning. After applying Data Augmentation, the performance and generalization ability of the model are further improved. Finally, it is proved that the method of transferring of MRI tumor labels to

PET-CT is feasible to detect the tumor on PET-CT.



致謝

首先，我要感謝劉建宏教授與尤信程教授。在我寫論文的過程中給予我許多專業的指導和建議，幫助我理清思路，掌握方法，每週固定的會議，更是讓我感受到了您們的負責任和耐心，以至於能夠順利完成研究。

此外，我也要感謝實驗室的同學。在這裡，我能夠與大家一起學習、一起成長，你們的支持和幫助對我來說是非常重要的。在我遇到問題的時候，總是願意伸出援手，給予我最大的支持和鼓勵。

在研究完成的過程中，還要感謝我的家人和朋友。您們的支持和鼓勵給了我最大的動力。在我遇到瓶頸的時候，您們總是給我最大的鼓勵和支持，讓我克服了所有的困難。

最後，我要向所有關注和支持我的人致以最衷心的感謝。謝謝您們的鼓勵和支持，讓我感受到了最大的溫暖。在未來的學習和工作中，我會繼續努力，不負眾望，回報社會。



目錄

摘要.....	i
ABSTRACT.....	ii
致謝.....	iv
目錄.....	v
表目錄.....	ix
圖目錄.....	x
1 第一章 緒論.....	1
1.1 研究動機與目的.....	1
1.2 論文的組織架構.....	2
2 第二章 背景介紹與相關研究.....	3
2.1 人工神經網路.....	3
2.1.1 單層神經網路.....	3
2.1.2 多層神經網路.....	4
2.2 深度學習.....	4
2.2.1 卷積神經網路.....	4
2.2.2 循環神經網路.....	6
2.2.3 殘差網路.....	6
2.2.4 自動編碼器.....	7
2.2.5 Transformer 架構.....	9
2.2.6 Vision Transformer 架構.....	10
2.2.7 Swin Transformer 架構.....	11
2.2.8 U-Net 架構.....	15

2.2.9 SwinUNETR 架構	17
2.2.10 監督式學習	18
2.2.11 遷移學習	19
2.2.12 自我監督式學習	19
2.3 評估指標與損失函數	22
2.3.1 Dice	22
2.3.2 Specificity.....	22
2.3.3 Dice Loss.....	23
2.3.4 Focal Loss	23
2.3.5 Contrastive Loss	23
2.4 Pytorch	24
2.5 醫療影像處理套件	25
2.5.1 Pydicom.....	25
2.5.2 High Order Slice Interpolation.....	25
2.5.3 3D Slicer.....	25
2.6 醫療影像資料集	26
2.6.1 MRI 核磁共振	26
2.6.2 PET-CT 正子電腦斷層掃描.....	27
2.6.3 BraTS2021 資料集	27
2.6.4 Ours MRI 資料集.....	28
2.6.5 TCIA PET-CT 腦部資料集.....	29
2.6.6 Ours PET-CT 資料集	29
2.7 相關文獻探討	30
3 第三章 研究方法	32
3.1 MRI 腦部資料處理	32

3.1.1 處理 Ours MRI 資料.....	32
3.1.2 處理 Brats2021 資料	34
3.2 PET-CT 腦部資料處理.....	35
3.2.1 處理 Ours PET-CT 資料	35
3.2.2 處理 TCIA PET & CT 腦部資料.....	37
3.3 Unet 與 SwinUNETR 模型訓練.....	38
3.3.1 Unet 模型參數	38
3.3.2 SwinUNETR 模型參數	39
3.3.3 訓練前處理	41
3.3.4 使用 BraTS2021 資料集進行 Supervised Learning	41
3.3.5 使用 Ours MRI 資料集進行 Supervised Learning	42
3.3.6 使用 BraTS2021 + Ours MRI 資料集進行 Supervised Learning.....	42
3.4 留一驗證的 Data Augmentation.....	43
3.5 針對 MRI 小腫瘤患者的模型訓練	44
3.5.1 使用 BraTS2021 + MRI 小腫瘤資料集進行 Supervised Learning	45
3.5.2 使用 MRI 小腫瘤資料集進行 Supervised Learning	46
3.5.3 對 MRI 小腫瘤資料集進行 Transfer Learning	47
3.5.4 對 MRI 小腫瘤資料集進行 Self-Supervised Learning	48
3.6 針對 PET-CT 大腫瘤患者的模型訓練.....	50
3.6.1 使用 PET-CT 大腫瘤資料集進行 Supervised Learning.....	51
3.6.2 使用 PET-CT 大腫瘤資料集進行 Self-Supervised Learning.....	52
4 第四章 實驗結果與討論.....	53
4.1 實驗電腦硬體設備與環境設置	54
4.2 所使用之資料集	56
4.3 實驗一： 測試 Unet 及 SwinUNETR 對 Brats2021 & Ours MRI 資料集上的	

Dice 表現	56
4.4 實驗二：以 BratTS2021 + MRI 小腫瘤資料集進行監督式學習並測試對 MRI 小腫瘤測試集上的 Dice 表現	61
4.5 實驗三：測試 Supervised Learning 對 MRI 小腫瘤資料集上的 Dice 表現...	62
4.6 實驗四：測試 Transfer Learning - Finetuning 對 MRI 小腫瘤資料集上的 Dice 表現.....	63
4.7 實驗五：測試 Transfer Learning – Layers Freezing 對 MRI 小腫瘤資料集上的 Dice 表現	65
4.8 實驗六：測試 Self-Supervised Learning 對 MRI 小腫瘤資料集上的 Dice 表現	66
4.8.1 測試模型在不同 Loss Function 下對偵測 MRI 小腫瘤的影響.....	68
4.9 實驗七：測試監督式學習在 PET-CT 大腫瘤資料集上的 Dice 表現	68
4.10 實驗八：測試 Self-Supervised Learning 在 PET-CT 大腫瘤資料集上的 Dice 表現.....	69
4.11 實驗九：評估腫瘤模型的 Specificity.....	71
4.12 結果與討論	74
5 第五章 結論及未來研究方向	77
5.1 結論	77
5.2 未來研究方向	77
6 參考文獻	78

表目錄

表 4.1 所有實驗概述	53
表 4.2 實驗機器硬體配備	55
表 4.3 實驗環境框架版本	55
表 4.4 監督式學習超參數	55
表 4.5 自監督式學習超參數	55
表 4.6 所使用資料集數量	56
表 4.7 對 BraTS2021 Train 訓練後對 BraTS2021 Test 預測之 Dice 比較	60
表 4.8 以 BraTS2021 Train 訓練後對 Ours Test 預測之 Dice 比較	60
表 4.9 以 Ours MRI Train 訓練後對 Ours MRI Test 預測之 Dice 比較	60
表 4.10 以 BraTS2021 + Ours MRI Train 訓練後對 Ours MRI Test 預測之 Dice 比較	61
表 4.11 MRI 大腫瘤與小腫瘤的 Dice 分數	61
表 4.12 實驗二之 Dice 結果	62
表 4.13 Finetuning 在各種 Epochs 數量下的 Dice 表現對比	64
表 4.14 對 MRI 正常患者偵測腫瘤之結果統計表	72

圖目錄

圖 2-1 單層神經元網路.....	3
圖 2-2 多層神經網路.....	4
圖 2-3 卷積運算示例圖.....	5
圖 2-4 卷積神經網路示例圖.....	5
圖 2-5 RNN 架構範例	6
圖 2-6 ResNet 架構示意圖.....	7
圖 2-7 自動編碼器 (Autoencoder) 示意圖	8
圖 2-8 Transformer 模型架構圖	10
圖 2-9 Vision Transformer (ViT) 架構圖.....	10
圖 2-10 Swin Transformer (Swin-T) 架構圖	11
圖 2-11 Swin Transformer Block 架構圖	12
圖 2-12 Swin Transformer Block 運算公式圖	13
圖 2-13 相對位置索引求解流程示意圖.....	13
圖 2-14 相對位置編碼矩陣圖.....	14
圖 2-15 Shifted Window 方法示意圖	14
圖 2-16 Cyclic Shift 方法示意圖	15
圖 2-17 U-Net 架構圖.....	16
圖 2-18 Swin UNETR 架構圖	17
圖 2-19 監督式學習示意圖.....	18
圖 2-20 遷移學習示意圖.....	19
圖 2-21 對比學習 Data Augmentation 示意圖	21
圖 2-22 對比學習框架示意圖.....	21
圖 2-23 Contrastive Loss 公式示意圖.....	24
圖 2-24 腦部 MRI 多模態示意圖	26

圖 2-25 腦部 PET-CT 示意圖	27
圖 2-26 多模態腦部 MRI 資料集示意圖	28
圖 2-27 振興醫院 MRI 資料集示意圖	28
圖 2-28 TCIA A Whole-body FDG-PET/CT dataset 示意圖	29
圖 2-29 Ours PET-CT 資料集示意圖	30
圖 3-1 DICOM 圖像像素轉換過程示意圖	34
圖 3-2 Ours PET-CT 資料集示意圖	35
圖 3-3 PET-CT 彩色圖轉灰階圖的各種計算方式的結果比較圖	36
圖 3-4 General Registration (BRAINS) 工具參數設定圖	36
圖 3-5 MRI 與 PET-CT Registration 結果對比圖	37
圖 3-6 TCIA PET-CT 處理流程示意圖	38
圖 3-7 Unet 模型參數圖	39
圖 3-8 SwinUNETR 模型參數圖	41
圖 3-9 BraTS2021 三折交叉驗證示意圖	41
圖 3-10 Ours MRI 三折交叉驗證示意圖	42
圖 3-11 BraTS2021 + Ours MRI 三折交叉驗證示意圖	43
圖 3-12 留一驗證的 Data Augmentation 示意圖	44
圖 3-13 MRI 腦部大腫瘤與小腫瘤資料集示意圖	45
圖 3-14 BraTS2021 + MRI 小腫瘤資料集留一驗證示意圖	46
圖 3-15 MRI 小腫瘤資料集留一驗證示意圖	46
圖 3-16 遷移學習 Finetuning 示意圖	47
圖 3-17 遷移學習 Layer Freezing 示意圖	48
圖 3-18 自我監督式學習 Image Augmentation 示意圖	49
圖 3-19 MRI 小腫瘤資料集自我監督式學習完整流程示意圖	50
圖 3-20 PET-CT 腦部大腫瘤與小腫瘤資料集示意圖	51

圖 3-21 PET-CT 大腫瘤資料集留一驗證示意圖	51
圖 3-22 PET-CT 大腫瘤資料集自我監督式學習完整流程示意圖	52
圖 4-1 Unet 及 SwinUNETR 對 BraTS2021 訓練資料之 Loss 變化	57
圖 4-2 Unet 及 SwinUNETR 對 BraTS2021 訓練資料之 Validation Dice 變化.....	57
圖 4-3 Unet 及 SwinUNETR 對 Ours MRI 訓練資料之 Loss 變化	58
圖 4-4 Unet 及 SwinUNETR 對 Ours MRI 訓練資料之 Validation Dice 變化.....	58
圖 4-5 Unet 及 SwinUNETR 對 BraTS2021 + Ours MRI 訓練資料之 Loss 變化.....	59
圖 4-6 Unet 及 SwinUNETR 對 BraTS2021 + Ours MRI 訓練資料之 Validation Dice 變 化.....	59
圖 4-7 MRI 在不同倍數的 Data Augmentation 下監督式學習對於小腫瘤的 Dice 變化	63
圖 4-8 MRI 小腫瘤在不同倍數的 Data Augmentation 下採用 Finetuning 策略之 Dice 變化.....	64
圖 4-9 MRI 小腫瘤在不同倍數的 Data Augmentation 下採用 Layers Freezing 方法之 Dice 變化	66
圖 4-10 SwinVit AutoEncoder 對 BraTS2021 資料集進行對比學習之 Loss 變化	67
圖 4-11 MRI 小腫瘤在不同倍數的 Data Augmentation 下自我監督式學習之 Dice 變化	67
圖 4-12 PET-CT 大腫瘤在不同倍數的 Data Augmentation 下監督式學習之 Dice 變化	69
圖 4-13 SwinVit AutoEncoder 對 TCIA 資料集進行對比學習之 Loss 變化.....	70
圖 4-14 PET-CT 大腫瘤在不同倍數的 Data Augmentation 下自我監督式學習之 Dice 變 化.....	70
圖 4-15 MRI 小腫瘤模型對正常患者進行腫瘤預測的結果代表圖	71
圖 4-16 PET-CT 大腫瘤模型對正常患者進行腫瘤預測的結果代表圖	73
圖 4-17 MRI 小腫瘤在不同倍數的 Data Augmentation 下採用四種不同方法之 Dice	

變化對比圖	74
圖 4-18 MRI 小腫瘤分割結果示例圖	74
圖 4-19 PET-CT 大腫瘤在不同倍數的 Data Augmentation 下採用兩種不同方法之 Dice 變化對比圖	75
圖 4-20 PET-CT 大腫瘤分割結果示例圖	76



第一章 緒論

1.1 研究動機與目的

在醫療影像處理的領域中，想要辨識圖像中的腫瘤，以 AutoEncoder 的網路架構進行深度學習有著非常好的效果，在特徵有效、腫瘤樣本足夠、資料集來源類似的情況下，通常預測出來的結果都很不錯。

而傳統的深度學習方法在醫療影像中的腫瘤偵測方面存在一定的限制。其中一個主要問題是標記資料的需求和標記的成本，這通常需要專業醫生花費大量時間和努力來進行。此外，由於腫瘤樣本的稀缺性，這也限制了傳統監督式學習方法的性能。


在腦部腫瘤分割的問題上，由於 Unet [1] 有著良好的分割性能，所以它一直是研究者們用來分割腫瘤的首選模型。根據近年來其他學者的研究 [2] 顯示，在 Unet [1] 網路架構的基礎，加上 Transformer [3] 模塊能有效改善分割效果。然而醫療影像資料屬於敏感和隱私保護的個人醫療資訊，因此取得醫療影像資料的成本相對較大，往往會導致出現資料樣本稀缺的問題。在資料樣本稀缺的情況下訓練出來的模型，分割效果往往大打折扣，甚至無法正確偵測出腫瘤區域。

相較於 MRI 腦部影像上的腫瘤特徵，PET-CT 的腫瘤區域用人工方式比較不容易辨識，因此在 PET-CT 上進行人工標記變得更加困難。為了解決這個問題，我們可以利用在 MRI 影像上進行人工標記的腫瘤標籤，將其轉移到同一位患者的 PET-CT 影像上。

本論文的研究目的是探討自我監督式學習在醫療影像中的應用，特別是在腦部腫瘤偵測方面的應用。我們的目標是評估自我監督式學習方法在有限的資料樣本的情況下對腦部腫瘤偵測的性能表現，並比較其與傳統監督式學習和遷移學習方法。此外，我們還將通過對 MRI 進行的人工標籤轉移到 PET-CT 上，以進行 PET-CT 的模型的訓練並評估其方法在 PET-CT 腫瘤偵測上的有效性。

1.2 論文的組織架構

本論文的組織架構如下：本論文第二章探討背景介紹與相關研究；第三章研究方法則介紹處理醫療影像資料以及所進行的深度學習方法；第四章為本論文的各種不同的實驗來評估深度學習方法在腫瘤分割上的表現；最後第五章結論與未來研究方向將會回顧第一章至第四章的研究成果並做出結論，同時提出我們認為較有意義的未來研究方向。



第二章 背景介紹與相關研究

本章節會介紹本論文中相關領域背景知識與深度學習框架，包括 Transformer 模型、Unet 網路架構、SwinUnetr 網路架構、監督式學習、自我監督式學習、遷移學習、Pytorch 套件、核磁共振 MRI、正子電腦斷層掃描 PET-CT、本論文中所使用的醫療影像處理套件及資料集。

2.1 人工神經網路

人工神經網路(Artificial Neural Network)是一種模擬生物神經網路的計算模型。它由大量人工神經元組成，神經元之間通過連接進行信息傳遞和計算。廣泛應用於機器學習和人工智能領域，在圖像識別、語音識別、自然語言處理等領域取得了重大突破和應用。

2.1.1 單層神經網路

單層神經網路 (Single-layer Neural Network)，是最簡單的神經網路模型之一。它由一個接收輸入並產生輸出的單個神經元組成。在單層神經網路中，所有輸入都直接連接到輸出，沒有額外的隱藏層。如圖 2-1 所示。




圖 2-1 單層神經元網路

2.1.2 多層神經網路

多層神經網路 (Multilayer Neural Network)，也稱為深度神經網路 (Deep Neural Network)，是一種包含多個神經層的神經網路模型。它通常由一個輸入層、多個隱藏層和一個輸出層所組成。




圖 2-2 多層神經網路

2.2 深度學習

深度學習 (Deep Learning) 是一種基於多層神經網路的機器學習方法。它模仿人類大腦中神經元的連接和組織方式，深度學習的核心是使用深度神經網絡 (Deep Neural Networks)。這些網路通常由多個隱藏層組成，每個隱藏層包含許多神經元。每個神經元接收前一層神經元的輸出，通過權重連接和非線性激活函數計算。通過不斷調整神經元之間的權重，深度學習網路可以自動學習複雜的特徵，以實現高效的預測能力。

2.2.1 卷積神經網路

卷積神經網路 (CNN) 是一種深度學習模型，通常用於圖像和視覺資料處理。它主要用於圖像識別、目標檢測和圖像分割。卷積神經網路的核心結構是卷積層 (Convolutional Layer)，它利用卷積運算從圖像中提取特徵。卷積操作包括建立一個稱為卷積核 (Kernel)

Map)的小矩陣，在元素級將其與輸入圖像相乘，然後將乘積求和以獲得卷積結果的一個元素。通過對圖像滑動卷積核，可以對整個圖像進行特徵提取。圖 2-3 為卷積運算示例圖：




圖 2-3 卷積運算示例圖

卷積神經網路還包括一個池化層 (Pooling Layer)，用於減小特徵映射的大小並保留重要特徵。常用的池化操作包括最大池化 (Max Pooling) 和平均池化 (Average Pooling)，分別提取特徵映射的最大值和平均值。卷積神經網路的結構通常由多個卷積層、池化層和全連接層 (Fully Connected Layer) 組成。全連接層負責將最後一個特徵映射，映射到相應的輸出類別，用於分類或預測。卷積神經網路(Convolutional Neural Network, CNNs) 在圖像處理領域表現良好，它可以自動學習圖像的局部特徵並將其組合起來，從而實現高級特徵的提取和識別。圖 2-4 為卷積神經網路示例圖：




圖 2-4 卷積神經網路示例圖

2.2.2 循環神經網路

循環神經網路(Recurrent Neural Network, RNN)是一種廣泛應用於序列數據處理的神經網路模型。與傳統的前饋神經網路不同，RNNs 具有記憶和反饋機制來捕獲序列資料中的時間依賴性。RNN 的關鍵特徵是它的循環結構，它允許信息在網路中持久地傳輸。它在處理序列資料時具有記憶能力，能夠捕捉序列中的上下文信息。在每個時間步長，RNN 接收前一個時間步長的輸入和隱藏狀態，然後根據權值進行計算，並將結果作為該時間步長的輸出和下一個時間步長的隱藏狀態。這種反饋連接允許 RNNs 積累先前的信息，並在處理序列時具有記憶和上下文感知能力。

下圖為簡單的 RNN 模型，A 的輸入是 X_t (向量)，輸出為值 h_t ，在圖中我們將等號左邊的架構展開之後可以得到等號右邊的部分，可以看到每一個輸出值即 h_0 到 h_t 不只受上一層輸入的影響，也受到同一層前一個輸出的影響。




圖 2-5 RNN 架構範例

我們以一個簡單的例子來說明 RNN 原理對輸出的影響，假設下面這兩個句子：

- His grade is under 60, so he "failed the exam"
- His grade is above 60, so he "passed the exam"

在分析 "so he" 的下一個詞時，若不考慮前文，"failed" 與 "passed" 的機率是相等的，反之，如果考慮 "under 60"，選 "failed" 的機率應該就會大於 "passed"。

2.2.3 殘差網路

在神經網路的訓練中，為了提高模型性能，除了改變參數或調整輸入參數外，就是

加深網絡的層數。然而，當神經網絡的深度達到一定的層數時，可能會出現梯度消失問題，但是可以使用 Normalized Initialization 等方法解決此問題。K. He 等人的研究[4]表明，56 層網路的結果比 20 層網路的結果更差，這個結果並不是由於過擬合造成的。因此，K. He 等人提出的深度殘差網絡[4]架構，是可以解決這個問題的。

在圖 2-6 的左半部分，是我們通常所使用的神經網路。假設我們輸入一個 input，網路層的輸出為 $F(\text{input})$ ，那麼我們最終的輸出將等於 $F(\text{input})$ 。在圖 2-6 的右半部分則是一個殘差架構，可以看到輸入的部分有一條線連接到網路的最終輸出，所以我們的最終輸出等於 $F(\text{input}) + \text{input}$ 。




圖 2-6 ResNet 架構示意圖

2.2.4 自動編碼器

Autoencoder 是深度學習中的一種架構，其輸入與預測輸出完全相同。通過壓縮資料、降低維度學習其中的規律使資料的特徵能夠盡可能以更少的神經元儲存，藉此減少神經網路儲存資訊量的負擔，其目的與主成份分析 (Principal components analysis, PCA) 相似。由於 Autoencoder 與數據高度相關，這代表其通常只能壓縮與訓練數據相似的數據，例如，當使用人類圖片作為訓練資料時，訓練出來的權重就很難對其他動物的圖片

進行壓縮。此外，經過 Autoencoder 壓縮後的數據維度較少，在經過還原成原本的圖像時通常會有小部分的損失。

一般來說，Autoencoder 分為編碼器（Encoder）和解碼器（Decoder）兩個部分。編碼器（Encoder）負責將輸入轉換至維度較低的隱藏層，過程中將會通過權重保留重要的特徵，因此這些特徵又被稱為 Latent variables。（Decoder）解碼器則是與編碼器（Encoder）完全相反的架構，能夠將 Latent variables 反向還原為大小與輸入完全相同的輸出，並將輸出與輸入進行比對計算誤差，隨後進一步更新模型中的權重。若 x 為輸入、Latent variables 為 v ，則編碼器公式如下：

$$v = F(Wx + \beta) \quad (2-1)$$

其中 F 代表所使用的激活函數， W 代表權重矩陣， β 為 bias vector。而當 v 進入解碼器轉換成與 x 相同大小的輸出 x' 時，解碼器的公式與編碼器類似：

$$v' = F'(W'x + \beta') \quad (2-2)$$

當進行訓練時，權重矩陣與 bias vector 便會根據訓練資料輸出的結果以損失函數計算誤差後去做更新的動作。一個典型的 Autoencoder 之編碼器與解碼器的隱藏層通常是由少量的全連接層（Fully Connected Layer）所組成，示意圖如圖 2-7，且編碼器與解碼器皆是由單一全連接層所構成。




圖 2-7 自動編碼器（Autoencoder）示意圖

目前 Autoencoder 常見的用途有兩項：第一項是資料的去噪，如影像去噪、語音處理和信號處理等。第二項是降低資料的維度以便進行可視化，便於人類理解資料在低維度時彼此之間的相似程度與深度學習在辨別時所應用到的特徵。

2.2.5 Transformer 架構

Transformer（變換器）於 2017 年由 Google 大腦的一個團隊推出[3]，它是一種採用自注意力機制（Self-Attention）的深度學習模型，這一機制可以按輸入資料各部分重要性的不同而分配不同的權重。其中 Attention 架構結合了 CNN 及 RNN 的優點，並且能改善 RNN 不能平行運算的缺點。Transformer 則是基於 Attention 架構的 Encoder 和 Decoder，該模型主要用於自然語言處理（NLP）與電腦視覺（CV）領域。

Transformer 模型架構如圖 2-8 所示，圖的左半部為 Encoder，圖的右半部為 Decoder，分別在 Encoder 和 Decoder 中使用了堆疊式的 Self-Attention 和點式全連接層。




圖 2-8 Transformer 模型架構圖

資料來源：參考文獻[3]

2.2.6 Vision Transformer 架構

Vision Transformer (ViT) [15] 成功將 Transformer 引入到計算機視覺領域，架構與原始的 Transformer 幾乎相同，它允許將圖像視為輸入，是一種針對圖像識別等視覺處理任務的 Transformer，其架構如圖 2-9 所示：




圖 2-9 Vision Transformer (ViT) 架構圖

資料來源：參考文獻[15]

Vision Transformer 模型使用 Transformer Encoder 作為基礎模型從圖像中提取特徵，並將這些處理過的特徵傳遞到多層感知器頭部 (MLP Head) 中進行分類。由於基礎 Transformer 的計算量已經非常大了，因此 Vision Transformer 使用一種稱為 Patch Embedding 的方法將圖像劃分為固定大小且沒有重疊的小區域，稱為 Patch (例如 16×16)。然後，每個 Patch 被平鋪成一個一維向量，將它們串在一起形成一個輸入序列。這個序列的長度可以看作是 NLP 中輸入序列的長度 (假設輸入圖像為 224×224 ，每個 Patch 大小為 16×16 ，則序列 n 的長度為 196)。每個 Patch 的一維向量的維數等於單詞向量編碼的長度 (假設圖片通道為 3，則每個向量的長度為 768)。

為了便於後續的分類任務，Vision Transformer 還引入了一個可學習的 Class Token。這個 Token 被插入到圖像序列的開頭。整個序列連同可學習的位置編碼，被輸入到多個串行變壓器編碼器。這些編碼器使用全局注意力計算和特徵提取來工作，其中內部的自注意模塊用於 Patch 之間或序列之間的特徵提取。Feed Forward 塊為每個 Patch 或序列執行特徵轉換。從最後一個 Transformer 編碼器的輸出序列(即 Class Token 位置的輸出)中提取位置 0 對應的向量。然後用 MLP 分類器對這個向量進行分類。

2.2.7 Swin Transformer 架構

Swin Transformer [10] 是 ViT 的改進，原本的 ViT 計算開銷太大，且無法應用於物件偵測、影像切割等任務，Swin Transformer 的名字來自於“Shifted Window Transformer”，主要使用 Shifted Window 方法降低模型的計算複雜度，Swin Transformer 的架構如圖 2-10 所示：




圖 2-10 Swin Transformer (Swin-T) 架構圖

資料來源：參考文獻[10]

Patch Partition 主要是將輸入的圖片切分多個不重疊的 Patch，跟 Vision Transformer 一樣，每個 Patch 被視為一個 Token，其特徵被設置為原始像素 RGB 值的拼接。圖 2-12 中使用 4×4 的 Patch 大小，因此每個 Patch 的特徵維度是 $4 \times 4 \times 3 = 48$ 。Linear Embedding 則是將 Patch 做線性轉換，將其投影到任意維度 C，接下來會經過 Swin Transformer Block，而 Swin Transformer Block 使 Token 維持在 $\frac{H}{4} \times \frac{W}{4}$ 的數量，Linear Embedding 與 Swin Transformer Block 一起表示為 Stage 1，輸出維度為

$$\frac{H}{4} \times \frac{W}{4} \times C。$$

接下來會通過 Patch Merging 讓分辨率減半，通道數加倍，類似於 CNN 的作用，並再次經過 Swin Transformer Block，Patch Merging 與 Swin Transformer Block 一起表示為 Stage 2，輸出維度為 $\frac{H}{8} \times \frac{W}{8} \times 2C$ 。接下來會重複兩次同 Stage 2 的過程，表示為 Stage 3 和 Stage 4，輸出維度分別為 $\frac{H}{16} \times \frac{W}{16} \times 4C$ 和 $\frac{H}{32} \times \frac{W}{32} \times 8C$ ，這三個 Stages 共同表示為一個 Hierarchical Representation。

接下來說明 Swin Transformer Block 內部的架構，如圖 2-11 所示：




圖 2-11 Swin Transformer Block 架構圖

資料來源：參考文獻[10]

這部分是整個 Swin Transformer 架構的核心，Swin Transformer 使用了 Window Self-Attention (W-MSA) 降低了計算的複雜度，為了保證不重疊窗口之間的關係，採用了 Shifted Window Self-Attention (SW-MSA) 的方式重新計算一遍窗口偏移之後的自注意力，所以 Swin Transformer Block 都是成對出現的 (W-MSA+SW-MSA 為一對)，我們可以用圖 2-12 中的公式來表示 Swin Transformer Block 的運算方法：

$$\begin{aligned} \hat{z}^l &= WMSA(LN(z^{l-1})) + z^{l-1}, \\ z^l &= MLP(LN(\hat{z}^l)) + \hat{z}^l, \\ \hat{z}^{l+1} &= SWMSA(LN(z^l)) + z^l, \\ z^{l+1} &= MLP(LN(\hat{z}^{l+1})) + \hat{z}^{l+1}. \end{aligned} \quad (2-3)$$

圖 2-12 Swin Transformer Block 運算公式圖

資料來源：參考文獻[10]

接下來說明一下相對位置編碼：

$$\text{Attention}(Q, K, V) = \text{SoftMax}\left(\frac{QK^T}{\sqrt{d_k}} + B\right)V \quad (2-4)$$

絕對位置編碼是進行 Self-Attention 計算之前為每一個 Token 添加一個可學習的參數，相對位置編碼是在進行 Self-Attention 計算時，在計算過程中添加一個可學習的相對位置參數。假設 Window Size = 2 x 2 即每個窗口有 4 個 Token (M=2)，在計算 Self-Attention 時，每個 Token 都要與所有的 Token 計算 QK 值，如圖 2-15 所示，當位置 1 的 Token 計算 Self-Attention 時，要計算位置 1 與位置 (1,2,3,4) 的 QK 值，即以位置 1 的 Token 為中心點，中心點位置坐標 (0,0)，其他位置計算與當前位置坐標的偏移量。




圖 2-13 相對位置索引求解流程示意圖

資料來源：參考文獻[10]

圖 2-13 最後生成的相對位置索引的 Shape 為 $(M^2 \times M^2)$ ，在網路中註冊成爲一個不可學習的變量，相對位置索引的作用就是根據最終的索引值找到對應的可學習的相對位置

編碼。相對位置索引的數值範圍為 $0 \sim 8$ ，即 $(2M-1) \times (2M-1)$ ，所以相對位置編碼可以由一個 3×3 的矩陣來表示，如圖 2-14 所示：




圖 2-14 相對位置編碼矩陣圖

資料來源：參考文獻[10]

如圖 2-16 中的 $0 \sim 8$ 為索引值，每個索引值都對應了 M^2 的可學習資料。繼續以圖 2-15 中 $M = 2$ 的窗口為例，當計算位置 1 對應的 M^2 個 QK 值時，應用的 Relative Position Index = $[4, 5, 7, 8](M/2)$ 個，對應的資料就是圖 2-16 中位置索引 4, 5, 7, 8 位置對應的 M^2 維資料，即 Relative Position Shape = $M^2 \times M^2$ 。以上過程主要是應用到 W-MSA 的部分當中。

接下來說明 SW-MSA 的部分，為了解決不重疊窗口之間沒有關聯的問題，採用了 Shifted Window 的方法（圖 2-15）。




圖 2-15 Shifted Window 方法示意圖

資料來源：參考文獻[10]

假如以 $(M/2, M/2)$ 向下取整的窗口重新對原圖進行分割，並將之前沒有關係的新窗口合并得到新的窗口劃分方法，如圖 2-17 所示，帶來的問題就是窗口個數增加了，為了避免窗口增加導致的額外計算量並保證不重疊窗口有關聯，最後使用了 Cyclic Shift 方

法（圖 2-16）。




圖 2-16 Cyclic Shift 方法示意圖

資料來源：參考文獻[10]

通過圖 2-16 的方式可以在保證不重疊窗口間有關係的基礎上不增加窗口的個數，讓運算更有效率。Swin Transformer [10] 的提出解決了之前 Transformer 應用在 CV 領域的缺點，具有替換掉 CNN 成為新的視覺任務 Backbone 的潛力。

2.2.8 U-Net 架構

本論文中使用的網路架構之一為 O. Ronneberger 等人所提出的 U-Net [1] 架構，它屬於一種自動編碼器（Autoencoder），常用於醫學影像分析等領域。它的名字來自於它獨特的網路結構形狀，看起來像是一個“U”字。U-Net 架構主要由兩個部分組成：編碼器（Encoder）和解碼器（Decoder），中間以跳躍連接（skip connections）進行連接。該結構通常基於卷積神經網絡（CNN）構建。完整的 U-Net 網路架構如下圖（圖 2-19）所示：




圖 2-17 U-Net 架構圖

資料來源：參考文獻[1]

圖 2-17 的左側稱為編碼器 (Encoder) 或壓縮路徑 (Contracting path)，右側則稱為解碼器 (Decoder) 或擴展路徑 (Expansive path)。編碼器由四個 Block 組成，每個 Block 包含兩個卷積層 (Convolutional Layers) 和一個最大池化層 (Max Pooling)，用於進行降採樣 (Downsampling)。每次降採樣後，特徵通道 (Feature Channels) 的數量會乘以 2，最終得到尺寸為 32x32 的特徵圖 (Feature Map)。解碼器也由四個 Block 組成。在每個 Block 開始之前，會使用反卷積層 (Deconvolution) 將特徵圖的尺寸乘以 2，同時將特徵通道的數量減半。然後，將得到的特徵圖與左側對稱的壓縮路徑的特徵圖進行合併，這種合併方式稱為跳躍連接 (skip connections)。由於壓縮路徑和擴展路徑的特徵圖尺寸不同，U-Net 通過裁剪壓縮路徑的特徵圖，使其與擴展路徑的尺寸相同，以實現特徵圖的歸一化。最後，在合併後接兩個卷積層 (Convolution)，得到尺寸為 388x388 的特徵圖。這種架構的特點是具有編碼器和解碼器之間的連接，這些連接允許特徵在不同層次進行信息傳遞，有助於提高分割結果的準確性。U-Net 被廣泛應用於醫學影像分割等領域，並取得了良好的效果。U-Net 的最後一層通常是一個 1x1 卷積層，用於將特徵圖映射

到輸出分割圖的通道數。根據應用的不同，輸出分割圖可以是二分類或多分類。

2.2.9 SwinUNETR 架構

本論文中使用的網路架構之一為 Hatamizadeh 等人所提出的 Swin Unetr 架構 [2]，網路架構和 U-Net 類似，但是編碼器的部分則是使用了 Swin Transformer，完整的 Swin UNETR 的架構如圖 2-18 所示：




圖 2-18 Swin UNETR 架構圖

資料來源：參考文獻[2]

以圖 2-18 為例，首先說明編碼器的部分：SwinUNETR 編碼器的 Patch size 為 $2 \times 2 \times 2$ ，特徵維度即為 $2 \times 2 \times 2 \times 4 = 32$ （後面乘 4 個 channels 數量），Embedding Space C 的大小設定為 48。此外，SwinUNETR 編碼器總共有 4 個 Stages，每個 Stage 由 2 個 Transformer Blocks 所組成，因此編碼器中的層數總共為 $L=8$ 。在第 1 個 Stage，使用 Linear Embedding 層來創建 $\frac{H}{2} \times \frac{W}{2} \times \frac{D}{2}$ 的 3D Token。為了表示編碼器的 Hierarchical Representation，在每個 Stage 結束時，利用 Patch Merging 層將 Feature Map 的尺寸減半。此外，Patch Merging 層將 Size 為 $2 \times 2 \times 2$ 的 Patch 分組並連接在一起，從而得到 $4C$ 維度的 Feature Embedding。隨後通過 Linear layer 將 Representations 的特徵尺寸減少至 $2C$ 。Stage 2，Stage 3，Stage 4 以同樣的方式進行從而分別得到

$\frac{H}{4} \times \frac{W}{4} \times \frac{D}{4}$, $\frac{H}{8} \times \frac{W}{8} \times \frac{D}{8}$, $\frac{H}{16} \times \frac{W}{16} \times \frac{D}{16}$ 的維度。

接下來說明解碼器的部分：與 U-Net 架構相同，SwinUNETR 編碼器的每個 Stage 的 Feature Map 通過 Skip Connections 連接至對應的每個解碼器 Stage。在編碼器的每個 stage i ($i \in \{0,1,2,3,4\}$) 以及最底部的 bottleneck ($i=5$)，輸出的 Feature Map 被 Reshape 至 $\frac{H}{2^i} \times \frac{W}{2^i} \times \frac{D}{2^i}$ 的維度並輸入到由 2 個 $3 \times 3 \times 3$ 的卷積層所組成的 Residual Block 中，而這些 Residual Blocks 由 Instance Normalization 進行一般化。隨後，利用反卷積層 (Deconvolution) 將 Feature Map 的尺寸提高 2 倍，將當前的輸出與上一個 Stage 的輸出拼接在一起，拼接完成後再輸入到另外一個與前面所敘述的結構相同的 Residual Block 中，最後使用 $1 \times 1 \times 1$ 的卷積層和 Sigmoid 激活函數計算最終的分割結果。

2.2.10 監督式學習

監督式學習 (Supervised Learning) 是一種基於標籤化資訊的學習方法，其中電腦從標註的資料 (Label) 中學習並做出預測。這些標記資料可以被視為標準答案，電腦透過比對預測與標記的差異來修正自身，以提高預測的準確性。監督式學習的優點之一是它能夠獲得較高的準確率。然而，監督式學習需要大量的人工標註工作，以標記可能的特徵，這是一個複雜的過程。隨著範圍的擴大和資訊量的增加，將所有特徵標記出來變得更加困難。因此，當面臨未知領域時，監督式學習幾乎無法運作。圖 2-19 為監督式學習的示意圖：




圖 2-19 監督式學習示意圖

2.2.11 遷移學習

遷移學習 (Transfer Learning) 是一種機器學習的技術，可以將特定任務所訓練得到的已訓練模型 (或預訓練模型 Pretrained Model)，轉移至其它相關的任務上。如此一來可以在其它任務上，減少所需要訓練的資料量。以圖 2-20 來說明，假設我們有大量的 Data1 (貓和狗的照片) 和少量的 Data2 (雞和鴨的照片)，我們先用 Data1 (貓和狗的照片) 訓練出 Model1 的模型，使用這個訓練完的模型參數當做 Data2 (雞和鴨的照片) 模型參數的初始值，繼續以 Data2 (雞和鴨的照片) 訓練該已初始化的模型，得到新的 Model2。




圖 2-20 遷移學習示意圖

遷移學習在深度學習上的應用一般有兩種策略，一種策略是微調 (Finetuning) —— 使用預訓練模型來對目標資料集進行所有層的訓練。另外一種策略是凍結訓練 (Layers Freezing) —— 只訓練指定層，把指定層外的所有層凍結 (權重不更新)，以本論文來說，我們只訓練最底部的兩層。

2.2.12 自我監督式學習

自我監督式學習 (Self-Supervised Learning) 是一種屬於無監督式學習 (Unsupervised Learning) 的方法，它利用大量的無標記資料，透過挖掘資料本身的資訊來學習資料的特徵，並將其應用於各種下游任務。常見的自我監督式學習包括以下三種：

- Generative methods：這種方法通過訓練模型在像素空間中重建圖像，從而獲取圖像

的語義訊息。例如，使用基於自動編碼器的模型進行圖像修補，生成合理的假設來填補圖像中缺失的部分。

- Predictive methods：Predictive methods 不需要重建圖像，而是對圖像進行各種變換，然後讓模型還原原始圖像。例如，在圖像中選擇兩個區域，利用其中一個區域預測另一個區域的相對位置。
- Contrastive methods：目前自我監督式學習中最廣泛應用的方法。其基本思想是，相同類別的圖像應該具有較高的相似度，而不同類別的圖像應該具有較低的相似度。通常，我們一般會對圖像進行各種資料增強的操作，然後讓模型比較經過增強後的圖像與原始圖像之間的相似度，該相似度越高越好，同時比較與其他圖像的相似度，該相似度低越好。本論文將採用此方法，所以會在接下來的小節進行比較詳細的介紹。

2.2.12.1 對比學習

對比學習（Contrastive Learning）[12] 是一種自我監督式學習的方法，用於在缺乏標籤的情況下，透過對比兩張圖片，使模型學習到資料集中的一般特徵。對比學習的過程可以簡單地描述為三個部分：

- Data Augmentation：對於資料集中的每張圖像，我們可以進行兩種 Data Augmentation，假設如圖 2-21 所示， x_i 為經過“縮放+去色”後得到的圖像， x_j 為經過“裁剪+重新著色”後得到的圖像，從而得到兩個版本的圖像，我們稱這兩張圖像 x_i 與 x_j 為一對正樣本（Positive Pairs），我們希望模型知道這兩個版本的圖像 x_i 與 x_j 是相似的，因為它們的來源是同一張圖片。如圖 2-21 所示，我們稱 x_i 與 z_i 為一對負樣本（Negative Pairs）， x_i 與 z_j 、 x_j 與 z_i 、 x_j 與 z_j 皆為負樣本，我們希望模型知道負樣本之間是不一樣的，因為它們來自不同圖像。




圖 2-21 對比學習 Data Augmentation 示意圖

- 編碼：我們將 Data Augmentation 後的資料進行神經網路的訓練，如圖 2-22 所示，假設我們使用 Encoder 神經網路，並表示它為一個函數： $h=f(x)$ ，其中 x 是 Data Augmentation 後的資料，經過 Encoder 後輸出為 h ，然後將 h 輸入到一組稱為 Projection Head 的 Dense Layers 中， $z=g(h)$ 表示將資料轉換到另外一個空間。對於下游任務，我們一般會把 Encoder 輸出後的部分全部拿掉，只取前面的部分。




圖 2-22 對比學習框架示意圖

- 損失最小化：當比較兩個向量的相似性時，我們需要某種方法量化它們之間的關係。余弦相似度是一種常用的方法，它根據兩個向量在空間中的夾角來衡量它們的相似度。如果兩個向量在空間中靠得越近（它們之間的夾角越小），則認為它們越相似。因此，我們可以使用余弦相似度作為度量，當包含的角度接近 0 時，兩個向量將獲

得高相似度，而當包含的角度較大時，它們將獲得低相似度。這種度量方法可以幫助我們有效地比較和分析計算機科學及相關領域中向量的相似性。詳細的計算公式（Contrastive Loss）我們將在 2.3.3 小節進行介紹。

2.3 評估指標與損失函數

評估指標是用於衡量機器學習模型或算法的度量指標，可以幫助我們評估模型的性能。損失函數（loss function）是一種用於評估模型預測與實際值不一致程度的指標，同時也是神經網路優化的目標函數。神經網路的訓練和優化過程旨在最小化損失函數，通過使損失函數的值越小，模型的預測結果與實際值越接近。在本篇論文中我們主要會使用 Dice 指標來對模型進行評估，而損失函數方面有使用 Dice Loss, Focal Loss 以及 Contrastive Loss。在此小節將會分別介紹評估指標 Dice 和三個損失函數。

2.3.1 Dice

Dice Coefficient，它是一種用於評估兩個樣本的相似性的度量函數，取值範圍在 0 到 1 之間，取值越大表示越相似。Dice Coefficient 定義如下：

$$dice = \frac{2|X \cap Y|}{|X| + |Y|} \quad (2-5)$$

其中 $|X \cap Y|$ 是 X 和 Y 之間的交集， $|X|$ 和 $|Y|$ 分別表示 X 和 Y 的元素個數，分子乘於 2 是為了保證分母重複計算後取值範圍在 $[0,1]$ 之間。

2.3.2 Specificity

特異度（Specificity）是用於評估二元分類模型的性能指標之一，它衡量了模型在預測負類樣本（真實為負）時的準確性。以醫學領域來說，Specificity 是衡量在所有實際上沒有癌症的人之中，多少比例的人是被模型預測為沒有癌症。

2.3.3 Dice Loss

Dice Loss [16] 為 Milletari 等人提出的一種損失函數，主要是應對語義分割中正負樣本強烈不平衡的場景。Dice Loss 來自 Dice Coefficient，因此 Dice Loss 可以表示為：

$$L_{dice} = 1 - \frac{2|X \cap Y|}{|X| + |Y|} \quad (2-6)$$

2.3.4 Focal Loss

Focal Loss 解決了訓練任務(如目標檢測)中的類別不平衡問題。Focal Loss 在交叉熵損失中加入一個 Modulating term，以便將學習集中在難以分類的樣本上。Focal Loss 的公式可以表示為：

$$FL(p_t) = -(1 - p_t)^r \log(p_t) \quad (2-7)$$

2.3.5 Contrastive Loss

Contrastive Loss [12] 是用於對比學習 (Contrastive Learning) 的損失函數。其思想是通過最小化正樣本 (Positive Pairs) 之間的距離和最大化負樣本 (Negative Pairs) 之間的距離。正樣本表示具有相同來源的兩張圖片，負樣本表示具有不同來源的兩張圖片。在 Contrastive Loss 中有使用到餘弦相似度 (Cosine Similarity)，公式如下：

$$\text{sim}(u, v) = \frac{u^T v}{\|u\| \|v\|} \quad (2-8)$$

而一對正樣本 (i, j) 的損失函數定義為：

$$\ell_{i,j} = -\log \frac{\exp(\text{sim}(z_i, z_j)/\tau)}{\sum_{k=1}^{2N} \mathbb{1}_{[k \neq i]} \exp(\text{sim}(z_i, z_k)/\tau)} \quad (2-9)$$

為了更好理解上面的公式，我們以圖 2-23 來表示：分子為計算一對正樣本之間的相似度，而分母是將一對正樣本之間的相似度與其它所有負樣本的相似度加總在一起。所以從理想的角度來看，我們希望正樣本之間的相似度越高越好，而負樣本之間的相似度越低越好，所以當分子與分母的值在越靠近的情況下，loss 值就會越小。

$$l(\text{img}_1, \text{img}_2) = -\log \left(\frac{e^{\text{similarity}(\text{img}_1, \text{img}_2)}}{e^{\text{similarity}(\text{img}_1, \text{img}_2)} + e^{\text{similarity}(\text{img}_1, \text{img}_3)} + e^{\text{similarity}(\text{img}_1, \text{img}_4)} + \dots} \right)$$

圖 2-23 Contrastive Loss 公式示意圖

2.4 Pytorch

PyTorch 是一個開源的 Python 機器學習 Library，基於 Torch，底層由 C++ 實現，應用於人工智慧領域，如電腦視覺和自然語言處理。它主要由 Meta Platforms 的人工智慧研究團隊開發。

使用 PyTorch 開發有下列優勢：

- 動態計算圖：PyTorch 使用動態計算圖的方式，使得開發者可以根據需要定義和修改計算圖，這使得模型的構建和調試更加靈活和直觀。同時，動態計算圖還提供了更好的調試和錯誤處理能力。
- 強大的 GPU 支持：PyTorch 提供了充分利用 GPU 加速計算的功能，可以極大地提高訓練速度和性能。它充分利用 GPU 的並行計算能力，並提供了易於使用的 GPU 張量類型和優化的計算函數。
- 自動微分：PyTorch 提供了自動微分的功能，使得計算梯度變得非常簡單。開發者只需要定義前向傳播過程，PyTorch 將自動計算梯度，從而實現反向傳播和參數更新。
- 豐富的庫和工具支持：PyTorch 生態系統提供了大量的庫和工具，用於數據處理、模型組建、視覺化、模型部署等。例如，PyTorch 提供了 torchvision 庫，用於處理圖像數據；還有 torchtext 庫，用於處理自然語言處理數據。
- 社區活躍：PyTorch 擁有一個活躍的社區，開發者可以輕鬆地獲得支持、文檔和示例代碼。此外，許多研究機構和企業都在使用 PyTorch 進行深度學習研究和應用，這也促進了社區的發展和擴大。

2.5 醫療影像處理套件

此小節將會介紹本篇論文所使用到的醫療影像處理套件，包括 Pydicom、High Order Slice Interpolation 內插工具以及 3D Slicer。

2.5.1 Pydicom

醫療影像通常都是以醫學數字成像和通信（DICOM）格式保存的，如 CT 電腦斷層掃描、MRI 核磁共振、超聲波等。其格式不同於一般的影像文件，它除了影像本身的像素資料外還包含了其它有用的資訊，像是患者的識別資料、所使用的儀器等等，以便將圖像與患者配對。Pydicom 則是一個用於處理 DICOM 格式文件的 Python 套件，它提供了非常方便的接口，支持 DICOM 格式的讀取跟寫入：可以將 DICOM 文件輸入 Python 結構，同時支持修改後的資料集可以再次寫入 DICOM 格式文件，它主要是用來對 DICOM 文件的各種資料元素進行操作。

2.5.2 High Order Slice Interpolation

High Order Slice Interpolation [5][20] 算法是一種針對醫療影像並基於高階對象和強度的切片插值算法，相較 Linear Interpolation 與 Cubic Interpolation 有更好的結果，並且證實了在 MRI 圖像上有著不錯的結果。第三章的研究方法中，在處理 MRI 內插時我們選擇用此算法進行切片的內插。

2.5.3 3D Slicer

3D Slicer [8][18] 是一款免費的開源工具，用於對醫學、生物醫學和其他 3D 圖像進行 Visualization、Processing、Segmentation、Registration 和 Analysis 的強大工具。在第三章的研究方法中我們使用 3D Slicer 的 Brain General Registration Tool 對 MRI、CT 以及 PET 進行切片對應，它有非常高效且精準的 Registration 結果，並且以直覺方便的 GUI 方式進行操作，參數可以按照情況進行彈性的調整。

2.6 醫療影像資料集

本論文中使用的資料集包括了 Brats2021 MRI 腦部資料集、醫院腦部資料集以及 TCIA PET-CT 腦部資料集，在此小節將會介紹資料集的相關資訊。

2.6.1 MRI 核磁共振

核磁共振簡稱為 MRI (Magnetic Resonance Imaging)，利用人體所含的氫原子與磁場原理利用無線電波所產生的影像且不具放射性，檢查目的是可知道病變的解剖位置及形狀，提供三種切面空間、軸切面(axial)、冠切面(coronal)、及矢切面(sagittal)、與良好功能的分析，且不具侵襲性或游離輻射的產生。一般腦部 MRI 使用不同的圖像序列和參數來提供關於腦組織的不同信息，我們稱之為 MRI 模態 (Series)，圖 2-24 為最常見的腦部 MRI 模態包括 T1-weighted、T2-weighted 與 Flair。T1-weighted 圖像是通過使用較短的 Time to Echo (TE) 和 Repetition Time (TR) 時間生成的，圖像的對比度和亮度主要由組織的 T1 特性決定。相反，T2-weighted 圖像是通過使用更長的 Time to Echo (TE) 和 Repetition Time (TR) 時間生成的，對比度和亮度主要由組織的 T2 特性決定。Flair 類似於 T2-weighted 圖像，但 Time to Echo (TE) 和 Repetition Time (TR) 的時間更長。通過這樣子的方式所產生的圖像，異常區域會保持明亮，而正常的腦脊液體會變得暗淡，因此可以使腦脊液體和異常之間的區別變得更加容易。




圖 2-24 腦部 MRI 多模態示意圖

2.6.2 PET-CT 正子電腦斷層掃描

正子電腦斷層掃描 (Positron Emission Tomography/ Computed tomography, PET-CT) 結合 PET 和 CT 的特點。用 PET 以色譜顯示癌細胞聚集處，並重疊 CT 所顯示的解剖影像，PET-CT 可精確的將癌細胞活動狀況及位置融合在一張影像資料中。在第三章研究方法的 3.2 小節中，我們會比較詳細的介紹如何將 PET 與 CT 融合成 PET-CT 的方法。圖 2-25 為 PET-CT 的示意圖：




圖 2-25 腦部 PET-CT 示意圖

2.6.3 BraTS2021 資料集

Brain Tumor Segmentation (BraTS) Challenge 為國際腦腫瘤分割挑戰賽，該競賽由北美放射學會 (RSNA)、美國神經放射學會 (ASNR) 和醫學圖像計算與計算機輔助干預 (MICCAI) 學會聯合舉辦，重點是利用多模態核磁共振成像 (MRI) 進行腦腫瘤檢測和分類。本篇論文使用的是最新的 BraTS2021 資料集 [13][14][15] 中的 Task1 (Segmentation) 資料，該資料總共有 1251 位病人的腦部 MRI 資料，包含了 BraTS2020 的 660 位病人。改腦部資料來自多家醫療機構的貢獻，地區包含了美國、德國、瑞士、加拿大、匈牙利、印度等的國家，所有病人的腫瘤資料均由一到四名專家按照相同的協議手動標記，最後由經驗豐富的委員會認證並且得到神經放射學家的批准。如圖 2-26 所示，每一位病人的腦部資料有四種模態 (Series): Flair、T1、T1ce、T2，每個模態的資料大小為 $240 \times 240 \times 155$ ，並共享腫瘤分割標籤。分割標籤分為 [0,1,2,4]，label0 表示背景 (background)，label1 表示為壞死瘤核 (NT, necrotic tumor core)，label2

表示浮腫區域(ED, peritumoral edema), label4 表示增強腫瘤區域(ET, enhancing tumor), 我們可以把 label1 + label2 + label4 視為整個腫瘤區域。病人的四種模態都進行了具有共同空間的 Registration、內插到相同的分辨率以及進行頭骨的剝離, 最終資料以 NifTI (.nii.gz) 格式儲存。




圖 2-26 多模態腦部 MRI 資料集示意圖

2.6.4 Ours MRI 資料集

本論文使用的另外一組腦部 MRI 資料由振興醫院提供, 病人的腫瘤區域是由一位專業的醫師進行標記, 所提供的 MRI 資料為沒有經過任何處理的原始 DICOM 格式。如圖 2-27 所示, MRI 資料包含不同方向的切面: 軸切面 (axial)、冠切面 (coronal)、及矢切面 (sagittal) 的影像, 並有多種模態 (Series), 在本篇論文當中, 我們將使用軸切面 (axial) 的 FLAIR 模態來進行實驗, 腫瘤區域的資訊則是以 JSON 格式儲存。MRI DICOM 檔與 JSON 檔需要經過一些額外的處理步驟, 才能用來當做訓練用的資料集, 處理方法會在第三章的研究方法中進行討論。




圖 2-27 振興醫院 MRI 資料集示意圖

2.6.5 TCIA PET-CT 腦部資料集

The Cancer Imaging Archive (TCIA) 是一個由美國國家癌症研究所 (NCI) 資助的大型開源資料庫，包含大量去識別化和匿名化的醫療影像。在我們的研究中，有標籤的 PET-CT 資料集數量非常少，因此為了進行 Self-Supervised Learning，我們使用了如圖 2-28 所示的 TCIA 的 A Whole-body FDG-PET/CT dataset，格式為 DICOM 原始資料，資料集包含了全身的 CT 電腦斷層掃描、PET 正子掃描以及手動標記的腫瘤圖像，但腦部位置沒有進行腫瘤的標記。我們的研究主要是針對腦部做實驗，因此我們只取頭部的切片，並把 CT 與 PET 融合成 PET-CT，命名為 TCIA PET-CT 腦部資料集，並用來進行 Self-Supervised Learning。對 CT 與 PET 圖像融合的方法會在第三章研究方法的 3.2 小節進行詳細的介紹。




圖 2-28 TCIA A Whole-body FDG-PET/CT dataset 示意圖

2.6.6 Ours PET-CT 資料集

本論文使用的另外一組腦部 PET-CT 資料集是跟 Ours MRI 對應的患者資料，資料格式為原始的 DICOM 格式，圖片為 RGB 模式，在實驗中我們會轉換成灰階模式，詳細的處理方式會在第三章研究方法的 3.2 小節中進行介紹。圖 2-29 為 Ours PET-CT 資料集示意圖：




圖 2-29 Ours PET-CT 資料集示意圖

2.7 相關文獻探討


Ronneberger 等學者 [1] 提出了一種稱為 Unet 的神經網路架構，它是一種基於自動編碼器的架構，此架構的特點是有一條通道（Skip Connection）將每一層編碼器的 Feature Map 與對應之解碼器的 Feature Map 進行相連，這樣做可以幫助解碼器在進行上採樣時保留更多的上下文信息，從而改善分割結果的準確率。也證實了 Unet 架構在 International Symposium on Biomedical Imaging (ISBI) 挑戰賽中優於先前的最佳方法。

Hatamizadeh 等學者 [2] 提出基於 Unet 的變形架構 SwinUNETR，其架構主要利用 Swin Transformer [10] 作為編碼器，而將編碼器與解碼器進行連接的通道（Skip Connection）上，加入了殘差網路。SwinUNETR 架構在 BraTS2021 分割挑戰賽中也獲得了很好的成績。

Ting Chen 等學者 [12] 提出了一種用於影像對比學習的框架 SimCLR，其框架簡化了先前提出的自監督式學習的算法。表明了對比學習中 Data Augmentation 的組合在預測任務方面起到關鍵的作用。也證實了 SimCLR 方法優於以前的自我監督式學習和半監督式學習的方法，在使用僅 1% 的訓練樣本下的準確率結果也很不錯。

Yucheng Tang 等學者 [11] 提出了一種 3D 醫療影像的自監督式學習框架，通過使用 Swin Transformer 編碼器進行對比學習，再轉移到 SwinUNETR 進行微調分割的任

務。作者們使用他們的方法，通過使用不同身體器官的 5,050 個開源 CT 圖像進行自我監督預訓練，隨後對 BTCV 和 MSD 資料集進行微調。結果表明，他們的模型在 BTCV 和 MSD 資料集的測試排行榜上排名第一。



第三章 研究方法

本章將說明本論文對資料集的前處理方式以及研究方法的實作細節。在開頭的 3.1 與 3.2 小節中，由於拿到的資料集不能直接用來當做機器學習的訓練樣本，因此需要做額外的處理。在 3.3 小節當中，我們選擇主流的網路架構來進行各種實驗，包括 Unet [1] 以及 SwinUNETR 網路架構 [2]。我們知道 Unet 是醫療影像分割任務的首選架構，雖然也有一些網路對分割任務有不錯的效果，但是其中 Unet 網路的有更好的表現，所以在大部分關於醫療影像分割的研究中，Unet 一直是首選模型，因此 Unet 是我們用來做實驗所選擇的第一個網路模型。Unet 架構被 O. Ronneberger 等人提出之後一直到現在，有非常多基於 Unet 架構的 Unet 變形網路，其中結合 Transformer 的 SwinUNETR 網路架構 [2] 根據 Hatamizadeh 等人的研究，我們認為在近年來它屬於較有突破性的代表，因此 SwinUNETR 是我們用來做實驗所選擇的第二個網路模型。接下來我們將利用 3.3 小節中的方法進行實驗並選擇性能較好的模型，繼續進行後續的實驗。在後續的實驗中我們將對 MRI 小腫瘤資料採用傳統監督式學習、遷移學習和自我監督式學習方法進行實驗，並進行比較。最後我們會對 PET-CT 大腫瘤資料進行傳統監督式學習和自我監督式學習進行比較。

3.1 MRI 腦部資料處理

由於拿到的資料集不能直接用來當做機器學習的訓練樣本，因此需要做額外的處理。此小節將會介紹我們如何對 Ours MRI 與 Brats2021 資料做處理。

3.1.1 處理 Ours MRI 資料

我們所拿到的醫院 MRI 資料為原始 DICOM 格式，每位病人的腦部資料都包含多個 Series，所以我們需要先對病人的 Series 進行分類，然後從中選擇我們要當做實驗對象的 Flair Series，把處理好的 Flair 圖像順序堆疊成三維的資料結構並儲存為 Nifti (.nii.gz) 格式。由醫生所標記的腫瘤位置資訊原本儲存在 JSON 檔案，我們同樣需要把

位置資訊轉換成圖片，最後一樣儲存為 NifTi (.nii.gz) 格式。所以每位病人的腦部資料最後的輸出為一對 NifTi 檔，分別為腦部圖像與腫瘤標籤。詳細的處理步驟如下：

- 進行 Series 分類：DICOM 儲存了圖片本身的像素資訊以及相關的 Meta-data，包含 Patient Information、Study Information、Series Information、Equipment Information 以及 Image Information。其中我們需要去解析 Series Information 的部分，它記載著 Series 相關的資訊。我們使用 Pydicom 套件來解析 DICOM 檔案，並使用 Pydicom 所提供的 dcmread 函式讀取 DICOM 檔，並訪問 Series Description 屬性（DICOM 的所有相關屬性可以到官方網站的 DICOM Standard Browser [17] 進一步了解），如此就可以很方便地進行 Series 的分類。
- DICOM 像素轉換：原始 DICOM 檔的圖像皆為 Low Image Data Range，會影響到後續訓練的結果。因此原始圖像需要經過額外的處理：包括 Modality LUT 轉換、VOI LUT 轉換以及 Presentation LUT 轉換。不同廠商生產的相同類型設備生成圖像時，無法確保這些圖像在度量上是相同的。為了解決這個問題，我們需要使用 Modality LUT (Lookup Table)，可以將圖像的原始資料轉換成一個標準的空間，以確保不同設備生成的圖像具有一致的度量標準。我們使用 DICOM 的 Rescale Slope 與 Rescale Intercept 兩個屬性對原始圖像像素進行計算並輸出為標準圖像像素：**標準影像像素 = 原始影像像素 × 斜率 (Slope) + 截距 (Intercept)**。VOI LUT (感興趣區域) 轉換步驟主要是增加感興趣區域的圖像資訊的對比度，此步驟主要使用 DICOM 的 Window Center/Level (窗位) 與 Window Width (窗寬) 這兩個屬性，

$$\text{計算公式可以表示為：} G(V) = \begin{cases} 0, & v < c - w/2 \\ \frac{gm}{w} \left(v + \frac{w}{2} - C \right), & c - w/2 \leq V \leq C + w/2 \\ gm, & V > C + W/2 \end{cases} \quad \text{, 其中}$$

V 為圖像數據 (經過 Modality LUT 轉換後的數據)，G 為顯示器顯示值，gm 為顯示器的最大顯示值，W 為窗寬，C 為窗位。Presentation LUT 則是對圖像數據做的最後一個轉換，我們在這步驟對圖像資料 Normalize 至 12 bits，最後以 12 bits 的灰階圖像進行保存。圖 2-28 表示 DICOM 圖像像素的轉換過程：




圖 3-1 DICOM 圖像像素轉換過程示意圖

- 解析 JSON 標記檔並轉換為圖檔：以我們拿到的 JSON 檔為例，腫瘤區域是用封閉的線條來表示，而線條是由連續的 segments 所組成，每一個 segment 為一組 a、b 坐標以及 width，利用這些坐標資訊描繪到空白的圖像畫布上，並進行線條內部的填充，最後進行圖像的保存。腦部圖像與腫瘤標記圖像的對應部分，則是用 DICOM 的 SopInstanceUID 屬性與 JSON 的檔名進行對應。
- 對腦部圖像及腫瘤標記圖像做內插：大部分病人的腦部切片數量範圍落在 48 ~ 51 張，其中有幾位病人只有 24 ~ 25 張，因此我們對腦部切片與對應的標記圖像做內插至 2 倍的數量，從 24 ~ 25 張變成 47 ~ 48 張，如此一來全部病人的切片數量範圍將會落在 47 ~ 51 張。內插算法我們使用第二章 2.5.2 小節所介紹的 High Order Slice Interpolation。

SwinUNETR 網路模型輸入的圖片維度大小需要是 32 的倍數（即 1st、2nd、3rd dimension 都必須可以被 32 整除），在切片數量的部分，所有病人的切片約 47 ~ 51 張，因此我們在切片尾部用黑色的空白圖像將切片數量補齊到 64 張，最後以 128 × 128 × 64 的三維資料結構進行 NifTi (.nii.gz) 格式的保存。

3.1.2 處理 Brats2021 資料

BraTS2021 資料集的張量大小為 240 × 240 × 155，因此需要把張量大小調整至 128 × 128 × 64，我們以 $S_{i=1}^{64} = 16 + V_{i \times 2}$ 的方式取切片（V 為 BraTS2021 的 155 張

切片，S 為取完後的 64 張切片)，因為前面 15 張切片都是空白的，所以我們從第 16 張開始每隔一張取一次切片，最後取滿 64 張為止。在腫瘤標籤方面，BraTS2021 資料集的腫瘤標籤分為 4 個 Labels，分別為 0, 1, 2, 4。0 為 Background，其餘 Labels 為不同的腫瘤。在我們的實驗中，不需要細分腫瘤，因此我們把 Labels 1, 2, 4 合併為 Label 1。

3.2 PET-CT 腦部資料處理

此小節將會介紹我們如何對 Ours PET-CT 與 TCIA PET & CT 資料做處理。

3.2.1 處理 Ours PET-CT 資料

醫院所提供的 PET-CT 腦部資料集沒有另外進行腫瘤的標記，因此需要把 MRI 腦部腫瘤標 Label 轉移到同一位病人的 PET-CT 上。為此我們需要對 MRI 與 PET-CT 做 Registration，將 PET-CT 腦部圖像對應到跟 MRI 腦部圖像一樣的空間位置及大小。我們使用 2.5 小節所介紹的 3D Slicer 中的 Brains General Registration Tool 進行對應。PET-CT 的 DICOM 文件屬於 Secondary Capture Image，即圖像不是 Original Data 而是經過額外處理後所產生的，如圖 3-2 所示圖像畫面中有其他額外的資訊，因此需要做處理才能繼續接下來的對應工作。




圖 3-2 Ours PET-CT 資料集示意圖

首先我們用 Photoshop 圖像處理工具把圖像裁剪到只剩腦部的範圍，並把多餘的部

分移除，最後縮放到跟 MRI 一樣的大小，並進行灰階轉換。在轉換灰階時，為了保留更多的細節，我們分別嘗試了三種灰階轉換方法：Average、Desaturation 以及 Luminosity。Average 的計算方式為 $\frac{R+G+B}{3}$ ，Desaturation 的計算方式為 $\frac{MAX(R,G,B)+MIN(R,G,B)}{2}$ ，Luminosity 的計算方式為： $(0.2989 \times R) + (0.5870 \times G) + (0.1140 \times B)$ 。從圖 3-3 中可以看到 Luminosity 保留了最多的腦部細節，因此我們採用此計算方式將彩色轉換為灰階，最後保存為 12-bit 的灰階圖像。




圖 3-3 PET-CT 彩色圖轉灰階圖的各種計算方式的結果比較圖

我們分別將 MRI 圖像與 PET-CT 灰階圖像 Import 到 3D Slicer 當中，此處以 3D Slicer 版本 5.2.2 為例，並選擇 General Registration (BRAINS) 工具，詳細參數設定如圖 3-4：




圖 3-4 General Registration (BRAINS) 工具參數設定圖

其中 Fixed Image Volume 為對應參考的 MRI 圖像，Moving Image Volume 為需要對應的 PET-CT 圖像，Percentage Of Samples 的參數默認值為 0.002，值越大對應過程就

會越耗時，但結果會比較精確，經過多次嘗試，我們設定為 0.1 會有更好的對應結果，但處理過程相對較慢。如圖 3-5 所示，左邊為 MRI 圖像，右邊為 Registration 輸出的 PET-CT 圖像，可以看到 PET-CT 已經成功對應到跟 MRI 相同的空間位置及大小，最後我們把輸出結果保存為 NifTi (.nii.gz) 格式。如此一來 MRI 的腫瘤 Label 就可以用在 PET-CT 上。




圖 3-5 MRI 與 PET-CT Registration 結果對比圖

3.2.2 處理 TCIA PET & CT 腦部資料

PET-CT 自我監督式學習所需要的資料集部分，我們使用 2.6.5 小節介紹的 TCIA 資料集，該資料集包含病人全身的 CT 斷層掃描以及 PET 正子掃描，我們的實驗主要是針對腦部，因此我們只取腦部的切片，並把 CT 與 PET 融合成 PET-CT。

我們同樣使用 2.5 小節所介紹的 3D Slicer 中的 Brains General Registration Tool 進行對應。在對應工作前，我們無需對 DICOM 文件做處理，直接將 CT 與 PET 的原始 DICOM 文件導入到 3D Slicer 中，並利用 General Registration (BRAINS) 工具做對應，參數與 3.2.1 小節中處理 MRI 與 PET-CT 對應的參數一致。如圖 3-4 所示，此處 Fixed Image Volume 選擇的是 CT 圖像，而 Moving Image Volume 選擇的是 PET 圖像。做完 Registration 後同樣保存為 NifTi (.nii.gz) 格式。接下來我們將導出的 CT 與 PET 圖像進行融合 (Fusion)。在融合前，按照 3.1.1 小節的“DICOM 像素轉換”步驟對 CT 圖像進行細節增強（如圖 3-6 所示），再把 PET 圖像以 50% 的透明度疊加到細節增強過後的 CT 圖像上，得到最終的 PET-CT 圖像。圖 3-6 為 TCIA PET-CT 處理流程示意圖：




圖 3-6 TCIA PET-CT 處理流程示意圖

3.3 Unet 與 SwinUNETR 模型訓練

在本節中，我們將介紹用於訓練 Unet 與 SwinUNETR 模型的實驗設計。我們選擇 Unet 與 SwinUNETR 模型是因為它們在醫療影像分割任務上具有良好的性能和廣泛的應用。Unet 從被提出以來到現在，一直都是分割模型的首選，而 SwinUNETR 則是近年來屬於具有突破性的代表，結合了 Transformer 的架構，具有更好的表現。我們想探討這兩個模型分別在 BraTS2021 以及我們自己的資料集上的分割表現，並選擇較好的模型用來進行後續的實驗。我們將介紹 Unet 和 SwinUNETR 模型架構、資料集前處理的部分，以及實驗步驟。

3.3.1 Unet 模型參數

在實驗當中，我們的 Unet 模型的由 5 個 Encoder Block 與 4 個 Decoder Block 所組成。模型輸入為 $1 \times 128 \times 128 \times 64$ ($Channel \times Height \times Width \times Depth$) 的圖像，然後經過 Stride 為 1 的卷積層將 Channel 數量增加至 16 個，得到 $16 \times 128 \times 128 \times 64$ 的 Feature Map。接著會經過 5 個 Encoder Block 如圖 3-7 所示，Encoder Block 中，輸入會先經過 Stride 為 2 的 3D 卷積層，後面緊接著 Instance Normalization 以及 ReLU 激活函數，再經過 Stride 為 1 的 3D 卷積層，最後再進行 Instance Normalization 以及 ReLU 激活函數後輸出。值得注意的是 Encoder Block 的輸

入與輸出都是以殘差網路方式進行連接。每經過一次 Encoder Block，Channel 數量將會加倍， $Height \times Width \times Depth$ 數量會減半。到第 5 個 Encoder Block 之後得到 $256 \times 8 \times 8 \times 4$ 的 Feature Map，然後接到第 1 個 Decoder Block 當做輸入。每一個 Decoder Block 中的輸入會先經過 Stride 為 2 的 3D 反卷積層，通過反卷積後的輸出與對應的 Encoder 拼接在一起（如圖 3-7 中左右相接的灰色箭頭），再經過 Stride 為 1 的 3D 卷積層，最後再進行 Instance Normalization 以及 ReLU 激活函數後輸出。Decoder Block 中的拼接層輸出與 Decoder Block 最後一層的輸出以殘差網路的方式進行連接。每經過一次 Decoder Block，Channel 數量將會減半， $Height \times Width \times Depth$ 數量會加倍。到第 4 個 Decoder Block 之後得到 $16 \times 128 \times 128 \times 64$ 的輸出。隨後再經由最後一層 Stride 為 1 的 3D 卷積網路，將 Channel 降低至 2 個數量，得到 $2 \times 128 \times 128 \times 64$ 的張量。我們最後會對結果進行 Argmax 的運算，取最大值的 Index，最終得到 $1 \times 128 \times 128 \times 64$ 的腫瘤分割圖像。




圖 3-7 Unet 模型參數圖

3.3.2 SwinUNETR 模型參數

在實驗中，我們的 SwinUNETR 模型由 5 個 Encoder Block 與 5 個 Decoder

圖 3-8 SwinUNETR 模型參數圖

3.3.3 訓練前處理

在訓練之前，我們會將資料集的數值縮放到 0 到 1 之間，這樣做的好處是可以消除不同資料之間不同的值帶來的偏差，可以讓模型在學習過程中收斂地更快，更有效率。接下來我們會對圖片進行隨機翻轉，讓模型可以學習到圖像在不同方向上的外觀和特徵，從而提高模型對於翻轉變換的泛化能力。

3.3.4 使用 BraTS2021 資料集進行 Supervised Learning

我們將分別使用 3.3.1 與 3.3.2 小節中介紹的模型，對 BraTS2021 資料集（1251 位病人）進行 3-Folds 交叉驗證。如圖 3-9 所示，首先我們將資料集劃分為 A, B, C 三個子集，每個子集包含 417 位病人資料。接著選擇 A 當做測試集，將剩餘的 B, C 作為訓練用的資料，進行一次完整的監督式訓練並對 A 進行評估。以此類推，輪流對 B, C 進行評估。




圖 3-9 BraTS2021 三折交叉驗證示意圖

3.3.5 使用 Ours MRI 資料集進行 Supervised Learning

我們將分別使用 3.3.1 與 3.3.2 小節中介紹的模型，對 Ours MRI 資料集（33 位病人）進行 3-Folds 交叉驗證。如圖 3-10 所示，首先我們將資料集劃分為 A, B, C 三個子集，每個子集包含 11 位病人資料。接著選擇 A 子集當做測試集，將剩餘的 B, C 作為訓練用的資料，進行一次完整的監督式訓練並對 A 進行評估。以此類推，輪流對 B, C 進行評估。




圖 3-10 Ours MRI 三折交叉驗證示意圖

3.3.6 使用 BraTS2021 + Ours MRI 資料集進行 Supervised Learning

我們將分別使用 3.3.1 與 3.3.2 小節中介紹的模型，對 Ours MRI 資料集（33 位病人）進行 3-Folds 交叉驗證。如圖 3-11 所示，首先我們將小腫瘤資料集劃分為 O1, O2, O3 三個子集，每個子集包含 11 位病人資料。接著選擇 O1 子集當做測試集，將剩餘的 O2, O3 與 BraTS2021 資料集（1251 位病人）合併作為訓練用的資料，進行一次完整的監督式訓練並對 O1 進行評估。以此類推，輪流對 O2, O3 進行評估。




圖 3-11 BraTS2021 + Ours MRI 三折交叉驗證示意圖

3.4 留一驗證的 Data Augmentation

針對 3.5 及 3.6 小節的所有實驗設計，我們將對留一驗證的訓練集進行 Data Augmentation 以擴充訓練集的數量。透過對原始資料應用各種轉換和變換，可以生成額外的訓練樣本，讓模型更好地學習資料的不同變化和特徵。如圖 3-12 所示，我們分別設計了不同的變換，包含：

- 旋轉：對圖片進行 $20^\circ \sim 50^\circ$ 或 $-20^\circ \sim -50^\circ$ 的旋轉。
- 縮放：對圖片進行 0.6~0.9 倍或 1.1~1.5 倍的縮放。
- 旋轉+縮放：分別應用旋轉與縮放，參數與上面一致。
- 仿射轉換：對圖片進行 0.4 的 Shear Transform。




圖 3-12 留一驗證的 Data Augmentation 示意圖

我們將進行不同倍數的資料擴增，包括 4 倍、8 倍、16 倍等，觀察模型在不同倍數下的表現，以及在某個倍數後表現達到最佳的情況。

3.5 針對 MRI 小腫瘤患者的模型訓練

BraTS2021 資料集的 1251 位病人都是以大面積且較為明顯的腫瘤為主。而 Ours MRI 資料集的 33 位病人當中，18 位病人的腫瘤是大面積的腫瘤，而其餘 15 位病人的腫瘤屬於小面積的腫瘤，即明說小腫瘤資料集在數量上是稀缺的。因此在資料稀缺的情況下，為了找出對於 MRI 小腫瘤的有效分割方法，如圖 3-13 所示，我們將 Ours MRI 資料集切分為“大腫瘤資料集（18 位病人）”與“小腫瘤資料集（15 位病人）”，並針對 MRI 小腫瘤資料集設計了四種不同的實驗方法：

- 將 BraTS2021 資料集與 MRI 小腫瘤資料集合併後，對 15 位小腫瘤病人進行留一驗證。
- 利用 MRI 小腫瘤資料集以不同倍數的 Data Augmentation 進行留一驗證。
- 利用 BraTS2021 資料集以 Supervised Learning 的方式進行模型預訓練，然後使用

Transfer Learning 的方式對 MRI 小腫瘤資料集以不同倍數的 Data Augmentation 進行 留一驗證。

- 利用 BraTS2021 資料集以 Self-Supervised Learning 的方式進行模型預訓練，再對 MRI 小腫瘤資料集以不同倍數的 Data Augmentation 進行留一驗證。




圖 3-13 MRI 腦部大腫瘤與小腫瘤資料集示意圖

在選擇網路模型方面，我們將 3.3 小節中的實驗方法所得出的結果作為參考，並選擇表現較好的模型對 MRI 小腫瘤資料集進行以上四種實驗。

3.5.1 使用 BraTS2021 + MRI 小腫瘤資料集進行 Supervised Learning

為了評估 BraTS2021 資料集對於 MRI 小腫瘤偵測的效果，我們將 BraTS2021 資料集與 MRI 小腫瘤資料集進行合併，並進行 15 位小腫瘤病人的留一驗證。如圖 3-14 所示，我們將進行總共 15 回合的留一驗證。在每一回合中，我們從這 15 位病人中選擇 1 位作為測試資料，將其餘 14 位與 BraTS2021 資料集合併作為訓練集。我們重複這個過程，直到對所有小腫瘤病人都進行了測試。




圖 3-14 BraTS2021 + MRI 小腫瘤資料集留一驗證示意圖

3.5.2 使用 MRI 小腫瘤資料集進行 Supervised Learning

首先我們將使用 3.5 小節中性能較好的模型對 MRI 小腫瘤資料集 (15 位病人) 進行留一驗證。如圖 3-15 所示，我們將進行總共 15 回合的留一驗證。在每一回合中，我們從 15 病人中選擇其中 1 位作為測試資料，其餘 14 位當做訓練集。重複進行這個過程，直到對每一位不重複的病人都進行了測試。這樣可以確保每位病人都有機會成為測試資料，從而獲得對模型性能的全面評估。




圖 3-15 MRI 小腫瘤資料集留一驗證示意圖

3.5.3 對 MRI 小腫瘤資料集進行 Transfer Learning

對於 MRI 小腫瘤的遷移學習，我們將分別使用 2.2.11 小節介紹的兩種策略：Finetuning 與 Layer Freezing。如圖 3-16 所示，首先我們會使用 BraTS2021 資料集（1251 位病人）進行完整的監督式訓練以得到 Pretrained Model，並利用 Pretrained Model 的權重來對 MRI 小腫瘤進行下游任務的 Finetuning 和 Layers Freezing 這兩種策略的留一驗證。

在 Finetuning 方面，需要選擇適合的 Epochs 數量，所以我們會分別使用 2 Epochs、4 Epochs、6 Epochs、8 Epochs and 10 Epochs 來對 4 倍的 Data Augmentation 進行訓練，並選擇其中表現較好的 Epochs 數量進行 Finetuning。圖 3-16 為 Finetuning 流程示意圖：




圖 3-16 遷移學習 Finetuning 示意圖

在 Layer Freezing 方面，如圖 3-17 所示，在下游任務中，我們只對最底部的兩層進行訓練，凍結除了底部兩層的其他權重。我們希望模型能夠保留之前在 BraTS2021 資

料集所學習到的特徵的同時，讓底部兩層進行新的小腫瘤的特徵學習任務，希望能夠提升模型的泛化性能。




圖 3-17 遷移學習 Layer Freezing 示意圖

3.5.4 對 MRI 小腫瘤資料集進行 Self-Supervised Learning

對於 MRI 小腫瘤的自我監督式學習，我們參考 [11][12] 的方法。首先我們將使用 SwinVit AutoEncoder 對 BraTS2021 資料集進行對比學習，然後用得到的 Pretrained Model 的權重進行 MRI 小腫瘤資料集的留一驗證。

關於對比學習的部分，如圖 3-18 所示，我們將 BraTS2021 資料集的一位病人進行兩種不同的 Image Augmentation，包含 Inner-cutout 及 Outer-cutout：

- Inner-cutout：對圖片內部進行隨機尺寸的裁剪並添加噪點，裁剪尺寸最小值為 5、

最大值為 32，裁剪數量為 6。

- Outer-cutout：對圖片外圈進行隨機尺寸的裁剪並添加噪點，裁剪尺寸最小值為 20、最大值為 64，裁剪數量為 6。




圖 3-18 自我監督式學習 Image Augmentation 示意圖

如圖 3-19 所示，在對比學習的部分，我們按照以下的步驟進行：

- 對原始病人資料進行 Augmentation，得到兩種不同的資料，我們稱之為 Aug 1 與 Aug 2。
- 將 Aug 1 和 Aug 2 分別輸入到 SwinVit AutoEncoder 模型，得到重建後的 Recon 1 與 Recon 2。
- 根據 2.3.2 小節介紹的損失函數，計算 Recon 1 與 Recon 2 的 Contrastive Loss.
- 計算 Recon 2 和未經過 Augmentation 的原始病人資料之間的 L1 Loss。
- 將 Contrastive Loss 的結果與 L1 Loss 的結果相加，得到綜合的損失。
- 最後用綜合損失更新模型的權重。

以上過程我們稱為 Self-Supervised Learning，訓練完後將會得到 SSL Pretrained Model。

對於 MRI 小腫瘤資料集的訓練，我們選擇 SwinUNETR 模型，並把 SSL Pretrained Model 的 SwinVit Encoder 的權重轉移到 SwinUNETR 的 SwinVit Encoder 上，並對權

重進行凍結，只訓練 SwinUNETR 的 Decoder 部分。完整的訓練過程如圖 3-19 所示：




圖 3-19 MRI 小腫瘤資料集自我監督式學習完整流程示意圖

3.6 針對 PET-CT 大腫瘤患者的模型訓練

在腫瘤偵測任務中，MRI 小腫瘤的偵測相較大腫瘤來說面臨著更大的挑戰。考慮到 PET-CT 的腫瘤標籤是由 MRI 轉移而來的，因此可以預期 PET-CT 在小腫瘤偵測方面的表現會更加困難。鑒於這一點，我們優先專注於使用 PET-CT 大腫瘤資料集進行實驗。我們對 PET-CT 大腫瘤資料集設計了兩種不同的實驗方法：

- 利用 PET-CT 大腫瘤資料集以不同倍數的 Data Augmentation 進行留一驗證。
- 利用 TCIA 資料集以 Self-Supervised Learning 的方式進行模型訓練，再對 PET-CT 大腫瘤資料集以不同倍數的 Data Augmentation 進行留一驗證。




圖 3-20 PET-CT 腦部大腫瘤與小腫瘤資料集示意圖

3.6.1 使用 PET-CT 大腫瘤資料集進行 Supervised Learning

首先我們將使用 3.5 小節中性能較好的模型對 PET-CT 大腫瘤資料集（18 位病人）進行留一驗證。如圖 3-21 所示，我們將進行總共 18 回合的留一驗證。在每一回合中，我們從 18 病人中選擇其中 1 位作為測試資料，其餘 17 位當做訓練集。重複進行這個過程，直到對每一位不重複的病人都進行了測試。這樣可以確保每位病人都有機會成為測試資料，從而獲得對模型性能的全面評估。




圖 3-21 PET-CT 大腫瘤資料集留一驗證示意圖

3.6.2 使用 PET-CT 大腫瘤資料集進行 Self-Supervised Learning

關於 PET-CT 大腫瘤資料集的 Self-Supervised Learning，與 3.5.4 小節的實驗設計完全一樣，首先我們將使用 SwinVitAutoEncoder 對 TCIA 資料集進行對比學習，然後用得到的 Pretrained Model 的權重進行 PET-CT 大腫瘤資料集的留一驗證。完整的 PET-CT 大腫瘤資料集的 Self-Supervised Learning 流程如圖 3-22 所示：




圖 3-22 PET-CT 大腫瘤資料集自我監督式學習完整流程示意圖

第四章 實驗結果與討論

在本章節中，我們會介紹實驗環境與所使用的資料集，接著將會使用第三章中的各種方法，進行實驗，在每個實驗中，所有腦部資料集的圖像大小為 $128 \times 128 \times 64$ 的樣本進行實驗，本論文包含的實驗如下：

表 4.1 所有實驗概述

編號	實驗名稱	實驗概述
一	測試 Unet 及 SwinUNETR 對 Brats2021 & Ours MRI 資料集上的 Dice 表現	分別使用 Unet 及 SwinUNETR 模型對 BraTS2021 資料集、Ours MRI 資料集進行 3 折交叉驗證以測試兩個模型的 Dice 表現，並相互比較。
二	以 BratTS2021 + MRI 小腫瘤資料集進行監督式學習並測試對 MRI 小腫瘤測試集上的 Dice 表現	利用 SwinUNETR 模型對 BratTS2021 + MRI 小腫瘤資料集進行留一驗證以測試模型在 MRI 小腫瘤測試集上的 Dice 表現。
三	測試 Supervised Learning 對 MRI 小腫瘤資料集上的 Dice 表現	利用 SwinUNETR 模型對 MRI 小腫瘤資料集進行留一驗證以測試模型在 MRI 小腫瘤測試集上的 Dice 表現。
四	測試 Transfer Learning - Finetuning 對 MRI 小腫瘤資料集上的 Dice 表現	利用 SwinUNETR 模型對 BraTS2021 資料集進行訓練，然後利用訓練好的模型權重初始化接下來要對 MRI 小腫瘤資料集訓練的網路模型，以微調的方式進行留一驗證，並測試模型在 MRI 小腫瘤測試集上的 Dice 表現。
五	測試 Transfer Learning - Layers Freezing 對 MRI 小腫瘤資料集上的 Dice 表現	利用 SwinUNETR 模型對 BraTS2021 資料集進行訓練，然後利用訓練好的模型權重初始化接下來要對 MRI 小腫瘤資料集訓練的網路模型，之後凍結除了底部兩層以外的所有網路層，只針對底部兩層做權重的更新，以此方式進行留一驗證，並測試模型在 MRI 小腫瘤測試集上的的 Dice 表現。
六	測試 Self-Supervised Learning 對 MRI 小腫瘤資料集上的 Dice 表現	先利用 SwinVit AutoEncoder 對 BraTS2021 資料集進行對比學習，然後使用訓練好的 Encoder 權重去初始化接下來要對 MRI 小腫瘤資料集訓練的 SwinUNETR 模型的 Encoder，並鎖定 Encoder 權重的更新，只訓練 Decoder 部分，以此方式進行留一驗證，並測試模型在 MRI 小腫

		瘤測試集上的 Dice 表現。
七	測試 Supervised Learning 在 PET-CT 大腫瘤資料集上的 Dice 表現	利用 SwinUNETR 模型對 PET-CT 大腫瘤資料集進行留一驗證，並測試模型在 PET-CT 大腫瘤測試集上的 Dice 表現。
八	測試 Self-Supervised Learning 在 PET-CT 大腫瘤資料集上的 Dice 表現	先利用 SwinVit AutoEncoder 對 TCIA 資料集進行對比學習，然後使用訓練好的 Encoder 權重去初始化接下來要對 PET-CT 大腫瘤資料集訓練的 SwinUNETR 模型的 Encoder，並鎖定 Encoder 權重的更新，只訓練 Decoder 部分，以此方式進行 Leave One Out Cross Validation，並測試模型在 PET-CT 大腫瘤測試集上的 Dice 表現。
九	評估腫瘤模型的 Specificity	利用實驗三至實驗六中表現最好的 MRI 小腫瘤模型以及實驗七至實驗八中表現最好的 PET-CT 大腫瘤模型，對沒有腫瘤的正常患者進行預測，以評估這兩個模型的 Specificity。

4.1 實驗電腦硬體設備與環境設置

實驗機器有兩台，詳細的電腦硬體設備如表 4.2 所示，表 4.3 是實驗所使用的深度學習框架的版本，以及視覺化工具包版本。

表 4.2 實驗機器硬體配備

處理器	Intel Core i9-9900x @3.50GHZ	Intel Core i7-6700 @3.40GHZ
記憶體	32GB DDR4	32GB DDR4
顯示卡	Nvidia GTX 1080-Ti	Nvidia GTX 1080-Ti
主機板	Gigabyte X299 Designer EX	ASUS 820MT
作業系統	Ubuntu 20.04.6 LTS	Windows 10 Pro

表 4.3 實驗環境框架版本

Python	3.10
Pytorch	2.0.0
CUDA	11.6
MONAI	1.2.0

表 4.4 監督式學習超參數

Epochs	100
Batch Size	1
Optimizer	Adam
Learning rate	1e-4
Loss	Dice Loss / Focal Loss / DiceFocal Loss

表 4.5 自監督式學習超參數

Epochs	300
Batch Size	1
Optimizer	Adam
Learning rate	1e-4

Loss	Contrastive Loss + L1 Loss
------	----------------------------

4.2 所使用之資料集

在我們的實驗當中，使用了 BraTS 最新的資料集、The Cancer Imaging Archive 的開源資料，以及振興醫院提供的資料：包含 BraTS2021 Dataset、Ours MRI Dataset、TCIA PET-CT Dataset、Ours PET-CT Dataset。這些資料集的來源及處理方式在 3.1 及 3.2 小節已經進行說明，以上資料列在表 4.6：

表 4.6 所使用資料集數量

Dataset		數量
BraTS2021		1,251
TCIA		400
Ours MRI	Small Tumor	15
	Large Tumor	18
Ours PET-CT	Small Tumor	15
	Large Tumor	18
No Tumor MRI		22
No Tumor PET-CT		13

在實驗一中，我們使用 BraTS2021 及 Ours MRI 資料集來進行實驗。接下來如表 4.7 所示，我們把 Ours MRI 與 Ours PET-CT 拆分成大腫瘤及小腫瘤資料集。在實驗二~六中，我們使用 MRI Small Tumor 資料集進行實驗。在實驗七~八中，我們使用 PET-CT Large Tumor 資料集進行實驗。在實驗九中我們使用 No Tumor MRI 以及 No Tumor PET-CT 資料集進行實驗。

4.3 實驗一：測試 Unet 及 SwinUNETR 對 Brats2021 &

Ours MRI 資料集上的 Dice 表現

- 實驗概述

這項實驗我們想知道 Unet 及 SwinUNETR 模型分別對 BraTS2021 及 Ours MRI 資料集上的 Dice 表現。我們將分別使用 3.3.4, 3.3.5, 3.3.6 小節中介紹的方法進行 3 折交叉驗證。超參數的部分，除了使用 200 Epochs，其餘設定和表 4.4 一樣。

- 數據與討論



圖 4-1 Unet 及 SwinUNETR 對 BraTS2021 訓練資料之 Loss 變化



圖 4-2 Unet 及 SwinUNETR 對 BraTS2021 訓練資料之 Validation Dice 變化

圖 4-1 和 圖 4-2 是 Unet 及 SwinUNETR 對 BraTS2021 訓練集進行訓練時的 Loss 與 ValidationDice 變化。可以看到在訓練過程中 SwinUNETR 的收斂速度比 Unet 更快，到了 100 Epochs 之後兩者收斂速度大致上變得一致。而在 Validation Dice 方面，兩個模型的 Dice 值到了 50 Epochs 之後上升變得緩慢。訓練後兩個模型的 Loss 值最低能降到 0.03 左右，而 Validation Dice 方面，Unet 最高能達到 0.88 左右，SwinUNETR 則是 0.91 左右。



圖 4-3 Unet 及 SwinUNETR 對 Ours MRI 訓練資料之 Loss 變化




圖 4-4 Unet 及 SwinUNETR 對 Ours MRI 訓練資料之 Validation Dice 變化

圖 4-3 和 圖 4-4 是 Unet 及 SwinUNETR 對 Ours MRI 訓練集進行訓練時的 Loss 與 Validation Dice 變化。大致上兩者的收斂速是差不多的，到了 180 Epochs 之後 Loss 下降得非常緩慢。在 Validation Dice 方面，Unet 與 SwinUNETR 則別是到了 160 Epochs 和 60 Epochs 之後後上升速度變慢。因為 Ours MRI 的資料集數量非常少，訓練後 Unet 與 SwinUNETR 的 Loss 值分別最低只能降到 0.3 與 0.2 左右，而 Validation Dice 分別則是最高能到 0.27 與 0.45 左右。



圖 4-5 Unet 及 SwinUNETR 對 BraTS2021 + Ours MRI 訓練資料之 Loss 變化




圖 4-6 Unet 及 SwinUNETR 對 BraTS2021 + Ours MRI 訓練資料之 Validation Dice 變

化

圖 4-5 和 圖 4-6 是 Unet 及 SwinUNETR 對 BraTS2021 + Ours MRI 訓練集進行訓練時的 Loss 與 Validation Dice 變化。在訓練過程中 SwinUNETR 的收斂速度比 Unet 更快，到了 50 Epochs 左右之後兩者的收斂速度大致上變得一致。而在 Validation Dice 方面，兩個模型的 Dice 值到了 20 Epochs 之後上升比之前緩慢。訓練後兩個模型的 Loss 值最低能降到 0.03 左右，而 Validation Dice 方面，Unet 最高能達到 0.91 左右，SwinUNETR 則是 0.92 左右。

表 4.7 對 BraTS2021 Train 訓練後對 BraTS2021 Test 預測之 Dice 比較

	BraTS2021 - Dice			
	Fold-1	Fold-2	Fold-3	Average
Unet	0.8728	0.8785	0.8662	0.8725
SwinUNETR	0.9041	0.9083	0.8983	0.9036

表 4.8 以 BraTS2021 Train 訓練後對 Ours Test 預測之 Dice 比較

	Ours MRI - Dice			
	Fold-1	Fold-2	Fold-3	Average
Unet	0.2562	0.2582	0.2578	0.2574
SwinUNETR	0.2834	0.2925	0.2855	0.2871

表 4.9 以 Ours MRI Train 訓練後對 Ours MRI Test 預測之 Dice 比較

	Ours MRI - Dice			
	Fold-1	Fold-2	Fold-3	Average
Unet	0.2646	0.3774	0.2168	0.2863
SwinUNETR	0.3405	0.4765	0.2331	0.3500

表 4.10 以 BraTS2021 + Ours MRI Train 訓練後對 Ours MRI Test 預測之 Dice 比較

	Ours MRI Test - Dice			
	Fold-1	Fold-2	Fold-3	Average
Unet	0.2631	0.5098	0.2965	0.3565
SwinUNETR	0.3627	0.5815	0.3171	0.4204

表 4.11 MRI 大腫瘤與小腫瘤的 Dice 分數

Type of Tumor	Average Dice
Large Tumor (18 patients)	0.7867
Small Tumor (15 patients)	0.0332

從表 4.7 與 4.8 可以看到，SwinUNETR 分別在 BraTS2021 測試集和 Ours MRI 測試集上的 Dice 都比 Unet 高 3% 左右。以表 4.9 與表 4.10 來說，SwinUNETR 比 Unet 高 6.3% 左右。總體來說 SwinUNETR 模型的性能不管是在 BraTS2021 資料集還是 Ours MRI 資料集上的 Dice 表現，都比 Unet 高 4~5%。另外從結果來看，對 Ours MRI 測試集進行預測的 Dice 結果比對 BraTS2021 測試集預測的 Dice 結果還要低，我們認為這是由於 Ours MRI 資料集的 33 位患者當中，有 15 位是屬於小腫瘤患者，從表 4.11 中可以看到，大腫瘤的平均 Dice 分數有達到 0.7867，而小腫瘤的平均 Dice 分數只有 0.0332，由此可見對於這些小腫瘤患者進行預測時的結果較差，甚至無法準確偵測到腫瘤，從而影響了整體的表現。對於小腫瘤患者而言，不管是在 BraTS2021 資料集還是在 Ours MRI 資料集中，訓練樣本都是非常稀缺的。

4.4 實驗二：以 BraTS2021 + MRI 小腫瘤資料集進行監督式學習並測試對 MRI 小腫瘤測試集上的 Dice 表現

• 實驗概述

在這項實驗中我們想知道 BraTS2021 對偵測小腫瘤患者是否有幫助，因此我們合併

BraTS2021 資料集和 Ours MRI 小腫瘤資料集後進行訓練。我們透過 3.5.1 小節中介紹的方法進行實驗，超參數設定如表 4.4 所示。

- 數據與討論

表 4.12 實驗二之 Dice 結果

Patient ID	Dice
001	0.0749
002	0.0115
003	0
004	0.1538
005	0
006	0
007	0
008	0
009	0
010	0.0127
011	0
012	0
013	0
014	0.0077
015	0
Average	0.0174

從表 4.12 來看，BraTS2021 對於小腫瘤偵測上的幫助非常有限，主要是因為 BraTS2021 資料集都是大腫瘤樣本，而 Ours MRI 資料集的小腫瘤樣本也非常稀缺，導致實驗結果的表現不佳。從 Dice 的平均值來看，這項實驗的模型在小腫瘤偵測方面的性能還有很大的提升空間。

4.5 實驗三：測試 Supervised Learning 對 MRI 小腫瘤資料集上的 Dice 表現

- 實驗概述

我們在這項實驗中採用 3.5.2 小節所提到的方法，利用 SwinUNETR 模型對 MRI

小腫瘤資料集進行各種不同倍數的 Data Augmentation，並使用留一驗證的方法，測試模型在不同倍數的 Data Augmentation 下的 Dice 表現。

- 數據與討論




圖 4-7 MRI 在不同倍數的 Data Augmentation 下監督式學習對於小腫瘤的 Dice 變化

觀察圖 4-7 的實驗結果，我們發現使用 Data Augmentation 可以顯著提升 Dice 的表現。與沒有應用 Data Augmentation 的情況相比，使用 4 倍的 Data Augmentation 可以使 Dice 提升 10.3% 左右，而 8 倍的 Data Augmentation 相對 4 倍的提升僅約為 0.7% 左右，而進一步將 Data Augmentation 增加到 16 倍後相對 8 倍則下降約 0.1% 左右，由此可知在超過 8 倍的 Data Augmentation 後，Dice 分數已不再提升。

4.6 實驗四：測試 Transfer Learning - Finetuning 對 MRI 小腫瘤資料集上的 Dice 表現

- 實驗概述

這項實驗我們利用 3.5.3 小節所提到的 Finetuning 策略，使用 SwinUNETR 模型對 BraTS2021 資料集進行訓練，然後利用 Pretrained Model 的權重初始化接下來要對 MRI 小腫瘤資料集訓練的網路模型，以 Finetuning 的方式進行留一驗證。關於

Pretrained Model 的訓練超參數設定如表 4.4 所示。Finetuning 的 Epochs 數量我們以 4 倍的 Data Augmentation 進行訓練並觀察在 2、4、6、8、10 個 Epochs 下的表現，並利用表現最好的 Epochs 數量進行其他倍數的微調。Data Augmentation 則是使用 3.4 小節所介紹的方法進行。

- 數據與討論

表 4.13 Finetuning 在各種 Epochs 數量下的 Dice 表現對比

Data Augmentation ×4	
Epochs	Average Dice
2	0.0512
4	0.0927
6	0.1109
8	0.1032
10	0.1051

從表 4.13 可以看到，4 倍 Data Augmentation 的微調在 6 個 Epochs 數量下表現最佳，因此我們採用 6 Epochs 數量進行其他倍數的訓練。




圖 4-8 MRI 小腫瘤在不同倍數的 Data Augmentation 下採用 Finetuning 策略之 Dice 變化

觀察圖 4-8 的實驗結果，我們發現使用 Data Augmentation 可以顯著提升 Dice 的表現。具體而言，與沒有應用 Data Augmentation 的情況相比，使用 4 倍的 Data Augmentation 可以使 Dice 提升 8.2% 左右，而 8 倍的 Data Augmentation 相對 4 倍的提升約為 1.1% 左右，而進一步將 Data Augmentation 增加到 16 倍後相對 8 倍提升僅約 0.4% 左右。根據這項實驗的結果來看，Data Augmentation 在增加到 16 倍後的提升已經將近極限，Dice 最高能達到 0.126。

4.7 實驗五：測試 Transfer Learning – Layers Freezing 對 MRI 小腫瘤資料集上的 Dice 表現

- 實驗概述

這項實驗我們利用 3.5.3 小節所提到的 Layers Freezing 策略，使用 SwinUNETR 模型對 BraTS2021 資料集進行訓練，然後利用 Pretrained Model 的權重初始化接下來要對 MRI 小腫瘤資料集訓練的網路模型，再來凍結除了底部兩層以外的所有網路層，只針對底部兩層做權重的更新，以此方式進行留一驗證。關於 Pretrained Model 及下游任務的訓練超參數設定如表 4.4 所示。Data Augmentation 則採用 3.4 小節所介紹的方法。

- 數據與討論




圖 4-9 MRI 小腫瘤在不同倍數的 Data Augmentation 下採用 Layers Freezing 方法之 Dice 變化

觀察圖 4-9 的實驗結果，我們發現使用 Data Augmentation 可以顯著提升 Dice 的表現。與沒有應用 Data Augmentation 的情況相比，使用 4 倍的 Data Augmentation 可以使 Dice 提升 5.3% 左右，而 8 倍的 Data Augmentation 相對 4 倍的同樣提升約為 5.3% 左右，而進一步將 Data Augmentation 增加到 16 倍後相對 8 倍則下降約 0.2% 左右。與 Finetuning 的策略比較，Layers Freezing 需要更多的訓練資料才能達到與 Finetuning 一樣的表現。Layers Freezing 策略的最高 Dice 能達到 0.1195，比 Finetuning 低 0.7% 左右。

4.8 實驗六：測試 Self-Supervised Learning 對 MRI 小腫瘤資料集上的 Dice 表現

- 實驗概述

這項實驗我們使用 3.5.4 小節介紹的方法，首先利用 SwinVit AutoEncoder 對 BraTS2021 資料集進行 Contrastive Learning，然後使用訓練好的 Encoder 權重去初始化接下來要對 MRI 小腫瘤資料集訓練的 SwinUNETR 模型的 Encoder，並鎖定 Encoder 權重的更新，只訓練 Decoder 部分，以此方式進行留一驗證，並測試模型在 MRI 小腫瘤測試集上的 Dice 表現。

- 數據與討論



圖 4-10 SwinVit AutoEncoder 對 BraTS2021 資料集進行對比學習之 Loss 變化

圖 4-10 展示了 SwinVit AutoEncoder 對 BraTS2021 訓練集進行對比學習時的 Loss 變化。Loss 值從 Epochs 1 到 Epochs 20 之間迅速下降，到了 40 個 Epochs 之後，下降速度顯著減緩，當到了 280 個 Epochs 之後，Loss 值無明顯下降趨勢，這代表對比學習的模型已經接近收斂狀態。




圖 4-11 MRI 小腫瘤在不同倍數的 Data Augmentation 下自我監督式學習之 Dice 變化

觀察圖 4-11 的實驗結果，與沒有應用 Data Augmentation 的情況相比，使用 4 倍的 Data Augmentation 可以使 Dice 提升 8.4% 左右。而 8 倍的 Data Augmentation 相

對 4 倍的提升約為 0.8% 左右，而進一步將 Data Augmentation 增加到 16 倍後相對 8 倍提升了 3.7% 左右。Data Augmentation 增加到 32 倍後，相較於 16 倍下降約 0.2% 左右。由此可知，自我監督式學習方法在 Data Augmentation 16 倍下已達到學習的極限，而最高 Dice 分數能達到 0.1882。

4.8.1 測試模型在不同 Loss Function 下對偵測 MRI 小腫瘤的影響

我們分別使用 Dice Loss, Focal Loss 和 DiceFocal Loss 進行 MRI 小腫瘤模型的訓練。結果顯示模型在 Dice Loss 下的 Dice 分數為 0.1816，Focal Loss 下的 Dice 分數為 0.0327，而 DiceFocal Loss 下的 Dice 分數為 0.1633。其中可以看到 Dice Loss 對於偵測 MRI 小腫瘤上遠比 Focal Loss 還要來得好，DiceFocal Loss 則是比 DiceLoss 低一些。總體來說對 MRI 小腫瘤的偵測任務上，使用 DiceLoss 的結果是最好的。

4.9 實驗七：測試監督式學習在 PET-CT 大腫瘤資料集上的 Dice 表現

- 實驗概述

在這項實驗中我們採用 3.6.1 所提到的方法，利用 SwinUNETR 模型對 PET-CT 大腫瘤資料集進行各種不同倍數的 Data Augmentation，並使用留一驗證的方法，測試模型在不同倍數的 Data Augmentation 下的 Dice 表現。

- 數據與討論




圖 4-12 PET-CT 大腫瘤在不同倍數的 Data Augmentation 下監督式學習之 Dice 變化

觀察圖 4-12 的實驗結果，我們發現使用 Data Augmentation 可以顯著提升 Dice 的表現。與沒有應用 Data Augmentation 的情況相比，使用 4 倍的 Data Augmentation 可以使 Dice 提升 5.7% 左右，而 8 倍的 Data Augmentation 相對 4 倍的提升僅約為 1.7% 左右，而進一步將 Data Augmentation 增加到 16 倍後相對 8 倍則提升僅約 1% 左右，由此可模型到了 16 倍的 Data Augmentation 後性能幾乎達到極限。

4.10 實驗八：測試 Self-Supervised Learning 在 PET-CT 大腫瘤資料集上的 Dice 表現

- 實驗概述

這項實驗我們使用 3.6.2 小節介紹的方法，首先利用 SwinVit AutoEncoder 對 TCIA 資料集進行對比學習，然後使用訓練好的 Encoder 權重去初始化接下來要對 PET-CT 大腫瘤資料集訓練的 SwinUNETR 模型的 Encoder，並鎖定 Encoder 權重的更新，只訓練 Decoder 部分，以此方式進行留一驗證，並測試模型在 PET-CT 大腫瘤測試集上的 Dice 表現。

- 數據與討論



圖 4-13 SwinVit AutoEncoder 對 TCIA 資料集進行對比學習之 Loss 變化

圖 4-13 展示了 SwinVit AutoEncoder 對 TCIA 資料集進行對比學習時的 Loss 變化。Loss 值從 Epochs 1 到 Epochs 25 之間迅速下降，到了 125 個 Epochs 之後，下降速度減緩，當到了 350 個 Epochs 之後，Loss 值無明顯下降趨勢，這代表對比學習的模型已經接近收斂狀態。




圖 4-14 PET-CT 大腫瘤在不同倍數的 Data Augmentation 下自我監督式學習之 Dice 變化

觀察圖 4-14 的實驗結果，與沒有應用 Data Augmentation 的情況相比，使用 4 倍

的 Data Augmentation 可以使 Dice 提升 11% 左右。而 8 倍的 Data Augmentation 相對 4 倍的提升僅約為 1% 左右，而進一步將 Data Augmentation 增加到 16 倍後相對 8 倍來說已無明顯的提升。由此可知，自我監督式學習方法在 Data Augmentation 8 倍下已達到學習的極限，而最高 Dice 分數能達到 0.3293。

4.11 實驗九：評估腫瘤模型的 Specificity

- 實驗概述

這項實驗我們利用實驗三至實驗六中表現最好的 MRI 小腫瘤模型以及實驗七至實驗八中表現最好的 PET-CT 大腫瘤模型，對沒有腫瘤的正常患者進行預測，以評估這兩個模型的 Specificity。

- 數據與討論

以 MRI 小腫瘤模型來說，我們對 22 位沒有腫瘤的 MRI 正常患者進行腫瘤偵測，結果顯示其中有 10 位患者被偵測出腫瘤。所以有 12 位患者是沒有偵測出腫瘤，因此 Specificity 為 54.5%。而這 10 位被偵測出腫瘤的區域皆為白色亮點的區域，以圖 4-15 來說，這些白色亮點被醫生認定為是白質化現象而不是真正的腫瘤。因此想要提高模型的 Specificity，在訓練資料集上除了腫瘤標籤之外，可能還需要其它額外的資訊。




圖 4-15 MRI 小腫瘤模型對正常患者進行腫瘤預測的結果代表圖

此外，我們對這 22 位正常患者（每位患者為 64 張切片）的每一張切片進行人工檢查，並統計出以下資訊：

- 小白點的存在與否統計：對於這些切片中，有多少切片擁有小白點，以及有多少切片沒有小白點。
- 模型預測的結果統計：
 - 沒有小白點的切片被模型誤判為有腫瘤的情況。
 - 沒有小白點的切片被模型正確判定為沒有腫瘤的情況。
 - 有小白點的切片被模型正確判定為有腫瘤的情況。
 - 有小白點的切片被模型誤判為沒有腫瘤的情況。

表 4.14 對 MRI 正常患者偵測腫瘤之結果統計表

Patient ID	無小白點		有小白點	
	偵測出腫瘤	未偵測出腫瘤	偵測出腫瘤	未偵測出腫瘤
01	3	61		
02		64		
03		46	11	7
04	2	62		
05		49	8	7
06		64		
07	5	59		
08		64		
09		60	2	2
10		64		
11		64		
12		60	1	3
13		64		

14		64		
15	4	48	8	8
16		54	2	8
17		64		
18		64		
19		64		
20		64		
21		55	2	7
22		64		

通過表 4.14 的統計，後續我們可以對小腫瘤模型的準確性和效能做出更詳細的評估。

對於 PET-CT 大腫瘤的正常患者的偵測，我們用 18 位大腫瘤患者以及 13 位正常患者使用 SwinUNETR 模型進行留一交叉驗證，實驗結果顯示，13 位正常患者皆被誤判為有腫瘤，因此 Specificity 為 0%。這情況我們猜測對於 Ours PET-CT 而言，我們需要更多的資訊才能夠讓模型有能力去分辨有腫瘤或沒有腫瘤。因此我們額外對 Ours PET-CT 資料進行一階微分，並且與原始的 PET-CT 資料一起當做 Training Data 進行模型訓練，實驗結果表明，進行一階微分仍然無法改善。




圖 4-16 PET-CT 大腫瘤模型對正常患者進行腫瘤預測的結果代表圖

4.12 結果與討論




圖 4-17 MRI 小腫瘤在不同倍數的 Data Augmentation 下採用四種不同方法之 Dice 變化對比圖




圖 4-18 MRI 小腫瘤分割結果示例圖

以 MRI 小腫瘤患者來說，自我監督式學習在不同倍數的下的表現都明顯優於其他三種方法。根據圖 4-17 中的結果觀察，在沒有應用 Data Augmentation 之前的情況下，我們可以看到自我監督式學習的 Dice 分數有明顯高於實驗三、四、五中的方法。在其他倍數下的 Data Augmentation，自我監督式學習的 Dice 分數也明顯占優勢。另外，當 Data Augmentation 從 8 倍增加到 16 倍時，實驗三、四、五的表現已無明顯的提升，然而自我監督式學習的表現還有明顯在上升的趨勢，直到 32 倍後自我監督式學習的表現已到達極限。另外，以圖 4-18 中的上面一位患者為例，在沒有資料增強的情況下，沒有正確猜測出小腫瘤，經過資料增強後有正確猜測出小腫瘤。而以圖 4-18 中的下面一位患者為例，在沒有資料增強下會出現猜測錯誤，經過資料增強後則有正確猜測出小腫瘤，可以說明在資料增強後，模型的性能以及泛化能力都有一定的提升。




圖 4-19 PET-CT 大腫瘤在不同倍數的 Data Augmentation 下採用兩種不同方法之 Dice 變化對比圖




圖 4-20 PET-CT 大腫瘤分割結果示例圖

在 PET-CT 大腫瘤患者方面，以圖 4-19 的結果來說，自我監督式學習的表現比監督式學習更好一些，到了 16 倍的資料增強下，兩者的表現變得更接近。以圖 4-20 的腫瘤分割結果來看，有一些患者能夠正確偵測出腫瘤區域，但也有另外一些則是偵測錯誤或是沒有被正確偵測出來。總體來說，以 MRI 腫瘤標籤轉移到 PET-CT 的方法，確實能夠有效偵測出部分患者的腫瘤區域，但未被正確偵測出的患者我們認為可能是因為 PET-CT 腫瘤特徵不明顯或資料集本身的問題導致無法有效地進行特徵學習，但具體原因需要再進一步進行相關研究。

第五章 結論及未來研究方向

5.1 結論

比起一般的 U-Net 模型，具有 Transformer 模塊的 U-Net 變形網路 (SwinUNETR) 在醫療影像分割任務上表現更好。然而，使用 MRI 大腫瘤資料進行訓練對於 MRI 小腫瘤的偵測任務上，並沒有帶來顯著的幫助。此外，根據實驗結果顯示自我監督式學習比傳統監督式學習和遷移學習取得更好的性能表現。對於 MRI 小腫瘤偵測任務方面，以實驗結果來看，使用 Data Augmentation 能夠提升腫瘤偵測的性能和泛化能力，另外在訓練資料上除了腫瘤標籤之外可能需要更多的資訊才能改善模型的 Specificity。而在 PET-CT 大腫瘤偵測任務方面，以 MRI 腫瘤標籤轉移到 PET-CT 的方法所進行訓練的 PET-CT 模型，確實能夠有效偵測出部分患者的腫瘤。

5.2 未來研究方向

在自我監督式學習的預訓練模型上應用更多不同的資料增強組合來進行實驗，以探討是否能夠有效提高 MRI 小腫瘤的模型性能。

關於白質化現象被 MRI 小腫瘤模型判定為腫瘤的部分，因為我們目前的實驗沒有把白質化病人加入訓練集，所以未來可以將白質化病人加入訓練集以改善此問題。

除了做 MRI 腫瘤分割任務的實驗，未來可以考慮同時使用腫瘤以及白質化病人，對腦部進行疾病的分類。

對於 PET-CT 大腫瘤偵測方面，有些患者的腫瘤區域未被正確偵測出來，以及對正常患者誤判為有腫瘤的情況，可能是因為 PET-CT 資料集本身的問題而導致無法有效地進行特徵學習。目前我們還無法確定問題的具體原因，因此需要進一步進行相關研究，以獲得更明確的答案。

在腦腫瘤分割任務上主要關注在切割的區域準不準確，並沒有考慮到哪些病人是正常患者或是有疾病的，因此未來可以按照這個切入點去做研究。

參考文獻

- [1] O. Ronneberger, P. Fischer, and T. Brox, "U-net: Convolutional networks for biomedical image segmentation," *In Proc. MICCAI, volume 9351 of LNCS*, p. 234–241, 2015.
- [2] Hatamizadeh, A., Nath, V., Tang, Y., Yang, D., Roth, H. and Xu, D., "Swin UNETR: Swin Transformers for Semantic Segmentation of Brain Tumors in MRI Images," *arXiv preprint arXiv:2201.01266*, 2022.
- [3] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, Illia Polosukhin., "Attention Is All You Need," *arXiv:1706.03762*, 2017.
- [4] Kaiming He, Xiangyu Zhang, Shaoqing Ren, Jian Sun, "Deep Residual Learning for Image Recognition," *arXiv:1512.03385*, 2015.
- [5] A. Horváth, "Registration-based High Order Slice Interpolation," [Online]. Available: <https://www.mathworks.com/matlabcentral/fileexchange/63907-registration-based-high-order-slice-interpolation>.
- [6] "Pytorch," [Online]. Available: <https://pytorch.org/docs/stable/index.html>.
- [7] "Pydicom," [Online]. Available: <https://pydicom.github.io/>.
- [8] Fedorov A., Beichel R., Kalpathy-Cramer J., Finet J., Fillion-Robin J-C., Pujol S., Bauer C., Jennings D., Fennessy F.M., Sonka M., Buatti J., Aylward S.R., Miller J.V., Pieper S., Kikinis R., "3D Slicer as an Image Computing Platform for the Quantitative Imaging Network. Magnetic Resonance Imaging," 2012 Nov. [Online]. Available: <https://slicer.readthedocs.io/en/latest/>.
- [9] "Monai," [Online]. Available: <https://monai.io/>.

- [10] Liu, Z., Lin, Y., Cao, Y., Hu, H., Wei, Y., Zhang, Z., Lin, S., Guo, B, "Swin transformer: Hierarchical vision transformer using shifted windows," *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 2021.
- [11] Tang, Yucheng, Dong Yang, Wenqi Li, Holger R. Roth, Bennett Landman, Daguang Xu, Vishwesh Nath, and Ali Hatamizadeh, "Self-supervised pre-training of swin transformers for 3d medical image analysis," *In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 20730-20740, 2022.
- [12] Chen, Ting, et al, "A simple framework for contrastive learning of visual representations," *International conference on machine learning*. PMLR, 2020.
- [13] U.Baid, et al., "The RSNA-ASNR-MICCAI BraTS 2021 Benchmark on Brain Tumor Segmentation and Radiogenomic Classification," *arXiv:2107.02314*, 2021.
- [14] B. H. Menze, A. Jakab, S. Bauer, J. Kalpathy-Cramer, K. Farahani, J. Kirby, et al, "The Multimodal Brain Tumor Image Segmentation Benchmark (BRATS)," *IEEE Transactions on Medical Imaging* 34(10), 1993-2024.
- [15] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, et al, "An image is worth 16x16 words: Transformers for image recognition at scale," *arXiv preprint arXiv:2010.11929*, 2020.
- [16] Milletari, F., Navab, N., Ahmadi, S.A, "V-net: Fully convolutional neural networks for volumetric medical image segmentation," *2016 fourth international conference on 3D vision (3DV)*, 2016.
- [17] "Browser, DICOM Standard," [Online]. Available: <https://dicom.innolitics.com/ciods>.
- [18] "3D Slicer," [Online]. Available: <https://www.slicer.org/>.
- [19] Horváth A., Pezold S., Weigel M., Parmar K., Cattin P, "High Order Slice Interpolation

for Medical Images," *Simulation and Synthesis in Medical Imaging*, vol. 10557, 2017.

