



國立臺北科技大學

資訊工程系碩士班

碩士學位論文

胸部 CT 影像於 COPD 輔助診斷之研究
A Study on the Auxiliary Diagnosis of COPD using
Chest CT images

研究生：張博翔

指導教授：劉建宏、尤信程博士

中華民國一百一十五年七月

國立臺北科技大學
研究所碩士學位論文口試委員會審定書

本校資訊工程研究所張博翔君

所提論文，經本委員會審定通過，合於碩士資格，特此證明。

學位考試委員會

委

員：

尤信程

陳咸廷

劉建宏

指導教授：

尤信程 劉建宏

所

長：

劉建宏

中華民國 一百一十五年 六月 二十四 日

摘要

關鍵詞：胸部 CT、慢性阻塞性肺病、量化生物標記、Hybrid Mamba-Attention、TAP-CT、類別不平衡

慢性阻塞性肺病（Chronic Obstructive Pulmonary Disease, COPD）之臨床評估主要仰賴肺功能檢查，但胸部電腦斷層影像（computed tomography, CT）亦可提供肺部結構資訊。本研究建立以胸部 CT 為基礎之 COPD 輔助判讀流程，並於同一份 66 例病人（Normal 33、Abnormal 33）與相同之資料切分與驗證協定下，比較三種方法：以 12 項肺氣腫、肺容積、氣道與血管相關特徵為輸入之量化生物標記模型（FCNN）、僅使用 CT 影像之 Hybrid Mamba-Attention，以及結合凍結 TAP-CT 表徵之 TAP-CT late fusion。三種方法皆共同應用於 Normal/Abnormal 分類、塌陷角（Angle of Collapse, AC）三分類／二分類／連續值迴歸，以及由阻塞指數（Obstruction Index, OI）衍生之二分類。經病人層級分層五折交叉驗證，Normal/Abnormal 分類以 Hybrid Mamba-Attention 最佳（準確率 0.879），FCNN（0.848）僅落後約 3 個百分點；OI 二分類以 TAP-CT late fusion 最佳（0.834），量化與純影像模型幾乎相同。塌陷角則為深度影像模型較具優勢之訊號：三分類僅 TAP-CT late fusion 維持較高之整體正確率（0.774），排除中間組之二分類以 Hybrid Mamba-Attention 最佳（0.885）；連續角度迴歸則三方法互有領先，TAP-CT late fusion 之 MAE 最低（ 14.60° ）、FCNN 之 R^2 最高（0.215）。結果顯示，正常／異常與 OI 等與量化特徵高度相關之任務，僅以 12 維定量參數即可達到相當好之區分；塌陷角則需深度影像模型，且凍結 TAP-CT 嵌入對角度與 OI 任務有幫助，惟於影像訊號已足夠之任務中反而略微稀釋純影像特徵。

ABSTRACT

Keywords: chest CT, COPD, quantitative biomarkers, Hybrid Mamba-Attention, TAP-CT, class imbalance

Clinical assessment of chronic obstructive pulmonary disease (COPD) relies primarily on pulmonary function testing; however, chest computed tomography (CT) can also provide structural information about the lungs. This study establishes a chest CT-based workflow for auxiliary COPD assessment and, on the same 66 patients (Normal 33, Abnormal 33) under an identical data-split and validation protocol, compares three methods: a quantitative biomarker model (FCNN) taking 12 emphysema-, lung-volume-, airway-, and vessel-related features as input, an image-only Hybrid Mamba-Attention model, and a TAP-CT late fusion model combining frozen TAP-CT representations. All three methods were applied to Normal/Abnormal classification, Angle of Collapse (AC) three-class classification, binary classification and continuous regression, and a binary classification derived from the Obstruction Index (OI). Under patient-level stratified five-fold cross-validation, Normal/Abnormal classification was best with Hybrid Mamba-Attention (accuracy 0.879), with FCNN (0.848) trailing by only about three percentage points; OI binary classification was best with TAP-CT late fusion (0.834), for which the quantitative and image-only models were almost identical. AC proved to be the signal for which deep imaging models hold an advantage: only TAP-CT late fusion sustained overall accuracy in the three-class task (0.774); the binary task excluding the intermediate group was best with Hybrid Mamba-Attention (0.885); and for continuous regression the three methods led on different metrics, with TAP-CT late fusion attaining the lowest MAE (14.60°) and FCNN the highest R^2 (0.215). The results indicate that tasks highly correlated with quantitative features, such as Normal/Abnormal and OI, can be separated reasonably well using only 12 quantitative parameters, whereas AC requires deep imaging models; frozen TAP-CT embeddings benefit the angle and OI tasks, yet slightly dilute pure image features on tasks where the imaging signal is already sufficient.

誌謝

本論文得以完成，有賴多方師長與家人的支持與協助，謹致最誠摯之謝意。

首先感謝指導教授尤信程教授。在研究過程中，每當面臨方向不明、難以取捨之際，教授總能協助釐清優先次序，給予明確的研究建議；此外，教授積極促成本研究與醫療院所之合作，使資料蒐集得以順利進行，對本研究之推展貢獻甚鉅。

同時感謝指導教授劉建宏教授在研究態度上的提點。教授時常提醒應對自身工作保持嚴謹，即便外在要求不高，亦需自我維持一定水準，此觀念對本人之研究習慣有深遠影響。

此外，特別感謝振興醫院陳威廷醫師。陳醫師在百忙之中，慷慨提供胸部 CT 影像與肺功能檢查資料，並給予豐富的醫學背景知識、文獻建議與研究方向，使本研究得以在具臨床意義的問題框架下進行，對本論文之貢獻不可或缺。

最後，感謝家人長期以來的支持與包容，使本人得以專心完成學業。

目錄

摘要	i
ABSTRACT	ii
誌謝	iii
目錄	iv
表目錄	vi
圖目錄	vii
第一章 緒論	1
1.1 研究背景與動機	1
1.2 研究目的	2
1.3 論文架構	3
第二章 背景與文獻回顧	4
2.1 慢性阻塞性肺病與肺功能檢查	4
2.2 CT 影像表徵與量化生物標記	5
2.3 肺部、氣道與血管影像分割	7
2.4 三維醫學影像深度學習模型	9
2.4.1 Mamba	9
2.5 TAP-CT 預訓練影像表徵	11
第三章 研究方法	12
3.1 研究流程	12
3.2 資料集	14
3.3 資料前處理	15
3.4 肺部結構分割與量化參數擷取	16
3.5 量化生物標記模型	20
3.6 三維 CT 網路架構設計	21
3.7 塌陷角迴歸任務	23
3.8 TAP-CT 影像嵌入與融合策略	23
3.9 交叉驗證、資料增強與平衡取樣	24

3.10	三方法整合預測	25
3.11	評估指標	26
第四章	實驗結果	28
4.1	研究問題	28
4.2	實驗環境設定	28
4.3	實驗結果	30
4.3.1	RQ1 COPD Normal/Abnormal	30
4.3.2	RQ2 塌陷角	32
4.3.3	RQ3 OI 二分類	35
第五章	結論與未來展望	36
5.1	結論	36
5.2	未來展望	37
參考文獻		39
附錄 A	補充實驗	43
A.1	GOLD 四分級分類	43

表目錄

3.1	三維 CT 編碼器架構超參數	23
3.2	TAP-CT late fusion 模型超參數	24
4.1	實驗硬體設備	29
4.2	CT 量化生物標記分支實驗環境	29
4.3	三維 CT 深度學習分支實驗環境	29
4.4	三方法之訓練設定與驗證協定	29
4.5	RQ1 Normal/Abnormal 三方法比較 (n=66, 33/33)	30
4.6	RQ1 三模型 hard voting 結果	30
4.7	RQ2a 塌陷角三分類三方法比較 (n=66; Sens/Spec 為 macro)	33
4.8	RQ2b 塌陷角二分類三方法比較 (n=61, 排除中間組)	33
4.9	RQ2b 三模型 hard voting 結果	33
4.10	RQ2c 塌陷角連續值迴歸三方法比較 (n=66, 合併計算)	34
4.11	RQ3 OI 二分類三方法比較 (n=66, 32/34)	35
4.12	RQ3 三模型 hard voting 結果	35
A.1	補充實驗: GOLD 四分級分類結果 (TAP-CT late fusion)	44

圖目錄

2.1	具選擇機制之狀態空間模型架構	10
3.1	電腦斷層影像量化生物標記分類流程概覽（分割與量化見 3.4 節、分類器見 3.5 節）	13
3.2	TAP-CT late fusion 模型流程概覽（資料增強見 3.9 節、影像編碼器見 3.6 節、融合策略見 3.8 節）	13
3.3	資料集病人年齡與性別分布	15
3.4	3D Slicer 肺部結構分割結果範例。左上為軸向切面、右上為三維立體檢視、左下為冠狀切面、右下為矢狀切面，各顏色區塊對應不同肺葉及血管結構之分割遮罩。	17
3.5	全連接神經網路分類器架構	20
3.6	混合式 Mamba 注意力影像編碼器架構	21
4.1	RQ1 Abnormal 病人的 Grad-CAM 熱力圖	31
4.2	RQ1 判斷錯誤個案的 Grad-CAM 熱力圖	32
A.1	補充實驗：GOLD 四分級分類混淆矩陣	45

第一章 緒論

1.1 研究背景與動機

慢性阻塞性肺病（Chronic Obstructive Pulmonary Disease, COPD）是一種以持續性氣流受限為主要特徵之慢性呼吸道疾病。其造成之肺功能損害不易完全逆轉；若未能及早發現並追蹤，將增加急性惡化與生活品質受損之風險 [1]。如何從臨床影像資料中提取客觀且可解釋之輔助資訊，以協助早期識別與病情追蹤，是 COPD 醫療決策支援的重要課題。

临床上，COPD 之診斷與嚴重程度評估主要仰賴肺功能檢查。此類檢查可量化氣流受限程度，卻較難直接呈現肺部結構異常之位置與型態；若僅依賴單一生理測量結果，可能不足以反映肺部結構異常之型態與分布 [1, 2]。

胸部電腦斷層影像（computed tomography, CT）可補充肺部局部結構資訊。若將 CT 影像轉換為量化生物標記，並結合三維影像模型分析，便可分別從量化特徵與深度影像表徵兩個方向提供 COPD 輔助判讀依據 [2]。

為實現上述目標，近年醫學影像分析逐漸結合自動分割、量化特徵擷取與深度學習模型。對於 COPD CT 影像而言，自動化流程可先由肺葉、氣道與血管等結構分割開始，再計算肺氣腫比例、肺容積、氣道相關比例與血管相關指標等特徵；此類特徵具有較高可解釋性，能與 COPD 病理變化相互對應 [2]。另一方面，三維深度影像模型可直接由 CT 體積資料學習空間表徵，補足人工定義特徵可能無法涵蓋之影像訊息 [3, 4]。兩類方法在可解釋性與影像訊息涵蓋範圍上各有側重，可互為補充。

然而，實際醫學影像研究常受限於資料量不足、掃描協議不一致、分割品質差異與類別分布不均等問題。若模型評估僅呈現整體準確率，容易忽略資料不平衡造成的偏差，也可能掩蓋 Abnormal 個案漏判等临床上更需關注的問題 [5]。

因此，本研究以胸部 CT 影像為核心，建立 COPD 輔助診斷之自動化分析流程，並於同一份 66 例病人與相同之資料切分與驗證協定下，比較三種方法：以 12 項 CT 量化生物標記為輸入之量化生物標記模型（以下簡稱 FCNN）、僅使用 CT 影像之 Hybrid Mamba-Attention 影像模型，以及結合預訓練胸部 CT 表徵之 TAP-CT late fusion。本研究將個案分為 Normal 與 Abnormal 兩類，其中 Abnormal 組為合作醫師依肺功能與臨

床判讀所標示之 COPD 患者。三種方法皆應用於 Normal/Abnormal 分類、由肺功能流量-容積曲線衍生之塌陷角（Angle of Collapse, AC）三分類、排除中間組之塌陷角二分類、塌陷角連續值迴歸，以及由阻塞指數（Obstruction Index, OI）衍生之二分類等 COPD 輔助判讀任務，以檢視量化特徵與深度影像模型於各任務之相對優勢。

1.2 研究目的

本研究以胸部 CT 影像為基礎，於同一份 66 例病人與相同之資料切分與驗證協定下，建立並比較三種互補之 COPD 輔助診斷方法，並於多項臨床相關任務中評估其相對優勢，分述如下。

首先，本研究建置 CT 量化生物標記分析流程，涵蓋肺葉、氣道與血管自動分割，以及全肺肺氣腫比例、肺容積、小血管體積比例、氣道管壁指標、血管密度與肺動脈等效直徑等 12 項特徵計算，並以全連接神經網路作為量化生物標記模型，評估量化特徵於各任務輔助辨識 COPD 相關表徵之能力 [2]。

其次，本研究以僅使用 CT 影像之 Hybrid Mamba-Attention 深度模型直接分析 CT 體積資料，並進一步評估結合預訓練胸部 CT 特徵之 TAP-CT late fusion，比較純影像深度模型與融合預訓練表徵於各任務之表現。

第三，本研究將上述三種方法共同應用於 Normal/Abnormal 二分類、塌陷角三分類（ $AC \leq 131^\circ$ 、 $131^\circ < AC < 152^\circ$ 、 $AC \geq 152^\circ$ ）、排除中間組後之塌陷角二分類、塌陷角連續值迴歸，以及由阻塞指數（OI）衍生之二分類等任務，逐一比較量化特徵、純影像深度模型與融合模型在可解釋性與效能上之差異，評估各方法於不同 COPD 輔助判讀任務中之適用情境。

最後，本研究針對小樣本與類別不平衡問題，採用相同之交叉驗證、影像增強與類別平衡策略，並以多指標評估避免以單一指標過度推論模型效能；另以 GOLD 四級分類作為補充實驗。

1.3 論文架構

本論文共分為五章並附補充實驗附錄，其架構說明如下：

1. **第一章：**說明研究背景與動機、研究目的及論文架構。
2. **第二章：**整理 COPD 臨床背景、胸部 CT 影像分析、肺部結構分割、CT 量化生物標記、三維醫學影像模型與肺功能相關表徵預測之相關研究。
3. **第三章：**說明研究材料與方法，包含影像前處理與肺部結構分割流程、CT 量化生物標記擷取、分類模型建置，以及三維深度學習模型與評估策略。
4. **第四章：**呈現實驗結果，逐一比較 FCNN、Hybrid Mamba-Attention 與 TAP-CT late fusion 三種方法於 Normal/Abnormal 分類、塌陷角三分類／二分類／迴歸與 OI 二分類之表現，並討論各任務效能與限制；GOLD 四分級分類則列於附錄作為補充實驗。
5. **第五章：**總結本研究結果，並提出後續於資料擴充、分割品質改善、模型泛化驗證與臨床應用評估之未來方向。
6. **附錄：**補充實驗，呈現 GOLD 四分級分類之結果與其樣本不平衡限制。

第二章 背景與文獻回顧

2.1 慢性阻塞性肺病與肺功能檢查

慢性阻塞性肺病（COPD）是一種常見且具有異質性的慢性呼吸道疾病，其核心特徵為持續性呼吸道症狀與氣流受限。COPD 的病理變化通常涉及小氣道發炎與重塑、氣道狹窄、肺實質破壞、肺氣腫與氣體滯留等現象，因此病患可能出現慢性咳嗽、咳痰、活動性喘促與運動耐受度下降等臨床表現。由於 COPD 之疾病進展具有長期性，且肺功能下降後不易完全恢復，臨床上需透過客觀檢查評估氣流受限程度與疾病嚴重度 [1]。

肺功能檢查（Pulmonary Function Test, PFT）是 COPD 診斷與嚴重程度評估中最重要之生理測量工具，其中又以肺量計測定（spirometry）最常用。肺量計測定可量測用力肺活量（Forced Vital Capacity, FVC）、一秒用力呼氣容積（Forced Expiratory Volume in one second, FEV1）與 FEV1/FVC 比值。FVC 代表受測者深吸氣後以最大力量呼出的總氣體量；FEV1 則代表用力呼氣第一秒內排出的氣體量；FEV1/FVC 比值可反映第一秒呼出量相對於總用力肺活量的比例，因此常用於判斷是否存在氣流受限。依 GOLD 指引，支氣管擴張劑後 FEV1/FVC 小於 0.70 為確認持續性氣流受限的重要判準之一。除上述核心指標外，肺功能檢查亦可包含中段用力呼氣流速（FEF25–75%）、肺總量（TLC）與肺餘容積（RV）等，用以描述小氣道功能與氣體滯留情形 [1]。

GOLD 指引以固定比值準則作為 COPD 之判定前提：支氣管擴張劑後 FEV1/FVC 小於 0.70 始確認為持續性氣流受限，若 FEV1/FVC 大於或等於 0.70 則不符合此氣流受限判準。在已確認氣流受限的情況下，GOLD 分級再依支氣管擴張劑後 FEV1 佔預測值百分比（FEV1 percent predicted）區分氣流受限嚴重程度。FEV1 預測值會依年齡、身高、性別等生理條件估計，再以實測 FEV1 除以預測值取得百分比。GOLD 1 為 FEV1 大於或等於 80% 預測值，代表輕度氣流受限；GOLD 2 為 50% 至未滿 80%，代表中度氣流受限；GOLD 3 為 30% 至未滿 50%，代表重度氣流受限；GOLD 4 則為低於 30%，代表極重度氣流受限 [1]。此分級方式可將連續的肺功能數值轉換為具臨床意義的嚴重度類別，因此常作為 COPD 相關研究中的標籤依據。

值得注意的是，GOLD 嚴重度分級在研究文獻中常依 FEV1 預測值百分比建立分類

標籤；然而正式臨床診斷仍需整合 FEV1/FVC 判準、症狀與病史，因此以 FEV1 衍生之 GOLD 分類在研究情境中通常被視為肺功能導向的嚴重度候選標籤，而非完整臨床分期。

然而，肺功能檢查主要反映整體呼吸生理狀態，較難直接指出肺部結構異常的位置、型態與分布。同樣的 FEV1 或 GOLD 分級可能對應不同程度的肺氣腫、氣道壁增厚、過度充氣或血管改變，因此單一肺功能指標未必能完整描述 COPD 的影像表型 [2]。基於此限制，結合胸部 CT 影像之量化特徵與三維影像模型，並將 PFT 相關資訊作為參考標籤，可望補充單一肺功能指標難以呈現之 COPD 影像表型，並支援肺功能相關表徵之預測與輔助判讀。

除傳統肺量計數值外，流量容積曲線之幾何表徵亦可反映呼氣過程中的曲線形狀變化。Topalovic 等人以塌陷角度 (Angle of Collapse, AC) 描述曲線凹陷程度，並指出其與肺氣腫表徵具有關聯 [6]。此外，由肺功能檢查亦可衍生阻塞指數 (Obstruction Index, OI) 等指標，用以反映氣道阻塞與肺氣腫傾向。Mochizuki 等人以 OI 量化最大呼氣流量-容積曲線下降段之凹陷程度，其定義為用力肺活量與曲線上尖峰呼氣流量一半處之容積差值之比值，並指出該指標與 CT 上之肺氣腫範圍具有關聯，且此關聯不受 FEV1 影響 [7]。此結果顯示，曲線凹陷程度所攜帶之肺氣腫資訊，未必能由單一肺量計數值完全涵蓋。本研究以固定門檻將 OI 轉換為二分類標籤，作為肺功能導向之衍生標籤之一。相較於直接將個案壓縮為單一正常或異常類別，AC 為連續角度，可保留不同病人之肺功能曲線差異；若再依具解釋意義之角度門檻建立分級標籤，則可進一步觀察連續肺功能表徵轉換為分類任務後對模型學習與結果解讀之影響。因此，AC 可同時作為連續迴歸目標與衍生分類標籤來源，有助於觀察由肺功能表徵預測延伸至輔助分級之分析過程。

2.2 CT 影像表徵與量化生物標記

胸部電腦斷層影像具有高空間解析度，可呈現肺實質、氣道、血管與肺葉分布等解剖結構，因此常被用於補充肺功能檢查無法直接呈現的局部結構資訊。對 COPD 而言，CT 影像中常見的結構性表徵包含肺氣腫造成的低衰減區域、肺過度充氣所反映的肺容積增加、氣道壁增厚或氣道狹窄，以及肺血管床減少或肺動脈相關變化等。這些

影像表徵可對應 COPD 中肺實質破壞、小氣道病變與血管重塑等病理變化，因此 CT 不僅可作為視覺判讀工具，也可作為影像量化分析的資料來源 [8, 2]。

肺氣腫是 COPD 在 CT 影像中最常被量化的表徵之一。肺氣腫區域因肺泡壁破壞與氣腔擴大而呈現較低密度，因此在吸氣相 CT 中常以低衰減區域比例描述其範圍。常見作法是在肺部遮罩內計算低於特定 Hounsfield unit 閾值的 voxel 比例，例如低於 -950 HU 的低衰減區比例可作為肺氣腫負荷之指標。Gevenois 等人比較 HRCT 密度與肺氣腫之病理形態量測後指出，-950 HU 閾值與實際肺氣腫程度具良好對應，因此此閾值常作為定量肺氣腫分析的依據之一 [9]。此類指標可進一步依肺葉計算，以呈現肺氣腫分布是否集中於特定肺葉或呈現不均勻分布。相較於僅以整體肺功能數值描述病患狀態，肺葉別肺氣腫比例能提供更具有位置資訊的影像表型描述。

肺容積與過度充氣亦是 COPD 影像評估中的重要概念。COPD 患者因氣流受限與呼氣不完全，可能產生氣體滯留與肺過度充氣，使總肺體積或特定肺葉體積出現改變。CT 影像若經過肺部或肺葉分割，便可依 voxel spacing 計算實際體積，將肺部形態由視覺印象轉換為可比較的數值。Bakker 等人回顧 quantitative CT 與肺功能檢查之關係時指出，CT 可萃取 residual volume、total lung capacity 等肺容積資訊，且此類 CT-derived lung volume 與 PFT 量測之肺容積具有相關性，特別適合用於描述 COPD 的過度充氣相關表徵 [10]。此類體積特徵雖可能受吸氣程度、體型差異與掃描範圍影響，但仍可作為描述 COPD 影像表徵的重要補充資訊。

除肺實質外，COPD 亦會影響氣道結構。慢性發炎與氣道重塑可能造成氣道壁增厚、氣道腔狹窄與小氣道阻塞。CT 量化分析中常見的氣道相關指標包含氣道壁比例 (wall area percentage, WA%)、氣道體積與肺體積之比例，以及由氣道遮罩推估的相關形態特徵。既有研究指出，WA% 是 COPD 吸菸族群中常用的中央氣道形態量測指標，且與 FEV1 預測值百分比具有相關性；系統性回顧亦顯示 WA%、wall thickness、Pi10 與 luminal area 等 CT 氣道參數已被廣泛用於 COPD 與相關呼吸疾病研究 [11, 12]。理想情況下，WA% 需根據氣道腔與氣道壁的可靠分割結果計算；若缺乏完整的 lumen 與 wall 標註，則只能以可取得之氣道遮罩或氣管標籤進行近似估計。因此，在使用氣道量化指標時，必須同時說明分割來源與計算限制，避免將自動估計結果過度解釋為精確的小氣道壁厚量測。

肺血管變化也是 COPD 影像分析中逐漸受到重視的面向。肺氣腫造成肺泡壁與微

血管床破壞，可能使血管密度下降；另一方面，COPD 亦可能伴隨肺血管重塑與肺動脈壓力相關變化。Matsuoka 等人以 CT 量測小肺血管橫截面積，發現小血管面積比例與肺氣腫比例及肺功能指標相關，顯示肺血管量化可提供肺實質破壞以外的補充資訊 [13]。因此，CT 影像中可由血管分割結果計算總血管體積、血管密度、小血管體積比例 (small vessel volume percentage, SVV%) 與肺動脈直徑等指標。血管密度通常可定義為分割血管體積相對於總肺體積之比例；SVV% 則可透過血管遮罩與距離轉換等方式估計小血管負荷。肺動脈與主動脈直徑比例 (PA:A ratio) 亦常被視為肺血管與肺高壓相關的影像指標；Wells 等人曾以 CT 上肺動脈與主動脈直徑比例大於 1 作為肺動脈擴大指標，並探討其與 COPD 急性惡化之關係 [14]。

綜合而言，CT 量化生物標記可將 COPD 相關影像表徵轉換為客觀且可供模型分析的數值。本研究依據既有 quantitative CT 文獻，選取可描述肺實質破壞、過度充氣、氣道重塑與肺血管變化之特徵。然而，量化結果仍會受到掃描協議、吸氣程度、分割品質與指標定義差異影響，解讀時需保留其限制。

2.3 肺部、氣道與血管影像分割

胸部 CT 影像雖可呈現肺實質、氣道與血管等細部解剖結構，但若未先界定各結構所在區域，影像灰階值與體積資訊便難以轉換為具生理意義的量化特徵。因此，在 COPD 相關 CT 分析中，影像分割通常扮演兩項關鍵角色：其一為建立特徵計算的解剖區域，例如以肺部或肺葉遮罩限定肺氣腫比例與肺容積之計算範圍；其二為提供可解釋的結構標籤，使氣道與血管相關指標能對應至特定病理變化。若分割邊界錯誤、末端管狀結構漏失，或將非目標組織誤判為目標結構，後續低衰減區比例、血管密度、小血管體積比例與氣道相關特徵皆可能受到影響。因此，影像分割並非單純的前處理程序，而是 quantitative CT 分析可信度的重要基礎。

深度學習已成為醫學影像分割的重要方法。Litjens 等人回顧深度學習於醫學影像分析之應用時指出，卷積神經網路已廣泛應用於影像分類、偵測與分割等任務 [3]。其中，U-Net 透過 encoder-decoder 結構與 skip connection 保留局部空間資訊，奠定了許多生物醫學影像分割模型的基礎 [15]。針對三維醫學影像分割，nnU-Net 進一步提出自動化設定策略，依資料特性調整前處理、網路架構與訓練流程，降低不同任務間人工調

參的需求 [16]。在研究與實作工具方面，3D Slicer 可支援醫學影像讀取、分割、三維視覺化與量測 [17]；MONAI 則提供以 PyTorch 為基礎的醫學影像深度學習框架，整合資料轉換、模型訓練與推論流程 [18]。

肺部與肺葉分割是 COPD 量化 CT 分析中最基礎的結構分割任務。Hofmanninger 等人針對例行性胸部影像之肺部分割進行研究，指出模型表現高度受到資料多樣性影響，臨床應用時需面對不同掃描協議、疾病型態與影像品質所造成的變異 [19]。TotalSegmentator 則建立可分割多種 CT 解剖結構的自動化工具，顯示多器官與多結構 label map 已逐漸成為 CT 影像量化研究的重要基礎 [20]。針對肺氣腫量化，Li 等人提出 EmphysemaSeg，結合自動肺葉分割與肺氣腫評估，用於低劑量肺癌篩檢 CT 中的肺葉別肺氣腫量化 [21]。上述研究說明，肺部與肺葉分割不僅用於排除非肺部組織，也會直接影響肺氣腫比例、肺葉體積與疾病分布型態之估計。

氣道分割相較於肺部遮罩更具挑戰性，原因在於氣道樹具有細長、多分支、末端管徑小且與肺血管相鄰等特性，分割時容易出現末端分支中斷、管腔漏失或誤判其他低密度結構等問題。Garcia-Uceda 等人提出以 3D convolutional neural networks 為基礎的自動氣道分割方法，並在胸部 CT 資料中驗證其對氣道樹萃取的可行性 [22]。AeroPath 則建立含有肺氣腫、腫瘤等病理變化之氣道分割 benchmark，強調胸部病理變化會增加氣道分割困難度，並提供評估模型於複雜臨床影像中穩健性的資料與基準方法 [23]。因此，氣道分割品質將直接影響 airway-derived features 之可信度。

血管分割則與 COPD 影像中肺血管床減少、小血管比例改變與肺動脈相關指標有關。Matsuoka 等人以 CT 量測小肺血管橫截面積，顯示小血管量化與肺氣腫比例及氣流受限具有關聯 [13]。在自動分割方法上，肺血管與氣道皆屬細長管狀結構，相對於背景 voxel 數量極少，容易形成類別不平衡與末端分支漏失問題。Qin 等人提出 tubule-sensitive CNN，用於肺部氣道與肺動靜脈分割，並針對管狀結構在 CT 中比例小、形態細長與分支複雜等問題設計模型策略 [24]。因此，血管密度、SVV% 與肺動脈相關指標雖可提供 COPD 血管表型資訊，但其可靠性仍取決於血管分割對主幹血管與末端小血管的偵測能力。

綜合上述文獻，不同分割工具之標籤定義、輸出格式與適用情境並不完全一致。肺部與肺葉分割主要影響肺容積與肺氣腫比例，氣道與血管分割則影響相應之結構量化結果；不同來源之分割輸出不宜視為完全等價。

2.4 三維醫學影像深度學習模型

胸部 CT 屬於三維體積影像，其資訊不僅存在於單一切面，也包含切片之間的連續解剖關係。COPD 相關影像表徵亦具三維分布特性，例如肺氣腫之肺葉或區域性分布，以及氣道與血管沿肺內空間形成之分支結構。因此，僅以二維切片分析易忽略跨切片的空間連續性；三維深度學習模型則可直接以 CT volume 為輸入，學習局部紋理、區域分布與全肺形態等特徵。

早期三維醫學影像深度學習多以 3D convolutional neural networks (3D CNN) 為基礎，可於深度、高度與寬度三個方向同時萃取局部特徵。Park 等人以 inflated 3D CNN 由低劑量胸部 CT 預測 FVC 與 FEV1，並據以判斷高風險族群 [4]；BeyondCT 則結合 3D CNN、Vision Transformer 與人口統計資料預測 FVC 與 FEV1，反映以 CNN 擷取局部特徵、再以 Transformer 捕捉全域關係之發展趨勢 [25]。此類研究顯示，三維 CT 模型除可輸出疾病類別外，亦能以迴歸方式估計連續肺功能指標。

Transformer 透過 self-attention 建立元素間關係，Vision Transformer 進一步將影像切分為 patch token 後套用此機制 [26]；Wu 等人即以其進行 CT 肺氣腫亞型分類 [27]。然而標準 self-attention 之計算量隨 token 數量平方成長，直接用於高解析三維 CT 成本過高。Swin Transformer 改以 shifted window attention 建立階層式特徵，在降低運算量的同時保留多尺度資訊 [28]。

2.4.1 Mamba

state space model (SSM) 與 Mamba 近年開始被引入醫學影像分析。Mamba 以 selective state space mechanism 建立長序列建模能力，且序列長度複雜度接近線性，適合處理 token 數量龐大的三維體積資料 [29]。在醫學影像領域，nnMamba 結合 CNN 之局部表示與 SSM 之長距離建模，應用於三維分割、分類與 landmark detection [30]；SegMamba 針對三維醫學影像分割設計 Mamba 架構以提升 whole-volume 建模效率 [31]；MedMamba 則將 Vision Mamba 應用於多種醫學影像分類 [32]。

Mamba 的核心為具選擇機制的狀態空間模型 (selective state space model)，其運作概念如圖 2.1 所示。狀態空間模型以隱藏狀態描述序列演化：將前一時刻狀態 h_{t-1} 與當

前輸入 x_t 經狀態轉移矩陣 A 與輸入矩陣 B_t 更新為 h_t ，再由輸出矩陣 C_t 映射為輸出 y_t 。連續形式之狀態方程須先離散化，模型以步長參數 Δ_t 控制此過程，使狀態得以沿序列遞迴計算。

傳統狀態空間模型參數固定，難以依內容選擇性保留或遺忘資訊。Mamba 的關鍵改良在於選擇機制（selection mechanism）：如圖 2.1 下方所示， B_t 、 C_t 與 Δ_t 改由輸入 x_t 動態生成，使模型可依當前內容調整狀態更新強度，選擇性關注序列中具資訊量的片段；並採硬體感知（hardware-aware）計算設計以減少記憶體讀寫成本。相較於 self-attention 隨 token 數量呈平方成長的複雜度，Mamba 對序列長度接近線性，特別適合 token 數量龐大的三維 CT，可在保留長距離建模能力的同時降低運算負擔。

資料來源：Gu 與 Dao[29]




圖 2.1: 具選擇機制之狀態空間模型架構

整體而言，三維醫學影像模型的發展可視為由局部特徵萃取走向局部與全域表徵整合：3D CNN 擅長局部紋理，Transformer 與 Swin 類模型強調跨區域多尺度關係，Mamba 類模型則在保留長距離建模的同時降低高維資料之運算負擔。對 COPD 輔助診斷而言，這些模型可作為第 2.2 節量化生物標記之外的補充途徑，直接由 CT volume 學習與肺功能、肺氣腫分布或疾病嚴重程度相關之隱含特徵。惟三維深度模型需較多資料與嚴謹驗證，於小樣本情境易受掃描協議差異、標籤雜訊與類別不平衡影響，故仍須搭配資料增強、交叉驗證與多指標評估。

2.5 TAP-CT 預訓練影像表徵

近年醫學影像深度學習除針對單一任務訓練模型外，亦逐漸重視由大量未標註或弱標註影像建立可轉移之預訓練表徵。此類 foundation model 期望先由大規模資料學得一般性影像結構，再於下游任務中透過 feature extraction、輕量分類頭或有限微調降低標註資料不足造成的限制。對 CT 影像而言，若預訓練模型僅沿用二維自然影像設定，可能難以完整描述切片間之體積關係；因此，如何建立可處理三維 CT volume 的通用表徵，已成為 CT foundation model 發展的重要方向。

Veenboer 等人提出之 TAP-CT (Task-Agnostic Pretraining of Computed Tomography) 即以 CT 體積影像之通用預訓練為核心。該研究將 Vision Transformer 與 DINOv2 類自監督學習概念延伸至 volumetric CT，並針對三維 patch embedding、位置編碼與體積式資料增強進行調整，使模型可由 CT volume 建立具深度資訊之影像表示。其預訓練資料涵蓋大量 CT volumes，研究結果指出 TAP-CT 可在下游任務中提供穩定之 frozen representation，作為低資源情境下除完整 end-to-end fine-tuning 以外的特徵來源 [33]。

TAP-CT 對本研究所關注之小樣本胸部 CT 任務具有兩項參考意義。首先，COPD 相關影像表徵同時包含肺實質低衰減區、肺部空間分布與氣道血管周邊結構，若僅依本研究有限資料自訓練影像編碼器，模型可學得之表徵可能受資料量與標籤分布限制；預訓練 CT embedding 則提供另一種由大量 CT 影像學得之表示來源。其次，TAP-CT 之 frozen representation 可與任務導向模型輸出形成互補比較：前者強調通用 CT 表徵之可轉移性，後者則針對本研究之塌陷角與肺功能相關標籤調整特徵。因此，於下游任務中可檢視預訓練 embedding 與三維影像模型特徵融合後是否提供額外效益。

然而，TAP-CT 屬於通用 CT 預訓練模型，並非專為 COPD、肺功能檢查或塌陷角標籤建立之疾病特異模型。其 embedding 是否能保留與呼氣流量容積曲線、GOLD 分級或 Normal/Abnormal 判讀相關之訊息，仍需依實際資料與下游任務驗證。基於此，本研究將 TAP-CT 視為三維 CT 深度學習分支中的預訓練表徵補充來源，而非取代可解釋 CT 量化生物標記或任務導向三維模型之唯一方法。

第三章 研究方法

3.1 研究流程

本研究以胸部電腦斷層影像為主要輸入，建立 COPD 輔助診斷與肺功能相關表徵預測流程。原始胸部 CT 影像先由 DICOM 轉換為 NIfTI volume，再依實驗目的進入兩條分支：

1. **CT 量化生物標記分析分支：**強調影像特徵之可解釋性。轉換後之 CT 影像先經肺部、肺葉、血管與氣道相關分割流程產生 label map，再依各結構遮罩計算肺氣腫比例、肺容積、血管密度、小血管體積比例、氣道相關比例與肺動脈等效直徑等數值特徵；上述分割與量化流程詳見第 3.4 節。所得特徵可對應肺實質、血管與氣道結構變化，本研究將其視為 CT 量化生物標記，並以全連接神經網路作為量化生物標記模型，於各研究問題任務（Normal/Abnormal 二分類、塌陷角三分類、塌陷角二分類、塌陷角迴歸與 OI 二分類）進行分類或迴歸，模型架構詳見第 3.5 節。本分支之整體流程概覽如圖 3.1 所示。
2. **三維 CT 深度學習模型分析分支：**保留完整三維影像輸入，不先將 CT volume 壓縮為人工定義特徵。NIfTI 影像經尺寸統一、強度正規化與資料增強（詳見第 3.9 節）後輸入三維模型；三維編碼器架構（Hybrid Mamba-Attention）詳見第 3.6 節，其與預訓練胸部 CT 嵌入之 TAP-CT 融合策略詳見第 3.8 節。本研究於各研究問題任務中比較三種方法：上述量化生物標記模型、僅使用 CT 影像之 Hybrid Mamba-Attention，以及結合凍結 TAP-CT 嵌入之 TAP-CT late fusion；三種方法皆於 Normal/Abnormal 二分類、塌陷角三分類、塌陷角二分類、塌陷角連續值迴歸與 OI 二分類共同評估。GOLD 分級分類則另作為補充實驗。其中 TAP-CT late fusion 模型之整體流程概覽如圖 3.2 所示。




圖 3.1: 電腦斷層影像量化生物標記分類流程概覽（分割與量化見 3.4 節、分類器見 3.5 節）




圖 3.2: TAP-CT late fusion 模型流程概覽（資料增強見 3.9 節、影像編碼器見 3.6 節、融合策略見 3.8 節）

3.2 資料集

本研究資料由振興醫院提供，包含病人胸部 CT 的 DICOM 影像及肺功能檢查 (PFT)。本研究業經振興醫院人體試驗委員會 (Institutional Review Board, IRB) 審查通過，計畫名稱為「胸部 CT 影像應用於 COPD 輔助診斷之人工智慧研究」，核准編號為 CHGH-IRB (1240)115-22。

為使三種方法之比較公平，本研究以同一份 66 例病人作為標準資料集，三個研究問題之三種方法皆於此 66 例上訓練與評估，各例皆可與 PFT 資料對應。全部 66 例之 Normal/Abnormal 標籤為 Normal 33 例、Abnormal 33 例，其二元標籤由合作醫師依 ATS/ERS 肺功能判讀標準判定 [34]；Abnormal 組對應臨床判定之 COPD 個案。

PFT 資料另用於整理塌陷角度 (AC) 與阻塞指數 (OI) 等肺功能導向標籤。塌陷角度係由肺功能檢查之呼氣流量容積曲線萃取的幾何指標；參考 Topalovic 等人提出之 AC 與肺氣腫關係，本研究採用 131° 與 152° 作為角度分級門檻 [6]。OI 為由肺功能檢查衍生之阻塞指數，用以描述最大呼氣流量-容積曲線下降段之凹陷程度，其定義為用力肺活量與曲線上尖峰呼氣流量一半處之容積差值之比值；Mochizuki 等人指出該指標可反映 CT 上之肺氣腫範圍 [7]。本研究以門檻 $OI=3$ 建立二分類標籤：以 $OI \geq 3$ 為正類、 $OI < 3$ 為負類；66 例中 $OI < 3$ 者 32 例、 $OI \geq 3$ 者 34 例。此門檻係依本研究資料之分布選定，使兩類樣本數接近平衡，與該文獻所報告之最佳切點並不相同。

本研究 66 例資料之病人年齡與性別分布如圖 3.3 所示。病人年齡以 60–69 歲區間人數最多，整體呈現中高齡為主之分布，與 COPD 好發於中高齡族群之臨床特性一致。

AC 三分類任務將影像依肺功能曲線衍生角度分為三類： $AC \leq 131^\circ$ 為 AC 低值組， $131^\circ < AC < 152^\circ$ 為 AC 中間組， $AC \geq 152^\circ$ 為 AC 高值組。66 例資料中，三類樣本數分別為 14、5 與 47 例。上述 AC 類別為肺功能曲線衍生標籤，不等同於臨床 Normal/Abnormal 二元標籤。由於 AC 中間組樣本數較少，且其肺功能曲線特徵介於兩端之間、較不明確，本研究另設計 AC 二分類任務，排除 $131^\circ < AC < 152^\circ$ 之 5 例，只保留 $AC \leq 131^\circ$ 與 $AC \geq 152^\circ$ 兩端較明確之 61 例資料。

GOLD 標籤僅用於補充實驗（見附錄 A），依 GOLD 2025 固定比值準則整理 [1]：以支氣管擴張劑後 FEV_1/FVC 低於 70% 作為 COPD 判定條件，再依支氣管擴張劑後 $FEV_1\%$ 預測值分為 GOLD 1（輕度， $FEV_1\% \geq 80\%$ ）、GOLD 2（中度，




圖 3.3: 資料集病人年齡與性別分布

50% $\leq$ FEV₁% < 80%)、GOLD 3 (重度, 30% $\leq$ FEV₁% < 50%) 與 GOLD 4 (極重度, FEV₁% < 30%)。66 例資料中, 支氣管擴張劑後 FEV₁/FVC $\geq$ 70% 者歸為 Class 0 (沒有 COPD, 34 例), GOLD 1 至 4 各有 2、11、13 與 6 例, 合計 32 例。GOLD 分級分類任務排除 Class 0, 僅以此 32 例進行四分類訓練與評估。

3.3 資料前處理

本研究之前處理目的在於將原始 DICOM 影像與 PFT 資料整理為後續分割、量化參數擷取與標籤建立可使用之格式。由於量化分析仰賴 HU 閾值與實際 voxel spacing, 轉換流程需保留影像強度與空間資訊, 避免影響後續體積與低衰減區比例計算。

原始胸部 CT 以 DICOM series 形式儲存。同一病人可能具有多組掃描序列或重建影像, 因此本研究先依 SeriesInstanceUID 與 DICOM metadata 將影像分組, 再排除 scout、snapshot、冠狀面或矢狀面重建影像, 以及不適合肺部分析之非目標序列。若同一病人具有多個可用胸部 CT series, 則優先選擇適合肺部結構分析之軸向胸部或肺窗序列。完成序列選擇後, 依 ImagePositionPatient 對切片排序, 並利用 ImageOrientationPatient、PixelSpacing 與 SliceThickness 等欄位建立三維空間方向與 voxel spacing。

CT 強度值轉換依據 DICOM 中之 RescaleSlope 與 RescaleIntercept 進行。對每個原始儲存像素值 P , 其對應之 HU 值依 DICOM 標準之 modality LUT 以線性轉換計算 [35], 如式 (3.1) 所示:

$$HU = P \times \text{RescaleSlope} + \text{RescaleIntercept} \quad (3.1)$$

其中 RescaleSlope (DICOM tag 0028,1053) 與 RescaleIntercept (0028,1052) 由掃描儀於影像 metadata 中記錄；胸部 CT 常見設定為 RescaleSlope 等於 1、RescaleIntercept 等於 -1024，使空氣對應約 -1000 HU、水對應約 0 HU。透過此轉換可使影像強度與原始掃描條件保持一致。此步驟對本研究特別重要，因為後續量化分析高度依賴影像強度的正確性；若未正確轉換 HU，相關影像表徵與量化結果皆可能產生系統性偏差。轉換後之影像以 NIfTI 格式儲存，並保留必要之空間與強度資訊，以支援後續分析流程。

PFT 資料則以病人為單位與 CT volume 對應，用於建立 Normal/Abnormal 二元標籤、FEV1 預測值百分比相關分級，以及塌陷角度 (AC) 與阻塞指數 (OI) 等肺功能導向標籤。

3.4 肺部結構分割與量化參數擷取

本研究以 NIfTI volume 為輸入，透過 3D Slicer 結合 MONAI Auto3DSeg 產生多類別 label map [17, 18]。Label 1 至 5 對應五個肺葉並合併為總肺遮罩，label 6 至 9 對應血管、氣管、肺靜脈系統與肺動脈。氣道結構另以 AeroPath 分割結果補充 [23]，若 airway mask 可取得則優先採用，否則以 label map 中之氣管標籤近似。分割後確認各主要結構 label 非空且 voxel 數合理，再進行特徵計算。分割結果範例如圖 3.4 所示。

肺氣腫比例定義為遮罩內 $HU < -950$ 之 voxel 占比 (%)，分別計算於總肺與各肺葉遮罩，此閾值為 CT 肺氣腫定量分析之常用標準 [9]。血管密度、小血管體積比例 (SVV%)、氣道壁比例 (WA%) 與氣道肺體積比例均以對應結構體積除以總肺體積表示。SVV% 可反映 COPD 中小血管床減少之影像表徵 [13]。肺動脈等效直徑由肺動脈 label 之體積以等效球體公式反推：

$$d_{PA} = 2 \left(\frac{3V_{PA}}{4\pi} \right)^{1/3} \quad (3.2)$$

其中 V_{PA} 為肺動脈 label 體積 (mm^3)， d_{PA} 為等效直徑 (mm)。此指標之性質須特




圖 3.4: 3D Slicer 肺部結構分割結果範例。左上為軸向切面、右上為三維立體檢視、左下為冠狀切面、右下為矢狀切面，各顏色區塊對應不同肺葉及血管結構之分割遮罩。


別說明：其一，該值由分割體積換算而來，並非臨床影像上對肺動脈主幹之直接口徑量測，亦不等同於文獻中以主幹直徑或肺動脈／主動脈直徑比（PA:A ratio）定義之臨床指標 [14]；其二，本研究之肺動脈 label 涵蓋分割所得之肺動脈結構整體而非僅主幹，且肺動脈實為分支管狀結構而非球體，故等效球體換算所得之數值同時受血管口徑與 label 涵蓋範圍影響。因此 d_{PA} 宜視為肺動脈 label 體積之單調轉換，用以描述個案間肺動脈結構量之相對差異，不應以臨床主幹直徑之正常值（約 24–29 mm）加以解讀。

本研究最終輸出下列 12 項量化特徵：

1. **全肺肺氣腫比例** (Total_Empysema_Percent)：五葉合併總肺遮罩內 HU < -950 之 voxel 占比 (%)。
2. **左上葉肺氣腫比例** (Left_Superior_Lobe_Empysema)：左上葉遮罩內 HU < -950 之 voxel 占比 (%)。
3. **左下葉肺氣腫比例** (Left_Inferior_Lobe_Empysema)：左下葉遮罩內 HU < -950 之 voxel 占比 (%)。
4. **右上葉肺氣腫比例** (Right_Superior_Lobe_Empysema)：右上葉遮罩內 HU < -950 之 voxel 占比 (%)。
5. **右中葉肺氣腫比例** (Right_Middle_Lobe_Empysema)：右中葉遮罩內 HU < -950 之 voxel 占比 (%)。
6. **右下葉肺氣腫比例** (Right_Inferior_Lobe_Empysema)：右下葉遮罩內 HU < -950 之 voxel 占比 (%)。
7. **小血管體積比例** (SVV_Percent)：以 distance transform 估計直徑小於 5 mm 之血管體積後除以總肺體積 (%)。
8. **氣道壁比例** (WA_Percent)：氣道壁體積占氣道總體積（壁加內腔）之比例，反映氣道壁相對厚度 (%)。
9. **血管密度** (Vessel_Density_Percent)：分割血管體積除以總肺體積 (%)。
10. **氣道肺體積比例** (Airway_Lung_Ratio_Percent)：氣道體積除以總肺體積 (%)。

11. **總肺體積** (Total_Lung_Volume_ml)：五個肺葉體積加總，單位 mL。
12. **肺動脈等效直徑** (PA_Diameter_mm)：由肺動脈 label 體積依式 (3.2) 換算之等效球體直徑，單位 mm；其涵蓋範圍與解讀限制見前述說明。

肺氣腫比例、血管與氣道比例以百分比表示，肺體積與肺動脈等效直徑保留物理單位，供後續模型標準化與分類使用。



3.5 量化生物標記模型




圖 3.5: 全連接神經網路分類器架構

量化生物標記模型（FCNN）以第 3.4 節所述之 12 項 CT 量化特徵作為輸入，並作為三方法比較中的基準，於各研究問題任務中進行分類或迴歸：Normal/Abnormal 二分類、塌陷角三分類、塌陷角二分類與 OI 二分類採用分類頭，塌陷角連續值迴歸則改用單一輸出之迴歸頭。相較於三維 CT 模型，此分支輸入維度低，且各特徵對應明確的肺部結構變化，在本研究 66 例小樣本條件下具有較好的可解釋性。

由於各特徵單位與尺度不同，模型訓練前僅以 training fold 資料估計各特徵之均值與標準差進行 StandardScaler（z-score）標準化，避免驗證資料洩漏至標準化參數估計。

模型採用全連接神經網路，其架構如圖 3.5 所示。模型以 12 維量化特徵作為輸入，經由三層 hidden layers 擷取特徵組合關係，最後依任務輸出各類別 logits 或連續預測值。

模型訓練設定與驗證方式如下：

- **輸入：**第 3.4 節所列 12 項量化特徵（已以每折 StandardScaler 標準化）。
- **模型架構：**主幹維度為 $12 \rightarrow 64 \rightarrow 32 \rightarrow 16$ ，各 hidden layer 後接 batch normalization、ReLU activation 與 dropout；輸出頭依任務為對應類別數之 logits（分類）或單一輸出（塌陷角迴歸）。

- **訓練目標**：分類任務採用 class-weighted cross entropy 以因應類別不平衡，塌陷角迴歸採用 smooth L1 loss。FCNN 不使用影像增強。
- **最佳化與訓練設定**：Optimizer 採用 Adam，learning rate 為 0.001；batch size 設為 16，固定訓練 100 epochs，並關閉 early stopping，改以最終 epoch 之模型評估，避免以驗證折選取停止點造成之樂觀偏差。
- **驗證方式**：採用病人層級分層五折交叉驗證，隨機種子固定為 42，每折獨立估計標準化參數並重新訓練，合併五折驗證預測計算整體效能。

3.6 三維 CT 網路架構設計




圖 3.6: 混合式 Mamba 注意力影像編碼器架構

三維 CT 影像模型直接由完整 CT volume 學習肺部空間表徵，補足量化生物標記僅能描述預先定義特徵的限制。模型由影像編碼器、pooling 與 MLP prediction head 組成，編碼器輸出經 pooling 彙整為固定維度特徵向量，再依任務輸出迴歸值或分類分數。本研究之三維影像編碼器採用 Hybrid Mamba-Attention 架構：以 Gong 等人提出之 nnMamba 分類編碼器 [30] 為主幹，其以三維 convolution stem 擷取局部特徵後，將特徵圖展平為空間 token sequence，透過數個 residual Mamba block 建立跨切片與跨區域的長程依賴關係；各 residual block 內含通道注意力縮放，Mamba block 則採用 Gu 與 Dao 提出之選擇性狀態空間模型（selective state space model）[29]。在此基礎上，本研究於最深層特徵之空間 token 上加入一層標準多頭自注意力（multi-head self-attention）模組 [36] 作為 global attention bridge，使模型在保留 Mamba 三維長程建模能力的同時，額外整合全域空間關係，並將原 nnMamba 分類頭替換為單一輸出之迴歸／分類 prediction head。

Hybrid Mamba-Attention 影像編碼器之細部架構如圖 3.6 所示。模型先以三維卷積建立局部低階特徵，再依序通過三個 Mamba stage 擷取不同解析度下之空間表徵；各階段輸出經 adaptive average pooling 彙整後進行逐層融合，最後結合 attention block 輸出之深層特徵形成 352 維三維影像表示。此設計使模型同時保留早期局部紋理、中階空間結構與深層全域關係，作為後續迴歸或 prediction head 之輸入。

損失函數依任務類型選定：Normal/Abnormal 二元分類採用 binary cross entropy with logits loss；AC 三分類與 AC 二分類採用 cross entropy loss；GOLD 分級因類別嚴重不平衡，改採 Lin 等人提出之 focal loss[37] 以降低多數類別主導訓練之影響。

Hybrid Mamba-Attention 編碼器之架構超參數如表 3.1 所示，其以三維卷積與 Mamba 骨幹為主體，並於最深層加入多頭注意力橋接模組。

三維 CT 模型之訓練設定如下：以 AdamW 最佳化器（learning rate 1×10^{-4} 、weight decay 1×10^{-3} ）搭配 ReduceLROnPlateau 學習率調整（factor 0.5、patience 2），並採用混合精度（AMP）與梯度裁剪（1.0）以穩定小樣本訓練。batch size 設為 12，各任務固定訓練 100 epochs 並關閉 early stopping，以最終 epoch 之模型評估，避免以測試折選取停止點造成之樂觀偏差。輸入影像統一為 $112 \times 136 \times 112$ 、強度窗為 $[-1000, 400]$ HU，迴歸目標以每折 z-score 標準化，並以病人層級分層五折交叉驗證評估，隨機種子固定為 42。

表 3.1: 三維 CT 編碼器架構超參數

Model	Hyperparameter	Value
Hybrid Mamba-Attention	In-channels	1
	Base channels	32
	Mamba blocks	3
	Hidden dim	128
	Dropout	0.3
	Attention heads	8
	Attention layers	1
	MLP ratio	2.0
	Attention dropout	0.1

3.7 塌陷角迴歸任務

本節實驗以塌陷角（AC）作為連續迴歸目標（對應 RQ2c），並沿用三方法比較架構：FCNN 輸入 12 維定量特徵，Hybrid Mamba-Attention 與 TAP-CT late fusion 則輸入 CT volume，各以單一輸出之 prediction head 迴歸病人之連續角度值。其中 Hybrid Mamba-Attention 為僅使用影像特徵之深度模型，TAP-CT late fusion 則額外串接凍結之 TAP-CT 特徵（見第 3.8 節），以評估融合預訓練 CT 表徵對連續角度預測之效益。

標籤標準化依每折訓練資料的均值與標準差進行，深度模型學習標準化後的角度，驗證時再還原為原始單位計算誤差，避免驗證資料洩漏至標準化參數估計。訓練採用 smooth L1 loss 以降低極端誤差的影響。迴歸表現以 MAE、RMSE、決定係數 R^2 與 Pearson 相關係數評估，各指標之定義與計算方式（含合併計算之說明）見第 3.11 節。

3.8 TAP-CT 影像嵌入與融合策略

TAP-CT 為針對三維 CT 預訓練的影像編碼模型，可將 CT volume 轉換為固定維度的特徵向量 [33]。其預訓練模型提供數種變體，命名依骨幹規模（Base、Small）與輸入形式（3D 直接處理三維體積，2.5D 以切片堆疊近似三維資訊）區分：Base 三維變體（B-3D）輸出 2304 維特徵，Small 之三維與 2.5D 變體（S-3D、S-2.5D）則輸出 1152 維特徵。

由於本研究樣本數有限，不重新訓練 TAP-CT 權重，而是固定其參數直接擷取特

徵。為避免小樣本下高維特徵增加融合層過擬合風險，並保留塌陷角與肺功能相關之立體結構資訊，本研究於所有 late fusion 任務統一採用 TAP-CT-S-3D (1152 維)；若單一 CT 被切成多段處理，則先整合同一病人的多段特徵再輸入後續模型。為求行文簡潔，後續章節一律以「TAP-CT」統稱此變體，文中之「TAP-CT late fusion」即指採用凍結 TAP-CT-S-3D 特徵之融合模型。

TAP-CT 特徵以 late fusion 方式用於各研究問題任務：將 Hybrid Mamba-Attention 從原始 CT 產生的特徵與凍結之 TAP-CT 特徵串接後，輸入 MLP 預測頭（迴歸為單一輸出，分類則為類別數輸出），評估融合預訓練 CT 表徵後之效果。

上述 late fusion 於 Normal/Abnormal 二分類、塌陷角三分類、塌陷角二分類、塌陷角迴歸與 OI 二分類（以及補充實驗之 GOLD 分級）各任務均採用相同之 TAP-CT-S-3D 特徵與相同融合架構，僅預測頭輸出依任務調整；因此後續結果章中各「TAP-CT late fusion」模型之差異僅來自任務設定與損失函數，而非所用之 TAP-CT 變體不同。

融合模型以 Hybrid Mamba-Attention 為影像骨幹，將其特徵與凍結之 TAP-CT 嵌入串接後，經投影層與 MLP 分類頭輸出，相關超參數如表 3.2 所示。其餘最佳化器、學習率調整、固定訓練預算與交叉驗證設定與第 3.6 節所述之三維 CT 模型相同。

表 3.2: TAP-CT late fusion 模型超參數

Hyperparameter	Value
Image backbone	Hybrid Mamba-Attention
Fusion projection dim	128
Fusion dropout	0.1
Fused head hidden dim	256
Head dropout	0.3
Epochs	100
Batch size	12

3.9 交叉驗證、資料增強與平衡取樣

所有實驗以病人為資料切分單位，同一病人的 CT、TAP-CT 特徵與增強樣本只能出現在同一 fold，避免資料洩漏。

- **交叉驗證：**三個研究問題之三種方法皆採病人層級分層五折，以 training fold 估計

標準化參數。塌陷角連續值迴歸依角度分布建立 quantile bins 後分層切分，降低各折角度分布差異。補充實驗之 GOLD 分級亦採五折，但因 GOLD 1 僅有 2 例，允許其驗證樣本跨折重複使用，以確保各折均能涵蓋所有分級類別。

- **三維影像輸入：**所有 CT 體積以 HU 為單位載入後，先以三線性內插重取樣至統一尺寸 $112 \times 136 \times 112$ ，使原始矩陣大小與切片張數（63 至 386 張）不一的影像具有一致的輸入維度。接著依序以 $[-1000, 400]$ HU 窗寬截斷，最後以 z-score 標準化。處理後之張量 ($1 \times 112 \times 136 \times 112$) 即為網路輸入。
- **影像增強：**僅套用於深度模型（Hybrid Mamba-Attention 與 TAP-CT late fusion）之 training fold，FCNN 不使用影像增強。本研究對每筆訓練樣本產生 5 倍增強，變換包含小幅旋轉、平移、縮放、強度縮放、強度平移與高斯雜訊，以擴充小樣本訓練資料之多樣性。
- **類別平衡：**分類任務皆進行類別平衡。深度模型於 training fold 內以增強樣本平衡各類別，FCNN 則以 class-weighted cross entropy 處理類別不平衡；決策一律取 argmax，不另行調整閾值。補充實驗之 GOLD 分級因類別更不平衡，另補至每類 13 筆。

3.10 三方法整合預測

除逐一比較三種方法之表現外，本研究另以 hard voting（多數決）將三種方法之預測整合為單一預測，觀察結合異質特徵來源後是否能收斂各單模型之誤判。此整合僅適用於分類任務，於 Normal/Abnormal 二分類（RQ1）、排除中間組之塌陷角二分類（RQ2b）與 OI 二分類（RQ3）中進行。

具體作法為：每位病人由量化生物標記模型（FCNN）、Hybrid Mamba-Attention 與 TAP-CT late fusion 各就其預測類別投一票，取得票較多之類別為該病人之最終預測。因參與投票之模型數為奇數（三個），每位病人皆可得到明確結論而不會出現平手。

hard voting 不另行訓練模型，亦不使用任何額外參數：其輸入為前述三種方法於病人層級分層五折交叉驗證所得之驗證折預測，各病人之票數僅由三模型對該病人之預測決定，故整合結果與各單模型沿用相同之資料切分與驗證協定。整合後之預測以與

各單模型相同之 accuracy、sensitivity 與 specificity 評估（定義見第 3.11 節），以與單模型之表現直接對照。

3.11 評估指標

本研究依任務類型選擇評估指標。Normal/Abnormal 二元分類以 accuracy、sensitivity 與 specificity 評估，各指標定義如方程式 (3.3)[5]。其中 Abnormal 為陽性類別（對應 COPD 個案）。

$$\begin{aligned} \text{Accuracy} &= \frac{TP + TN}{TP + TN + FP + FN} \\ \text{Sensitivity} &= \text{Recall} = \frac{TP}{TP + FN} \\ \text{Specificity} &= \frac{TN}{TN + FP} \end{aligned} \quad (3.3)$$

AC 二分類沿用上述二元分類指標，以 AC 低值組為陽性類別。AC 三分類存在類別不平衡，整體 accuracy 易受多數類別主導，故除 accuracy 外，另以 one-vs-rest 方式將各類別依序視為陽性、其餘類別視為陰性，分別計算 sensitivity 與 specificity 後取各類別之算術平均（macro 平均）作為該任務之 sensitivity 與 specificity。依方程式 (3.3) 之定義，macro 平均之 sensitivity 即各類別 recall 之平均，其數值等同 balanced accuracy。補充實驗之 GOLD 分級因類別更不平衡，另報告 macro precision、macro recall、macro-F1 與 balanced accuracy，相關定義見附錄 A。

對於連續 AC 迴歸任務，本研究以 mean absolute error (MAE)、root mean squared error (RMSE)、coefficient of determination (R^2) 與 Pearson correlation coefficient 評估預測值與真實角度之差異及相關程度。設真實值為 y_i ，預測值為 $\hat{y}_i$ ，其平均值分別為 $\bar{y}$ 與 $\bar{\hat{y}}$ ，則各項指標定義如方程式 (3.4)：

$$\begin{aligned}
\text{MAE} &= \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i|, \\
\text{RMSE} &= \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2}, \\
R^2 &= 1 - \frac{\sum_{i=1}^N (y_i - \hat{y}_i)^2}{\sum_{i=1}^N (y_i - \bar{y})^2}, \\
\text{Pearson} &= \frac{\sum_{i=1}^N (y_i - \bar{y}) (\hat{y}_i - \bar{\hat{y}})}{\sqrt{\sum_{i=1}^N (y_i - \bar{y})^2} \sqrt{\sum_{i=1}^N (\hat{y}_i - \bar{\hat{y}})^2}}.
\end{aligned} \tag{3.4}$$

MAE 與 RMSE 衡量預測誤差大小，其中 RMSE 對極端誤差較敏感； R^2 描述模型對角度變異的解釋程度；Pearson coefficient 則反映預測值與真實值的線性相關強度。

本研究之迴歸指標採合併計算，即先合併五折全體驗證預測，再一次計算 MAE、RMSE、 R^2 與 Pearson，而非逐折計算後取平均。此作法使 R^2 之總變異（總平方和 SST）在全體樣本上唯一定義，可避免各折僅約 13 例時，逐折 R^2 因以各折局部變異正規化而極不穩定，並確保 RMSE 與 R^2 對誤差平方和維持單調一致的排序關係。

第四章 實驗結果

4.1 研究問題

本章以三個研究問題（Research Questions, RQs）彙整實驗結果。三個 RQ 共用同一份 66 例病人與相同之資料切分與驗證協定，並在每個任務中比較三種方法：以 12 項 CT 量化生物標記為輸入之量化生物標記模型（FCNN）、僅使用 CT 影像之 Hybrid Mamba-Attention 影像模型，以及結合凍結 TAP-CT 病人層級嵌入之 TAP-CT late fusion 模型。下文分別以「FCNN」、「Hybrid Mamba-Attention」與「TAP-CT late fusion」稱之。

RQ1： 胸部 CT 能否區分臨床標記之 Normal 與 Abnormal 個案？

RQ2： 塌陷角於（a）三分類、（b）二分類與（c）角度迴歸三個子任務下，三種方法之可預測性為何？

RQ3： 阻塞指數（OI）之二分類表現如何？

三個 RQ 之敏感度（Sensitivity）與特異度（Specificity）正類定義如下：RQ1 為 Abnormal、RQ2b 為 AC 低值組（塌陷／異常）、RQ3 為 $OI \geq 3$ ；RQ2a 為三分類，其 Sensitivity 與 Specificity 以 one-vs-rest macro 平均計算。各比較表中之粗體代表該表 Accuracy（或迴歸各欄）之最佳者。

4.2 實驗環境設定

本研究實驗之硬體設備如表 4.1 所示。量化生物標記分支之分割與特徵擷取於 Windows 環境執行，影像模型訓練與評估則於 Ubuntu 環境執行。兩分支之軟體環境整理如表 4.2 與表 4.3。

為使三種方法之比較公平，本研究對三個 RQ 採用相同之資料切分與驗證協定，各方法之訓練設定如表 4.4 所示。

表 4.1: 實驗硬體設備

Item	Specification
CPU	Intel Core i7-12700K 3.60GHz 12-Core Processor
GPU	NVIDIA GeForce RTX 4070 Ti SUPER
RAM	32GB DDR4-3200MHz
Storage	1TB NVMe SSD + 2TB SATA HDD

表 4.2: CT 量化生物標記分支實驗環境

Item	Description
Operating system	Windows 11 Pro 64-bit
Segmentation and image processing tools	3D Slicer, MONAI Auto3DSeg, AeroPath, SimpleITK
Model training and data processing libraries	PyTorch, scikit-learn, NumPy, pandas

表 4.3: 三維 CT 深度學習分支實驗環境

Item	Description
Operating system	Ubuntu 24.04.4 LTS (Noble Numbat), Linux kernel 6.17.0-29-generic, x86_64
Deep learning environment	Python 3.11, PyTorch 2.8.0, CUDA 12.8, MONAI
Medical imaging and data processing libraries	SimpleITK, nibabel, scikit-learn, pandas, matplotlib
TAP-CT related libraries	transformers, timm, einops

表 4.4: 三方法之訓練設定與驗證協定

Setting	Value
Epochs	100
Cross-validation	五折驗證
Random seed	42
Batch size	12 (深度模型) / 16 (FCNN)
Learning rate	1×10^{-4} (深度模型) / 1×10^{-3} (FCNN)
Loss function	分類: class-weighted CE (FCNN), BCE/CE (深度模型); 迴歸: smooth L1
Image augmentation	5 倍 (僅深度模型; FCNN 不使用)
Decision rule	argmax, 不調整閾值

4.3 實驗結果

4.3.1 RQ1 COPD Normal/Abnormal

RQ1 於 66 例 (Normal 33、Abnormal 33) 下比較三種方法之 Normal/Abnormal 辨識能力，其中 Abnormal 組對應合作醫師依 ATS/ERS 肺功能判讀標準判定之 COPD 個案 [34]。各方法之 Accuracy、Sensitivity 與 Specificity 之五折平均與標準差如表 4.5 所示。

表 4.5: RQ1 Normal/Abnormal 三方法比較 (n=66, 33/33)

Model	Accuracy	Sensitivity	Specificity
FCNN	0.848 ± 0.084	0.800 ± 0.214	0.910 ± 0.074
Hybrid Mamba-Attention	0.879 ± 0.078	0.848 ± 0.091	0.914 ± 0.114
TAP-CT late fusion	0.866 ± 0.107	0.848 ± 0.091	0.886 ± 0.140

註：Hybrid Mamba-Attention 與 TAP-CT late fusion 之 Sensitivity 其五折平均與標準差恰好相同，係因各折陽性 (Abnormal) 樣本僅約 6-7 例，逐折 Sensitivity 僅能取少數離散值，兩模型恰落在同一組數值集合，屬小樣本巧合；實際漏判之折次與個案於兩模型並不相同。

由表 4.5 可見，三種方法之 Accuracy 相當接近 (0.848–0.879)，以 Hybrid Mamba-Attention 最佳 (0.879 ± 0.078)，TAP-CT late fusion 次之 (0.866 ± 0.107)，FCNN (0.848 ± 0.084) 僅落後約 3 個百分點。三種方法之 Specificity 皆高於 Sensitivity，其中 FCNN 之 Sensitivity 標準差偏高 (± 0.214)，反映其在部分折上對 Abnormal 個案之召回較不穩定。整體而言，正常與異常之區分僅以 12 維定量參數即已相當接近深度影像模型，顯示此任務之影像訊號多可被量化生物標記涵蓋，加入凍結 TAP-CT 嵌入之融合並未進一步提升 Accuracy。

再來，本研究進一步以 hard voting 將三種方法 (量化生物標記、CT 影像、TAP-CT late fusion) 之預測整合為單一預測 (作法見第 3.10 節)：每位病人由 FCNN、Hybrid Mamba-Attention 與 TAP-CT late fusion 各投一票，取得預測較多之類別為最終預測；因模型數為奇數，每位病人皆有明確結論而無平手。整合後之整體表現如表 4.6 所示。

表 4.6: RQ1 三模型 hard voting 結果

Accuracy	Sensitivity	Specificity
0.895 ± 0.077	0.848 ± 0.091	0.943 ± 0.114

hard voting 之 Accuracy 為 0.894，略高於三個單模型中最佳之 Hybrid Mamba-

Attention (逐案 0.879)，Specificity 由各單模型之 0.886–0.914 提升至 0.939 (假陽性由 3–4 例降至 2 例)，Sensitivity 則維持於 0.848。若依三模型投票之一致性分層，可見準確率提升之來源：三模型完全一致 (3–0) 者共 50 例，其中 48 例正確 (96.0%)；三模型分歧 (2–1) 者共 16 例，僅 11 例正確 (68.8%)。此顯示當三種異質特徵來源意見一致時投票結果幾乎必然正確，誤判集中於模型彼此矛盾之少數邊緣個案，即「臨床標籤與 CT 量化特徵互相矛盾」之病人。因此 hard voting 可小幅提升整體正確率與特異度，但無法超越單模型共同之判別上限。

為檢視三維 CT 深度學習分支之判別依據，圖 4.1 呈現三名 Abnormal 個案於軸狀面 (Axial)、冠狀面 (Coronal) 與矢狀面 (Sagittal) 之 Grad-CAM 熱力圖。




圖 4.1: RQ1 Abnormal 病人的 Grad-CAM 熱力圖

此外，圖 4.2 呈現三名判斷錯誤個案之 Grad-CAM 熱力圖，可觀察模型於誤判時所關注之影像區域，作為錯誤案例之補充分析。




圖 4.2: RQ1 判斷錯誤個案的 Grad-CAM 熱力圖

4.3.2 RQ2 塌陷角

RQ2 評估三種方法對 AC 表徵之可預測性，分為三分類（RQ2a）、排除 $131^\circ < AC < 152^\circ$ 中間組之二分類（RQ2b）與連續角度迴歸（RQ2c）三個子任務。

4.3.2.1 RQ2a 三分類

RQ2a 依 $AC \leq 131^\circ$ 、 $131^\circ < AC < 152^\circ$ 、 $AC \geq 152^\circ$ 將 66 例分為 AC 低值、中間與高值三組（樣本數分別為 14、5、47），Sensitivity 與 Specificity 以 one-vs-rest macro 平均呈現，結果如表 4.7 所示。

RQ2a 中僅 TAP-CT late fusion 維持較高之整體正確率（ 0.774 ± 0.042 ），FCNN（ 0.577 ± 0.119 ）與 Hybrid Mamba-Attention（ 0.518 ± 0.253 ）皆偏弱，後者跨折變異尤大。三種方法之共同瓶頸皆為僅 5 例之中間組；此結果初步顯示塌陷角為 CT 影像較能

表 4.7: RQ2a 塌陷角三分類三方法比較 (n=66；Sens/Spec 為 macro)

Model	Accuracy	Sensitivity	Specificity
FCNN	0.577 ± 0.119	0.458 ± 0.063	0.768 ± 0.060
Hybrid Mamba-Attention	0.518 ± 0.253	0.510 ± 0.137	0.741 ± 0.121
TAP-CT late fusion	0.774 ± 0.042	0.550 ± 0.079	0.830 ± 0.056

反映、而 12 維定量參數較難捕捉之訊號，且凍結 TAP-CT 嵌入對此三分類任務有明顯助益。

4.3.2.2 RQ2b 二分類

RQ2b 排除 $131^\circ < AC < 152^\circ$ 中間組之 5 例，僅保留 AC 低值組與 AC 高值組共 61 例，以 AC 低值組為正類，結果如表 4.8 所示。

表 4.8: RQ2b 塌陷角二分類三方法比較 (n=61，排除中間組)

Model	Accuracy	Sensitivity	Specificity
FCNN	0.755 ± 0.087	0.767 ± 0.200	0.747 ± 0.080
Hybrid Mamba-Attention	0.885 ± 0.086	0.867 ± 0.163	0.891 ± 0.122
TAP-CT late fusion	0.871 ± 0.080	0.867 ± 0.163	0.871 ± 0.106

註：兩深度模型 Sensitivity 之平均與標準差相同，原因同表 4.5（每折陽性僅 3 例之小樣本巧合），實際漏判折次並不相同。

排除中間組後，AC 二分類表現明顯提升，且以 Hybrid Mamba-Attention 最佳 (0.885 ± 0.086)，TAP-CT late fusion 次之 (0.871 ± 0.080)，FCNN 最弱 (0.755 ± 0.087)。此結果與 RQ2a 一致，說明 AC 低值與高值兩端具有較明確之影像差異；惟在此已相當明確之二分任務中，凍結 TAP-CT 嵌入未再帶來增益，反而略微稀釋純影像模型之表現。

與 RQ1 相同，本研究亦以 hard voting 將三種方法預測整合為單一預測。整合後之整體表現如表 4.9 所示。

表 4.9: RQ2b 三模型 hard voting 結果

Accuracy	Sensitivity	Specificity
0.901 ± 0.063	0.933 ± 0.133	0.891 ± 0.100

hard voting 之 Accuracy 為 0.902，高於三個單模型中最佳之 Hybrid Mamba-Attention（逐案 0.885）；於排除中間組之 61 例（AC 低值 14、AC 高值 47，以 AC 低值為正類）

中，Sensitivity 達 0.929（14 例正類僅漏判 1 例）、Specificity 達 0.894（47 例負類誤判 5 例）。此顯示於 AC 兩端影像差異已相當明確之二分任務，結合三種異質特徵來源之投票可進一步收斂各單模型之誤判，小幅提升整體正確率與召回。

4.3.2.3 RQ2c 角度迴歸

RQ2c 將 AC 視為連續值，改以迴歸指標評估。各方法之 MAE、RMSE、決定係數 R^2 與 Pearson 相關係數如表 4.10 所示，其中 MAE 越低、RMSE 越低、 R^2 與 Pearson r 越高越佳，各欄最佳者以粗體標示。

表 4.10: RQ2c 塌陷角連續值迴歸三方法比較（n=66，合併計算）

Model	MAE (°)	RMSE (°)	R^2	Pearson r
FCNN	16.58	20.83	0.215	0.477
Hybrid Mamba-Attention	15.49	23.55	-0.004	0.376
TAP-CT late fusion	14.60	21.00	0.202	0.509

註：本表採合併計算（合併五折全體驗證預測後計算一組指標），故不列標準差；逐折之離散度甚大（例如 TAP-CT late fusion 之逐折 R^2 約介於 -0.13 至 0.66），主因每折僅約 13 例，使逐折 R^2 以各折局部變異正規化而極不穩定。

RQ2c 之迴歸指標採合併計算（合併五折全體驗證預測後計算，詳見第 3.11 節）。三種方法於不同指標互有領先：TAP-CT late fusion 取得最低 MAE（14.60）與最高 Pearson r（0.509），FCNN 則取得最低 RMSE（20.83）與最高 R^2 （0.215），Hybrid Mamba-Attention 之 R^2 近乎 0（-0.004），對連續角度幾乎無解釋力。就兩個深度模型而言，加入凍結 TAP-CT 嵌入之融合明顯優於純影像模型（ R^2 由 -0.004 升至 0.202），顯示預訓練 CT 表徵對連續角度預測確有助益；惟三種方法之 R^2 均不高（最高僅約 0.22），顯示單以 CT 影像或通用 CT 表徵精準估計連續肺功能指標仍具限制。

綜合 RQ2 三個子任務可見，塌陷角之分類任務較能由深度影像模型捕捉：三分類（RQ2a）由 TAP-CT late fusion 勝出，排除中間組之二分類（RQ2b）由 Hybrid Mamba-Attention 勝出。連續角度迴歸（RQ2c）則三種方法互有領先，TAP-CT late fusion 於 MAE 與 Pearson r 最佳、FCNN 於 RMSE 與 R^2 最佳，而純影像之 Hybrid Mamba-Attention 對連續角度幾無解釋力；整體而言，塌陷角之分類較能由深度影像模型反映，連續角度之精準迴歸則仍具限制。

4.3.3 RQ3 OI 二分類

RQ3 以肺功能檢查衍生之阻塞指數 (OI) 依門檻 $OI=3$ 建立二分類標籤，66 例中 $OI<3$ 者 32 例、 $OI\geq 3$ 者 34 例，以 $OI\geq 3$ 為正類，結果如表 4.11 所示。

表 4.11: RQ3 OI 二分類三方法比較 (n=66, 32/34)

Model	Accuracy	Sensitivity	Specificity
FCNN	0.804 ± 0.054	0.733 ± 0.065	0.876 ± 0.110
Hybrid Mamba-Attention	0.803 ± 0.036	0.767 ± 0.065	0.843 ± 0.106
TAP-CT late fusion	0.834 ± 0.088	0.848 ± 0.106	0.819 ± 0.149

RQ3 中三種方法之 Accuracy 相當接近 (0.803–0.834)，以 TAP-CT late fusion 最佳 (0.834 ± 0.088)，FCNN (0.804 ± 0.054) 與 Hybrid Mamba-Attention (0.803 ± 0.036) 幾乎相同。此結果與 RQ1 類似：肺氣腫原即與量化特徵高度相關，故 FCNN 於此 OI 導向任務即可達到足夠之辨識表現；而 TAP-CT late fusion 仍能小幅提升整體正確率與 Sensitivity。

與 RQ1、RQ2b 相同，本研究亦以 hard voting 整合三種方法（量化生物標記、CT 影像、TAP-CT late fusion）之預測：每位病人由 FCNN、Hybrid Mamba-Attention 與 TAP-CT late fusion 各投一票，取得預測較多之類別為最終預測；因模型數為奇數，每位病人皆有明確結論而無平手。整合後之整體表現如表 4.12 所示。

表 4.12: RQ3 三模型 hard voting 結果

Accuracy	Sensitivity	Specificity
0.834 ± 0.088	0.757 ± 0.167	0.910 ± 0.074

hard voting 之 Accuracy 為 0.833，與最佳單模型 TAP-CT late fusion (逐案 0.834) 相當；於 66 例 ($OI<3$ 者 32、 $OI\geq 3$ 者 34，以 $OI\geq 3$ 為正類) 中，Specificity 提升至 0.906 (32 例負類僅誤判 3 例)，高於各單模型之 0.819–0.876，惟 Sensitivity 降至 0.765 (34 例正類漏判 8 例)。此顯示於此 OI 導向任務，三模型投票主要以犧牲部分召回換取較高之特異度，整體正確率則未超越最佳單模型之判別上限。

第五章 結論與未來展望

5.1 結論

本研究以胸部 CT 影像為核心，建立 COPD 輔助診斷之影像分析流程，並於同一份 66 例病人（Normal 33、Abnormal 33）與相同之資料切分與驗證協定下，比較三種方法：以 12 項可解釋量化生物標記為輸入之量化生物標記模型、僅使用 CT 影像之 Hybrid Mamba-Attention，以及結合凍結 TAP-CT 表徵之 TAP-CT late fusion。三種方法皆共同應用於 Normal/Abnormal 分類、塌陷角三分類／二分類／連續值迴歸與 OI 二分類等任務，以逐一檢視量化特徵與深度影像模型於各任務之相對優勢。

於 Normal/Abnormal 分類（RQ1）中，三種方法之 Accuracy 相當接近（0.848–0.879），以 Hybrid Mamba-Attention 最佳（ 0.879 ± 0.078 ），TAP-CT late fusion 次之（ 0.866 ± 0.107 ），FCNN（ 0.848 ± 0.084 ）僅落後約 3 個百分點。由 OI 衍生之二分類（RQ3）亦呈相同型態，三者 Accuracy 介於 0.803–0.834，以 TAP-CT late fusion 最佳（ 0.834 ± 0.088 ），FCNN（ 0.804 ± 0.054 ）與 Hybrid Mamba-Attention（ 0.803 ± 0.036 ）幾乎相同。此二任務顯示，與量化特徵高度相關之判讀目標，僅以 12 維定量參數即可達到接近深度影像模型之表現。

塌陷角（RQ2）則為深度影像模型較具優勢之訊號。三分類（RQ2a）中僅 TAP-CT late fusion 維持較高之整體正確率（ 0.774 ± 0.042 ），FCNN（ 0.577 ± 0.119 ）與 Hybrid Mamba-Attention（ 0.518 ± 0.253 ）皆偏弱，後者跨折變異尤大；排除中間組之二分類（RQ2b）以 Hybrid Mamba-Attention 最佳（ 0.885 ± 0.086 ），FCNN 最弱（ 0.755 ± 0.087 ）；連續角度迴歸（RQ2c，採合併計算）則三種方法互有領先，TAP-CT late fusion 取得最低 MAE（14.60）與最高 Pearson r（0.509），FCNN 取得最低 RMSE（20.83）與最高 R^2 （0.215），而純影像之 Hybrid Mamba-Attention 之 R^2 近乎 0（-0.004），對連續角度幾乎無解釋力。整體而言，凍結 TAP-CT 嵌入之融合對塌陷角三分類與 OI 任務有幫助，於連續角度迴歸亦明顯優於純影像模型，但於 Normal/Abnormal 與塌陷角二分類等影像訊號已足夠之任務中，反而略微稀釋純影像特徵。

綜合上述結果，正常／異常與 OI 等與量化特徵高度相關之任務，僅以 12 維定量參數即可達到相當好之區分；塌陷角則為深度影像模型較具優勢之訊號。惟三種方法

之 R^2 與角度迴歸表現皆偏低，且塌陷角三分類之中間組（僅 5 例）為共同瓶頸，較細緻之肺功能相關任務仍需更多資料與臨床資訊支持。本研究成果較適合作為影像輔助判讀流程之可行性基礎，而非取代現行肺功能檢查或臨床診斷流程。

就方法與資料整體而言，本研究結果之解讀仍需考量數項限制。其一，資料量有限且主要來自單一合作來源，雖已採交叉驗證降低資料切分之偶然性，但尚未完成外部資料集驗證，模型之泛化能力仍須保守看待。其二，量化生物標記高度依賴肺部、肺葉、血管與氣道之分割品質，若分割遮罩出現邊界錯誤或末端血管、氣道漏失，肺氣腫比例、血管密度與氣道相關比例皆可能受到影響。其三，三維深度模型雖具與量化生物標記相當之分類效能，但其折間表現變異較大，且可解釋性、錯誤案例分析與臨床可用門檻仍待補強，尚不足以單獨作為臨床判讀依據。上述限制並不否定影像輔助判讀之可行性，而是界定本研究結果適用之範圍，並指向後續須優先處理之問題。


5.2 未來展望

後續研究可由資料、模型與臨床驗證三個方向延伸。資料面上，應持續擴充胸部 CT 與 PFT 配對資料，並納入不同掃描設備、掃描協議與醫療場域之資料，以驗證模型對外部資料的穩定性。若能建立多中心資料集，將有助於評估模型是否能跨機構、跨掃描條件維持相近表現，亦可緩解 GOLD 等任務之類別不平衡問題。

模型面上，量化生物標記分支可進一步強化肺葉、血管與氣道分割品質控管，並建立自動化失敗偵測機制，以降低錯誤分割對特徵計算之影響。三維影像模型則可加入模型校準、不確定性估計與可解釋性分析，例如觀察模型關注區域是否對應肺氣腫、氣道壁增厚或血管稀疏等 COPD 相關影像表徵。對於 AC 與 GOLD 相關任務，未來可嘗試以多任務學習同時預測 Normal/Abnormal、塌陷角與嚴重度分級，使模型共享與肺功能變化相關之影像表徵。

臨床應用面上，後續可將 CT 影像特徵與年齡、性別、吸菸史、症狀量表、PFT 指標及醫師判讀結果整合為多模態模型。針對各任務中之誤判個案，未來可依年齡、性別等臨床背景變項進行分層或錯誤分布分析（demographic subgroup analysis），以釐清模型漏判或誤判是否與特定族群有關。此類模型與分析較能貼近 COPD 實際診斷流程，也可降低單一影像模型對資料偏差或標籤不確定性的敏感度。最終，若要進入臨床輔

助判讀情境，仍需進行前瞻性驗證、錯誤案例審查與臨床工作流程評估，確認模型輸出能以可解釋且可被醫師採納的方式補充現有診斷資訊。



參考文獻

- [1] Global Initiative for Chronic Obstructive Lung Disease. *Global Strategy for the Diagnosis, Management, and Prevention of Chronic Obstructive Pulmonary Disease: 2025 Report*. Global Initiative for Chronic Obstructive Lung Disease, 2025. URL: <https://goldcopd.org/2025-gold-report/>.
- [2] Sohee Park et al. “Quantitative CT imaging in chronic obstructive pulmonary disease”. In: *British Journal of Radiology* (2025). DOI: 10.1093/bjr/tqaf105.
- [3] Geert Litjens et al. “A survey on deep learning in medical image analysis”. In: *Medical Image Analysis* 42 (2017). DOI: 10.1016/j.media.2017.07.005.
- [4] Hyunjung Park et al. “Deep Learning-based Approach to Predict Pulmonary Function at Chest CT”. In: *Radiology* 307.2 (2023). DOI: 10.1148/radiol.221488.
- [5] Haibo He and Eduardo A. Garcia. “Learning from Imbalanced Data”. In: *IEEE Transactions on Knowledge and Data Engineering* 21.9 (2009). DOI: 10.1109/TKDE.2008.239.
- [6] Marko Topalovic et al. “Computer quantification of airway collapse on forced expiration to predict the presence of emphysema”. In: *Respiratory Research* 14.1 (2013), p. 131. DOI: 10.1186/1465-9921-14-131.
- [7] Fumi Mochizuki et al. “The Concavity of the Maximal Expiratory Flow–Volume Curve Reflects the Extent of Emphysema in Obstructive Lung Diseases”. In: *Scientific Reports* 9.1 (2019), p. 13159. DOI: 10.1038/s41598-019-49591-2.
- [8] Shin Matsuoka et al. “Quantitative CT assessment of chronic obstructive pulmonary disease”. In: *Radiographics* 30.1 (2010). DOI: 10.1148/rg.301095110.
- [9] Pierre A. Gevenois et al. “Comparison of computed density and macroscopic morphometry in pulmonary emphysema”. In: *American Journal of Respiratory and Critical Care Medicine* 152.2 (1995). DOI: 10.1164/ajrccm.152.2.7633722.
- [10] Jens T. Bakker et al. “Measuring pulmonary function in COPD using quantitative chest computed tomography analysis”. In: *European Respiratory Review* 30.161 (2021). DOI: 10.1183/16000617.0031-2021.
- [11] George R. Washko et al. “Computed tomographic measures of airway morphology in smokers and never-smoking normals”. In: *Journal of Applied Physiology* 116.6 (2014). DOI: 10.1152/japplphysiol.00004.2013.
- [12] Ivan Dudurych et al. “Bronchial wall parameters on CT in healthy never-smoking, smoking, COPD, and asthma populations: a systematic review and meta-analysis”. In: *European Radiology* 32 (2022). DOI: 10.1007/s00330-022-08600-1.

- [13] Shin Matsuoka et al. “Quantitative CT measurement of cross-sectional area of small pulmonary vessel in COPD: correlations with emphysema and airflow limitation”. In: *Academic Radiology* 17.1 (2010). DOI: 10.1016/j.acra.2009.07.022.
- [14] J. Michael Wells et al. “Pulmonary arterial enlargement and acute exacerbations of COPD”. In: *New England Journal of Medicine* 367.10 (2012). DOI: 10.1056/NEJMoa1203830.
- [15] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. “U-Net: Convolutional Networks for Biomedical Image Segmentation”. In: *Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015*. Vol. 9351. Lecture Notes in Computer Science. 2015. DOI: 10.1007/978-3-319-24574-4_28.
- [16] Fabian Isensee et al. “nnU-Net: a self-configuring method for deep learning-based biomedical image segmentation”. In: *Nature Methods* 18.2 (2021). DOI: 10.1038/s41592-020-01008-z.
- [17] Andriy Fedorov et al. “3D Slicer as an image computing platform for the Quantitative Imaging Network”. In: *Magnetic Resonance Imaging* 30.9 (2012). DOI: 10.1016/j.mri.2012.05.001.
- [18] M. Jorge Cardoso et al. “MONAI: An open-source framework for deep learning in healthcare”. In: *arXiv preprint arXiv:2211.02701* (2022). DOI: 10.48550/arXiv.2211.02701.
- [19] Johannes Hofmanninger et al. “Automatic lung segmentation in routine imaging is primarily a data diversity problem, not a methodology problem”. In: *European Radiology Experimental* 4.1 (2020). DOI: 10.1186/s41747-020-00173-2.
- [20] Jakob Wasserthal et al. “TotalSegmentator: Robust Segmentation of 104 Anatomic Structures in CT Images”. In: *Radiology: Artificial Intelligence* 5.5 (2023). DOI: 10.1148/ryai.230024.
- [21] Thomas Z. Li et al. “Quantifying emphysema in lung screening computed tomography with robust automated lobe segmentation”. In: *Journal of Medical Imaging* 10.4 (2023). DOI: 10.1117/1.JMI.10.4.044002.
- [22] Antonio Garcia-Uceda et al. “Automatic airway segmentation from computed tomography using robust and efficient 3-D convolutional neural networks”. In: *Scientific Reports* 11 (2021). DOI: 10.1038/s41598-021-95364-1.
- [23] Karen-Helene Støverud et al. “AeroPath: An airway segmentation benchmark dataset with challenging pathology and baseline method”. In: *PLOS ONE* 19.10 (2024). DOI: 10.1371/journal.pone.0311416.
- [24] Yulei Qin et al. “Learning Tubule-Sensitive CNNs for Pulmonary Airway and Artery-Vein Segmentation in CT”. In: *IEEE Transactions on Medical Imaging* 40.6 (2021). DOI: 10.1109/TMI.2021.3062280.

- [25] Kaiwen Geng et al. “BeyondCT: A deep learning model for predicting pulmonary function from chest CT scans”. In: *arXiv preprint arXiv:2408.05645* (2024). DOI: 10.48550/arXiv.2408.05645.
- [26] Alexey Dosovitskiy et al. “An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale”. In: *International Conference on Learning Representations*. 2021. URL: <https://openreview.net/forum?id=YicbFdNTTy>.
- [27] Yanan Wu et al. “A vision transformer for emphysema classification using CT images”. In: *Physics in Medicine & Biology* 66.24 (2021). DOI: 10.1088/1361-6560/ac3dc8.
- [28] Ze Liu et al. “Swin Transformer: Hierarchical Vision Transformer Using Shifted Windows”. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision*. 2021. DOI: 10.1109/ICCV48922.2021.00986.
- [29] Albert Gu and Tri Dao. “Mamba: Linear-Time Sequence Modeling with Selective State Spaces”. In: *arXiv preprint arXiv:2312.00752* (2023). DOI: 10.48550/arXiv.2312.00752.
- [30] Haifan Gong et al. “nnMamba: 3D Biomedical Image Segmentation, Classification and Landmark Detection with State Space Model”. In: *arXiv preprint arXiv:2402.03526* (2024). DOI: 10.48550/arXiv.2402.03526.
- [31] Zhaohu Xing et al. “SegMamba: Long-range Sequential Modeling Mamba For 3D Medical Image Segmentation”. In: *Medical Image Computing and Computer Assisted Intervention – MICCAI 2024*. Vol. 15008. Lecture Notes in Computer Science. Springer Nature Switzerland, 2024. DOI: 10.1007/978-3-031-72111-3_54.
- [32] Yubiao Yue and Zhenzhang Li. “MedMamba: Vision Mamba for Medical Image Classification”. In: *arXiv preprint arXiv:2403.03849* (2024). DOI: 10.48550/arXiv.2403.03849.
- [33] Tim Veenboer et al. “TAP-CT: 3D Task-Agnostic Pretraining of Computed Tomography Foundation Models”. In: *arXiv preprint arXiv:2512.00872* (2025). DOI: 10.48550/arXiv.2512.00872.
- [34] Sanja Stanojevic et al. “ERS/ATS technical standard on interpretive strategies for routine lung function tests”. In: *European Respiratory Journal* 60.1 (2022), p. 2101499. DOI: 10.1183/13993003.01499-2021.
- [35] National Electrical Manufacturers Association. *Digital Imaging and Communications in Medicine (DICOM) Standard, Part 3: Information Object Definitions (PS3.3)*. NEMA. Rosslyn, VA, USA, 2024. URL: <https://www.dicomstandard.org/>.
- [36] Ashish Vaswani et al. “Attention Is All You Need”. In: *Advances in Neural Information Processing Systems*. Vol. 30. 2017. URL: <https://proceedings.neurips.cc/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html>.

- [37] Tsung-Yi Lin et al. “Focal Loss for Dense Object Detection”. In: *Proceedings of the IEEE International Conference on Computer Vision*. 2017. DOI: 10.1109/ICCV.2017.324.



附錄 A 補充實驗

除正文三個研究問題之三方法比較外，本研究另保留一項補充實驗以供參考：以 TAP-CT late fusion 進行之 GOLD 四分級分類。其樣本與早期訓練設定與主線 RQ 不完全一致，故不納入正文之三方法對齊比較，僅作為延伸觀察。

A.1 GOLD 四分級分類

GOLD 四分級依第三章 GOLD 2025 標籤設定，排除 Class 0（支氣管擴張劑後 $FEV1/FVC \geq 70\%$ ，34 例），以 GOLD 1 至 GOLD 4 共 32 例（各類 2、11、13、6 例）進行四分級，並以 focal loss 訓練，結果如表 A.1 與圖 A.1 所示。

本補充實驗之設定須特別說明：其一，因 GOLD 1 僅有 2 例，五折切分允許其驗證樣本跨折重複使用，以確保各折均能涵蓋所有分級類別，此作法使驗證樣本並非完全互斥，所得結果具樂觀偏差；其二，訓練折內另將各類別補至 13 筆以平衡類別分布；其三，本實驗之訓練設定與正文三方法對齊比較並不完全一致。因此下列數值僅供延伸觀察，不宜與正文各研究問題之結果直接比較。

本補充實驗因類別嚴重不平衡，除 accuracy 外另報告 macro precision、macro recall、macro-F1 與 balanced accuracy。設共有 K 個類別，第 k 類之 precision、recall 與 F1 定義如方程式 (A.1)：

$$\begin{aligned} \text{Precision}_k &= \frac{TP_k}{TP_k + FP_k} \\ \text{Recall}_k &= \frac{TP_k}{TP_k + FN_k} \\ F1_k &= \frac{2 \times \text{Precision}_k \times \text{Recall}_k}{\text{Precision}_k + \text{Recall}_k} \end{aligned} \quad (\text{A.1})$$

各 macro 指標與 balanced accuracy 則為各類別指標之算術平均，定義如方程式 (A.2)：

$$\begin{aligned}
\text{MacroPrecision} &= \frac{1}{K} \sum_{k=1}^K \text{Precision}_k \\
\text{MacroRecall} &= \frac{1}{K} \sum_{k=1}^K \text{Recall}_k \\
\text{MacroF1} &= \frac{1}{K} \sum_{k=1}^K \text{F1}_k \\
\text{BalancedAccuracy} &= \text{MacroRecall}
\end{aligned} \tag{A.2}$$

表 A.1: 補充實驗：GOLD 四分級分類結果（TAP-CT late fusion）

Metric	5-fold average
Accuracy	0.5429 ± 0.0571
Macro-F1	0.3798 ± 0.0870
Macro-Precision	0.4042 ± 0.0965
Macro-Recall	0.4083 ± 0.0553
Balanced Accuracy	0.4083 ± 0.0553

GOLD 四分級之五折平均 Accuracy 為 0.5429 ± 0.0571 、Macro-F1 為 0.3798 ± 0.0870 、Balanced Accuracy 為 0.4083 ± 0.0553 。由圖 A.1 可見，GOLD 3（13 例）與 GOLD 2（11 例）辨識相對較佳，GOLD 1（2 例）與 GOLD 4（6 例）兩端之極少樣本分級則為主要混淆來源；在 GOLD 1 樣本量極度不足之前提下，Balanced Accuracy 僅約 0.41，顯示資料不平衡是四分類可行性之主要限制。




圖 A.1: 補充實驗：GOLD 四分級分類混淆矩陣