



國立臺北科技大學

資訊工程系碩士班

碩士學位論文

胸部 CT 影像於 COPD 輔助診斷之研究

**A Study on the Auxiliary Diagnosis of COPD using
Chest CT images**

研究生：張博翔

指導教授：劉建宏、尤信程

中華民國一百一十五年七月



國立臺北科技大學

資訊工程系碩士班

碩士學位論文

胸部 CT 影像於 COPD 輔助診斷之研究
A Study on the Auxiliary Diagnosis of COPD using
Chest CT images

研究生：張博翔

指導教授：劉建宏、尤信程

中華民國一百一十五年七月

「學位論文口試委員會審定書」掃描檔

審定書填寫方式以系所規定為準，但檢附在電子論文內的掃描檔須具備以下條件：

1. 含指導教授、口試委員及系所主管的完整簽名。
2. 口試委員人數正確，碩士口試委員至少 3 人、博士口試委員至少 5 人。
3. 若此頁有論文題目，題目應和書背、封面、書名頁、摘要頁的題目相符。
4. 此頁有無浮水印皆可。

摘要

關鍵詞：胸部 CT、慢性阻塞性肺病、量化生物標記、Hybrid Mamba-Attention、TAP-CT、類別不平衡

慢性阻塞性肺病（Chronic Obstructive Pulmonary Disease, COPD）之臨床評估主要仰賴肺功能檢查，但胸部電腦斷層影像（computed tomography, CT）亦可提供肺部結構資訊。本研究建立以胸部 CT 為基礎之 COPD 輔助判讀流程，結合可解釋量化生物標記與三維深度影像模型。量化分支使用 54 例 CT，擷取 12 項肺氣腫、肺容積、氣道與血管相關特徵；其中 Abnormal 組對應合作醫師判定之 COPD 個案。經分層五折交叉驗證後，Normal/Abnormal 二分類之準確率為 92.59%，AUC 為 0.9784。同一 54 例資料用於三維 Mamba 之 Normal/Abnormal 二分類，五折平均準確率為 0.9409，AUC 為 1.0000。肺功能相關影像任務則使用擴充後之 66 例 CT，以 Mamba、SwinUNETR、Hybrid Mamba-Attention 與 TAP-CT 融合模型評估塌陷角度分類；排除 AC 中間組後，最佳 AC 二分類準確率為 0.9192，Macro-F1 為 0.8763。進一步以 AC 二分類候選輸出進行 hard voting 彙整時，候選輸出數量為 5 之準確率與未投票原始二分類基準皆為 0.919，且 sensitivity 皆維持 0.800。結果顯示，兩類方法可分別提供結構量化依據與影像表徵學習能力，而 hard voting 在本資料中未帶來明顯準確率提升。

ABSTRACT

Keywords: chest CT, COPD, quantitative biomarkers, Hybrid Mamba-Attention, TAP-CT, class imbalance

Clinical assessment of chronic obstructive pulmonary disease (COPD) primarily relies on pulmonary function testing; however, chest computed tomography (CT) can also provide structural information about the lungs. This study establishes a chest CT-based framework for auxiliary COPD assessment by combining interpretable quantitative biomarkers with three-dimensional deep imaging models. The quantitative branch used 54 CT scans and extracted 12 emphysema-, lung-volume-, airway-, and vascular-related features; the Abnormal group corresponded to COPD cases determined by the collaborating physician. Following stratified five-fold cross-validation, Normal/Abnormal classification achieved an accuracy of 92.59% and an AUC of 0.9784. The same 54 cases were used for three-dimensional Mamba Normal/Abnormal classification, achieving a mean accuracy of 0.9409 and an AUC of 1.0000. Pulmonary-function-related imaging tasks used an expanded dataset of 66 CT scans to evaluate Angle of Collapse classification with Mamba, SwinUNETR, Hybrid Mamba-Attention, and TAP-CT fusion models. After excluding the AC intermediate group, the best AC binary classification accuracy was 0.9192, with a Macro-F1 score of 0.8763. Further hard voting aggregation using AC binary candidate outputs with a candidate-output size of 5 matched the non-voting binary baseline accuracy of 0.919, while sensitivity remained 0.800 across settings. The results indicate that these two approaches can provide structural quantitative evidence and image representation learning capabilities, whereas hard voting did not substantially improve accuracy in this dataset.

誌謝

所有對於研究提供協助之人或機構，作者都可在誌謝中表達感謝之意。



目錄

摘要	i
ABSTRACT	ii
誌謝	iii
目錄	iv
表目錄	vi
圖目錄	vii
第一章 緒論	1
1.1 研究背景與動機	1
1.2 研究目的	2
1.3 論文架構	3
第二章 文獻回顧	4
2.1 慢性阻塞性肺病與肺功能檢查	4
2.2 CT 影像表徵與量化生物標記	5
2.3 肺部、氣道與血管影像分割	7
2.4 三維醫學影像深度學習模型	9
2.5 TAP-CT	10
第三章 研究方法	12
3.1 研究流程	12
3.2 資料集	14
3.3 資料前處理	15
3.4 肺部結構分割與量化參數擷取	15
3.5 量化 CT 分類模型	18
3.6 三維 CT 網路架構設計	20
3.7 塌陷角迴歸任務	21
3.8 TAP-CT 影像嵌入與融合策略	21
3.9 交叉驗證、資料增強與平衡取樣	22
3.10 Voting	23

3.11 評估指標	23
第四章 實驗結果與討論	25
4.1 研究問題	25
4.2 實驗環境設定	25
4.3 實驗結果分析	27
4.3.1 RQ1 量化特徵二分類結果	27
4.3.2 RQ2 三維 Mamba 二分類結果	28
4.3.3 RQ3 三維影像角度預測結果	29
4.3.4 RQ4 塌陷角衍生分類結果	30
4.3.5 RQ5 三維影像 GOLD 相關候選分級結果	32
4.3.6 RQ6 塌陷角二分類多數決結果	33
第五章 結論與未來展望	35
5.1 結論	35
5.2 研究限制	36
5.3 未來展望	36
參考文獻	38

表目錄

3.1 影像資料組成	14
4.1 實驗硬體設備	26
4.2 CT 量化生物標記分支實驗環境	26
4.3 三維 CT 深度學習分支實驗環境	26
4.4 RQ1 量化特徵二分類結果	27
4.5 RQ2 Mamba Normal/Abnormal 二分類結果	28
4.6 RQ3 塌陷角連續值迴歸結果	29
4.7 RQ4 AC 二分類結果	30
4.8 RQ4 AC 三分類結果	31
4.9 RQ5 GOLD 相關候選分級結果	32
4.10 RQ6 塌陷角二分類多數決結果	33



圖目錄

3.1	電腦斷層影像量化生物標記分類流程	13
3.2	三維電腦斷層影像後期融合模型流程	13
3.3	3D Slicer 肺部結構分割結果範例。左上為軸向切面、右上為三維立體檢視、左下為冠狀切面、右下為矢狀切面，各顏色區塊對應不同肺葉及血管結構之分割遮罩。	16
3.4	全連接神經網路分類器架構	18
3.5	混合式 Mamba 注意力影像編碼器架構	20
4.1	RQ1 量化特徵二分類混淆矩陣圖	28
4.2	Hybrid Mamba-Attention 合併五折測試樣本之塌陷角預測散佈圖	29
4.3	TAP-CT-S-2.5D late fusion 塌陷角三分類混淆矩陣	31
4.4	GOLD 候選分級分類效能比較	33

第一章 緒論

1.1 研究背景與動機

慢性阻塞性肺病（Chronic Obstructive Pulmonary Disease, COPD）是一種以持續性氣流受限為主要特徵之慢性呼吸道疾病。其造成之肺功能損害不易完全逆轉；若未能及早發現並追蹤，將增加急性惡化與生活品質受損之風險 [1]。如何從臨床影像資料中提取客觀且可解釋之輔助資訊，以協助早期識別與病情追蹤，是 COPD 醫療決策支援的重要課題。

临床上，COPD 之診斷與嚴重程度評估主要仰賴肺功能檢查。此類檢查可量化氣流受限程度，卻較難直接呈現肺部結構異常之位置與型態；若僅依賴單一生理測量結果，可能不足以反映肺部結構異常之型態與分布 [1, 2]。

胸部電腦斷層影像（computed tomography, CT）可補充肺部局部結構資訊。若將 CT 影像轉換為量化生物標記，並結合三維影像模型分析，便可分別從量化特徵與深度影像表徵兩個方向提供 COPD 輔助判讀依據 [2]。

為實現上述目標，近年醫學影像分析逐漸結合自動分割、量化特徵擷取與深度學習模型。對於 COPD CT 影像而言，自動化流程可先由肺葉、氣道與血管等結構分割開始，再計算肺氣腫比例、肺容積、氣道相關比例與血管相關指標等特徵；此類特徵具有較高可解釋性，能與 COPD 病理變化相互對應 [2]。另一方面，三維深度影像模型可直接由 CT 體積資料學習空間表徵，補足人工定義特徵可能無法涵蓋之影像訊息 [3, 4]。兩類方法在可解釋性與影像訊息涵蓋範圍上各有側重，可互為補充。

然而，實際醫學影像研究常受限於資料量不足、掃描協議不一致、分割品質差異與類別分布不均等問題。若模型評估僅呈現整體準確率，容易忽略資料不平衡造成的偏差，也可能掩蓋異常（Abnormal）個案漏判等临床上更需關注的問題 [5]。

因此，本研究以胸部 CT 影像為核心，建立 COPD 輔助診斷之自動化分析流程，並以可解釋量化特徵與三維影像模型進行比較。本研究將個案分為正常（Normal）與異常（Abnormal）兩類，其中異常組為合作醫師依肺功能與臨床判讀所標示之 COPD 患者。本研究探討兩類方法在小樣本資料下，應用於正常/異常分類、由肺功能流量-容積曲線衍生之塌陷角（collapse angle）連續值迴歸、塌陷角分級與 GOLD 分級等 COPD 輔助判

讀任務之可行性。

1.2 研究目的

本研究以胸部 CT 影像為基礎，建立兩條互補之 COPD 輔助診斷分析分支，並於多項臨床相關任務中評估其可行性，分述如下。

首先，本研究建置 CT 量化生物標記分析流程，涵蓋肺葉、氣道與血管自動分割，以及全肺肺氣腫比例、肺容積、小血管體積比例、氣道管壁指標、血管密度與肺動脈直徑等 12 項特徵計算，並以全連接神經網路進行正常/異常二元分類，評估量化特徵輔助辨識 COPD 個案之能力 [2]。

其次，本研究以三維 CT 深度學習模型直接分析 CT 體積資料，評估其於正常/異常二分類、塌陷角連續值迴歸、塌陷角三分類 ($AC \leq 131^\circ$ 、 $132^\circ \leq AC \leq 151^\circ$ 、 $AC \geq 152^\circ$)、排除中間灰區後之塌陷角二分類，以及 GOLD 四分級分類等任務之可行性，並比較 Mamba、Hybrid Mamba-Attention 等架構與結合預訓練胸部 CT 特徵 (TAP-CT) 之融合模型表現。

第三，本研究於正常/異常二分類任務下彙整量化生物標記方法與三維影像模型之結果，比較兩者在可解釋性與分類效能上之差異，評估各方法於 COPD 臨床輔助判讀中之適用情境。

最後，本研究針對小樣本與類別不平衡問題，探討三維影像增強、平衡取樣策略及 hard voting 多數決彙整對分類結果之影響，並以多指標評估避免以單一指標過度推論模型效能。

1.3 論文架構

本論文共分為五章，其架構說明如下：

1. **第一章：**說明研究背景與動機、研究目的及論文架構。
2. **第二章：**整理 COPD 臨床背景、胸部 CT 影像分析、肺部結構分割、CT 量化生物標記、三維醫學影像模型與肺功能相關表徵預測之相關研究。
3. **第三章：**說明研究材料與方法，包含影像前處理與肺部結構分割流程、CT 量化生物標記擷取、分類模型建置，以及三維深度學習模型與評估策略。
4. **第四章：**呈現實驗結果與討論，包含 CT 量化特徵分類結果、三維 CT 影像模型分類結果、塌陷角迴歸與衍生分類結果、hard voting 多數決結果，以及 GOLD 相關候選分級結果，並討論各任務效能與限制。
5. **第五章：**總結本研究成果，並提出後續於資料擴充、分割品質改善、模型泛化驗證與臨床應用評估之未來方向。

第二章 文獻回顧

2.1 慢性阻塞性肺病與肺功能檢查

慢性阻塞性肺病（Chronic Obstructive Pulmonary Disease, COPD）是一種常見且具有異質性的慢性呼吸道疾病，其核心特徵為持續性呼吸道症狀與氣流受限。COPD 的病理變化通常涉及小氣道發炎與重塑、氣道狹窄、肺實質破壞、肺氣腫與氣體滯留等現象，因此病患可能出現慢性咳嗽、咳痰、活動性喘促與運動耐受度下降等臨床表現。由於 COPD 之疾病進展具有長期性，且肺功能下降後不易完全恢復，臨床上需透過客觀檢查評估氣流受限程度與疾病嚴重度 [1]。

肺功能檢查（Pulmonary Function Test, PFT）是 COPD 診斷與嚴重程度評估中最重要之生理測量工具，其中又以肺量計測定（spirometry）最常用。肺量計測定可量測用力肺活量（Forced Vital Capacity, FVC）、一秒用力呼氣容積（Forced Expiratory Volume in one second, FEV1）與 FEV1/FVC 比值。FVC 代表受測者深吸氣後以最大力量呼出的總氣體量；FEV1 則代表用力呼氣第一秒內排出的氣體量；FEV1/FVC 比值可反映第一秒呼出量相對於總用力肺活量的比例，因此常用於判斷是否存在氣流受限。依 GOLD 指引，支氣管擴張劑後 FEV1/FVC 小於 0.70 為確認持續性氣流受限的重要判準之一 [1]。

除 FEV1、FVC 與 FEV1/FVC 外，肺功能檢查亦可包含中段用力呼氣流速（Forced Expiratory Flow between 25% and 75% of FVC, FEF25–75%）、尖峰呼氣流速（Peak Expiratory Flow, PEF）、肺活量（Vital Capacity, VC）、肺總量（Total Lung Capacity, TLC）與肺餘容積（Residual Volume, RV）等指標。這些指標可從不同角度反映呼氣流速、肺容量與氣體滯留情形。例如 FEF25–75% 常被用於觀察中小氣道功能，RV 增加則可能與氣體滯留有關。雖然上述指標能提供更完整的呼吸生理資訊，但 COPD 嚴重度分級與本研究後續標籤設計主要仍以 FEV1 及其預測值百分比為核心。

在已確認氣流受限的情況下，GOLD 分級通常依支氣管擴張劑後 FEV1 佔預測值百分比（FEV1 percent predicted）區分氣流受限嚴重程度。FEV1 預測值會依年齡、身高、性別等生理條件估計，再以實測 FEV1 除以預測值取得百分比。GOLD 1 為 FEV1 大於或等於 80% 預測值，代表輕度氣流受限；GOLD 2 為 50% 至未滿 80%，代表中度氣流受限；GOLD 3 為 30% 至未滿 50%，代表重度氣流受限；GOLD 4 則為低於 30%，代表

極重度氣流受限 [1]。此分級方式可將連續的肺功能數值轉換為具臨床意義的嚴重度類別，因此常作為 COPD 相關研究中的標籤依據。

然而，肺功能檢查主要反映整體呼吸生理狀態，較難直接指出肺部結構異常的位置、型態與分布。同樣的 FEV1 或 GOLD 分級可能對應不同程度的肺氣腫、氣道壁增厚、過度充氣或血管改變，因此單一肺功能指標未必能完整描述 COPD 的影像表型 [2]。基於此限制，本研究後續將 PFT 相關資訊視為重要參考標籤，並結合胸部 CT 影像之量化特徵與三維影像模型，探討影像資訊對 COPD 輔助判讀與肺功能相關表徵預測之補充價值。

除傳統肺量計數值外，流量容積曲線之幾何表徵亦可反映呼氣過程中的曲線形狀變化。Topalovic 等人以塌陷角度（Angle of Collapse, AC）描述曲線凹陷程度，並指出其與肺氣腫表徵具有關聯 [6]。相較於直接將個案壓縮為單一正常或異常類別，AC 為連續角度，可保留不同病人之肺功能曲線差異；若再依具解釋意義之角度門檻建立分級標籤，則可進一步觀察連續肺功能表徵轉換為分類任務後對模型學習與結果解讀之影響。因此，本研究同時將 AC 視為連續迴歸目標與衍生分類標籤來源，以完整記錄由肺功能表徵預測到輔助分級之實驗過程。

需要注意的是，本研究部分實驗使用資料集中支氣管擴張劑後 FEV1 佔預測值百分比建立 GOLD 相關分類標籤。由於正式 COPD 診斷與 GOLD 氣流受限分級仍需整合 FEV1/FVC 判準、症狀、病史與臨床判讀，因此本文在結果詮釋上將其視為肺功能導向之嚴重度候選標籤，而不直接等同完整臨床診斷或臨床分期。

2.2 CT 影像表徵與量化生物標記

胸部電腦斷層影像具有高空間解析度，可呈現肺實質、氣道、血管與肺葉分布等解剖結構，因此常被用於補充肺功能檢查無法直接呈現的局部結構資訊。對 COPD 而言，CT 影像中常見的結構性表徵包含肺氣腫造成的低衰減區域、肺過度充氣所反映的肺容積增加、氣道壁增厚或氣道狹窄，以及肺血管床減少或肺動脈相關變化等。這些影像表徵可對應 COPD 中肺實質破壞、小氣道病變與血管重塑等病理變化，因此 CT 不僅可作為視覺判讀工具，也可作為影像量化分析的資料來源 [7, 2]。

肺氣腫是 COPD 在 CT 影像中最常被量化的表徵之一。肺氣腫區域因肺泡壁破壞與

氣腔擴大而呈現較低密度，因此在吸氣相 CT 中常以低衰減區域比例描述其範圍。常見作法是在肺部遮罩內計算低於特定 Hounsfield unit 閾值的 voxel 比例，例如低於 -950 HU 的低衰減區比例可作為肺氣腫負荷之指標。Gevenois 等人比較 HRCT 密度與肺組織巨觀形態量測後指出，-950 HU 閾值與巨觀肺氣腫量測具良好對應，因此此閾值常作為定量肺氣腫分析的依據之一 [8]。此類指標可進一步依肺葉計算，以呈現肺氣腫分布是否集中於特定肺葉或呈現不均勻分布。相較於僅以整體肺功能數值描述病患狀態，肺葉別肺氣腫比例能提供更其位置資訊的影像表型描述。

肺容積與過度充氣亦是 COPD 影像評估中的重要概念。COPD 患者因氣流受限與呼氣不完全，可能產生氣體滯留與肺過度充氣，使總肺體積或特定肺葉體積出現改變。CT 影像若經過肺部或肺葉分割，便可依 voxel spacing 計算實際體積，將肺部形態由視覺印象轉換為可比較的數值。Bakker 等人回顧 quantitative CT 與肺功能檢查之關係時指出，CT 可萃取 residual volume、total lung capacity 等肺容積資訊，且此類 CT-derived lung volume 與 PFT 量測之肺容積具有相關性，特別適合用於描述 COPD 的過度充氣相關表徵 [9]。此類體積特徵雖可能受吸氣程度、體型差異與掃描範圍影響，但仍可作為描述 COPD 影像表徵的重要補充資訊。

除肺實質外，COPD 亦會影響氣道結構。慢性發炎與氣道重塑可能造成氣道壁增厚、氣道腔狹窄與小氣道阻塞。CT 量化分析中常見的氣道相關指標包含氣道壁比例 (wall area percentage, WA%)、氣道體積與肺體積之比例，以及由氣道遮罩推估的相關形態特徵。既有研究指出，WA% 是 COPD 吸菸族群中常用的中央氣道形態量測指標，且與 FEV1 預測值百分比具有相關性；系統性回顧亦顯示 WA%、wall thickness、Pi10 與 luminal area 等 CT 氣道參數已被廣泛用於 COPD 與相關呼吸疾病研究 [10, 11]。理想情況下，WA% 需根據氣道腔與氣道壁的可靠分割結果計算；若缺乏完整的 lumen 與 wall 標註，則只能以可取得之氣道遮罩或氣管標籤進行近似估計。因此，在使用氣道量化指標時，必須同時說明分割來源與計算限制，避免將自動估計結果過度解釋為精確的小氣道壁厚量測。

肺血管變化也是 COPD 影像分析中逐漸受到重視的面向。肺氣腫造成肺泡壁與微血管床破壞，可能使血管密度下降；另一方面，COPD 亦可能伴隨肺血管重塑與肺動脈壓力相關變化。Matsuoka 等人以 CT 量測小肺血管橫截面積，發現小血管面積比例與肺氣腫比例及肺功能指標相關，顯示肺血管量化可提供肺實質破壞以外的補充資訊

[12]。因此，CT 影像中可由血管分割結果計算總血管體積、血管密度、小血管體積比例（small vessel volume percentage, SVV%）與肺動脈直徑等指標。血管密度通常可定義為分割血管體積相對於總肺體積之比例；SVV% 則可透過血管遮罩與距離轉換等方式估計小血管負荷。肺動脈與主動脈直徑比例（PA:A ratio）亦常被視為肺血管與肺高壓相關的影像指標；Wells 等人曾以 CT 上肺動脈與主動脈直徑比例大於 1 作為肺動脈擴大指標，並探討其與 COPD 急性惡化之關係 [13]。然而，若缺乏可靠主動脈分割或標準化人工量測流程，則不宜將 PA:A ratio 列為已完成之自動量化結果。

綜合而言，CT 量化生物標記可將 COPD 相關影像表徵轉換為客觀且可供模型分析的數值。本研究依據既有 quantitative CT 文獻，選取可描述肺實質破壞、過度充氣、氣道重塑與肺血管變化之特徵。然而，量化結果仍會受到掃描協議、吸氣程度、分割品質與指標定義差異影響，解讀時需保留其限制。

2.3 肺部、氣道與血管影像分割

胸部 CT 影像雖可呈現肺實質、氣道與血管等細部解剖結構，但若未先界定各結構所在區域，影像灰階值與體積資訊便難以轉換為具生理意義的量化特徵。因此，在 COPD 相關 CT 分析中，影像分割通常扮演兩項關鍵角色：其一為建立特徵計算的解剖區域，例如以肺部或肺葉遮罩限定肺氣腫比例與肺容積之計算範圍；其二為提供可解釋的結構標籤，使氣道與血管相關指標能對應至特定病理變化。若分割邊界錯誤、末端管狀結構漏失，或將非目標組織誤判為目標結構，後續低衰減區比例、血管密度、小血管體積比例與氣道相關特徵皆可能受到影響。因此，影像分割並非單純的前處理程序，而是 quantitative CT 分析可信度的重要基礎。

深度學習已成為醫學影像分割的重要方法。Litjens 等人回顧深度學習於醫學影像分析之應用時指出，卷積神經網路已廣泛應用於影像分類、偵測與分割等任務 [3]。其中，U-Net 透過 encoder-decoder 結構與 skip connection 保留局部空間資訊，奠定了許多生物醫學影像分割模型的基礎 [14]。針對三維醫學影像分割，nnU-Net 進一步提出自動化設定策略，依資料特性調整前處理、網路架構與訓練流程，降低不同任務間人工調參的需求 [15]。在研究與實作工具方面，3D Slicer 可支援醫學影像讀取、分割、三維視覺化與量測 [16]；MONAI 則提供以 PyTorch 為基礎的醫學影像深度學習框架，整合資

料轉換、模型訓練與推論流程 [17]。

肺部與肺葉分割是 COPD 量化 CT 分析中最基礎的結構分割任務。Hofmanninger 等人針對例行性胸部影像之肺部分割進行研究，指出模型表現高度受到資料多樣性影響，臨床應用時需面對不同掃描協議、疾病型態與影像品質所造成的變異 [18]。TotalSegmentator 則建立可分割多種 CT 解剖結構的自動化工具，顯示多器官與多結構 label map 已逐漸成為 CT 影像量化研究的重要基礎 [19]。針對肺氣腫量化，Li 等人提出 EmphysemaSeg，結合自動肺葉分割與肺氣腫評估，用於低劑量肺癌篩檢 CT 中的肺葉別肺氣腫量化 [20]。上述研究說明，肺部與肺葉分割不僅用於排除非肺部組織，也會直接影響肺氣腫比例、肺葉體積與疾病分布型態之估計。

氣道分割相較於肺部遮罩更具挑戰性，原因在於氣道樹具有細長、多分支、末端管徑小且與肺血管相鄰等特性，分割時容易出現末端分支中斷、管腔漏失或誤判其他低密度結構等問題。Garcia-Uceda 等人提出以 3D convolutional neural networks 為基礎的自動氣道分割方法，並在胸部 CT 資料中驗證其對氣道樹萃取的可行性 [21]。AeroPath 則建立含有肺氣腫、腫瘤等病理變化之氣道分割 benchmark，強調胸部病理變化會增加氣道分割困難度，並提供評估模型於複雜臨床影像中穩健性的資料與基準方法 [22]。因此，氣道分割品質將直接影響 airway-derived features 之可信度。

血管分割則與 COPD 影像中肺血管床減少、小血管比例改變與肺動脈相關指標有關。Matsuoka 等人以 CT 量測小肺血管橫截面積，顯示小血管量化與肺氣腫比例及氣流受限具有關聯 [12]。在自動分割方法上，肺血管與氣道皆屬細長管狀結構，相對於背景 voxel 數量極少，容易形成類別不平衡與末端分支漏失問題。Qin 等人提出 tubule-sensitive CNN，用於肺部氣道與肺動靜脈分割，並針對管狀結構在 CT 中比例小、形態細長與分支複雜等問題設計模型策略 [23]。因此，血管密度、SVV% 與肺動脈相關指標雖可提供 COPD 血管表型資訊，但其可靠性仍取決於血管分割對主幹血管與末端小血管的偵測能力。

綜合上述文獻，不同分割工具之標籤定義、輸出格式與適用情境並不完全一致。肺部與肺葉分割主要影響肺容積與肺氣腫比例，氣道與血管分割則影響相應之結構量化結果；不同來源之分割輸出不宜視為完全等價。

2.4 三維醫學影像深度學習模型

胸部 CT 屬於三維體積影像，與單張二維影像相比，其資訊不僅存在於單一切面，也包含上下切片之間的連續解剖關係。COPD 相關影像表徵亦具有三維分布特性，例如肺氣腫可能呈現肺葉或區域性分布，氣道與血管則沿著肺內空間形成分支結構。因此，若僅以二維切片進行分析，可能忽略跨切片的空間連續性與整體肺部形態；三維深度學習模型則可直接以 CT volume 作為輸入，從體積資料中學習局部紋理、區域分布與全肺形態等特徵。

早期三維醫學影像深度學習多以 3D convolutional neural networks (3D CNN) 為基礎。3D convolution 可在深度、高度與寬度三個方向同時萃取局部特徵，使模型能保留體積影像中的空間鄰近關係。Park 等人以 inflated three-dimensional convolutional network 由低劑量胸部 CT 預測 FVC 與 FEV1，並進一步以預測之肺功能值判斷高風險族群，顯示三維 CT 模型可由影像中學習與肺功能相關的潛在表徵 [4]。BeyondCT 則結合 3D CNN、Vision Transformer 與人口統計資料，用於由非增強吸氣相胸部 CT 預測 FVC 與 FEV1；其設計反映了近年模型發展趨勢，即以 CNN 擷取局部影像特徵，再透過 Transformer 類架構捕捉較長距離的全域關係 [24]。此類研究說明，胸部 CT 模型除可輸出疾病類別外，亦可透過迴歸方式估計連續肺功能相關指標，作為後續門檻分級與風險判讀之前置表徵。

Transformer 架構原先發展於序列建模，後續 Vision Transformer 將影像切分為 patch token，利用 self-attention 建立影像區域之間的關係 [25]。在胸部 CT 與 COPD 相關研究中，Wu 等人曾將 Vision Transformer 應用於 CT 肺氣腫亞型分類，說明 attention-based 模型可用於辨識 centrilobular、panlobular 與 paraseptal emphysema 等不同影像型態 [26]。然而，標準 self-attention 的計算量會隨 token 數量平方成長，若直接用於高解析三維 CT，記憶體與運算成本皆相當高。Swin Transformer 以 shifted window attention 建立階層式特徵表示，在降低計算負擔的同時保留多尺度資訊 [27]；Swin UNETR 進一步將此概念引入三維醫學影像分割，以 Swin Transformer encoder 萃取多層級特徵，再與 U-Net 類 decoder 結合 [28]。這些研究顯示，Transformer 類模型有助於補足純 CNN 對長距離相依關係建模不足的問題。

近年 state space model (SSM) 與 Mamba 架構開始被引入醫學影像分析。Mamba 透

過 selective state space mechanism 建立長序列建模能力，並具有相對於標準 Transformer 更接近線性的序列長度複雜度，因此適合處理 token 數量龐大的影像或三維體積資料 [29]。在醫學影像領域，nnMamba 將 CNN 的局部表示能力與 SSM 的長距離建模能力結合，並應用於三維生物醫學影像分割、分類與 landmark detection 任務 [30]。SegMamba 則針對三維醫學影像分割設計 Mamba-based 架構，以提升 whole-volume feature modeling 的效率 [31]；MedMamba 則探討 Vision Mamba 於多種醫學影像分類任務中的應用，作為 Mamba-based medical image classification 的基準之一 [32]。

整體而言，三維醫學影像模型的發展可視為由局部特徵萃取走向局部與全域表徵整合的過程。3D CNN 適合捕捉 CT 中局部低衰減區、血管紋理與氣道周邊變化；Transformer 與 Swin 類模型則強調跨區域或多尺度關係；Mamba 類模型則嘗試在保留長距離建模能力的同時降低高維體積資料的計算負擔。對 COPD 輔助診斷而言，這些模型可作為 2.2 節量化生物標記之外的補充途徑，使模型直接由原始 CT volume 學習與肺功能、肺氣腫分布或疾病嚴重程度相關的隱含特徵，並同時支援連續肺功能表徵迴歸與衍生分類任務。然而，三維深度模型通常需要較多資料與嚴謹驗證；在小樣本醫學影像情境中，模型可能受到掃描協議差異、連續標籤雜訊、類別不平衡與資料切分方式影響，因此後續仍需搭配適當的資料增強、交叉驗證與多指標評估。

在模型輸出層面，多數決或集成式決策彙整亦常被用於降低單一分類器或單次推論結果之偶然性。集成學習的核心概念，是由多個具有差異性的分類決策共同產生最終輸出，以期降低模型變異或改善泛化表現 [33]。其中 hard voting 僅使用各成員輸出的類別標籤，並以多數類別作為最終結果；相較於 soft voting 需整合機率或信心分數，hard voting 的假設較簡單，也較容易在病人層級輸出中解釋 [34]。然而，多數決不必然帶來明顯準確率提升，也不保證改善少數類別召回率；因此，本研究在 hard voting 分析中以 accuracy、sensitivity 與 specificity 作為主要指標，分別觀察整體正確率、AC 低值組召回能力與 AC 高值組辨識能力。

2.5 TAP-CT

近年醫學影像深度學習除針對單一任務訓練模型外，亦逐漸重視由大量未標註或弱標註影像建立可轉移之預訓練表徵。此類 foundation model 期望先由大規模資料學得

一般性影像結構，再於下游任務中透過 feature extraction、輕量分類頭或有限微調降低標註資料不足造成的限制。對 CT 影像而言，若預訓練模型僅沿用二維自然影像設定，可能難以完整描述切片間之體積關係；因此，如何建立可處理三維 CT volume 的通用表徵，已成為 CT foundation model 發展的重要方向。

Veenboer 等人提出之 TAP-CT (Task-Agnostic Pretraining of Computed Tomography) 即以 CT 體積影像之通用預訓練為核心。該研究將 Vision Transformer 與 DINOv2 類自監督學習概念延伸至 volumetric CT，並針對三維 patch embedding、位置編碼與體積式資料增強進行調整，使模型可由 CT volume 建立具深度資訊之影像表示。其預訓練資料涵蓋大量 CT volumes，研究結果指出 TAP-CT 可在下游任務中提供穩定之 frozen representation，作為低資源情境下除完整 end-to-end fine-tuning 以外的特徵來源 [35]。

TAP-CT 對本研究所關注之小樣本胸部 CT 任務具有兩項參考意義。首先，COPD 相關影像表徵同時包含肺實質低衰減區、肺部空間分布與氣道血管周邊結構，若僅依本研究有限資料自訓練影像編碼器，模型可學得之表徵可能受資料量與標籤分布限制；預訓練 CT embedding 則提供另一種由大量 CT 影像學得之表示來源。其次，TAP-CT 之 frozen representation 可與任務導向模型輸出形成互補比較：前者強調通用 CT 表徵之可轉移性，後者則針對本研究之塌陷角與肺功能相關標籤調整特徵。因此，於下游任務中可分別檢視預訓練 embedding 單獨使用時之資訊量，以及其與三維影像模型特徵融合後是否提供額外效益。

然而，TAP-CT 屬於通用 CT 預訓練模型，並非專為 COPD、肺功能檢查或塌陷角標籤建立之疾病特異模型。其 embedding 是否能保留與呼氣流量容積曲線、GOLD 相關候選分級或正常異常判讀相關之訊息，仍需依實際資料與下游任務驗證。基於此，本研究將 TAP-CT 視為三維 CT 深度學習分支中的預訓練表徵補充來源，而非取代可解釋 CT 量化生物標記或任務導向三維模型之唯一方法。

第三章 研究方法

3.1 研究流程

本研究以胸部電腦斷層影像為主要輸入，建立 COPD 輔助診斷與肺功能相關表徵預測流程。原始胸部 CT 影像先由 DICOM 轉換為 NIfTI volume，再依實驗目的進入兩條分支：

1. **CT 量化生物標記分析分支：**強調影像特徵之可解釋性。轉換後之 CT 影像先經肺部、肺葉、血管與氣道相關分割流程產生 label map，再依各結構遮罩計算肺氣腫比例、肺容積、血管密度、小血管體積比例、氣道相關比例與肺動脈直徑等數值特徵。上述特徵可對應肺實質、血管與氣道結構變化，故本研究將其視為 CT 量化生物標記，並以全連接神經網路進行 Normal/Abnormal 二元分類。如圖 3.1 所示。
2. **三維 CT 深度學習模型分析分支：**保留完整三維影像輸入，不先將 CT volume 壓縮為人工定義特徵。NIfTI 影像經尺寸統一、強度正規化與必要之資料增強後輸入三維模型，模型設定包含 Mamba、SwinUNETR、Hybrid Mamba-Attention 與 TAP-CT 影像嵌入融合。此分支之任務包含 Normal/Abnormal 二分類、塌陷角連續值預測、塌陷角三分類、排除中間灰區後之二分類，以及 GOLD 分級分類。如圖 3.2 所示




圖 3.1: 電腦斷層影像量化生物標記分類流程




圖 3.2: 三維電腦斷層影像後期融合模型流程

3.2 資料集

本研究資料由北投振興醫院提供，包含病人胸部 CT 的 DICOM 影像及肺功能檢查 (pulmonary function test, PFT)。量化生物標記分支使用 54 例胸部 CT，其中 Normal 21 例、Abnormal 33 例；其 Normal/Abnormal 二元標籤由合作醫師依 ATS/ERS 肺功能判讀標準 [36]。

三維 CT 分支依任務使用兩種資料範圍。Normal/Abnormal 二分類任務沿用上述 54 例資料，以便與量化生物標記分支比較同一臨床二分類標籤下之表現；肺功能相關任務則使用擴充後之 66 例資料，包含前述 54 例與新增之 12 例 CT，且各例皆可與 PFT 資料對應。PFT 資料用於整理塌陷角度與 GOLD 相關候選標籤，並作為 Mamba、SwinUNETR、Hybrid Mamba-Attention 與 TAP-CT 融合模型訓練與驗證資料。塌陷角度 (Angle of Collapse, AC) 係由肺功能檢查之呼氣流量容積曲線萃取的幾何指標。參考 Topalovic 等人提出之 AC 與肺氣腫關係，本研究採用 131° 與 152° 作為角度分級門檻 [6]。各資料範圍與用途如表 3.1 所示。

表 3.1: 影像資料組成

資料集	數量	實驗用途
量化特徵與三維 CT 二分類	54	Normal 21 例、Abnormal 33 例；用於肺部結構分割、量化參數擷取與 Normal/Abnormal 二元分類。
三維 CT 肺功能標籤	66	由 PFT 整理之 AC 與 GOLD 標籤；用於 AC 連續值迴歸、AC 分級、排除中間灰區後之 AC 二分類與 GOLD 分類。

AC 三分類任務將影像依肺功能曲線衍生角度分為三類： $AC \leq 131^\circ$ 為 AC 低值組， $132^\circ \leq AC \leq 151^\circ$ 為 AC 中間組， $AC \geq 152^\circ$ 為 AC 高值組。原始 66 例資料中，三類樣本數分別為 14、5 與 47 例。上述 AC 類別為肺功能曲線衍生標籤，不等同於臨床 Normal/Abnormal 二元標籤。由於 AC 中間組樣本數較少且可能代表肺功能曲線表徵之灰區，本研究另設計 AC 二分類任務，排除 132° 至 151° 之 5 例，只保留 $AC \leq 131^\circ$ 與 $AC \geq 152^\circ$ 兩端較明確之 61 例資料。

GOLD 相關候選標籤則依肺功能檢查中 FEV1 佔預測值百分比進行整理，分為 GOLD 1、GOLD 2、GOLD 3 與 GOLD 4。於 66 例三維影像資料中，四類樣本數分別為 2、11、13 與 6 例。

3.3 資料前處理

本研究之前處理目的在於將原始 DICOM 影像與 PFT 資料整理為後續分割、量化參數擷取與標籤建立可使用之格式。由於量化分析仰賴 HU 閾值與實際 voxel spacing，轉換流程需保留影像強度與空間資訊，避免影響後續體積與低衰減區比例計算。

原始胸部 CT 以 DICOM series 形式儲存。同一病人可能具有多組掃描序列或重建影像，因此本研究先依 SeriesInstanceUID 與 DICOM metadata 將影像分組，再排除 scout、snapshot、冠狀面或矢狀面重建影像，以及不適合肺部分析之非目標序列。若同一病人具有多個可用胸部 CT series，則優先選擇適合肺部結構分析之軸向胸部或肺窗序列。完成序列選擇後，依 ImagePositionPatient 對切片排序，並利用 ImageOrientationPatient、PixelSpacing 與 SliceThickness 等欄位建立三維空間方向與 voxel spacing。

CT 強度值轉換依據 DICOM 中之 RescaleSlope 與 RescaleIntercept 進行。實際處理時，先將原始 pixel value 轉換為對應之 HU 值，使影像強度與原始掃描條件保持一致。此步驟對本研究特別重要，因為後續量化分析高度依賴影像強度的正確性；若未正確轉換 HU，相關影像表徵與量化結果皆可能產生系統性偏差。轉換後之影像以 NIfTI 格式儲存，並保留必要之空間與強度資訊，以支援後續分析流程。

PFT 資料則以病人為單位與 CT volume 對應，用於建立正常/異常二元標籤、FEV1 預測值百分比相關分級，以及塌陷角度（AC）等肺功能導向標籤。

3.4 肺部結構分割與量化參數擷取

本研究以 NIfTI volume 為輸入，透過 3D Slicer 結合 MONAI Auto3DSeg 產生多類別 label map[16, 17]。Label 1 至 5 對應五個肺葉並合併為總肺遮罩，label 6 至 9 對應血管、氣管、肺靜脈系統與肺動脈。氣道結構另以 AeroPath 分割結果補充 [22]，若 airway mask 可取得則優先採用，否則以 label map 中之氣管標籤近似。分割後確認各主要結構 label 非空且 voxel 數合理，再進行特徵計算。

肺氣腫比例定義為遮罩內 $HU < -950$ 之 voxel 占比（%），分別計算於總肺與各肺葉遮罩，此閾值為 CT 肺氣腫定量分析之常用標準 [8]。血管密度、小血管體積比例（SVV%）、氣道壁比例（WA%）與氣道肺體積比例均以對應結構體積除以總肺體積表




圖 3.3: 3D Slicer 肺部結構分割結果範例。左上為軸向切面、右上為三維立體檢視、左下為冠狀切面、右下為矢狀切面，各顏色區塊對應不同肺葉及血管結構之分割遮罩。

示。SVV% 可反映 COPD 中小血管床減少之影像表徵 [12]。肺動脈直徑由 label 體積以等效球體公式反推：

$$d_{PA} = 2 \left(\frac{3V_{PA}}{4\pi} \right)^{1/3} \quad (3.1)$$

其中 V_{PA} 為肺動脈 label 體積 (mm^3)， d_{PA} 為估計直徑 (mm)。此值由分割體積換算而來，非臨床影像上之直接量測。

本研究最終輸出下列 12 項量化特徵：

1. **全肺肺氣腫比例** (Total_Empysema_Percent)：五葉合併總肺遮罩內 HU < -950 之 voxel 占比。
2. **各肺葉肺氣腫比例** (共 5 項)：分別計算左上葉 (Left_Superior)、左下葉 (Left_Inferior)、右上葉 (Right_Superior)、右中葉 (Right_Middle) 與右下葉 (Right_Inferior) 遮罩內之 HU < -950 voxel 占比。
3. **小血管體積比例** (SVV_Percent)：以 distance transform 估計直徑小於 5 mm 之血管體積後除以總肺體積。
4. **氣道壁比例** (WA_Percent)：氣道壁體積占氣道總體積 (壁加內腔) 之比例，反映氣道壁相對厚度。
5. **血管密度** (Vessel_Density_Percent)：分割血管體積除以總肺體積。
6. **氣道肺體積比例** (Airway_Lung_Ratio_Percent)：氣道體積除以總肺體積。
7. **總肺體積** (Total_Lung_Volume_ml)：五個肺葉體積加總，單位 mL。
8. **肺動脈直徑估計值** (PA_Diameter_mm)：由 label 體積依式 (3.1) 換算，單位 mm。

肺氣腫比例、血管與氣道比例以百分比表示，肺體積與肺動脈直徑保留物理單位，供後續模型標準化與分類使用。

3.5 量化 CT 分類模型




圖 3.4: 全連接神經網路分類器架構

量化生物標記分類模型以第 3.4 節所述之 12 項 CT 量化特徵作為輸入，進行 Normal/Abnormal 二元分類。相較於三維 CT 模型，此分支輸入維度低，且各特徵對應明確的肺部結構變化，在本研究 54 例小樣本條件下具有較好的可解釋性。

標籤以 0 表示 Normal、1 表示 Abnormal。由於各特徵單位與尺度不同，模型訓練前僅以 training fold 資料計算各特徵的均值與標準差進行 z-score 標準化，避免驗證資料洩漏至標準化參數估計。

分類器採用全連接神經網路，其模型架構如圖 3.4 所示。模型以 12 維量化特徵作為輸入，經由三層 hidden layers 擷取特徵組合關係，最後輸出正常與異常兩類之 logits，並以 softmax 轉換為類別機率。

模型訓練設定與驗證方式如下：

- **輸入與標籤：**模型輸入為第 3.4 節所列 12 項量化特徵（已 z-score 標準化），標籤 0 為 Normal、1 為 Abnormal。
- **模型架構：**網路維度為 $12 \rightarrow 64 \rightarrow 32 \rightarrow 16 \rightarrow 2$ 。各 hidden layer 後接 batch normalization、ReLU activation 與 dropout，以增加非線性表示能力並降低小樣本訓練時之過擬合風險。

- **輸出與訓練目標：**輸出層包含 2 個 logits，分別對應 Normal 與 Abnormal 類別，並以 softmax 轉換為類別機率。模型訓練使用 CrossEntropyLoss。
- **最佳化與訓練設定：**Optimizer 採用 Adam，初始 learning rate 為 0.001，weight decay 為 1×10^{-5} ；batch size 設為 16，最多訓練 100 epochs。
- **學習率調整：**訓練過程使用 ReduceLROnPlateau 依驗證指標調整 learning rate，並以 early stopping 避免在小資料集上過擬合。
- **驗證方式：**採用 stratified five-fold cross validation，每折獨立估計標準化參數並重新訓練，合併五折驗證預測計算整體分類效能。



3.6 三維 CT 網路架構設計




圖 3.5: 混合式 Mamba 注意力影像編碼器架構

三維 CT 影像模型直接由完整 CT volume 學習肺部空間表徵，補足量化生物標記僅能描述預先定義特徵的限制。各模型皆由影像編碼器、pooling 與 MLP prediction head 組成，編碼器輸出經 pooling 彙整為固定維度特徵向量，再依任務輸出迴歸值或分類分數。本研究使用三種編碼器架構：

- **Mamba**：以三維 convolution stem 擷取局部特徵，再將特徵轉為空間 token sequence，透過 residual Mamba blocks 建立跨切片與跨區域的長程依賴關係。
- **SwinUNETR**：以階層式 Transformer 編碼器取得多層級三維影像表示，作為與

Mamba 比較的 attention-based 基準 [27, 28]。

- **Hybrid Mamba-Attention**：以 Mamba stages 為主要編碼流程，並在深層特徵加入 global multi-head attention bridge，使模型在保留 Mamba 三維建模能力的同時整合全域空間關係。

Hybrid Mamba-Attention 影像編碼器之細部架構如圖 3.5 所示。模型先以三維卷積建立局部低階特徵，再依序通過三個 Mamba stage 擷取不同解析度下之空間表徵；各階段輸出經 adaptive average pooling 彙整後進行逐層融合，最後結合 attention block 輸出之深層特徵形成 352 維三維影像表示。此設計使模型同時保留早期局部紋理、中階空間結構與深層全域關係，作為後續迴歸或 prediction head 之輸入。

損失函數依任務類型選定：Normal/Abnormal 二元分類採用 binary cross entropy with logits loss；AC 三分類、AC 二分類與 GOLD 分級等多類別任務採用 cross entropy loss。

3.7 塌陷角迴歸任務

本節實驗以塌陷角（AC）作為三維 CT 迴歸目標，模型輸入 CT volume，輸出對應病人的連續角度預測值。

標籤標準化依每折訓練資料的均值與標準差進行，模型學習標準化後的角度，驗證時再還原為原始單位計算誤差，避免驗證資料洩漏至標準化參數估計。訓練採用 smooth L1 loss 以降低極端誤差的影響，以 validation MAE 選取最佳 checkpoint。此任務用於評估三維 CT 模型能否從影像中學習到與肺功能曲線幾何形態相關的資訊。

3.8 TAP-CT 影像嵌入與融合策略

TAP-CT 為針對三維 CT 預訓練的影像編碼模型，可將 CT volume 轉換為固定維度的特徵向量 [35]。由於本研究樣本數有限，不重新訓練 TAP-CT 權重，而是固定參數直接擷取特徵。本文依實驗設定使用 TAP-CT-B-3D、TAP-CT-S-3D 與 TAP-CT-S-2.5D，分別產生 2304 維與 1152 維向量；若 CT 被切成多個區段處理，則先整合同一病人的多段特徵再進入後續模型。

TAP-CT 特徵用於 AC 分類與 GOLD 分級，比較以下兩種方式：

1. **TAP-CT 單獨分類**：僅以 TAP-CT 特徵為輸入，搭配 ABMIL 分類頭 [37]，評估預訓練特徵本身的分類能力。
2. **Late fusion**：將 Hybrid Mamba-Attention 從原始 CT 產生的特徵與 TAP-CT 特徵串接後，輸入 MLP 分類頭，評估兩者融合後的效果。

3.9 交叉驗證、資料增強與平衡取樣

所有實驗以病人為資料切分單位，同一病人的 CT、TAP-CT 特徵與增強樣本只能出現在同一 fold，避免資料洩漏。

- **交叉驗證**：量化特徵分類採 stratified five-fold，以 training fold 估計標準化參數。三維 CT 模型的 Normal/Abnormal、AC 三分類與 AC 二分類同樣採五折；AC 迴歸依角度分布建立 quantile bins 後分層切分，降低各折角度分布差異。GOLD 分級因少數類別樣本不足，改採三折。
- **三維影像輸入**：統一為 $1 \times 112 \times 136 \times 112$ 的 channel-first volume，並依任務進行 HU clipping 與強度正規化。
- **資料增強**：僅套用於 training fold。AC 三分類、AC 二分類與 TAP-CT late fusion 採較小幅度：旋轉 $\pm 5^\circ$ 、平移 0.03、縮放 0.97–1.03、強度縮放 0.98–1.02、強度平移 ± 0.05 、高斯雜訊標準差 0.02。GOLD 分級因類別更不平衡，幅度加大：旋轉 $\pm 7^\circ$ 、平移 0.05、縮放 0.95–1.05、強度縮放 0.95–1.05、強度平移 ± 0.1 、高斯雜訊標準差 0.03。
- **平衡取樣**：對類別不平衡任務，於 training fold 內對各類別產生虛擬增強樣本，每個 epoch 再以少數類別數量為基準隨機平衡取樣。測試的補樣本數如下：AC 三分類補至每類 50、75、100、200、300 筆，另測試每筆產生 12 個視圖的先平衡後增強設定；AC 二分類補至每類 100 筆；TAP-CT late fusion 的 AC 任務補至每類 100 筆、GOLD 分級補至每類 36 筆。

3.10 Voting

深度學習模型的預測結果會因 random seed 不同而產生變異，hard voting 透過彙整多個模型的輸出來降低此不確定性。本節針對 AC 二分類任務，以不同 random seed 訓練 7 個 TAP-CT late fusion 模型，對每位病人各產生一個預測後以多數決決定最終類別。候選數分別取 3、5、7（皆為奇數，不會平手），並以單一模型預測（未投票）作為 baseline。

評估以 accuracy、sensitivity 與 specificity 為主：sensitivity 反映 AC 低值組的召回能力，specificity 反映 AC 高值組的辨識能力，用以檢視多模型投票是否比單一模型更穩定或準確。

3.11 評估指標

本研究依任務類型選擇評估指標。Normal/Abnormal 二元分類以 accuracy、sensitivity、specificity、precision、F1-score 與 ROC-AUC 評估，並搭配 confusion matrix 呈現錯誤分類型態，各指標定義如方程式 (3.2)[5]。其中 Abnormal 為陽性類別（對應 COPD 個案）。

$$\begin{aligned} \text{Accuracy} &= \frac{TP + TN}{TP + TN + FP + FN} \\ \text{Sensitivity} &= \text{Recall} = \frac{TP}{TP + FN} \\ \text{Specificity} &= \frac{TN}{TN + FP} \\ \text{Precision} &= \frac{TP}{TP + FP} \\ \text{F1} &= \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \end{aligned} \quad (3.2)$$

ROC-AUC 以不同 threshold 下的 true positive rate 與 false positive rate 曲線描述模型整體區辨能力 [38]。

AC 三分類、AC 二分類與 GOLD 分級存在類別不平衡，因此除整體 accuracy 外，同時報告 macro precision、macro recall、macro-F1 與 balanced accuracy。Voting 分析則僅報告 accuracy、sensitivity 與 specificity。各類別指標定義如方程式 (3.3)：

$$\begin{aligned}
\text{Precision}_k &= \frac{\text{TP}_k}{\text{TP}_k + \text{FP}_k} \\
\text{Recall}_k &= \frac{\text{TP}_k}{\text{TP}_k + \text{FN}_k} \\
\text{F1}_k &= \frac{2 \times \text{Precision}_k \times \text{Recall}_k}{\text{Precision}_k + \text{Recall}_k}
\end{aligned} \tag{3.3}$$

Macro precision、macro recall、Macro-F1 與 balanced accuracy 定義如方程式 (3.4)：

$$\begin{aligned}
\text{MacroPrecision} &= \frac{1}{K} \sum_{k=1}^K \text{Precision}_k \\
\text{MacroRecall} &= \frac{1}{K} \sum_{k=1}^K \text{Recall}_k \\
\text{MacroF1} &= \frac{1}{K} \sum_{k=1}^K \text{F1}_k \\
\text{BalancedAccuracy} &= \text{MacroRecall}
\end{aligned} \tag{3.4}$$

對於連續 AC 迴歸任務，本研究以 mean absolute error (MAE)、root mean squared error (RMSE)、coefficient of determination (R^2) 與 Pearson correlation coefficient 評估預測值與真實角度之差異及相關程度。設真實值為 y_i ，預測值為 $\hat{y}_i$ ，其平均值分別為 $\bar{y}$ 與 $\bar{\hat{y}}$ ，則各項指標定義如方程式 (3.5)：

$$\begin{aligned}
\text{MAE} &= \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i|, \\
\text{RMSE} &= \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2}, \\
R^2 &= 1 - \frac{\sum_{i=1}^N (y_i - \hat{y}_i)^2}{\sum_{i=1}^N (y_i - \bar{y})^2}, \\
\text{Pearson} &= \frac{\sum_{i=1}^N (y_i - \bar{y})(\hat{y}_i - \bar{\hat{y}})}{\sqrt{\sum_{i=1}^N (y_i - \bar{y})^2} \sqrt{\sum_{i=1}^N (\hat{y}_i - \bar{\hat{y}})^2}}.
\end{aligned} \tag{3.5}$$

MAE 與 RMSE 衡量預測誤差大小，其中 RMSE 對極端誤差較敏感； R^2 描述模型對角度變異的解釋程度；Pearson coefficient 則反映預測值與真實值的線性相關強度。

第四章 實驗結果與討論

4.1 研究問題

本章依研究流程彙整六項研究問題 (Research Questions, RQs)，分別評估 CT 量化特徵、三維影像模型、肺功能衍生標籤與 hard voting 決策彙整於 COPD 輔助判讀之表現。結果分析著重於模型效能、類別辨識均衡性及其臨床判讀意義。

RQ1： 胸部 CT 影像擷取之量化生物標記，能否區分 Normal 與 Abnormal 個案？

RQ2： 輸入三維 CT 之 Mamba 模型，是否能於 54 例資料進行 Normal/Abnormal 二分類？

RQ3： 三維 CT 影像模型是否能預測肺功能塌陷角度？

RQ4： 塌陷角度衍生之二分類與三分類標籤，是否有助於肺功能相關影像判讀？

RQ5： 三維 CT 影像模型能否辨識 GOLD 相關候選分級？

RQ6： Hard voting 決策彙整對塌陷角二分類準確率、敏感度與特異度有何影響？

4.2 實驗環境設定

本研究實驗於本機工作站完成，硬體設備如表 4.1 所示。CT 量化生物標記分支於 Windows 環境執行，三維 CT 深度學習、塌陷角預測、hard voting、GOLD 相關候選分級與 TAP-CT 相關實驗則於 Ubuntu 環境執行。兩分支之軟體環境整理如表 4.2 與表 4.3。

表 4.1: 實驗硬體設備

項目	規格
CPU	Intel Core i7-12700K 3.60GHz 12-Core Processor
GPU	NVIDIA GeForce RTX 4070 Ti SUPER
RAM	32GB DDR4-3200MHz
Storage	1TB NVMe SSD + 2TB SATA HDD

表 4.2: CT 量化生物標記分支實驗環境

項目	內容
作業系統	Windows 11 Pro 64-bit
分割與影像處理工具	3D Slicer、MONAI Auto3DSeg、AeroPath、SimpleITK
模型訓練與資料處理套件	PyTorch、scikit-learn、NumPy、pandas

表 4.3: 三維 CT 深度學習分支實驗環境

項目	內容
作業系統	Ubuntu 24.04.4 LTS (Noble Numbat)，Linux kernel 6.17.0-29-generic，x86_64
深度學習環境	Python 3.11、PyTorch 2.8.0、CUDA 12.8、MONAI
醫學影像與資料處理套件	SimpleITK、nibabel、scikit-learn、pandas、matplotlib
TAP-CT 相關套件	transformers、timm、einops

4.3 實驗結果分析

4.3.1 RQ1 量化特徵二分類結果

RQ1 以 12 項 CT 衍生量化生物標記作為輸入，採五折交叉驗證評估 Normal 與 Abnormal 個案之辨識能力，結果如表 4.4 與圖 4.1 所示。本文之 Abnormal 組對應合作醫師判定之 COPD 個案。整體 Accuracy 為 0.9259，AUC 為 0.9784，顯示量化特徵已能有效區分兩類個案。Precision 與 Specificity 皆為 1.0000，代表本實驗未將 Normal 個案誤判為 Abnormal；Sensitivity 為 0.8788，仍有 4 筆 Abnormal 個案被判為 Normal。F1-score 為 0.9355，顯示模型在 precision 與 sensitivity 之間維持良好的綜合表現。此結果說明肺氣腫比例、肺容積、血管與氣道等特徵具有輔助判讀價值，但 Abnormal 個案漏判仍是後續模型優化的主要問題。

表 4.4: RQ1 量化特徵二分類結果

指標	整體結果	五折平均
Accuracy	0.9259	0.9273 ± 0.0680
Precision	1.0000	1.0000 ± 0.0000
Sensitivity	0.8788	0.8810 ± 0.1086
Specificity	1.0000	—
F1-score	0.9355	0.9331 ± 0.0626
AUC	0.9784	0.9657 ± 0.0430




圖 4.1: RQ1 量化特徵二分類混淆矩陣圖

4.3.2 RQ2 三維 Mamba 二分類結果

RQ2 評估三維 CT Mamba 模型於 54 例 Normal/Abnormal 二分類之表現。此任務沿用 RQ1 之二元標籤與五折交叉驗證設定，使三維影像模型可與 CT 量化生物標記分支在相同樣本範圍下比較；其中 Abnormal 組同樣對應 COPD 個案。各指標均以平均值與標準差呈現，如表 4.5 所示。

表 4.5: RQ2 Mamba Normal/Abnormal 二分類結果

指標	五折平均結果
AUC	1.0000 ± 0.0000
Accuracy	0.9409 ± 0.0422
Sensitivity	0.9019 ± 0.0718
Specificity	1.0000 ± 0.0000

Mamba Normal/Abnormal 二分類模型之 AUC 為 1.0000 ± 0.0000 ，Accuracy 為 0.9409 ± 0.0422 ，Specificity 亦達 1.0000 ± 0.0000 。Sensitivity 為 0.9019 ± 0.0718 ，顯示模型仍可能漏判部分 Abnormal 個案。與 RQ1 相比，三維影像模型可直接學習三維 CT 體積資料之空間表徵，整體 Accuracy 與 AUC 略高；但其臨床應用仍需處理 Abnormal 個案漏判

及模型可解釋性不足的問題。

4.3.3 RQ3 三維影像角度預測結果

RQ3 評估三維影像模型預測塌陷角連續值之能力，結果如表 4.6 所示。表中指標為各折評估結果之平均值，其中 MAE 另列標準差。

表 4.6: RQ3 塌陷角連續值迴歸結果

模型	MAE	RMSE	R^2	Pearson
Hybrid Mamba-Attention	15.8512 $\pm$ 4.7756	21.2647	0.1723	0.6699
Mamba	17.1180 $\pm$ 2.5754	23.9086	0.0314	0.3413
SwinUNETR	19.0884 $\pm$ 2.8357	24.3769	-0.0012	0.1898




圖 4.2: Hybrid Mamba-Attention 合併五折測試樣本之塌陷角預測散佈圖

Hybrid Mamba-Attention 取得最低 MAE，平均誤差為 15.8512 ± 4.7756 ，RMSE 為 21.2647，亦為三種模型中最低；五折 Pearson correlation 平均值為 0.6699，同樣優於其

他模型。Mamba 與 SwinUNETR 之 MAE 分別為 17.1180 ± 2.5754 與 19.0884 ± 2.8357 。由圖 4.2 可見，合併五折測試樣本後，真實塌陷角與預測塌陷角仍呈正相關，整體 Pearson correlation 為 0.523。此數值與表 4.6 所列之五折平均值採用不同彙整方式，前者將各折測試預測合併後計算，後者則先分別計算各折相關係數再取平均。散佈圖顯示模型能捕捉部分連續角度變化趨勢；然而迴歸線斜率低於 identity line，且多數預測值集中於約 155° – 175° ，表示模型對低角度樣本有高估傾向，對高角度樣本則略有低估。整體而言，在 Mamba 表徵後加入 attention bridge 可補充塌陷角預測所需之影像資訊；然而 R^2 仍偏低，表示單以 CT 影像精準估計連續肺功能指標仍具限制。

4.3.4 RQ4 塌陷角衍生分類結果

RQ4 比較塌陷角衍生標籤於二分類與三分類任務中的可辨識性。以下先呈現排除 132° – 151° AC 中間組後之 AC 二分類，再呈現保留 AC 中間組之 AC 三分類。baseline 代表各模型未使用虛擬補強之原始設定；aug100 與 aug300 則代表每類虛擬補強至 100 或 300 筆。

AC 二分類結果如表 4.7 所示。

表 4.7: RQ4 AC 二分類結果

模型	設定	Accuracy	Macro-F1	Bal. acc.
TAP-CT late fusion	aug100	0.9192 ± 0.0718	0.8763 ± 0.1186	0.8778 ± 0.1333
Hybrid Mamba-Attention	aug100	0.8692 ± 0.0656	0.8177 ± 0.0761	0.8289 ± 0.0963
Hybrid Mamba-Attention	baseline	0.7705 ± 0.0323	0.4350 ± 0.0101	0.5000 ± 0.0000

排除 AC 中間組後，AC 二分類表現明顯提升。TAP-CT late fusion 搭配 aug100 取得最高 Accuracy (0.9192 ± 0.0718)、Macro-F1 (0.8763 ± 0.1186) 與 Balanced accuracy (0.8778 ± 0.1333)，相較 Hybrid Mamba-Attention baseline 之 Macro-F1 0.4350 有大幅改善。Balanced accuracy 的提升亦表示模型對兩類樣本的辨識較為均衡。此結果指出，AC 低值組與 AC 高值組兩端樣本具有較明確的影像差異；後續 RQ6 進一步檢視 hard voting 是否能在二分類任務之外帶來額外準確率或敏感度改善。

AC 三分類結果如表 4.8 所示。

AC 三分類中，TAP-CT late fusion 搭配 aug100 取得最高 Macro-F1 (0.6141 ± 0.1403)，Accuracy 為 0.8209 ± 0.0939 。TAP-CT-S-2.5D late fusion 雖有最高 Accuracy ($0.8352 \pm$

表 4.8: RQ4 AC 三分類結果

模型	設定	Accuracy	Macro-F1	Bal. acc.
TAP-CT late fusion	aug100	0.8209 ± 0.0939	0.6141 ± 0.1403	0.6326 ± 0.1803
TAP-CT-S-2.5D late fusion	aug100	0.8352 ± 0.0831	0.5884 ± 0.0756	0.5933 ± 0.0952
TAP-CT ABMIL S-3D	baseline	0.7132 ± 0.0846	0.5883 ± 0.1381	0.6400 ± 0.2036
Hybrid Mamba-Attention	baseline	0.7879 ± 0.1018	0.5861 ± 0.1546	0.6200 ± 0.1154
Hybrid Mamba-Attention	aug300	0.7593 ± 0.1173	0.5713 ± 0.0748	0.6319 ± 0.1160

0.0831)，但 Macro-F1 較低，表示類別間辨識較不均衡。若以 Balanced accuracy 觀察，TAP-CT ABMIL S-3D baseline 為 0.6400 ± 0.2036 ，數值最高但跨折變異亦較大，顯示三分類模型仍需同時考量整體正確率、各類別均衡性與結果穩定性。為呈現整體 Accuracy 最高設定之錯誤分布，圖 4.3 採用 TAP-CT-S-2.5D late fusion 繪製混淆矩陣；該模型對 AC 高值組與 AC 低值組具有較穩定的判別能力，五折測試樣本中分別正確分類 43 例與 12 例。然而，AC 中間組 5 例皆被判為 AC 高值組，顯示模型傾向將中間灰區樣本歸入高角度端。相較於二分類，三分類需額外辨識樣本數較少且界線較模糊的 AC 中間組，因此 Macro-F1 明顯下降，顯示中間灰區會增加肺功能相關影像判讀難度。




圖 4.3: TAP-CT-S-2.5D late fusion 塌陷角三分類混淆矩陣

4.3.5 RQ5 三維影像 GOLD 相關候選分級結果

RQ5 評估三維影像模型對 GOLD 相關候選分級之辨識能力，結果如表 4.9 所示。表中結果皆以三折交叉驗證評估。由於四類樣本數不均且 GOLD 4 樣本數最少，本研究以 Macro-F1 作為主要比較指標，以降低多數類別對 Accuracy 的影響。baseline 代表未使用虛擬補強之原始訓練設定；aug36 與 aug200 則分別代表於各訓練折中將類別虛擬補強至每類 36 或 200 筆，並搭配平衡取樣訓練。其中 TAP-CT late fusion 為串接 Hybrid Mamba-Attention CT 特徵與 TAP-CT-B-3D 病人層級 frozen embedding 之融合設定。

表 4.9: RQ5 GOLD 相關候選分級結果

模型	資料設定	Accuracy	Macro-F1	Bal. acc.
Hybrid Mamba-Attention	aug36	0.5606 ± 0.1134	0.5323 ± 0.0479	0.5222 ± 0.0463
Hybrid Mamba-Attention	baseline	0.5152 ± 0.1868	0.4639 ± 0.1645	0.5194 ± 0.0834
Hybrid Mamba-Attention	aug200	0.5606 ± 0.0773	0.4436 ± 0.0674	0.4611 ± 0.0307
TAP-CT late fusion	aug36	0.6061 ± 0.0567	0.4063 ± 0.0479	0.4250 ± 0.0368
SwinUNETR	baseline	0.4444 ± 0.1361	0.3144 ± 0.1559	0.3472 ± 0.1084
Mamba	baseline	0.4259 ± 0.1458	0.3107 ± 0.0392	0.3674 ± 0.0606

Hybrid Mamba-Attention 搭配 aug36 取得最高 Macro-F1 (0.5323 ± 0.0479)，Accuracy 為 0.5606 ± 0.1134 ，Balanced accuracy 為 0.5222 ± 0.0463 。相較於 baseline，aug36 將 Macro-F1 由 0.4639 提升至 0.5323，表示適度補強可改善各類別平均辨識能力。aug200 的 Accuracy 與 aug36 相同，但 Macro-F1 降至 0.4436，顯示過量補強未能改善類別平均表現。

TAP-CT late fusion 搭配 aug36 取得最高 Accuracy (0.6061 ± 0.0567)，但 Macro-F1 僅為 0.4063 ± 0.0479 ，低於 Hybrid Mamba-Attention 的 aug36 與 baseline 設定。合併三折混淆矩陣後，TAP-CT late fusion 對 GOLD 1 具有較高辨識率，GOLD 3 亦有部分正確分類；然而 GOLD 4 未被正確辨識，且 GOLD 2、GOLD 3 與 GOLD 4 之間仍有混淆。此結果顯示 TAP-CT 表徵融合可提高整體正確率，但仍未改善少數嚴重度類別之平均辨識能力。SwinUNETR 與 Mamba baseline 之 Macro-F1 約為 0.31，顯示單純三維影像模型在 GOLD 候選分級上仍受限。




圖 4.4: GOLD 候選分級分類效能比較

4.3.6 RQ6 塌陷角二分類多數決結果

RQ6 針對排除 AC 中間組後之 AC 二分類任務，評估 hard voting 決策彙整對病人層級分類結果之影響。此實驗之候選預測來源與 RQ4 的 AC 二分類任務相同，皆為 TAP-CT late fusion 於相同資料範圍、相同五折切分與相同 AC 低值組/高值組標籤下產生之 validation fold 候選分類輸出。Hard voting 僅將這些既有 AC 二分類候選輸出進行多數決，不加入臨床 Normal/Abnormal 或 GOLD 相關候選分級標籤。表中候選輸出數量為 1 時，代表未投票之原始二分類基準；候選輸出數量為 3、5 與 7 時，則代表 hard voting 使用之 AC 二分類候選分類輸出數量。為使結果聚焦於較直接的錯誤型態，本文僅呈現 Accuracy、Sensitivity 與 Specificity，分別對應整體正確率、AC 低值組召回能力與 AC 高值組辨識能力。

表 4.10: RQ6 塌陷角二分類多數決結果

候選輸出數量	Accuracy	Sensitivity	Specificity
1	0.919 ± 0.072	0.800 ± 0.267	0.956 ± 0.054
3	0.903 ± 0.060	0.800 ± 0.267	0.933 ± 0.089
5	0.919 ± 0.072	0.800 ± 0.267	0.956 ± 0.089
7	0.903 ± 0.080	0.800 ± 0.267	0.933 ± 0.089

由表 4.10 可見，未投票之 TAP-CT late fusion 已取得 0.919 ± 0.072 的 Accuracy；hard voting 中表現最佳的候選輸出數量 5 亦為 0.919 ± 0.072 ，僅與原始二分類基準相

同。Specificity 方面，未投票基準為 0.956 ± 0.054 ，候選輸出數量 5 為 0.956 ± 0.089 ，平均值相近但投票後變異較大。因此，hard voting 並未在本資料中帶來明顯準確率提升，也未比原始二分類結果形成更穩定的特異度表現。

未投票基準與三種候選輸出數量的 Sensitivity 皆為 0.800 ± 0.267 ，且標準差偏高，代表 hard voting 並未改善 AC 低值組樣本之召回能力。候選輸出數量 3 與 7 的 Accuracy 皆為 0.903，低於未投票基準與候選輸出數量 5；其 Specificity 亦降至 0.933。整體而言，hard voting 在本研究中較適合作為結果穩定性檢查，而非主要效能提升策略；其對 accuracy 的增益有限，對 sensitivity 則沒有觀察到改善。



第五章 結論與未來展望

5.1 結論

本研究以胸部 CT 影像為核心，建立 COPD 輔助診斷之影像分析流程，並分別從可解釋 CT 量化生物標記與三維 CT 深度影像模型兩個方向進行評估。量化生物標記分支著重於肺氣腫比例、肺容積、血管與氣道相關特徵之可解釋性；三維影像模型分支則保留完整 CT volume，觀察模型是否能直接由影像空間表徵中學習與 Normal/Abnormal 判讀、肺功能塌陷角與 GOLD 相關候選分級有關之資訊。本文之 Abnormal 組對應合作醫師判定之 COPD 個案。整體而言，本研究結果顯示，胸部 CT 影像不僅可提供結構性病變之量化描述，也具備支援 COPD 相關輔助判讀任務之潛力。

在 Normal/Abnormal 二分類任務中，量化生物標記模型之整體 Accuracy 為 0.9259，AUC 為 0.9784；三維 Mamba 模型於同一 54 例資料中之五折平均 Accuracy 為 0.9409 ± 0.0422 ，AUC 為 1.0000 ± 0.0000 。前者可提供肺氣腫比例、肺容積、氣道與血管等具結構意義之量化依據，後者則可直接由 CT volume 學習空間表徵。兩類方法皆顯示影像資料具有輔助判讀潛力，但目前仍存在 Abnormal 個案漏判與小樣本切分變異等限制。

在肺功能相關任務中，Hybrid Mamba-Attention 於 AC 連續值迴歸取得最低 MAE，為 15.8512 ± 4.7756 ，但 R^2 僅為 0.1723，顯示影像模型尚不足以取代肺功能檢查。將 AC 轉換為衍生分類標籤後，排除 AC 中間組之二分類表現優於三分類，說明灰區樣本仍是模型判讀的主要難點。進一步以 hard voting 彙整 AC 二分類候選輸出時，候選輸出數量 5 之 Accuracy 為 0.919 ± 0.072 ，與未投票之 TAP-CT late fusion 原始二分類基準相同，顯示多數決並未帶來明顯準確率提升；未投票基準與三種候選輸出數量之 Sensitivity 皆維持 0.800 ± 0.267 ，代表 AC 低值組樣本之召回能力仍需改善。

GOLD 相關候選分級之最佳 Macro-F1 為 0.5323 ± 0.0479 ，仍低於 Normal/Abnormal 與 AC 二分類任務。此結果反映細緻嚴重度候選分級除受樣本數與類別不平衡影響外，亦需要症狀、病史與完整肺功能資訊共同判讀。因此，本研究之 GOLD 分級結果應定位為初步探索，而非完整臨床診斷模型。

綜合上述結果，胸部 CT 影像可透過量化生物標記與三維深度影像模型兩種互補形式支援 COPD 輔助判讀。前者有助於描述肺部結構變化，後者可學習較複雜的空間表

徵；然而，較細緻之肺功能相關任務仍需更多資料與臨床資訊支持。本研究成果較適合作為影像輔助判讀流程之可行性基礎，而非取代現行肺功能檢查或臨床診斷流程。

5.2 研究限制

本研究仍存在數項限制。第一，資料量有限且主要來自單一合作來源，雖已採交叉驗證降低資料切分偶然性，但尚未完成外部資料集驗證，因此模型泛化能力仍需保守解讀。第二，不同任務之資料範圍並不完全相同，量化生物標記分支與三維影像模型分支使用之樣本數、標籤來源與前處理流程皆有所差異，故跨分支比較應視為趨勢觀察，而非完全等條件下的模型競賽。

第三，量化生物標記高度依賴肺部、肺葉、血管與氣道分割品質。若分割遮罩出現邊界錯誤、末端血管或氣道漏失，肺氣腫比例、血管密度與氣道相關比例皆可能受影響。第四，GOLD 相關候選分級以肺功能資料整理之 FEV1 predicted 分組作為監督標籤，但完整 GOLD 評估仍需納入支氣管擴張劑後 FEV1/FVC、症狀負擔、急性惡化史與臨床判讀，因此本研究不宜將其直接等同於完整臨床分級。第五，三維深度模型雖可取得較高分類效能，但模型解釋性、錯誤案例分析與臨床可用門檻仍需進一步補強。第六，hard voting 僅彙整 AC 二分類任務既有候選輸出，仍可能受候選輸出數量與類別不平衡影響；若多數候選結果偏向 AC 高值組，AC 低值組樣本仍可能被稀釋。

5.3 未來展望

後續研究可由資料、模型與臨床驗證三個方向延伸。資料面上，應持續擴充胸部 CT 與 PFT 配對資料，並納入不同掃描設備、掃描協議與醫療場域之資料，以驗證模型對外部資料的穩定性。若能建立多中心資料集，將有助於評估模型是否能跨機構、跨掃描條件維持相近表現。

模型面上，量化生物標記分支可進一步強化肺葉、血管與氣道分割品質控管，並建立自動化失敗偵測機制，以降低錯誤分割對特徵計算之影響。三維影像模型則可加入模型校準、不確定性估計與可解釋性分析，例如觀察模型關注區域是否對應肺氣腫、氣道壁增厚或血管稀疏等 COPD 相關影像表徵。對於 AC 與 GOLD 相關任務，未來可

嘗試以多任務學習同時預測 Normal/Abnormal、塌陷角與候選分級，使模型共享與肺功能變化相關之影像表徵。由於本研究 hard voting 對 accuracy 與 sensitivity 的改善有限，後續若要使用決策彙整，應改以加權投票、機率平均或不確定性估計等方式檢驗是否能真正降低 AC 低值組樣本漏判。

臨床應用面上，後續可將 CT 影像特徵與年齡、性別、吸菸史、症狀量表、PFT 指標及醫師判讀結果整合為多模態模型。此類模型較能貼近 COPD 實際診斷流程，也可降低單一影像模型對資料偏差或標籤不確定性的敏感度。最終，若要進入臨床輔助判讀情境，仍需進行前瞻性驗證、錯誤案例審查與臨床工作流程評估，確認模型輸出能以可解釋且可被醫師採納的方式補充現有診斷資訊。



参考文献

- [1] Global Initiative for Chronic Obstructive Lung Disease. *Global Strategy for the Diagnosis, Management, and Prevention of Chronic Obstructive Pulmonary Disease: 2025 Report*. Global Initiative for Chronic Obstructive Lung Disease, 2025. URL: <https://goldcopd.org/2025-gold-report/>.
- [2] Sohee Park et al. “Quantitative CT imaging in chronic obstructive pulmonary disease”. In: *British Journal of Radiology* (2025). DOI: 10.1093/bjr/tqaf105.
- [3] Geert Litjens et al. “A survey on deep learning in medical image analysis”. In: *Medical Image Analysis* 42 (2017). DOI: 10.1016/j.media.2017.07.005.
- [4] Hyunjung Park et al. “Deep Learning-based Approach to Predict Pulmonary Function at Chest CT”. In: *Radiology* 307.2 (2023). DOI: 10.1148/radiol.221488.
- [5] Haibo He and Eduardo A. Garcia. “Learning from Imbalanced Data”. In: *IEEE Transactions on Knowledge and Data Engineering* 21.9 (2009). DOI: 10.1109/TKDE.2008.239.
- [6] Marko Topalovic et al. “Computer quantification of airway collapse on forced expiration to predict the presence of emphysema”. In: *Respiratory Research* 14.1 (2013), p. 131. DOI: 10.1186/1465-9921-14-131.
- [7] Shin Matsuoka et al. “Quantitative CT assessment of chronic obstructive pulmonary disease”. In: *Radiographics* 30.1 (2010). DOI: 10.1148/rg.301095110.
- [8] Pierre A. Gevenois et al. “Comparison of computed density and macroscopic morphometry in pulmonary emphysema”. In: *American Journal of Respiratory and Critical Care Medicine* 152.2 (1995). DOI: 10.1164/ajrccm.152.2.7633722.
- [9] Jens T. Bakker et al. “Measuring pulmonary function in COPD using quantitative chest computed tomography analysis”. In: *European Respiratory Review* 30.161 (2021). DOI: 10.1183/16000617.0031-2021.
- [10] George R. Washko et al. “Computed tomographic measures of airway morphology in smokers and never-smoking normals”. In: *Journal of Applied Physiology* 116.6 (2014). DOI: 10.1152/japplphysiol.00004.2013.
- [11] Ivan Dudurych et al. “Bronchial wall parameters on CT in healthy never-smoking, smoking, COPD, and asthma populations: a systematic review and meta-analysis”. In: *European Radiology* 32 (2022). DOI: 10.1007/s00330-022-08600-1.
- [12] Shin Matsuoka et al. “Quantitative CT measurement of cross-sectional area of small pulmonary vessel in COPD: correlations with emphysema and airflow limitation”. In: *Academic Radiology* 17.1 (2010). DOI: 10.1016/j.acra.2009.07.022.

- [13] J. Michael Wells et al. “Pulmonary arterial enlargement and acute exacerbations of COPD”. In: *New England Journal of Medicine* 367.10 (2012). DOI: 10 . 1056 / NEJMoa1203830.
- [14] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. “U-Net: Convolutional Networks for Biomedical Image Segmentation”. In: *Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015*. Vol. 9351. Lecture Notes in Computer Science. 2015. DOI: 10.1007/978-3-319-24574-4_28.
- [15] Fabian Isensee et al. “nnU-Net: a self-configuring method for deep learning-based biomedical image segmentation”. In: *Nature Methods* 18.2 (2021). DOI: 10 . 1038 / s41592-020-01008-z.
- [16] Andriy Fedorov et al. “3D Slicer as an image computing platform for the Quantitative Imaging Network”. In: *Magnetic Resonance Imaging* 30.9 (2012). DOI: 10 . 1016 / j . mri . 2012 . 05 . 001.
- [17] M. Jorge Cardoso et al. “MONAI: An open-source framework for deep learning in health-care”. In: *arXiv preprint arXiv:2211.02701* (2022). DOI: 10 . 48550 / arXiv . 2211 . 02701.
- [18] Johannes Hofmanninger et al. “Automatic lung segmentation in routine imaging is primarily a data diversity problem, not a methodology problem”. In: *European Radiology Experimental* 4.1 (2020). DOI: 10 . 1186/s41747-020-00173-2.
- [19] Jakob Wasserthal et al. “TotalSegmentator: Robust Segmentation of 104 Anatomic Structures in CT Images”. In: *Radiology: Artificial Intelligence* 5.5 (2023). DOI: 10 . 1148 / ryai . 230024.
- [20] Thomas Z. Li et al. “Quantifying emphysema in lung screening computed tomography with robust automated lobe segmentation”. In: *Journal of Medical Imaging* 10.4 (2023). DOI: 10.1117/1.JMI.10.4.044002.
- [21] Antonio Garcia-Uceda et al. “Automatic airway segmentation from computed tomography using robust and efficient 3-D convolutional neural networks”. In: *Scientific Reports* 11 (2021). DOI: 10 . 1038/s41598-021-95364-1.
- [22] Karen-Helene Støverud et al. “AeroPath: An airway segmentation benchmark dataset with challenging pathology and baseline method”. In: *PLOS ONE* 19.10 (2024). DOI: 10.1371/journal.pone.0311416.
- [23] Yulei Qin et al. “Learning Tubule-Sensitive CNNs for Pulmonary Airway and Artery-Vein Segmentation in CT”. In: *IEEE Transactions on Medical Imaging* 40.6 (2021). DOI: 10.1109/TMI.2021.3062280.

- [24] Kaiwen Geng et al. “BeyondCT: A deep learning model for predicting pulmonary function from chest CT scans”. In: *arXiv preprint arXiv:2408.05645* (2024). DOI: 10.48550/arXiv.2408.05645.
- [25] Alexey Dosovitskiy et al. “An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale”. In: *International Conference on Learning Representations*. 2021. URL: <https://openreview.net/forum?id=YicbFdNTTy>.
- [26] Yanan Wu et al. “A vision transformer for emphysema classification using CT images”. In: *Physics in Medicine & Biology* 66.24 (2021). DOI: 10.1088/1361-6560/ac3dc8.
- [27] Ze Liu et al. “Swin Transformer: Hierarchical Vision Transformer Using Shifted Windows”. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision*. 2021. DOI: 10.1109/ICCV48922.2021.00986.
- [28] Ali Hatamizadeh et al. “Swin UNETR: Swin Transformers for Semantic Segmentation of Brain Tumors in MRI Images”. In: *arXiv preprint arXiv:2201.01266* (2022). DOI: 10.48550/arXiv.2201.01266.
- [29] Albert Gu and Tri Dao. “Mamba: Linear-Time Sequence Modeling with Selective State Spaces”. In: *arXiv preprint arXiv:2312.00752* (2023). DOI: 10.48550/arXiv.2312.00752.
- [30] Haifan Gong et al. “nnMamba: 3D Biomedical Image Segmentation, Classification and Landmark Detection with State Space Model”. In: *arXiv preprint arXiv:2402.03526* (2024). DOI: 10.48550/arXiv.2402.03526.
- [31] Zhaohu Xing et al. “SegMamba: Long-range Sequential Modeling Mamba For 3D Medical Image Segmentation”. In: *Medical Image Computing and Computer Assisted Intervention – MICCAI 2024*. Vol. 15008. Lecture Notes in Computer Science. Springer Nature Switzerland, 2024. DOI: 10.1007/978-3-031-72111-3_54.
- [32] Yubiao Yue and Zhenzhang Li. “MedMamba: Vision Mamba for Medical Image Classification”. In: *arXiv preprint arXiv:2403.03849* (2024). DOI: 10.48550/arXiv.2403.03849.
- [33] Thomas G. Dietterich. “Ensemble Methods in Machine Learning”. In: *Multiple Classifier Systems*. Vol. 1857. Lecture Notes in Computer Science. Springer, 2000, pp. 1–15. DOI: 10.1007/3-540-45014-9_1.
- [34] Ludmila I. Kuncheva. *Combining Pattern Classifiers: Methods and Algorithms*. Hoboken, NJ: Wiley-Interscience, 2004. DOI: 10.1002/0471660264.
- [35] Tim Veenboer et al. “TAP-CT: 3D Task-Agnostic Pretraining of Computed Tomography Foundation Models”. In: *arXiv preprint arXiv:2512.00872* (2025). DOI: 10.48550/arXiv.2512.00872.

- [36] Sanja Stanojevic et al. “ERS/ATS technical standard on interpretive strategies for routine lung function tests”. In: *European Respiratory Journal* 60.1 (2022), p. 2101499. DOI: 10.1183/13993003.01499-2021.
- [37] Maximilian Ilse, Jakub M. Tomczak, and Max Welling. “Attention-based Deep Multiple Instance Learning”. In: *Proceedings of the 35th International Conference on Machine Learning*. Vol. 80. Proceedings of Machine Learning Research. PMLR, 2018, pp. 2127–2136. URL: <https://proceedings.mlr.press/v80/ilse18a.html>.
- [38] Tom Fawcett. “An introduction to ROC analysis”. In: *Pattern Recognition Letters* 27.8 (2006). DOI: 10.1016/j.patrec.2005.10.010.

