



國立臺北科技大學

資訊工程系碩士班

碩士學位論文

胸部 CT 影像於 COPD 輔助診斷之研究

**A Study on the Auxiliary Diagnosis of COPD using
Chest CT images**

研究生：張博翔

指導教授：劉建宏、尤信程

中華民國一百一十五年七月



國立臺北科技大學

資訊工程系碩士班

碩士學位論文

胸部 CT 影像於 COPD 輔助診斷之研究
A Study on the Auxiliary Diagnosis of COPD using
Chest CT images

研究生：張博翔

指導教授：劉建宏、尤信程

中華民國一百一十五年七月

「學位論文口試委員會審定書」掃描檔

審定書填寫方式以系所規定為準，但檢附在電子論文內的掃描檔須具備以下條件：

1. 含指導教授、口試委員及系所主管的完整簽名。
2. 口試委員人數正確，碩士口試委員至少 3 人、博士口試委員至少 5 人。
3. 若此頁有論文題目，題目應和書背、封面、書名頁、摘要頁的題目相符。
4. 此頁有無浮水印皆可。

摘要

關鍵詞：胸部 CT、慢性阻塞性肺病、量化生物標記、Hybrid Mamba-Attention、TAP-CT、類別不平衡

慢性阻塞性肺病（Chronic Obstructive Pulmonary Disease, COPD）為一種與氣道阻塞、肺氣腫相關之慢性呼吸道疾病。臨床上雖以肺功能檢查作為主要診斷依據，胸部電腦斷層影像（computed tomography, CT）仍可提供肺實質、氣道、血管等結構性資訊，具備作為輔助診斷與疾病表徵分析之潛力。本研究旨在建立以胸部 CT 影像為基礎之 COPD 輔助診斷流程，並結合可解釋之影像量化生物標記與 3D 深度影像模型，探討 CT 影像於正異常分類與肺功能相關塌陷角度分級之應用可行性。

本研究首先針對 54 筆臨床胸部 CT 影像建立量化特徵分析流程，由 CT 影像產生肺葉、血管與氣道相關分割標籤，並擷取 12 項具臨床意義之量化生物標記，包括全肺與分葉肺氣腫比例、小血管體積比例、氣道壁比例、血管密度、氣道肺體積比例、總肺容積及肺動脈直徑。分類模型採用全連接神經網路，並以 stratified five-fold cross validation 評估 Normal/Abnormal 分類效能。實驗結果顯示，量化特徵模型可達 92.59% 之整體準確率、0.9355 之 F1-score 與 0.9784 之 AUC，顯示胸部 CT 量化生物標記可提供具可解釋性之 COPD 輔助判讀依據。

其次，本研究進一步使用 66 筆具肺功能相關標籤之 3D CT 影像，將原始影像輸入 Mamba、SwinUNETR 與 Hybrid Mamba-Attention 等模型，分別進行以 131° 與 152° 為門檻之塌陷角度（Angle of Collapse, AC）三分類，以及排除 132° 至 151° 區間的二分類。為降低小樣本與類別不平衡的偏差，本研究採用交叉驗證，並僅於訓練中進行資料增強與平衡取樣。結果顯示，結合預先萃取之 TAP-CT 影像嵌入後，AC 三分類可達 0.8209 之 accuracy、0.6141 之 Macro-F1 與 0.6326 之 balanced accuracy，極端二分類則可達 0.9192 之 accuracy、0.8763 之 Macro-F1 與 0.8778 之 balanced accuracy。整體而言，本研究結果顯示，胸部 CT 量化生物標記與 3D 深度影像模型具有互補性，可分別提供可解釋之結構量化依據與影像層級之肺功能表徵學習能力，並可作為 COPD 輔助診斷之參考。

ABSTRACT

Keyword: chest CT, COPD, quantitative biomarkers, Hybrid Mamba-Attention, TAP-CT, class imbalance

Chronic obstructive pulmonary disease (COPD) is a chronic respiratory disease associated with airway obstruction and emphysema. Although pulmonary function testing remains the primary clinical basis for diagnosis, chest computed tomography (CT) provides structural information about lung parenchyma, airways, and vasculature, making it a potential source of auxiliary diagnostic evidence. This study develops a CT-based COPD auxiliary diagnostic framework that combines interpretable quantitative imaging biomarkers with 3D deep learning models, and evaluates its feasibility for Normal/Abnormal classification and pulmonary-function-related angle stratification.

For quantitative analysis, 54 clinical chest CT scans were processed to generate lobe, vessel, and airway label maps. Twelve clinically meaningful biomarkers were extracted, including emphysema percentages, small vessel volume ratio, airway wall ratio, vessel density, airway-to-lung volume ratio, total lung volume, and pulmonary artery diameter. A fully connected neural network with stratified five-fold cross-validation achieved 92.59% accuracy, an F1-score of 0.9355, and an AUC of 0.9784 for Normal/Abnormal classification, indicating that CT-derived biomarkers can provide interpretable evidence for COPD assessment.

For 3D image-based learning, 66 CT scans with pulmonary-function-related labels were evaluated using Mamba, SwinUNETR, and Hybrid Mamba-Attention models. The tasks included Angle of Collapse (AC) three-class classification using 131° and 152° as thresholds, and binary classification after excluding cases between 132° and 151° . With fused TAP-CT embeddings, AC three-class classification achieved 0.8209 accuracy, 0.6141 Macro-F1, and 0.6326 balanced accuracy, while binary classification achieved 0.9192 accuracy, 0.8763 Macro-F1, and 0.8778 balanced accuracy. Overall, CT-derived biomarkers and 3D models provide complementary evidence and may serve as references for COPD auxiliary diagnosis.

誌謝

所有對於研究提供協助之人或機構，作者都可在誌謝中表達感謝之意。



目錄

摘要	i
ABSTRACT	ii
誌謝	iii
目錄	iv
表目錄	vi
圖目錄	vii
第一章 緒論	1
1.1 研究背景與動機	1
1.2 研究目的	2
1.3 論文架構	3
第二章 文獻回顧	4
2.1 慢性阻塞性肺病與肺功能檢查	4
2.2 CT 影像表徵與量化生物標記	5
2.3 肺部、氣道與血管影像分割	7
2.4 三維醫學影像深度學習模型	9
2.5 TAP-CT	11
第三章 研究材料與方法	12
3.1 研究流程	12
3.2 資料集	13
3.3 資料前處理	14
3.4 肺部結構分割與量化參數擷取	15
3.5 量化 CT 分類模型	17
3.6 三維 CT 網路架構設計	19
3.7 塌陷角迴歸任務	20
3.8 TAP-CT 影像嵌入與融合策略	20
3.9 交叉驗證、資料增強與平衡取樣	21
3.10 評估指標	23

第四章	實驗結果與討論	26
4.1	研究問題	26
4.2	實驗環境設定	26
4.3	實驗結果分析	27
4.3.1	RQ1 量化特徵二分類結果	27
4.3.2	RQ2 三維影像模型二分類結果	28
4.3.3	RQ3 三維影像角度預測結果	29
4.3.4	RQ4 塌陷角能否提升肺功能相關影像判讀	30
4.3.5	RQ5 三維影像 GOLD 四分類結果	32
第五章	結論與未來展望	34
5.1	研究結論	34
5.2	未來工作	34
參考文獻		35




表目錄

3.1	本研究影像資料組成	13
3.2	肺功能相關標籤定義	14
4.1	實驗硬體設備	26
4.2	CT 量化生物標記分支實驗環境	27
4.3	三維 CT 深度學習分支實驗環境	27
4.4	RQ1 量化特徵二分類結果	27
4.5	RQ2 三維影像二分類實驗結果	29
4.6	RQ3 塌陷角連續值迴歸結果	30
4.7	RQ4 AC 三分類結果	31
4.8	RQ4 AC 二分類結果	31
4.9	RQ5 GOLD 相關候選分級結果	32



圖目錄

4.1	RQ1 量化特徵二分類混淆矩陣圖	28
4.2	三維影像二分類效能比較	29
4.3	塌陷角連續值迴歸平均絕對誤差比較	30
4.4	塌陷角三分類效能比較	31
4.5	塌陷角二分類效能比較	32
4.6	候選分級分類效能比較	33



第一章 緒論

1.1 研究背景與動機

慢性阻塞性肺病（Chronic Obstructive Pulmonary Disease, COPD）是一種以持續性氣流受限為主要特徵之慢性呼吸道疾病，其病理變化常包含肺實質破壞、肺氣腫、氣道發炎、氣道重塑與肺部血管變化。COPD 進展通常具有長期性與不可完全逆轉之特性，若未能及早發現並追蹤，其肺功能下降、急性惡化與生活品質受損等問題將對病患照護造成持續負擔 [1]。因此，如何利用既有臨床影像資料提供客觀、可重複且可解釋之輔助資訊，是 COPD 研究與醫療決策支援中重要的課題。

临床上，COPD 之診斷與嚴重程度評估主要仰賴肺功能檢查。肺功能檢查能反映整體呼吸生理狀態，並提供氣流受限程度之量化依據 [1]。然而，肺功能檢查較難直接呈現肺部結構異常之位置、範圍與型態；相同肺功能表現之病患，在肺氣腫分布、氣道壁變化、肺過度充氣與血管結構改變上仍可能存在差異。若僅依賴單一生理測量結果，可能不足以完整描述 COPD 的影像表型 [2]。

胸部電腦斷層影像（computed tomography, CT）具有高空間解析度，可呈現肺實質、氣道、血管與肺葉分布等解剖資訊。透過 CT 影像，可觀察低衰減區域所對應之肺氣腫變化、肺容積增加所反映之過度充氣現象，以及氣道與血管相關結構特徵。若能將 CT 影像進一步轉換為可量化之影像生物標記，便可使影像分析由主觀判讀延伸至數值化描述，並提供 COPD 輔助診斷與後續追蹤之參考 [2]。

近年醫學影像分析逐漸結合自動分割、量化特徵擷取與深度學習模型。對於 COPD CT 影像而言，自動化流程可先由肺葉、氣道與血管等結構分割開始，再計算肺氣腫比例、肺容積、氣道相關比例與血管相關指標等特徵；此類特徵具有較高可解釋性，能與 COPD 病理變化相互對應 [2]。另一方面，三維深度影像模型可直接由 CT 體積資料學習空間表徵，補足人工定義特徵可能無法涵蓋之影像訊息 [3, 4]。兩類方法各有優勢：量化特徵方法較容易解釋，深度影像模型則具備自動特徵學習能力。

然而，實際醫學影像研究常受限於資料量不足、掃描協議不一致、分割品質差異與類別分布不均等問題。若模型評估僅呈現整體準確率，容易忽略資料不平衡造成的偏差，也可能掩蓋異常個案漏判等临床上更需關注的問題 [5]。因此，本研究以胸部 CT

影像為核心，建立 COPD 輔助診斷之自動化分析流程，並以可解釋量化特徵與三維影像模型進行比較，探討兩者在小樣本資料下應用於 Normal/Abnormal 分類、肺功能塌陷角連續值迴歸、塌陷角分級與 GOLD 相關候選分級等 COPD 相關輔助判讀任務之可行性。

1.2 研究目的

本研究旨在建立以胸部 CT 影像為基礎之 COPD 輔助診斷流程，將影像資料轉換為具臨床意義之量化資訊，並評估不同影像分析策略於分類與肺功能相關表徵預測任務中之表現。研究目的分述如下。

首先，本研究建置胸部 CT 影像前處理與肺部結構分割流程，將原始影像轉換為後續量化分析可使用之資料格式，並擷取肺葉、氣道與血管等結構資訊。透過自動化流程，可降低人工處理成本，並提高多筆影像資料分析之一致性。

其次，本研究依據 COPD 相關影像表徵擷取 CT 量化生物標記，包括全肺與各肺葉肺氣腫比例、肺容積、氣道相關比例、血管密度、小血管體積比例與肺動脈相關指標等特徵。此類特徵可對應肺實質破壞、過度充氣、氣道重塑與血管變化等 COPD 相關結構異常，作為可解釋分類模型之輸入 [2]。

第三，本研究使用量化生物標記建立 Normal/Abnormal 分類模型，評估其區分正常與異常胸部 CT 個案之能力。模型評估採用交叉驗證，並搭配 accuracy、precision、recall、F1-score、AUC 與混淆矩陣等指標，以觀察模型整體表現及錯誤分類型態。

第四，本研究使用三維 CT 深度學習模型分析原始影像資料，評估其於 COPD 相關影像分類與肺功能相關表徵預測任務中之可行性。此部分先以塌陷角連續值迴歸觀察三維 CT 表徵對肺功能曲線衍生指標之預測能力，再延伸至 Normal/Abnormal 分類、塌陷角三分類、排除中間灰區後之二分類，以及 GOLD 相關候選分級分類，並與量化特徵方法進行比較。

最後，本研究針對小樣本與類別不平衡問題，探討資料分割、資料增強、平衡取樣與多指標評估對結果解讀之影響，避免以單一指標過度推論模型效能，並使研究結果維持於臨床輔助判讀與方法可行性評估之定位。

1.3 論文架構

本論文共分為五章，其架構說明如下：

1. **第一章：**說明研究背景與動機、研究目的及論文架構。
2. **第二章：**整理 COPD 臨床背景、胸部 CT 影像分析、肺部結構分割、CT 量化生物標記、三維醫學影像模型與肺功能相關表徵預測之相關研究。
3. **第三章：**說明研究材料與方法，包含資料來源、影像前處理、肺部結構分割、量化參數擷取、分類模型、三維影像模型、塌陷角連續值迴歸、塌陷角衍生分類標籤、GOLD 相關候選分級與評估方法。
4. **第四章：**呈現實驗結果與討論，包含 CT 量化特徵分類結果、三維 CT 影像模型分類結果、塌陷角迴歸與衍生分類結果、GOLD 相關候選分級結果、錯誤案例分析與綜合討論。
5. **第五章：**總結本研究成果，並提出後續於資料擴充、分割品質改善、模型泛化驗證與臨床應用評估之未來方向。

第二章 文獻回顧

2.1 慢性阻塞性肺病與肺功能檢查

慢性阻塞性肺病（Chronic Obstructive Pulmonary Disease, COPD）是一種常見且具有異質性的慢性呼吸道疾病，其核心特徵為持續性呼吸道症狀與氣流受限。COPD 的病理變化通常涉及小氣道發炎與重塑、氣道狹窄、肺實質破壞、肺氣腫與氣體滯留等現象，因此病患可能出現慢性咳嗽、咳痰、活動性喘促與運動耐受度下降等臨床表現。由於 COPD 之疾病進展具有長期性，且肺功能下降後不易完全恢復，臨床上需透過客觀檢查評估氣流受限程度與疾病嚴重度 [1]。

肺功能檢查（Pulmonary Function Test, PFT）是 COPD 診斷與嚴重程度評估中最重要之生理測量工具，其中又以肺量計測定（spirometry）最常用。肺量計測定可量測用力肺活量（Forced Vital Capacity, FVC）、一秒用力呼氣容積（Forced Expiratory Volume in one second, FEV1）與 FEV1/FVC 比值。FVC 代表受測者深吸氣後以最大力量呼出的總氣體量；FEV1 則代表用力呼氣第一秒內排出的氣體量；FEV1/FVC 比值可反映第一秒呼出量相對於總用力肺活量的比例，因此常用於判斷是否存在氣流受限。依 GOLD 指引，支氣管擴張劑後 FEV1/FVC 小於 0.70 為確認持續性氣流受限的重要判準之一 [1]。

除 FEV1、FVC 與 FEV1/FVC 外，肺功能檢查亦可包含中段用力呼氣流速（Forced Expiratory Flow between 25% and 75% of FVC, FEF25–75%）、尖峰呼氣流速（Peak Expiratory Flow, PEF）、肺活量（Vital Capacity, VC）、肺總量（Total Lung Capacity, TLC）與肺餘容積（Residual Volume, RV）等指標。這些指標可從不同角度反映呼氣流速、肺容量與氣體滯留情形。例如 FEF25–75% 常被用於觀察中小氣道功能，RV 增加則可能與氣體滯留有關。雖然上述指標能提供更完整的呼吸生理資訊，但 COPD 嚴重度分級與本研究後續標籤設計主要仍以 FEV1 及其預測值百分比為核心。

在已確認氣流受限的情況下，GOLD 分級通常依支氣管擴張劑後 FEV1 佔預測值百分比（FEV1 percent predicted）區分氣流受限嚴重程度。FEV1 預測值會依年齡、身高、性別等生理條件估計，再以實測 FEV1 除以預測值取得百分比。GOLD 1 為 FEV1 大於或等於 80% 預測值，代表輕度氣流受限；GOLD 2 為 50% 至未滿 80%，代表中度氣流受限；GOLD 3 為 30% 至未滿 50%，代表重度氣流受限；GOLD 4 則為低於 30%，代表

極重度氣流受限 [1]。此分級方式可將連續的肺功能數值轉換為具臨床意義的嚴重度類別，因此常作為 COPD 相關研究中的標籤依據。

然而，肺功能檢查主要反映整體呼吸生理狀態，較難直接指出肺部結構異常的位置、型態與分布。同樣的 FEV1 或 GOLD 分級可能對應不同程度的肺氣腫、氣道壁增厚、過度充氣或血管改變，因此單一肺功能指標未必能完整描述 COPD 的影像表型 [2]。基於此限制，本研究後續將 PFT 相關資訊視為重要參考標籤，並結合胸部 CT 影像之量化特徵與三維影像模型，探討影像資訊對 COPD 輔助判讀與肺功能相關表徵預測之補充價值。

除傳統肺量計數值外，流量容積曲線之幾何表徵亦可反映呼氣過程中的曲線形狀變化。Topalovic 等人以塌陷角度（Angle of Collapse, AC）描述曲線凹陷程度，並指出其與肺氣腫表徵具有關聯 [6]。相較於直接將個案壓縮為單一正常或異常類別，AC 為連續角度，可保留不同病人之肺功能曲線差異；若再依具解釋意義之角度門檻建立分級標籤，則可進一步觀察連續肺功能表徵轉換為分類任務後對模型學習與結果解讀之影響。因此，本研究同時將 AC 視為連續迴歸目標與衍生分類標籤來源，以完整記錄由肺功能表徵預測到輔助分級之實驗過程。

需要注意的是，本研究部分實驗使用資料集中支氣管擴張劑後 FEV1 佔預測值百分比建立 GOLD 相關分類標籤。由於正式 COPD 診斷與 GOLD 氣流受限分級仍需整合 FEV1/FVC 判準、症狀、病史與臨床判讀，因此本文在結果詮釋上將其視為肺功能導向之嚴重度候選標籤，而不直接等同完整臨床診斷或臨床分期。

2.2 CT 影像表徵與量化生物標記

胸部電腦斷層影像具有高空間解析度，可呈現肺實質、氣道、血管與肺葉分布等解剖結構，因此常被用於補充肺功能檢查無法直接呈現的局部結構資訊。對 COPD 而言，CT 影像中常見的結構性表徵包含肺氣腫造成的低衰減區域、肺過度充氣所反映的肺容積增加、氣道壁增厚或氣道狹窄，以及肺血管床減少或肺動脈相關變化等。這些影像表徵可對應 COPD 中肺實質破壞、小氣道病變與血管重塑等病理變化，因此 CT 不僅可作為視覺判讀工具，也可作為影像量化分析的資料來源 [7, 2]。

肺氣腫是 COPD 在 CT 影像中最常被量化的表徵之一。肺氣腫區域因肺泡壁破壞與

氣腔擴大而呈現較低密度，因此在吸氣相 CT 中常以低衰減區域比例描述其範圍。常見作法是在肺部遮罩內計算低於特定 Hounsfield unit 閾值的 voxel 比例，例如低於 -950 HU 的低衰減區比例可作為肺氣腫負荷之指標。Gevenois 等人比較 HRCT 密度與肺組織巨觀形態量測後指出，-950 HU 閾值與巨觀肺氣腫量測具良好對應，因此此閾值常作為定量肺氣腫分析的依據之一 [8]。此類指標可進一步依肺葉計算，以呈現肺氣腫分布是否集中於特定肺葉或呈現不均勻分布。相較於僅以整體肺功能數值描述病患狀態，肺葉別肺氣腫比例能提供更具有位置資訊的影像表型描述。

肺容積與過度充氣亦是 COPD 影像評估中的重要概念。COPD 患者因氣流受限與呼氣不完全，可能產生氣體滯留與肺過度充氣，使總肺體積或特定肺葉體積出現改變。CT 影像若經過肺部或肺葉分割，便可依 voxel spacing 計算實際體積，將肺部形態由視覺印象轉換為可比較的數值。Bakker 等人回顧 quantitative CT 與肺功能檢查之關係時指出，CT 可萃取 residual volume、total lung capacity 等肺容積資訊，且此類 CT-derived lung volume 與 PFT 量測之肺容積具有相關性，特別適合用於描述 COPD 的過度充氣相關表徵 [9]。此類體積特徵雖可能受吸氣程度、體型差異與掃描範圍影響，但仍可作為描述 COPD 影像表徵的重要補充資訊。

除肺實質外，COPD 亦會影響氣道結構。慢性發炎與氣道重塑可能造成氣道壁增厚、氣道腔狹窄與小氣道阻塞。CT 量化分析中常見的氣道相關指標包含氣道壁比例 (wall area percentage, WA%)、氣道體積與肺體積之比例，以及由氣道遮罩推估的相關形態特徵。既有研究指出，WA% 是 COPD 吸菸族群中常用的中央氣道形態量測指標，且與 FEV1 預測值百分比具有相關性；系統性回顧亦顯示 WA%、wall thickness、Pi10 與 luminal area 等 CT 氣道參數已被廣泛用於 COPD 與相關呼吸疾病研究 [10, 11]。理想情況下，WA% 需根據氣道腔與氣道壁的可靠分割結果計算；若缺乏完整的 lumen 與 wall 標註，則只能以可取得之氣道遮罩或氣管標籤進行近似估計。因此，在使用氣道量化指標時，必須同時說明分割來源與計算限制，避免將自動估計結果過度解釋為精確的小氣道壁厚量測。

肺血管變化也是 COPD 影像分析中逐漸受到重視的面向。肺氣腫造成肺泡壁與微血管床破壞，可能使血管密度下降；另一方面，COPD 亦可能伴隨肺血管重塑與肺動脈壓力相關變化。Matsuoka 等人以 CT 量測小肺血管橫截面積，發現小血管面積比例與肺氣腫比例及肺功能指標相關，顯示肺血管量化可提供肺實質破壞以外的補充資訊

[12]。因此，CT 影像中可由血管分割結果計算總血管體積、血管密度、小血管體積比例（small vessel volume percentage, SVV%）與肺動脈直徑等指標。血管密度通常可定義為分割血管體積相對於總肺體積之比例；SVV% 則可透過血管遮罩與距離轉換等方式估計小血管負荷。肺動脈與主動脈直徑比例（PA:A ratio）亦常被視為肺血管與肺高壓相關的影像指標；Wells 等人曾以 CT 上肺動脈與主動脈直徑比例大於 1 作為肺動脈擴大指標，並探討其與 COPD 急性惡化之關係 [13]。然而，若缺乏可靠主動脈分割或標準化人工量測流程，則不宜將 PA:A ratio 列為已完成之自動量化結果。

綜合而言，CT 量化生物標記的價值在於將 COPD 相關影像表徵轉換為客觀、可重複且可供模型分析的數值。本研究採用之 CT 特徵並非任意挑選，而是依據既有 COPD quantitative CT 文獻中常見且具病理對應之影像表徵整理而成：肺氣腫比例可反映肺實質破壞，肺容積可描述過度充氣與形態差異，氣道指標可對應氣道重塑，血管指標則補充肺血管床與肺動脈相關資訊。這些特徵具有較高可解釋性，適合用於小樣本資料下的傳統機器學習或神經網路分類模型。然而，CT 量化結果仍會受到掃描協議、重建參數、吸氣程度、分割品質與指標定義差異影響，因此後續方法章需明確說明各項特徵之輸入、公式與限制。

2.3 肺部、氣道與血管影像分割

胸部 CT 影像雖可呈現肺實質、氣道與血管等細部解剖結構，但若未先界定各結構所在區域，影像灰階值與體積資訊便難以轉換為具生理意義的量化特徵。因此，在 COPD 相關 CT 分析中，影像分割通常扮演兩項關鍵角色：其一為建立特徵計算的解剖區域，例如以肺部或肺葉遮罩限定肺氣腫比例與肺容積之計算範圍；其二為提供可解釋的結構標籤，使氣道與血管相關指標能對應至特定病理變化。若分割邊界錯誤、末端管狀結構漏失，或將非目標組織誤判為目標結構，後續低衰減區比例、血管密度、小血管體積比例與氣道相關特徵皆可能受到影響。因此，影像分割並非單純的前處理程序，而是 quantitative CT 分析可信度的重要基礎。

深度學習已成為醫學影像分割的重要方法。Litjens 等人回顧深度學習於醫學影像分析之應用時指出，卷積神經網路已廣泛應用於影像分類、偵測與分割等任務 [3]。其中，U-Net 透過 encoder-decoder 結構與 skip connection 保留局部空間資訊，奠定了許多

生物醫學影像分割模型的基礎 [14]。針對三維醫學影像分割，nnU-Net 進一步提出自動化設定策略，依資料特性調整前處理、網路架構與訓練流程，降低不同任務間人工調參的需求 [15]。在研究與實作工具方面，3D Slicer 可支援醫學影像讀取、分割、三維視覺化與量測 [16]；MONAI 則提供以 PyTorch 為基礎的醫學影像深度學習框架，整合資料轉換、模型訓練與推論流程 [17]。

肺部與肺葉分割是 COPD 量化 CT 分析中最基礎的結構分割任務。Hofmanninger 等人針對例行性胸部影像之肺部分割進行研究，指出模型表現高度受到資料多樣性影響，臨床應用時需面對不同掃描協議、疾病型態與影像品質所造成的變異 [18]。TotalSegmentator 則建立可分割多種 CT 解剖結構的自動化工具，顯示多器官與多結構 label map 已逐漸成為 CT 影像量化研究的重要基礎 [19]。針對肺氣腫量化，Li 等人提出 EmphysemaSeg，結合自動肺葉分割與肺氣腫評估，用於低劑量肺癌篩檢 CT 中的肺葉別肺氣腫量化 [20]。上述研究說明，肺部與肺葉分割不僅用於排除非肺部組織，也會直接影響肺氣腫比例、肺葉體積與疾病分布型態之估計。

氣道分割相較於肺部遮罩更具挑戰性，原因在於氣道樹具有細長、多分支、末端管徑小且與肺血管相鄰等特性，分割時容易出現末端分支中斷、管腔漏失或誤判其他低密度結構等問題。Garcia-Uceda 等人提出以 3D convolutional neural networks 為基礎的自動氣道分割方法，並在胸部 CT 資料中驗證其對氣道樹萃取的可行性 [21]。AeroPath 則建立含有肺氣腫、腫瘤等病理變化之氣道分割 benchmark，強調胸部病理變化會增加氣道分割困難度，並提供評估模型於複雜臨床影像中穩健性的資料與基準方法 [22]。然而，COPD 氣道量化若要進一步估計 WA% 或氣道壁厚，通常需要可靠的 airway lumen 與 wall 資訊；若僅取得氣道樹遮罩或氣管標籤，則較適合解釋為 airway-derived features，而不宜直接視為精確的小氣道壁厚量測。

血管分割則與 COPD 影像中肺血管床減少、小血管比例改變與肺動脈相關指標有關。Matsuoka 等人以 CT 量測小肺血管橫截面積，顯示小血管量化與肺氣腫比例及氣流受限具有關聯 [12]。在自動分割方法上，肺血管與氣道皆屬細長管狀結構，相對於背景 voxel 數量極少，容易形成類別不平衡與末端分支漏失問題。Qin 等人提出 tubule-sensitive CNN，用於肺部氣道與肺動靜脈分割，並針對管狀結構在 CT 中比例小、形態細長與分支複雜等問題設計模型策略 [23]。因此，血管密度、SVV% 與肺動脈相關指標雖可提供 COPD 血管表型資訊，但其可靠性仍取決於血管分割對主幹血管

與末端小血管的偵測能力。

綜合上述文獻，肺部、肺葉、氣道與血管分割分別支撐 COPD quantitative CT 中不同類型的影像生物標記：肺部與肺葉分割影響肺容積與肺氣腫比例，氣道分割影響 airway-derived features，血管分割則影響血管密度、小血管比例與肺動脈相關估計。既有研究已提供多種可用的深度學習模型、公開工具與 benchmark，但各方法在標籤定義、輸出格式、資料來源與疾病情境上並不完全一致。因此，在後續方法章中，需明確說明實際採用之分割來源、輸出標籤、特徵計算方式與限制，避免將不同來源之分割結果視為完全等價。

2.4 三維醫學影像深度學習模型

胸部 CT 屬於三維體積影像，與單張二維影像相比，其資訊不僅存在於單一切面，也包含上下切片之間的連續解剖關係。COPD 相關影像表徵亦具有三維分布特性，例如肺氣腫可能呈現肺葉或區域性分布，氣道與血管則沿著肺內空間形成分支結構。因此，若僅以二維切片進行分析，可能忽略跨切片的空間連續性與整體肺部形態；三維深度學習模型則可直接以 CT volume 作為輸入，從體積資料中學習局部紋理、區域分布與全肺形態等特徵。

早期三維醫學影像深度學習多以 3D convolutional neural networks (3D CNN) 為基礎。3D convolution 可在深度、高度與寬度三個方向同時萃取局部特徵，使模型能保留體積影像中的空間鄰近關係。Park 等人以 inflated three-dimensional convolutional network 由低劑量胸部 CT 預測 FVC 與 FEV1，並進一步以預測之肺功能值判斷高風險族群，顯示三維 CT 模型可由影像中學習與肺功能相關的潛在表徵 [4]。BeyondCT 則結合 3D CNN、Vision Transformer 與人口統計資料，用於由非增強吸氣相胸部 CT 預測 FVC 與 FEV1；其設計反映了近年模型發展趨勢，即以 CNN 擷取局部影像特徵，再透過 Transformer 類架構捕捉較長距離的全域關係 [24]。此類研究說明，胸部 CT 模型除可輸出疾病類別外，亦可透過迴歸方式估計連續肺功能相關指標，作為後續門檻分級與風險判讀之前置表徵。

Transformer 架構原先發展於序列建模，後續 Vision Transformer 將影像切分為 patch token，利用 self-attention 建立影像區域之間的關係 [25]。在胸部 CT 與 COPD 相關研究

中，Wu 等人曾將 Vision Transformer 應用於 CT 肺氣腫亞型分類，說明 attention-based 模型可用於辨識 centrilobular、panlobular 與 paraseptal emphysema 等不同影像型態 [26]。然而，標準 self-attention 的計算量會隨 token 數量平方成長，若直接用於高解析三維 CT，記憶體與運算成本皆相當高。Swin Transformer 以 shifted window attention 建立階層式特徵表示，在降低計算負擔的同時保留多尺度資訊 [27]；Swin UNETR 進一步將此概念引入三維醫學影像分割，以 Swin Transformer encoder 萃取多層級特徵，再與 U-Net 類 decoder 結合 [28]。這些研究顯示，Transformer 類模型有助於補足純 CNN 對長距離相依關係建模不足的問題。

近年 state space model (SSM) 與 Mamba 架構開始被引入醫學影像分析。Mamba 透過 selective state space mechanism 建立長序列建模能力，並具有相對於標準 Transformer 更接近線性的序列長度複雜度，因此適合處理 token 數量龐大的影像或三維體積資料 [29]。在醫學影像領域，nnMamba 將 CNN 的局部表示能力與 SSM 的長距離建模能力結合，並應用於三維生物醫學影像分割、分類與 landmark detection 任務 [30]。SegMamba 則針對三維醫學影像分割設計 Mamba-based 架構，以提升 whole-volume feature modeling 的效率 [31]；MedMamba 則探討 Vision Mamba 於多種醫學影像分類任務中的應用，作為 Mamba-based medical image classification 的基準之一 [32]。

整體而言，三維醫學影像模型的發展可視為由局部特徵萃取走向局部與全域表徵整合的過程。3D CNN 適合捕捉 CT 中局部低衰減區、血管紋理與氣道周邊變化；Transformer 與 Swin 類模型則強調跨區域或多尺度關係；Mamba 類模型則嘗試在保留長距離建模能力的同時降低高維體積資料的計算負擔。對 COPD 輔助診斷而言，這些模型可作為 2.2 節量化生物標記之外的補充途徑，使模型直接由原始 CT volume 學習與肺功能、肺氣腫分布或疾病嚴重程度相關的隱含特徵，並同時支援連續肺功能表徵迴歸與衍生分類任務。然而，三維深度模型通常需要較多資料與嚴謹驗證；在小樣本醫學影像情境中，模型可能受到掃描協議差異、連續標籤雜訊、類別不平衡與資料切分方式影響，因此後續仍需搭配適當的資料增強、交叉驗證與多指標評估。

2.5 TAP-CT

近年醫學影像深度學習除針對單一任務訓練模型外，亦逐漸重視由大量未標註或弱標註影像建立可轉移之預訓練表徵。此類 foundation model 期望先由大規模資料學得一般性影像結構，再於下游任務中透過 feature extraction、輕量分類頭或有限微調降低標註資料不足造成的限制。對 CT 影像而言，若預訓練模型僅沿用二維自然影像設定，可能難以完整描述切片間之體積關係；因此，如何建立可處理三維 CT volume 的通用表徵，已成為 CT foundation model 發展的重要方向。

Veenboer 等人提出之 TAP-CT (Task-Agnostic Pretraining of Computed Tomography) 即以 CT 體積影像之通用預訓練為核心。該研究將 Vision Transformer 與 DINOv2 類自監督學習概念延伸至 volumetric CT，並針對三維 patch embedding、位置編碼與體積式資料增強進行調整，使模型可由 CT volume 建立具深度資訊之影像表示。其預訓練資料涵蓋大量 CT volumes，研究結果指出 TAP-CT 可在下游任務中提供穩定之 frozen representation，作為低資源情境下除完整 end-to-end fine-tuning 以外的特徵來源 [33]。

TAP-CT 對本研究所關注之小樣本胸部 CT 任務具有兩項參考意義。首先，COPD 相關影像表徵同時包含肺實質低衰減區、肺部空間分布與氣道血管周邊結構，若僅依本研究有限資料自訓練影像編碼器，模型可學得之表徵可能受資料量與標籤分布限制；預訓練 CT embedding 則提供另一種由大量 CT 影像學得之表示來源。其次，TAP-CT 之 frozen representation 可與任務導向模型輸出形成互補比較：前者強調通用 CT 表徵之可轉移性，後者則針對本研究之塌陷角與肺功能相關標籤調整特徵。因此，於下游任務中可分別檢視預訓練 embedding 單獨使用時之資訊量，以及其與三維影像模型特徵融合後是否提供額外效益。

然而，TAP-CT 屬於通用 CT 預訓練模型，並非專為 COPD、肺功能檢查或塌陷角標籤建立之疾病特異模型。其 embedding 是否能保留與呼氣流量容積曲線、GOLD 相關候選分級或正常異常判讀相關之訊息，仍需依實際資料與下游任務驗證。基於此，本研究將 TAP-CT 視為三維 CT 深度學習分支中的預訓練表徵補充來源，而非取代可解釋 CT 量化生物標記或任務導向三維模型之唯一方法。

第三章 研究材料與方法

3.1 研究流程

本研究以胸部電腦斷層影像為主要輸入，建立 COPD 輔助診斷與肺功能相關表徵預測流程。原始胸部 CT 影像先由 DICOM 轉換為 NIfTI volume，再依實驗目的進入兩條互補之分析分支，分別說明如下：

1. **CT 量化生物標記分析分支：**此分支強調影像特徵之可解釋性。轉換後之 CT 影像先經肺部、肺葉、血管與氣道相關分割流程產生 label map，再依各結構遮罩計算肺氣腫比例、肺容積、血管密度、小血管體積比例、氣道相關比例與肺動脈直徑等數值特徵。上述特徵可對應肺實質、血管與氣道結構變化，故本研究將其視為 CT 量化生物標記，並以全連接神經網路進行 Normal/Abnormal 二元分類。
2. **三維 CT 深度學習模型分析分支：**此分支保留完整三維影像輸入，不先將 CT volume 壓縮為人工定義特徵。NIfTI 影像經尺寸統一、強度正規化與必要之資料增強後輸入三維模型，模型設定包含 Mamba、SwinUNETR、Hybrid Mamba-Attention 與 TAP-CT 影像嵌入融合。此分支之任務包含 Normal/Abnormal 分類、塌陷角連續值預測、塌陷角三分類、排除中間灰區後之二分類，以及 GOLD 相關候選分級分類。

兩條分支之分析重點並不相同。CT 量化生物標記分析分支著重於以具解剖意義之數值特徵支援小樣本分類；三維 CT 深度學習模型分析分支則著重於由原始影像直接學習肺部空間表徵，以補充人工定義特徵可能無法涵蓋之資訊。為避免資料洩漏，三維影像模型之訓練與驗證皆以病人為單位切分資料，使同一病人之原始影像與增強影像不會同時出現在訓練與驗證集合中。後續章節將分別說明兩類方法之資料範圍、模型設定與評估結果，並於討論中比較其互補性與限制。

3.2 資料集

本研究資料由北投振興醫院合作醫師提供，包含病人胸部 CT 之 DICOM 影像及肺功能檢查（pulmonary function test, PFT）資料。原始 CT 影像以 DICOM series 形式儲存，經資料轉換流程產生 NIfTI volume 後，再依不同實驗目的建立量化特徵資料集與三維影像資料集。

量化生物標記分支使用其中 54 例胸部 CT，其中正常（Normal）21 例、異常或 COPD（Abnormal/COPD）33 例；其正常/異常二元標籤由合作醫師依 ATS/ERS 肺功能判讀標準與 PFT 結果判定 [34]。此資料集用於肺部結構分割、量化參數擷取與正常/異常二元分類。由於本分支之核心目標為驗證 CT-derived biomarkers 是否能提供可解釋之 COPD 輔助判讀依據，因此每一例影像皆需具備可供後續特徵計算之 CT volume、肺部相關 label map 與量化參數輸出。另有後續新增之 12 例正常傾向 CT 已完成初步轉換，但未併入此 54 例量化特徵主實驗，以避免在未重跑完整分割、特徵擷取與交叉驗證流程前改變已報告之資料範圍。

三維 CT 深度學習分支使用 66 例可與 PFT 資料對應之 CT 影像。PFT 資料用於整理塌陷角度與 GOLD 相關候選標籤，並作為 Mamba、SwinUNETR、Hybrid Mamba-Attention 與 TAP-CT 融合模型訓練與驗證時之監督訊號。塌陷角度（Angle of Collapse, AC）係由肺功能檢查之呼氣流量容積曲線萃取的幾何指標，並非 CT 影像中的解剖角度。參考 Topalovic 等人提出之 AC 與肺氣腫關係，本研究採用 131° 與 152° 作為角度分級門檻 [6]。

表 3.1: 本研究影像資料組成

資料集	例數	標籤與實驗用途
量化生物標記資料集	54	正常 21 例、異常或 COPD 33 例，標籤由醫師依 ATS/ERS 標準與 PFT 判定；用於肺部結構分割、量化參數擷取與正常/異常二元分類。
三維 CT 影像資料集	66	具由 PFT 整理之 AC 與 GOLD 相關候選標籤；用於三維 CT 模型訓練、AC 連續值迴歸、塌陷角度分級、排除中間灰區後之二分類與 GOLD 相關分類。

AC 三分類任務將影像分為三類： $AC \leq 131^\circ$ 為 emphysema/abnormal-like 類別， $132^\circ \leq AC \leq 151^\circ$ 為 intermediate 類別， $AC \geq 152^\circ$ 為 normal-like 類別。原始 66 例資料中，三類樣本數分別為 14、5 與 47 例。由於 intermediate 類別樣本數較少且可能代表

肺功能曲線表徵之灰區，本研究另設計 AC 二分類任務，排除 132° 至 151° 之 5 例，只保留 $AC \leq 131^{\circ}$ 與 $AC \geq 152^{\circ}$ 兩端較明確之 61 例資料。

GOLD 相關候選標籤則依肺功能檢查中 FEV1 佔預測值百分比進行整理，分為 GOLD 1、GOLD 2、GOLD 3 與 GOLD 4。於 66 例三維影像資料中，四類樣本數分別為 36、11、13 與 6 例。需要注意的是，此分組主要反映 FEV1 predicted 所對應之氣流受限嚴重度候選標籤；正式 COPD 診斷與 GOLD 分級仍需結合支氣管擴張劑後 FEV1/FVC、症狀、病史與臨床判讀。因此，本研究在方法與結果中將其稱為 GOLD 相關候選分級或肺功能導向分級，不將其直接等同於完整臨床診斷。

表 3.2: 肺功能相關標籤定義

標籤類型	類別條件	例數	說明
AC 連續值迴歸	連續角度	66	由 PFT 流量容積曲線衍生之 AC，作為單一實數迴歸目標
AC 三分類	$\leq 131^{\circ}$	14	肺氣腫或異常傾向
AC 三分類	$132^{\circ}-151^{\circ}$	5	中間灰區，於二分類中排除
AC 三分類	$\geq 152^{\circ}$	47	正常傾向
AC 二分類	兩端類別	61	僅保留 $\leq 131^{\circ}$ 與 $\geq 152^{\circ}$ 樣本
GOLD 相關候選分級	GOLD 1-4	36、11、13、6	依 FEV1 預測值百分比整理

3.3 資料前處理

本研究之前處理目的在於將臨床原始 DICOM 影像與 PFT 資料整理為後續分割、量化參數擷取與標籤建立可使用之格式。由於量化分析仰賴 HU 閾值與實際 voxel spacing，轉換流程需保留影像強度與空間資訊，避免影響後續體積與低衰減區比例計算。

原始胸部 CT 以 DICOM series 形式儲存。同一病人可能具有多組掃描序列或重建影像，因此本研究先依 SeriesInstanceUID 與 DICOM metadata 將影像分組，再排除 scout、snapshot、冠狀面或矢狀面重建影像，以及不適合肺部分析之非目標序列。若同一病人具有多個可用胸部 CT series，則優先選擇適合肺部結構分析之軸向胸部或肺窗序列。完成序列選擇後，依 ImagePositionPatient 對切片排序，並利用 ImageOrientationPatient、PixelSpacing 與 SliceThickness 等欄位建立三維空間方向與 voxel spacing。

CT 強度值轉換依據 DICOM 中之 RescaleSlope 與 RescaleIntercept 進行。設原始

pixel value 為 p ，RescaleSlope 為 m ，RescaleIntercept 為 b ，則轉換後之 HU 值定義為：

$$HU = mp + b. \quad (3.1)$$

此步驟對本研究特別重要，因為肺氣腫比例係依 HU 小於 -950 之低衰減區域計算；若未正確轉換 HU，後續低衰減區、肺密度與相關量化特徵皆可能產生系統性偏差。轉換後之影像以 NIfTI 格式儲存，並保留 affine、spacing 與 HU intensity，以利後續分割、體積計算與模型輸入。

PFT 資料則以病人為單位與 CT volume 對應。合作醫師提供之 PFT 結果用於建立正常/異常二元標籤、FEV1 預測值百分比相關分級，以及塌陷角度（AC）等肺功能導向標籤。資料整理時以病人識別碼對應 CT 與 PFT，並檢查是否存在缺漏、重複或無法對應之個案；僅具備可用 CT volume 與相應標籤者納入後續模型分析。

3.4 肺部結構分割與量化參數擷取

量化生物標記分支之目的，是將胸部 CT 中與 COPD 相關之肺葉、血管與氣道結構轉換為 12 項病人層級數值特徵。本研究以前處理後之 HU-preserved NIfTI volume 作為輸入，透過 3D Slicer 結合 MONAI Auto3DSeg 產生多類別 label map[16, 17]。主實驗中，label 1 至 label 5 對應五個肺葉並合併為總肺遮罩；label 6 至 label 9 則對應血管、氣管、肺靜脈系統與肺動脈等結構。氣道結構另以 AeroPath 分割結果作為補充來源 [22]；當 voxel-based airway mask 可取得時，優先用於氣道相關特徵，否則以 label map 中可用之氣管或氣道標籤近似估計。分割完成後，本研究檢查輸出檔案、主要 label 是否為非空值，以及各主要結構 voxel 數是否合理，再進行量化參數計算。

所有體積計算皆根據 NIfTI header 中的 voxel spacing 進行。設三個方向之 spacing 分別為 s_x 、 s_y 與 s_z ，某結構區域 R 之 voxel 數為 N_R ，則單一 voxel 體積與結構體積定義如下：

$$v_{\text{voxel}} = s_x s_y s_z, \quad V_R = \frac{N_R v_{\text{voxel}}}{1000}. \quad (3.2)$$

其中 v_{voxel} 之單位為 mm^3 ， V_R 之單位為 mL。肺氣腫比例採用低衰減區域（low

attenuation area) 概念，在總肺或指定肺葉遮罩內計算 HU 小於 -950 之 voxel 比例；此門檻常用於 CT 肺氣腫定量分析 [8]。若 R 表示總肺或任一肺葉區域，肺氣腫比例定義為：

$$E_R = \frac{N_{R, HU < -950}}{N_R} \times 100\% . \quad (3.3)$$

血管、氣道與肺動脈相關特徵則依下列比例或等效直徑計算：

$$\begin{aligned} D_{\text{vessel}} &= \frac{V_{\text{vessel}}}{V_{\text{lung}}} \times 100\% \\ \text{SVV} &= \frac{V_{\text{small}}}{V_{\text{lung}}} \times 100\% \\ \text{WA} &= \frac{V_{\text{wall}}}{V_{\text{lumen}} + V_{\text{wall}}} \times 100\% \\ R_{\text{airway}} &= \frac{V_{\text{airway}}}{V_{\text{lung}}} \times 100\% \\ d_{\text{PA}} &= 2 \left(\frac{3V_{\text{PA}}}{4\pi} \right)^{1/3} . \end{aligned} \quad (3.4)$$

其中 V_{lung} 為總肺體積， V_{vessel} 為血管體積， V_{small} 為直徑小於 5 mm 之小血管體積， V_{airway} 為氣道體積， V_{PA} 為肺動脈 label 體積。SVV% 可反映 COPD 中小血管床減少或肺氣腫相關血管破壞之影像表徵 [12]；肺動脈直徑則為本研究根據分割體積定義之 segmentation-based equivalent diameter，非臨床標準手動量測值。雖然 PA:A ratio 已被用於 COPD 肺血管相關研究 [13]，但本研究未取得可靠主動脈分割或人工量測結果，因此未納入最終分類特徵。

本研究最終輸出下列 12 項量化特徵，作為後續分類模型之輸入：

1. **全肺肺氣腫比例** (Total_Emphysema_Percent)：於五個肺葉合併後之總肺遮罩內，計算 HU 小於 -950 之 voxel 佔比，單位為百分比。
2. **左上葉肺氣腫比例** (Left_Superior_Lobe_Emphysema)：於左上葉遮罩內計算 HU 小於 -950 之 voxel 佔比，用於描述左上葉低衰減區程度。
3. **左下葉肺氣腫比例** (Left_Inferior_Lobe_Emphysema)：於左下葉遮罩內計算 HU 小於 -950 之 voxel 佔比，用於描述左下葉低衰減區程度。

4. **右上葉肺氣腫比例** (Right_Superior_Lobe_Emphysema)：於右上葉遮罩內計算 HU 小於 -950 之 voxel 佔比，用於描述右上葉低衰減區程度。
5. **右中葉肺氣腫比例** (Right_Middle_Lobe_Emphysema)：於右中葉遮罩內計算 HU 小於 -950 之 voxel 佔比，用於描述右中葉低衰減區程度。
6. **右下葉肺氣腫比例** (Right_Inferior_Lobe_Emphysema)：於右下葉遮罩內計算 HU 小於 -950 之 voxel 佔比，用於描述右下葉低衰減區程度。
7. **小血管體積比例** (SVV_Percent)：由血管遮罩與 distance transform 估計小血管區域，並以小血管體積除以總肺體積表示，單位為百分比。
8. **氣道壁比例** (WA_Percent)：以氣道 lumen 與 wall 之估計體積計算 wall volume 佔總氣道體積之比例，作為氣道壁相對增厚之近似特徵。
9. **血管密度** (Vessel_Density_Percent)：以分割血管體積除以總肺體積表示，反映 CT 中可見血管結構相對於肺容積之比例。
10. **氣道肺體積比例** (Airway_Lung_Ratio_Percent)：以氣道體積除以總肺體積表示，描述氣道結構相對於肺部整體體積之比例。
11. **總肺體積** (Total_Lung_Volume_ml)：由左上葉、左下葉、右上葉、右中葉與右下葉五個肺葉體積加總而得，單位為 mL。
12. **肺動脈直徑估計值** (PA_Diameter_mm)：由肺動脈 label 體積換算為等效球體直徑，作為肺動脈相關之自動估計特徵，單位為 mm。

上述 12 項特徵皆輸出為結構化數值資料；其中肺氣腫比例、血管與氣道比例皆為百分比，總肺體積與肺動脈直徑則分別保留其物理單位，以便後續模型標準化與分類分析。

3.5 量化 CT 分類模型

量化生物標記分類模型以第 3.4 節所述之 12 維 CT-derived biomarkers 作為輸入，目標為區分正常與異常或 COPD 個案。相較於直接輸入完整三維 CT，量化特徵模型之輸

入維度較低，且每一個特徵皆可對應至肺氣腫、肺容積、血管或氣道相關影像表徵，因此較適合用於本研究 54 例小樣本資料之可解釋分類分析。

每位病人之特徵向量記為 $\mathbf{x}_i$ ，其包含第 3.4 節列出之 12 個實數特徵；標籤 y_i 以 0 表示正常、1 表示異常或 COPD。由於各特徵單位與尺度不同，例如百分比、毫升與毫米，模型訓練前需先進行標準化。對於第 j 個特徵，僅使用訓練資料計算平均值 μ_j 與標準差 σ_j ，再將訓練與驗證資料轉換為：

$$z_{ij} = \frac{x_{ij} - \mu_j}{\sigma_j}. \quad (3.5)$$

此作法可避免總肺體積或肺動脈直徑等尺度較大的特徵主導神經網路權重，同時避免在交叉驗證中因驗證資料參與標準化參數估計而造成資料洩漏。

分類器採用全連接神經網路，其模型架構、訓練設定與驗證方式如下：

- **輸入與標籤：**模型輸入為第 3.4 節所列 12 項量化特徵；標籤為二元分類，0 表示正常，1 表示異常或 COPD。標準化參數僅由 training fold 估計，避免驗證資料資訊洩漏至訓練流程。
- **模型架構：**網路維度為 $12 \rightarrow 64 \rightarrow 32 \rightarrow 16 \rightarrow 2$ 。各 hidden layer 後接 batch normalization、ReLU activation 與 dropout，以增加非線性表示能力並降低小樣本訓練時之過擬合風險。
- **輸出與訓練目標：**輸出層包含 2 個 logits，分別對應正常與異常或 COPD 類別，並以 softmax 轉換為類別機率。模型訓練使用 CrossEntropyLoss。
- **最佳化與訓練設定：**Optimizer 採用 Adam，初始 learning rate 為 0.001，weight decay 為 1×10^{-5} ；batch size 設為 16，最多訓練 100 epochs。
- **學習率調整與早停：**訓練過程使用 ReduceLROnPlateau 依驗證指標調整 learning rate，並以 early stopping 避免模型在小資料集上過度擬合。
- **驗證方式：**模型採用 stratified five-fold cross validation。每一 fold 以四個 folds 作為訓練集、一個 fold 作為驗證集，並維持正常與異常或 COPD 樣本比例；每一 fold 皆重新建立標準化器並重新訓練模型，最後合併五個 fold 之驗證預測以計算整體分類效能。

3.6 三維 CT 網路架構設計

三維 CT 影像模型之目的在於直接由完整 CT volume 學習肺部空間特徵，補足量化生物標記僅能描述預先定義特徵之限制。本研究採用之模型皆由影像編碼器、特徵彙整模組與 prediction head 組成。前處理後之三維 CT volume 先輸入編碼器以擷取空間特徵，再經 pooling 形成病人層級表示，最後由 prediction head 依任務輸出迴歸值或分類預測分數。各模型架構設定如下：

- **Mamba-based model**：本研究之 Mamba-based model 以三維 convolution stem 擷取局部影像紋理與結構，再將特徵轉換為空間 token sequence，並透過 residual Mamba blocks 建立跨切片與跨區域之特徵關係。此架構用於由完整三維 CT volume 建立肺部影像特徵。
- **SwinUNETR-based model**：本研究將 SwinUNETR-based model 作為 Transformer 類影像編碼器設定。模型由階層式三維影像特徵中取得多層級表示，再經特徵彙整與輸出模組產生預測結果，用於與 Mamba 類編碼方式進行比較 [27, 28]。
- **Hybrid Mamba-Attention model**：Hybrid Mamba-Attention model 以 Mamba stages 作為主要編碼流程，並於深層特徵加入 global multi-head attention bridge，使最終階段之空間 token 可進一步進行全域關係整合。此設定保留 Mamba-based encoder 之三維特徵建模流程，並加入 attention-based 特徵整合模組以形成混合式影像特徵。
- **Prediction head**：上述模型於編碼器輸出後接續 pooling 與 MLP prediction head。Pooling 用以彙整三維空間特徵，將體積影像表示轉換為病人層級特徵向量；其後之 prediction head 則依任務設定輸出連續塌陷角度預測值，或輸出對應分類任務之預測分數。

三維影像模型之訓練目標依任務輸出型態設定。Normal/Abnormal 二元分類以單一 logit 表示異常傾向，訓練採用 binary cross entropy with logits loss；AC 三分類、排除中間灰區後之二分類與 GOLD 相關候選分級則輸出各類別之預測分數，並採用 cross entropy loss 進行分類訓練。

3.7 塌陷角迴歸任務

本研究後半段實驗以肺功能檢查所得之塌陷角作為三維 CT 表徵學習目標。塌陷角由 PFT 流量容積曲線整理而得，代表肺功能曲線形態之連續量化指標。模型以三維 CT volume 為輸入，輸出單一連續預測值，用以估計每位病人之塌陷角。

由於塌陷角為連續角度值，不同 fold 中的角度分布可能略有差異，本研究在每一 fold 內先以訓練資料計算塌陷角之平均值與標準差，再用此訓練資料統計量將角度標籤標準化。模型訓練時學習的是標準化後的塌陷角，而不是直接預測原始角度；驗證時則使用同一組訓練資料統計量，將模型輸出轉回原始角度單位，再與真實塌陷角計算 MAE 等迴歸誤差。此流程可避免驗證資料參與標準化參數估計，同時使不同 folds 的模型皆在相同原則下訓練與評估。

訓練階段採用 smooth L1 loss，以降低少數極端誤差對模型更新之影響；模型選擇則依 validation MAE 決定最佳 checkpoint。此任務用於評估三維 CT 模型是否能由胸部影像學習與肺功能曲線幾何表徵相關之資訊。

3.8 TAP-CT 影像嵌入與融合策略

除由本研究資料訓練之三維 CT 影像編碼器外，本研究亦納入預訓練 CT foundation model 之影像嵌入作為輔助表徵。TAP-CT 係針對體積式 CT 影像建立之 task-agnostic 預訓練模型，將 Vision Transformer 與自監督式表徵學習延伸至三維 CT volume，使模型可在下游任務中提供 frozen representation 作為特徵來源 [33]。考量本研究之三維影像資料量有限，本文未直接以 PFT 標籤完整微調 TAP-CT backbone，而是先擷取固定之 TAP-CT 影像嵌入，再與第 3.6 節所述 Hybrid Mamba-Attention 特徵進行比較或融合。

TAP-CT 影像嵌入由每位病人之 CT volume 產生，並依病人識別碼與塌陷角衍生分類標籤對應。特徵擷取流程先以深度方向之視窗讀取體積影像，取得預訓練模型輸出後，再將同一病人之視窗層級資訊彙整為病人層級向量。依實驗設定不同，本文使用 TAP-CT-B-3D、TAP-CT-S-3D 或 TAP-CT-S-2.5D 所產生之 frozen embedding；其中 TAP-CT-B-3D 融合設定使用 2304 維病人層級向量，TAP-CT-S 系列融合設定使用 1152 維向量。此作法使預訓練 CT 表徵可直接作為後續分類器或融合模組之輸入，而不需在

每一個交叉驗證 fold 重新更新 TAP-CT 權重。

在進行融合前，本研究先以 TAP-CT frozen embedding 建立輕量分類探測設定，觀察預訓練影像嵌入本身對塌陷角衍生標籤是否保留可用訊息。其後，TAP-CT 相關實驗主要用於 AC 三分類與排除中間灰區後之 AC 二分類，並比較下列策略：

1. **TAP-CT 單獨分類**：僅載入 TAP-CT frozen embedding，不再輸入原始三維 CT volume。本文以 attention-based multiple instance learning (ABMIL) 分類頭彙整 embedding 表徵，再輸出塌陷角分類結果，用以作為預訓練 CT 特徵單獨使用時之比較基準 [35]。
2. **Late fusion**：Hybrid Mamba-Attention 分支先由 CT volume 產生病人層級特徵，TAP-CT embedding 則先投影至融合維度；兩類特徵串接後輸入 MLP 分類頭。此設定直接保留本研究自訓練之三維 CT 特徵與預訓練 CT 表徵，觀察兩者結合後是否能補充塌陷角分類所需資訊。

上述策略皆以病人層級資料切分為前提；TAP-CT 特徵與原始 CT volume 需對應至同一病人，且資料增強所產生之訓練視圖僅能出現在 training fold。藉由同時保留 TAP-CT 單獨分類與 late fusion，本研究可分別觀察預訓練 CT 表徵之獨立資訊量，以及其與任務導向三維影像特徵結合後對 AC 分類任務之補充效果。

3.9 交叉驗證、資料增強與平衡取樣

本研究樣本數有限，且部分任務存在明顯類別不平衡，因此所有模型評估皆採交叉驗證設計，並以病人為資料切分單位。若同一病人存在原始影像、重採樣影像、資料增強視圖或 TAP-CT embedding，皆視為同一病人之衍生資料，僅能出現在同一 fold 之訓練或驗證集合中，不得跨集合分配，以避免資料洩漏。

- **交叉驗證設定**：量化生物標記分類實驗採 stratified five-fold cross validation，於每一 fold 維持正常與異常或 COPD 樣本比例，並僅以 training fold 估計特徵標準化參數。三維 CT 模型之 Normal/Abnormal、AC 三分類與 AC 二分類實驗亦以病人層級 five-fold cross validation 進行；AC 連續值迴歸則先依角度分布建立 quantile

bins，再以分層方式切分 folds，以降低各 fold 角度分布差異。若特定任務因少數類別樣本過少而不適合五折切分，則調整為較少 folds，使每一驗證 fold 仍保有可評估之類別樣本；GOLD 相關候選分級即採三折設定。

- **三維影像輸入：**三維 CT 輸入於模型訓練前統一為 $1 \times 112 \times 136 \times 112$ 之 channel-first volume，並依任務設定進行 HU window clipping 與強度正規化。
- **資料增強設定：**資料增強僅套用於 training fold，驗證資料保留原始影像處理流程。本研究使用之增強方式與參數如下：

- **AC 三分類、AC 二分類與 TAP-CT late fusion：**三維旋轉範圍 $\pm 5^\circ$ 、相對影像尺寸之平移比例 0.03、縮放範圍 0.97–1.03、強度縮放範圍 0.98–1.02、強度平移範圍 -0.05 – 0.05 ，以及標準差 0.02 之高斯雜訊。

- **GOLD 相關候選分級：**因類別數較多且少數類別樣本更少，採用較大的增強幅度，包含三維旋轉範圍 $\pm 7^\circ$ 、相對影像尺寸之平移比例 0.05、縮放範圍 0.95–1.05、強度縮放範圍 0.95–1.05、強度平移範圍 -0.1 – 0.1 ，以及標準差 0.03 之高斯雜訊。

- **平衡取樣：**對於 AC 三分類、AC 二分類與 GOLD 相關候選分級等類別不平衡任務，本研究使用平衡取樣與虛擬資料增強減少多數類別主導訓練的情形。多數實驗先於每一個 training fold 內依目標類別數產生虛擬增強樣本，再於每一 epoch 以該 fold 之少數類別樣本數為基準，對各類別進行隨機平衡取樣，使訓練批次中各類別具有較接近的出現機率。本研究實際測試之平衡強度如下：

- **AC 三分類：**包含僅進行每個 epoch 之少數類別基準下採樣而不額外補樣本之設定，以及將各類別補至 50、75、100、200 與 300 筆訓練樣本之設定；另測試先平衡後增強之設定，於每一 epoch 先取平衡基礎樣本，再為每筆樣本產生 12 個訓練視圖。

- **AC 二分類：**排除中間灰區後之二分類主要測試將兩類補至每類 100 筆訓練樣本之設定。

- **TAP-CT late fusion：**AC 三分類與 AC 二分類之 TAP-CT late fusion 主要採用每類 100 筆訓練樣本之虛擬增強設定。

- **GOLD 相關候選分級**：測試將四個 GOLD 相關候選類別補至每類 36 筆與 200 筆訓練樣本之設定。

3.10 評估指標

本研究依任務輸出型態選擇評估指標。Normal/Abnormal 二元分類以 confusion matrix、accuracy、sensitivity、specificity、precision、F1-score 與 ROC-AUC 描述模型區辨能力及錯誤分類型態。二元分類中，true positive (TP) 表示異常個案被正確判定為異常，true negative (TN) 表示正常個案被正確判定為正常，false positive (FP) 表示正常個案被誤判為異常，false negative (FN) 表示異常個案被誤判為正常。由 TP、TN、FP 與 FN 可定義 accuracy、sensitivity、specificity、precision、negative predictive value 與 F1-score 等指標 [5]。

$$\begin{aligned}
 \text{Accuracy} &= \frac{TP + TN}{TP + TN + FP + FN} \\
 \text{Sensitivity} &= \text{Recall} = \frac{TP}{TP + FN} \\
 \text{Specificity} &= \frac{TN}{TN + FP} \\
 \text{Precision} &= \frac{TP}{TP + FP} \\
 \text{NPV} &= \frac{TN}{TN + FN} \\
 \text{F1} &= \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}
 \end{aligned} \tag{3.6}$$

Receiver operating characteristic curve (ROC curve) 以 true positive rate (TPR) 與 false positive rate (FPR) 表示不同 decision threshold 下的分類結果。Area under the curve (AUC) 為 ROC curve 下方面積，用於描述模型整體區辨能力 [36]。

$$\begin{aligned}
 \text{TPR} &= \frac{TP}{TP + FN} \\
 \text{FPR} &= \frac{FP}{FP + TN} \\
 \text{AUC} &= \int_0^1 \text{TPR}(\text{FPR}) d\text{FPR}
 \end{aligned} \tag{3.7}$$

Precision-recall curve 以 precision 與 recall 作為座標軸。Average precision (AP) 或

area under precision–recall curve (AUPRC) 可表示 precision–recall curve 下方面積 [37]。

$$\begin{aligned}
\text{Recall} &= \frac{TP}{TP + FN} \\
\text{Precision} &= \frac{TP}{TP + FP} \\
\text{AUPRC} &= \int_0^1 \text{Precision}(\text{Recall}) d\text{Recall}
\end{aligned} \tag{3.8}$$

AC 三分類、AC 二分類與 GOLD 相關候選分級亦需考量類別數量不均，因此本文除整體 accuracy 外，同時報告 macro-precision、macro-recall、macro-F1、balanced accuracy 與 confusion matrix。若類別數為 K ，第 k 類之 true positive、false positive 與 false negative 分別為 TP_k 、 FP_k 與 FN_k ，則各類別之 precision、recall 與 F1-score 定義如下：

$$\begin{aligned}
\text{Precision}_k &= \frac{TP_k}{TP_k + FP_k} \\
\text{Recall}_k &= \frac{TP_k}{TP_k + FN_k} \\
F1_k &= \frac{2 \times \text{Precision}_k \times \text{Recall}_k}{\text{Precision}_k + \text{Recall}_k}
\end{aligned} \tag{3.9}$$

Macro-precision、macro-recall、macro-F1 與 balanced accuracy 定義如下：

$$\begin{aligned}
\text{MacroPrecision} &= \frac{1}{K} \sum_{k=1}^K \text{Precision}_k \\
\text{MacroRecall} &= \frac{1}{K} \sum_{k=1}^K \text{Recall}_k \\
\text{MacroF1} &= \frac{1}{K} \sum_{k=1}^K F1_k \\
\text{BalancedAccuracy} &= \frac{1}{K} \sum_{k=1}^K \text{Recall}_k
\end{aligned} \tag{3.10}$$

對於連續 AC 迴歸任務，本研究以 mean absolute error (MAE)、root mean squared error (RMSE)、coefficient of determination (R^2) 與 Pearson correlation coefficient 評估預測值與真實角度之差異及相關程度。設真實值為 y_i ，預測值為 $\hat{y}_i$ ，真實值平均為 $\bar{y}$ ，則 MAE、RMSE 與 R^2 定義如下：

$$\begin{aligned}
\text{MAE} &= \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i|, \\
\text{RMSE} &= \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2}, \\
R^2 &= 1 - \frac{\sum_{i=1}^N (y_i - \hat{y}_i)^2}{\sum_{i=1}^N (y_i - \bar{y})^2}.
\end{aligned} \tag{3.11}$$

MAE 可直接表示預測角度與真實角度之平均絕對差距；RMSE 對較大誤差較為敏感； R^2 用於描述模型相對於真實值變異之解釋程度；Pearson correlation coefficient 則用於觀察預測值與真實值之線性相關方向與強度。由於本文目前報告之主要深度模型結果為分類與迴歸輸出，而非分割模型比較，因此 Dice similarity coefficient 與 Hausdorff distance 不列為主要實驗結果指標。



第四章 實驗結果與討論

4.1 研究問題

本章依據本研究之實驗流程與任務設計，將結果分析整理為五項研究問題 (Research Questions, RQs)。此安排旨在分別檢視可解釋量化特徵與三維 CT 深度學習模型於 COPD 輔助判讀及肺功能相關表徵預測中所能提供之資訊，並保留由二元分類、連續值迴歸至衍生分級任務之實驗歷程。各研究問題說明如下：

RQ1： 胸部 CT 影像擷取之量化生物標記，能否區分 COPD 正常與異常？

RQ2： 輸入三維 CT 之影像模型，是否能進行正常與異常分類？

RQ3： 三維 CT 影像模型是否能預測肺功能塌陷角度？

RQ4： 將塌陷角度轉換為三分類與排除中間灰區後之二分類，是否有助於肺功能相關影像判讀？

RQ5： 三維 CT 影像模型 GOLD 分級效果如何？

4.2 實驗環境設定

本研究實驗主要於本機工作站完成，硬體設備如表 4.1 所示。依實驗流程不同，CT 量化生物標記分支於 Windows 環境執行；三維 CT 深度學習、塌陷角預測、GOLD 相關候選分級與 TAP-CT 相關實驗則於 Ubuntu 環境執行。兩個分支之作業系統、主要框架與用途分別整理如表 4.2 與表 4.3。

表 4.1: 實驗硬體設備

項目	規格
CPU	Intel Core i7-12700K 3.60GHz 12-Core Processor
GPU	NVIDIA GeForce RTX 4070 Ti SUPER
RAM	32GB DDR4-3200MHz
Storage	1TB NVMe SSD + 2TB SATA HDD

表 4.2: CT 量化生物標記分支實驗環境

項目	內容
作業系統	Windows 11 Pro 64-bit
分割與影像處理工具	3D Slicer、MONAI Auto3DSeg、AeroPath、SimpleITK
模型訓練與資料處理套件	PyTorch、scikit-learn、NumPy、pandas

表 4.3: 三維 CT 深度學習分支實驗環境

項目	內容
作業系統	Ubuntu 24.04.4 LTS (Noble Numbat), Linux kernel 6.17.0-29-generic, x86_64
深度學習環境	Python 3.11、PyTorch 2.8.0、CUDA 12.8、MONAI
醫學影像與資料處理套件	SimpleITK、nibabel、scikit-learn、pandas、matplotlib
TAP-CT 相關套件	transformers、timm、einops

4.3 實驗結果分析

4.3.1 RQ1 量化特徵二分類結果

量化特徵二分類之五折交叉驗證結果如表 4.4 所示，整體混淆矩陣如圖 4.1 所示。

表 4.4: RQ1 量化特徵二分類結果

指標	整體結果	五折平均
Accuracy	0.9259	0.9273 ± 0.0680
Precision	1.0000	1.0000 ± 0.0000
Sensitivity	0.8788	0.8810 ± 0.1086
Specificity	1.0000	—
F1-score	0.9355	0.9331 ± 0.0626
AUC	0.9784	0.9657 ± 0.0430

從表 4.4 與圖 4.1 可以看出，CT 量化生物標記於 Normal/Abnormal 二分類中具有穩定辨識能力，整體 Accuracy 為 0.9259，AUC 為 0.9784。模型之 Precision 與 Specificity 皆為 1.0000，表示本實驗中未將 Normal 個案誤判為 Abnormal；然而 Sensitivity 為 0.8788，混淆矩陣中仍有 4 筆 Abnormal 個案被判為 Normal。此結果顯示，肺氣腫比




圖 4.1: RQ1 量化特徵二分類混淆矩陣圖

例、肺容積、血管與氣道等量化特徵能有效支援二分類判讀，但對部分異常個案仍可能出現低估。

4.3.2 RQ2 三維影像模型二分類結果

三維 CT Normal/Abnormal 分類結果如表 4.5 所示。本節列出同一 nnMamba 三維影像模型於 Normal/Abnormal 二分類任務下之不同原始訓練輸出結果；表中模型參數簡寫採「原始輸出後綴加主要辨識特性」命名，例如 e5-bestAUC 對應 nnMamba_2026-02-12_15:32:33_e5，其中 bestAUC、lowSens、highSpec 與 balSS 分別表示最高 AUC、Sensitivity 相對較低、Specificity 較高，以及 Sensitivity/Specificity 較均衡。結果來源為本研究之 nnMamba 實驗紀錄¹，各列皆為五折交叉驗證之平均值與標準差。

從表 4.5 與圖 4.2 可以看出，三維影像模型在 Normal/Abnormal 二分類任務中表現最佳者為 e5-bestAUC，其 AUC 達到 1.0000 ± 0.0000 ，Accuracy 為 $0.9409 \pm$

¹彙整結果取自 nnMamba_paper_experiment_notes/results/Normal_v_Abnormal.md；各列數值與原始 results.json 對應關係核對自 nnMamba_paper_experiment_notes/runs/classification/Normal_v_Abnormal/。

表 4.5: RQ2 三維影像二分類實驗結果

排名	模型參數簡寫	AUC	Accuracy	Sensitivity	Specificity
1	e5-bestAUC	1.0000 ± 0.0000	0.9409 ± 0.0422	0.9019 ± 0.0718	1.0000 ± 0.0000
2	e1-lowSens	0.9643 ± 0.0714	0.8491 ± 0.1690	0.7857 ± 0.2172	0.9500 ± 0.1000
3	e2soft-highSpec	0.9486 ± 0.1029	0.9167 ± 0.1291	0.8571 ± 0.2213	1.0000 ± 0.0000
4	0320-balSS	0.9400 ± 0.1200	0.8709 ± 0.1683	0.8714 ± 0.1238	0.8800 ± 0.2400

0.0422。e2soft-highSpec 同樣維持 1.0000 之 Specificity，但 AUC 與 Accuracy 略低於 e5-bestAUC；e1-lowSens 之 Sensitivity 相對較低，顯示其異常個案辨識較不穩定；0320-balSS 則呈現較接近的 Sensitivity 與 Specificity。整體而言，四組 nnMamba 訓練輸出之 AUC 皆高於 0.94，顯示直接由三維 CT volume 學習影像表徵可有效區分 Normal 與 Abnormal 個案；但不同訓練輸出之 Accuracy、Sensitivity 與 Specificity 仍有差異，代表小樣本資料切分與訓練過程之變異仍會影響最終分類穩定性。




圖 4.2: 三維影像二分類效能比較

4.3.3 RQ3 三維影像角度預測結果

塌陷角連續值迴歸結果如表 4.6 所示。

表 4.6: RQ3 塌陷角連續值迴歸結果

排名	模型	MAE	RMSE	R^2	Pearson
1	Hybrid Mamba-Attention	15.8512 ± 4.7756	21.2647	0.1723	0.6699
2	nnMamba regressor	17.1180 ± 2.5754	23.9086	0.0314	0.3413
3	Mamba	17.5599 ± 2.2596	25.0490	-0.0606	0.3812
4	SwinUNETR	19.0884 ± 2.8357	24.3769	-0.0012	0.1898




圖 4.3: 塌陷角連續值迴歸平均絕對誤差比較

從表 4.6 與圖 4.3 可以看出，在塌陷角連續值迴歸任務中，Hybrid Mamba-Attention 取得最低 MAE，平均誤差為 15.8512 ± 4.7756 ，同時 Pearson correlation 達到 0.6699，優於其他三種模型。nnMamba regressor 與 Mamba 的 MAE 分別為 17.1180 ± 2.5754 與 17.5599 ± 2.2596 ，SwinUNETR 則為 19.0884 ± 2.8357 。此結果顯示，在本研究資料中，於 Mamba 表徵後加入 attention bridge 可提升塌陷角連續值預測表現。

4.3.4 RQ4 塌陷角能否提升肺功能相關影像判讀

4.3.4.1 三分類結果

AC 三分類結果如表 4.7 所示。

從表 4.7 與圖 4.4 可以看出，AC 三分類任務中表現最佳者為 TAP-CT late fusion 搭配 aug100，Accuracy 為 0.8209 ± 0.0939 ，Macro-F1 為 0.6141 ± 0.1403 。雖然 TAP-CT-S-2.5D late fusion 搭配 aug100 具有最高 Accuracy (0.8352 ± 0.0831)，但其 Macro-F1 低於 TAP-CT late fusion，表示不同類別間的平均辨識能力較不均衡。整體而言，TAP-CT

表 4.7: RQ4 AC 三分類結果

排名	模型	設定	Accuracy	Macro-F1	Bal. acc.
1	TAP-CT late fusion	aug100	0.8209 ± 0.0939	0.6141 ± 0.1403	0.6326 ± 0.1803
2	TAP-CT-S-2.5D late fusion	aug100	0.8352 ± 0.0831	0.5884 ± 0.0756	0.5933 ± 0.0952
3	TAP-CT ABMIL S-3D	pooled	0.7132 ± 0.0846	0.5883 ± 0.1381	0.6400 ± 0.2036
4	Hybrid Mamba-Attention	baseline	0.7879 ± 0.1018	0.5861 ± 0.1546	0.6200 ± 0.1154
5	Hybrid Mamba-Attention	aug300	0.7593 ± 0.1173	0.5713 ± 0.0748	0.6319 ± 0.1160

embedding 與三維 CT 特徵進行 late fusion 後，能在三分類任務中取得較佳的 Macro-F1。




圖 4.4: 塌陷角三分類效能比較

4.3.4.2 二分類結果

AC 二分類結果如表 4.8 所示。

表 4.8: RQ4 AC 二分類結果

排名	模型	設定	Accuracy	Macro-F1	Bal. acc.
1	TAP-CT late fusion	extreme aug100	0.9192 ± 0.0718	0.8763 ± 0.1186	0.8778 ± 0.1333
2	Hybrid Mamba-Attention	aug100	0.8692 ± 0.0656	0.8177 ± 0.0761	0.8289 ± 0.0963
3	Hybrid Mamba-Attention	baseline	0.7705 ± 0.0323	0.4350 ± 0.0101	0.5000 ± 0.0000

從表 4.8 與圖 4.5 可以看出，排除中間灰區後之 AC 二分類結果明顯優於三分類。TAP-CT late fusion 搭配 extreme + aug100 取得最高 Accuracy (0.9192 ± 0.0718) 與 Macro-F1 (0.8763 ± 0.1186)，相較於 Hybrid Mamba-Attention baseline 的 Macro-F1 0.4350

有明顯提升。此結果顯示，當移除角度介於 132 至 151 度之中間樣本後，影像模型較能區分低角度異常傾向與正常傾向個案。




圖 4.5: 塌陷角二分類效能比較

4.3.5 RQ5 三維影像 GOLD 四分類結果

GOLD 相關候選分級結果如表 4.9 所示。

表 4.9: RQ5 GOLD 相關候選分級結果

排名	模型	設定	Accuracy	Macro-F1	Bal. acc.
1	Hybrid Mamba-Attention	aug36	0.5606 ± 0.1134	0.5323 ± 0.0479	0.5222 ± 0.0463
2	Hybrid Mamba-Attention	baseline	0.5152 ± 0.1868	0.4639 ± 0.1645	0.5194 ± 0.0834
3	Hybrid Mamba-Attention	aug200	0.5606 ± 0.0773	0.4436 ± 0.0674	0.4611 ± 0.0307
4	SwinUNETR	baseline	0.4444 ± 0.1361	0.3144 ± 0.1559	0.3472 ± 0.1084
5	Mamba	baseline	0.4259 ± 0.1458	0.3107 ± 0.0392	0.3674 ± 0.0606

從表 4.9 與圖 4.6 可以看出，GOLD 相關候選分級中表現最佳者為 Hybrid Mamba-Attention 搭配 aug36，Accuracy 為 0.5606 ± 0.1134 ，Macro-F1 為 0.5323 ± 0.0479 。與未使用類別補強之 Hybrid Mamba-Attention 相比，aug36 的 Macro-F1 由 0.4639 提升至 0.5323，顯示在 GOLD 類別分布不平衡的情況下，適度資料增強有助於改善平均分類表現。相較之下，aug200 雖然 Accuracy 同為 0.5606，但 Macro-F1 降至 0.4436，代表過量補強未必能進一步提升各類別辨識能力。




圖 4.6: 候選分級分類效能比較

第五章 結論與未來展望

5.1 研究結論

5.2 未來工作



參考文獻

- [1] Global Initiative for Chronic Obstructive Lung Disease. *Global Strategy for the Diagnosis, Management, and Prevention of Chronic Obstructive Pulmonary Disease: 2025 Report*. Global Initiative for Chronic Obstructive Lung Disease, 2025. URL: <https://goldcopd.org/2025-gold-report/>.
- [2] Sohee Park et al. “Quantitative CT imaging in chronic obstructive pulmonary disease”. In: *British Journal of Radiology* (2025). DOI: 10.1093/bjr/tqaf105.
- [3] Geert Litjens et al. “A survey on deep learning in medical image analysis”. In: *Medical Image Analysis* 42 (2017). DOI: 10.1016/j.media.2017.07.005.
- [4] Hyunjung Park et al. “Deep Learning-based Approach to Predict Pulmonary Function at Chest CT”. In: *Radiology* 307.2 (2023). DOI: 10.1148/radiol.221488.
- [5] Haibo He and Eduardo A. Garcia. “Learning from Imbalanced Data”. In: *IEEE Transactions on Knowledge and Data Engineering* 21.9 (2009). DOI: 10.1109/TKDE.2008.239.
- [6] Marko Topalovic et al. “Computer quantification of airway collapse on forced expiration to predict the presence of emphysema”. In: *Respiratory Research* 14.1 (2013), p. 131. DOI: 10.1186/1465-9921-14-131.
- [7] Shin Matsuoka et al. “Quantitative CT assessment of chronic obstructive pulmonary disease”. In: *Radiographics* 30.1 (2010). DOI: 10.1148/rg.301095110.
- [8] Pierre A. Gevenois et al. “Comparison of computed density and macroscopic morphometry in pulmonary emphysema”. In: *American Journal of Respiratory and Critical Care Medicine* 152.2 (1995). DOI: 10.1164/ajrccm.152.2.7633722.
- [9] Jens T. Bakker et al. “Measuring pulmonary function in COPD using quantitative chest computed tomography analysis”. In: *European Respiratory Review* 30.161 (2021). DOI: 10.1183/16000617.0031-2021.
- [10] George R. Washko et al. “Computed tomographic measures of airway morphology in smokers and never-smoking normals”. In: *Journal of Applied Physiology* 116.6 (2014). DOI: 10.1152/japplphysiol.00004.2013.
- [11] Ivan Dudurych et al. “Bronchial wall parameters on CT in healthy never-smoking, smoking, COPD, and asthma populations: a systematic review and meta-analysis”. In: *European Radiology* 32 (2022). DOI: 10.1007/s00330-022-08600-1.
- [12] Shin Matsuoka et al. “Quantitative CT measurement of cross-sectional area of small pulmonary vessel in COPD: correlations with emphysema and airflow limitation”. In: *Academic Radiology* 17.1 (2010). DOI: 10.1016/j.acra.2009.07.022.
- [13] J. Michael Wells et al. “Pulmonary arterial enlargement and acute exacerbations of COPD”. In: *New England Journal of Medicine* 367.10 (2012). DOI: 10.1056/NEJMoa1203830.

- [14] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. “U-Net: Convolutional Networks for Biomedical Image Segmentation”. In: *Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015*. Vol. 9351. Lecture Notes in Computer Science. 2015. DOI: 10.1007/978-3-319-24574-4_28.
- [15] Fabian Isensee et al. “nnU-Net: a self-configuring method for deep learning-based biomedical image segmentation”. In: *Nature Methods* 18.2 (2021). DOI: 10.1038/s41592-020-01008-z.
- [16] Andriy Fedorov et al. “3D Slicer as an image computing platform for the Quantitative Imaging Network”. In: *Magnetic Resonance Imaging* 30.9 (2012). DOI: 10.1016/j.mri.2012.05.001.
- [17] M. Jorge Cardoso et al. “MONAI: An open-source framework for deep learning in health-care”. In: *arXiv preprint arXiv:2211.02701* (2022). DOI: 10.48550/arXiv.2211.02701.
- [18] Johannes Hofmanninger et al. “Automatic lung segmentation in routine imaging is primarily a data diversity problem, not a methodology problem”. In: *European Radiology Experimental* 4.1 (2020). DOI: 10.1186/s41747-020-00173-2.
- [19] Jakob Wasserthal et al. “TotalSegmentator: Robust Segmentation of 104 Anatomic Structures in CT Images”. In: *Radiology: Artificial Intelligence* 5.5 (2023). DOI: 10.1148/ryai.230024.
- [20] Thomas Z. Li et al. “Quantifying emphysema in lung screening computed tomography with robust automated lobe segmentation”. In: *Journal of Medical Imaging* 10.4 (2023). DOI: 10.1117/1.JMI.10.4.044002.
- [21] Antonio Garcia-Uceda et al. “Automatic airway segmentation from computed tomography using robust and efficient 3-D convolutional neural networks”. In: *Scientific Reports* 11 (2021). DOI: 10.1038/s41598-021-95364-1.
- [22] Karen-Helene Støverud et al. “AeroPath: An airway segmentation benchmark dataset with challenging pathology and baseline method”. In: *PLOS ONE* 19.10 (2024). DOI: 10.1371/journal.pone.0311416.
- [23] Yulei Qin et al. “Learning Tubule-Sensitive CNNs for Pulmonary Airway and Artery-Vein Segmentation in CT”. In: *IEEE Transactions on Medical Imaging* 40.6 (2021). DOI: 10.1109/TMI.2021.3062280.
- [24] Kaiwen Geng et al. “BeyondCT: A deep learning model for predicting pulmonary function from chest CT scans”. In: *arXiv preprint arXiv:2408.05645* (2024). DOI: 10.48550/arXiv.2408.05645.

- [25] Alexey Dosovitskiy et al. “An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale”. In: *International Conference on Learning Representations*. 2021. URL: <https://openreview.net/forum?id=YicbFdNTTy>.
- [26] Yanan Wu et al. “A vision transformer for emphysema classification using CT images”. In: *Physics in Medicine & Biology* 66.24 (2021). DOI: 10.1088/1361-6560/ac3dc8.
- [27] Ze Liu et al. “Swin Transformer: Hierarchical Vision Transformer Using Shifted Windows”. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision*. 2021. DOI: 10.1109/ICCV48922.2021.00986.
- [28] Ali Hatamizadeh et al. “Swin UNETR: Swin Transformers for Semantic Segmentation of Brain Tumors in MRI Images”. In: *arXiv preprint arXiv:2201.01266* (2022). DOI: 10.48550/arXiv.2201.01266.
- [29] Albert Gu and Tri Dao. “Mamba: Linear-Time Sequence Modeling with Selective State Spaces”. In: *arXiv preprint arXiv:2312.00752* (2023). DOI: 10.48550/arXiv.2312.00752.
- [30] Haifan Gong et al. “nnMamba: 3D Biomedical Image Segmentation, Classification and Landmark Detection with State Space Model”. In: *arXiv preprint arXiv:2402.03526* (2024). DOI: 10.48550/arXiv.2402.03526.
- [31] Zhaohu Xing et al. “SegMamba: Long-range Sequential Modeling Mamba For 3D Medical Image Segmentation”. In: *Medical Image Computing and Computer Assisted Intervention – MICCAI 2024*. Vol. 15008. Lecture Notes in Computer Science. Springer Nature Switzerland, 2024. DOI: 10.1007/978-3-031-72111-3_54.
- [32] Yubiao Yue and Zhenzhang Li. “MedMamba: Vision Mamba for Medical Image Classification”. In: *arXiv preprint arXiv:2403.03849* (2024). DOI: 10.48550/arXiv.2403.03849.
- [33] Tim Veenboer et al. “TAP-CT: 3D Task-Agnostic Pretraining of Computed Tomography Foundation Models”. In: *arXiv preprint arXiv:2512.00872* (2025). DOI: 10.48550/arXiv.2512.00872.
- [34] Sanja Stanojevic et al. “ERS/ATS technical standard on interpretive strategies for routine lung function tests”. In: *European Respiratory Journal* 60.1 (2022), p. 2101499. DOI: 10.1183/13993003.01499-2021.
- [35] Maximilian Ilse, Jakub M. Tomczak, and Max Welling. “Attention-based Deep Multiple Instance Learning”. In: *Proceedings of the 35th International Conference on Machine Learning*. Vol. 80. Proceedings of Machine Learning Research. PMLR, 2018, pp. 2127–2136. URL: <https://proceedings.mlr.press/v80/ilse18a.html>.
- [36] Tom Fawcett. “An introduction to ROC analysis”. In: *Pattern Recognition Letters* 27.8 (2006). DOI: 10.1016/j.patrec.2005.10.010.

- [37] Takaya Saito and Marc Rehmsmeier. “The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets”. In: *PLOS ONE* 10.3 (2015). DOI: 10.1371/journal.pone.0118432.

