



國立臺北科技大學

資訊工程系碩士班

碩士學位論文

**彩色都卜勒心臟超音波早期偵測生物人工主
動脈瓣膜退化之研究**

**Early Detection of Bioprosthetic Aortic Degeneration
from Color Doppler Echocardiography**

研究生：顧庭維

指導教授：尤信程、劉建宏

中華民國一百一十四年七月



國立臺北科技大學

資訊工程系碩士班

碩士學位論文

**彩色都卜勒心臟超音波早期偵測生物人工主
動脈瓣膜退化之研究**

**Early Detection of Bioprosthetic Aortic Degeneration
from Color Doppler Echocardiography**

研究生：顧庭維

指導教授：尤信程、劉建宏

中華民國一百一十四年七月

摘要

關鍵詞：主動脈瓣膜置換術、深度學習、生物人工瓣膜、資料增強、彩色都卜勒

生物人工主動脈瓣膜置換術後的定期追蹤，有助於及早偵測瓣膜功能退化。彩色都卜勒超音波影像具有即時性及操作簡便等優勢，能以色彩方式直觀呈現血液穿越心臟瓣膜的速度與方向，是評估瓣膜狹窄或逆流等功能的重要工具，然而受限於資料集規模較小且網路上並無公開的彩色都普勒超音波資料集，導致準確率仍有提升的空間。

為了解決問題，本研究提出了兩種方法來提升模型的準確率：1. 結合資料增強和 Grad-CAM，並加入擾流區域的判斷，將這些額外特徵資訊結合原始影像特徵一同納入現有模型之訓練階段；2. 使用網路上公開的黑白超音波資料集，利用自監督學習的方法來訓練模型，以 SimCLR 對比式學習架構為基礎進行預訓練，後續再將預訓練的模型以少量已標記之生物人工主動脈瓣膜術後彩色都卜勒影像進行線性評估的可行性。

最後，將本研究所採用的模型與現有模型進行比較，實驗結果顯示，在長軸資料集中，方法一的模型正確率高出 6%，方法二的模型正確率高出 10%，於混和資料集中，兩種方法也皆優於現有模型。最終，證實兩種方法於生物人工主動脈瓣膜退化早期偵測的可行性。

Abstract

Keyword: Aortic Valve Replacement, Deep Learning, Bioprosthetic Valve, Data Augmentation, Color Doppler

Regular follow-up after bioprosthetic aortic valve replacement is crucial for the early detection of valve function deterioration. Color Doppler echocardiography offers advantages such as real-time imaging and ease of operation, and intuitively visualizes the velocity and direction of blood flow across cardiac valves using color encoding. This makes it an important tool for evaluating valvular stenosis or regurgitation. However, due to the limited size of available datasets and the lack of publicly available color Doppler ultrasound datasets, there remains considerable room for improvement in diagnostic accuracy.

To address this issue, this study proposes two approaches to enhance model accuracy: 1. Combining data augmentation with Grad-CAM to identify turbulent flow regions, incorporating these auxiliary structural features along with original image features into the model training process; 2. Leveraging publicly available grayscale ultrasound datasets to pre-train the model using a self-supervised learning framework based on SimCLR contrastive learning, followed by fine-tuning the pre-trained model using a small set of labeled color Doppler echocardiographic images from post-operative bioprosthetic aortic valve patients. Finally, the proposed models were compared with existing baseline models. Experimental results showed that in the PLAX dataset, the first approach improved classification accuracy by 4%, and the second approach achieved a 7% improvement. On the mixed dataset, both methods outperformed the baseline model. These findings confirm the feasibility of using the proposed approaches for early detection of bioprosthetic aortic valve degeneration.

目錄

摘要	i
Abstract	ii
目錄	v
第一章 緒論	1
1.1 研究動機與背景	1
1.2 研究目的	3
1.3 論文的組織架構	4
第二章 背景介紹與相關研究	5
2.1 心臟介紹	5
2.1.1 心臟切面影像	6
2.2 生物人工主動脈瓣膜	8
2.2.1 瓣膜置換術	9
2.2.2 結構性瓣膜退化：	9
2.3 心臟超音波影像	10
2.3.1 超音波影像的類型	10
2.3.2 二維超音波影像的優勢與劣勢	11
2.3.3 彩色都卜勒影像的優勢與劣勢	12
2.4 深度學習模型概述	13
2.4.1 卷積神經網路 (Convolutional Neural Network, CNN)	13
2.4.2 殘差網路 (Residual Network, ResNet)	15
2.4.3 混合卷積神經網路 (Mixed Convolutional Network, MC3)	16
2.4.4 監督式學習 (Supervised Learning)	17
2.4.5 自監督式學習 (Self-Supervised Learning)	18
2.4.6 對比學習 (Contrastive Learning)	19
2.5 影像可解釋性	20
2.6 評估指標與損失函數	22
2.6.1 常用分類評估指標	22

2.6.2	損失函數 (Loss Function)	23
2.6.3	最佳化器 (Optimizer)	24
2.7	Pytorch	25
2.8	相關文獻探討	26
第三章	研究方法	27
3.1	資料集	27
3.1.1	彩色都卜勒影像資料集	27
3.1.2	黑白心臟超音波資料集	28
3.2	訓練方法	29
3.2.1	應用資料增強之監督式學習	29
3.2.2	自監督模式	30
3.3	資料前處理步驟	31
3.3.1	遮罩處理	31
3.3.2	血流資訊提取	32
3.3.3	灰階轉換	33
3.3.4	時間插值	33
3.3.5	資料縮放	33
3.3.6	資料取樣	34
3.4	監督式學習模型架構與資料增強方法	35
3.4.1	MC3-18 模型參數	35
3.4.2	資料增強方法	36
3.4.3	Grad-CAM 和擾流區域判斷方法	37
3.5	自監督式學習模型架構與資料增強方法	38
3.5.1	SimCLR 模型參數	38
3.5.2	資料增強方法	39
3.5.3	自監督式學習與下游線性評估流程	40
第四章	實驗結果與分析	41
4.1	實驗環境與設備	41
4.2	實驗所用資料集	43

4.3	研究問題	44
4.4	實驗結果分析	44
4.4.1	實驗一：資料增強對 MC3 模型效能的影響	45
4.4.2	實驗二：使用 Grad-CAM 與影像擾流區塊	47
4.4.3	實驗三：自監督學習與傳統監督式學習之比較	49
4.4.4	實驗四：混合資料集於自監督學習與監督學習模型的比較	50
4.4.5	實驗五：簡單平均融合法結合長、短軸模型於同時具長、短軸患者 之評估	51
4.5	研究問題回應	53
第五章	結論與未來展望	55
5.1	結論	55
5.2	研究限制	55
5.3	未來展望	56
參考文獻		57

圖目錄

2.1	心臟結構示意圖	6
2.2	胸骨旁長軸觀 (PLAX) 示意圖	7
2.3	胸骨旁短軸觀 (PSAX) 示意圖	7
2.4	彩色都卜勒混疊 (aliasing) 效應示意圖	13
2.5	卷積運算示意圖	14
2.6	卷積神經網路 (CNN) 簡易架構示意圖	15
2.7	殘差塊 (Residual Block) 示意圖	16
2.8	混合卷積神經網路 (MC3) 架構示意圖	17
2.9	監督式學習 (Supervised Learning) 流程示意圖	18
2.10	對比學習 (Contrastive Learning) 示意圖	19
2.11	Grad-CAM 與原影像比較圖	21
3.1	應用資料增強之監督式學習流程	30
3.2	自監督模式流程	31
3.3	遮罩處理示意圖	32
3.4	血流資訊提取示意圖	32
3.5	灰階轉換示意圖	33
3.6	資料增強示意圖	37
3.7	提取擾流區域示意圖	38
4.1	六種資料增強方式於長軸資料集準確度之比較	45
4.2	六種資料增強方式於短軸資料集準確度之比較	45
4.3	各資料增強方法的平均準確率比較	47
4.4	Grad-CAM 與影像擾流區塊於長軸資料集準確度比較	48
4.5	Grad-CAM 與影像擾流區塊於短軸資料集準確度比較	48
4.6	不同方法於 R0-R5 子集的平均準確率比較圖	52

表目錄

4.1	本論文主要實驗概述	41
4.2	實驗硬體設備	42
4.3	實驗所用深度學習框架及函式庫版本	42
4.4	模型訓練的主要超參數設定	43
4.5	實驗所用資料集概述	43
4.6	所使用資料集數量	44
4.7	Preprocessed PLAX 各資料增強方法之 MC3 模型測試正確率	46
4.8	Preprocessed PSAX 各資料增強方法之 MC3 模型測試正確率	46
4.9	自監督學習與監督學習模型在 PLAX 資料集上的比較	49
4.10	自監督學習與監督學習模型在 PSAX 資料集上的比較	49
4.11	自監督學習與監督學習模型在混合資料集上的比較	50
4.12	不同方法於 R0-R5 子集的準確率比較	52

第一章 緒論

1.1 研究動機與背景

生物人工主動脈瓣膜（Bioprosthetic Aortic Valve, BAV）因能避免患者接受長期抗凝治療，並具有比機械瓣膜更優異的血流動力學表現，已逐漸成為高齡患者與具有高出血風險之病患進行瓣膜置換手術時的首要選擇。相較於機械瓣膜需終身服用抗凝劑以降低栓塞風險，生物瓣膜在術後初期使用短暫抗凝即可，大幅提升病患術後生活品質。然而，生物瓣膜本質上為動物來源或人工培養的「活體」組織，長期暴露在循環血液流體的動態壓力與機械應力環境下，容易發生瓣膜葉片鈣化、退化或產生裂紋，逐漸導致結構性瓣膜劣化（Structural Valve Degeneration, SVD）與瓣膜返流（regurgitation）等併發症，進一步影響瓣膜的耐用性，降低病患的預後表現 [1]。

因此，生物人工主動脈瓣膜置換術後的定期影像追蹤，對於及早偵測瓣膜功能退化至關重要。臨床上一般建議病患接受瓣膜置換術後至少每年進行一次影像追蹤，以評估瓣膜功能及早期發現可能存在的瓣膜退化或血流異常現象，避免延誤治療時機 [2]。然而，定期影像追蹤所使用的檢查工具需兼具操作便利性、即時性與無創性，才能被廣泛地用於大量病患的常規追蹤診察之中。

彩色都卜勒心臟超音波（Color Doppler Echocardiography）正是符合上述需求的一種醫學影像技術，具備非侵入性、即時顯示、高可攜性以及成本低廉等多重優點 [3]。醫師僅需將超音波探頭輕輕放置於病患胸壁，即可於床邊快速獲取心臟瓣膜的動態影像及血流資訊。透過彩色編碼的流速影像，醫師能清楚且直觀地判斷血流方向，即靠近或遠離探頭之方向與血流速度梯度，進而同步觀察瓣膜組織運動情形以及潛在的血流紊亂與逆流狀況。此技術的運用可大幅提高瓣膜功能退化偵測的效率與準確性，使其成為臨床診斷及術後評估的主要影像工具之一。

儘管彩色都卜勒心臟超音波具備上述的臨床優勢，但在現實醫療情境中，彩色都卜勒影像的判讀仍高度仰賴專業醫師之經驗，且評估過程需要耗費大量時間及人力成本。此外，影像品質不穩定、雜訊干擾嚴重或是輕微異常的辨識困難，也經常導致主觀誤差及診斷上的分歧。隨著超音波檢查需求持續增加，醫院及醫療體系逐漸面臨影像判讀人力不足、醫師工作負荷過重的問題，如何有效提高判讀效率與降低主觀誤差，已成為當

前重要的研究課題 [4, 5, 6]。

近年來，人工智慧 (Artificial Intelligence, AI) 技術迅速發展，尤其是深度學習 (Deep Learning) 方法在醫療領域的應用成效更是引人注目。透過卷積神經網路 (CNN) 等深度學習技術，AI 已被廣泛應用於醫療影像分析之中，成功地在胸腔 X 光、電腦斷層掃描 (CT)、核磁共振影像 (MRI) 及超音波影像等各種醫療影像中展現出優秀的診斷能力 [7, 8]。人工智慧結合醫療影像不僅能顯著提高診斷效率，亦能降低人為判斷的誤差，協助醫師快速、準確地作出診療決策，具有廣大的潛在臨床價值。

儘管如此，現階段將 AI 技術應用於生物人工主動脈瓣膜置換術後彩色都卜勒影像之研究仍相對較少，現有 AI 模型在早期偵測瓣膜退化之準確率方面，仍存在進步空間。本研究目前所面臨的重要挑戰之一，即在於瓣膜相關的彩色都卜勒影像資料相對不足，且缺乏網路上公開可用的資料集，造成模型訓練困難及泛化能力受限。此外，如何有效地將有限的影像資料，透過適當的影像增強技術 (Data Augmentation)，提高退化偵測的準確率，亦為本研究的重要研究目標。

本研究分為兩種面向進行：

- 基於潘建蒼所提出的生物人工主動脈瓣膜置換術後退化偵測模型加入多種影像增強策略 [9]。
- 研究自監督學習 (Self-Supervised Learning, SSL) 於生物人工主動脈瓣膜功能退化偵測的可行性。

本研究主要目的為提升模型於瓣膜退化偵測任務上的準確度及效率，除了將探討不同 AI 演算法及模型架構在實際臨床影像上的性能差異外，亦將針對臨床實務需求，評估所開發之 AI 輔助診斷工具在真實醫療環境中的可用性與臨床價值。

綜合而言，本研究期望透過技術創新與方法整合，有效提升彩色都卜勒心臟超音波用於生物人工主動脈瓣膜功能退化偵測的效率與準確性，為臨床心臟瓣膜疾病的管理提供更為精準、有效且可行的解決方案，進一步改善患者的術後預後與生活品質，並期許此研究成果未來能成為相關醫學影像 AI 研究的重要參考依據，為醫療影像技術的進步貢獻一份心力。

1.2 研究目的

為了解決 1.1 節所述之彩色都卜勒心臟超音波影像的資料量不足、人工判讀主觀性高以及現有模型準確度有限等挑戰，本研究旨在透過強化影像增強策略與導入自監督學習策略，提升生物人工主動脈瓣膜置換術後退化偵測模型的準確性與臨床實用性。具體研究目標說明如下：

- **整合多樣化影像增強策略至既有模型：**在不改變既有資料前處理的前提下，系統性評估多種影像增強策略對於準確率的影響，本研究亦將導入視覺注意力分析技術（Gradient-weighted Class Activation Mapping, Grad-CAM），以有效地了解過往模型在進行瓣膜退化偵測任務時的主要關注區域，並透過影像處理方法計算彩色都卜勒影像中的擾流區域面積及數量，將這些額外特徵資訊結合原始影像特徵一同納入模型之訓練階段，以期進一步提升模型對於早期偵測瓣膜退化任務的準確度。
- **驗證自監督學習於生物人工主動脈瓣膜置換術後退化偵測的可行性：**為了在有限標註資料的情境下有效提升模型的泛化性與準確度，本研究將首次嘗試引入自監督學習（Self-Supervised Learning, SSL）之技術，並以 SimCLR（Simple Framework for Contrastive Learning of Visual Representations）對比式學習架構為基礎進行研究。我們計畫使用網路上公開之黑白超音波影像資料集，建立自監督學習之預訓練流程，利用大量未標註的超音波影像進行前期特徵學習，使模型得以學習到通用且具泛化力的時空特徵表現。後續再將預訓練的模型以少量已標記之生物人工主動脈瓣膜術後彩色都卜勒影像進行線性評估（Linear Evaluation），並與傳統監督式深度學習方法進行比較分析，評估 SSL 模式在本研究之情境下對偵測的準確度，並驗證該方法之臨床應用潛力與可行性。

藉由上述目標，本研究期望可以充分挖掘資料潛力、突破資料量不足的限制，並驗證自監督學習於生物人工主動脈瓣膜置換術後早期退化偵測的可行性。進而提升生物人工主動脈瓣膜置換術後退化偵測的準確性、穩定性與臨床應用價值外，也希望為未來人工智慧技術與醫療影像分析在心臟瓣膜疾病監測領域的發展奠定堅實的基礎，提供後續相關研究及臨床應用之重要參考。

1.3 論文的組織架構

本論文的整體組織架構共分為五個主要章節，各章節的具體內容安排與說明如下所述：

- **第二章背景介紹與相關研究：**本章主要介紹本研究主題之相關背景與理論基礎，首先探討生物人工主動脈瓣膜（Bioprosthetic Aortic Valve, BAV）的特性、優缺點及其臨床應用現況，並說明瓣膜功能退化如瓣膜劣化與返流之形成原因與臨床重要性。接著，深入探討彩色都卜勒心臟超音波之技術原理、臨床應用及其面臨的挑戰，包括影像品質不穩定、資料量不足與判讀主觀性高等問題。最後，對現今人工智慧（AI）及深度學習技術於醫療影像分析之相關研究進行詳細文獻回顧，並探討資料增強（Data Augmentation）方法與自監督學習（Self-Supervised Learning, SSL）技術。
- **第三章研究方法：**本章將詳細描述本研究所使用之影像資料集之來源、收集方法與特性分析，並系統性地描述本研究所提出的兩大研究方法：影像增強策略與自監督學習技術的整合應用，本章最後將闡明如何設定比較基準（BaseLine）、評估指標（如敏感性、特異性）。
- **第四章實驗結果與討論：**本章將針對本研究提出的方法進行實驗驗證，呈現不同影像增強策略及自監督學習技術於人工生物瓣膜退化偵測任務之各項實驗結果，包括不同模型之準確度、敏感性、特異性及其他重要統計指標。
- **第五章結論與未來研究方向：**最後一章將總結本研究之主要貢獻、研究結果的重要性及其對臨床應用之潛在價值。同時，本章亦將提出本研究現有之研究限制與挑戰，並建議未來可能進一步發展之研究方向，以推動心臟瓣膜疾病監測技術的持續創新與臨床實踐的有效性。

第二章 背景介紹與相關研究

本章將針對本研究涉及的相關領域知識與所採用之深度學習方法進行詳細的介紹。內容將涵蓋生物人工主動脈瓣膜的臨床背景與特性，以及彩色都卜勒心臟超音波影像之相關技術理論與醫療應用。此外，也會深入介紹本研究所採用之人工智慧技術與模型架構，包含用於時空影像特徵擷取之深度學習模型，以及監督式學習（Supervised Learning）和自監督學習（Self-Supervised Learning, SSL）兩種學習策略。同時，本研究採用之深度學習框架與開發工具（如 PyTorch 套件）以及醫療影像處理相關工具之使用方式，也會於本章進行詳細說明。

2.1 心臟介紹

心臟是人體最關鍵的生命維持器官之一，位於胸腔中央、左右肺葉之間，呈錐形結構，外部由心包膜包覆。其主要功能為透過節律性收縮與舒張，將血液泵送至全身與肺部，負責輸送氧氣與營養物質，並回收代謝產物。心臟的正常運作高度依賴於內部各結構的協調，包括心房、心室、瓣膜與主要血管等部分。

- **心房（Atria）**：位於心臟的上方，共有左右兩個心房。右心房負責接收來自全身的缺氧靜脈血，左心房則接收來自肺部富含氧氣的靜脈血。心房的主要功能為將血液引導至下方的心室。
- **心室（Ventricles）**：位於心臟下方，是心臟最主要的泵浦單元。右心室將缺氧血液送入肺動脈進行氣體交換，左心室則將含氧血液送入主動脈，供應全身各器官。左心室的壁厚明顯大於右心室，以因應較大的輸出阻力。
- **瓣膜（Valves）**：心臟內共具有四個瓣膜，分別為二尖瓣、三尖瓣、主動脈瓣與肺動脈瓣。瓣膜負責在心臟收縮與舒張期間有序開合，防止血液逆流，確保單向循環功能。任一瓣膜的結構異常或功能障礙，均可能導致血流受阻或逆流，進而影響整體心臟效能。
- **心血管血管（Cardiovascular Vessels）**：包括從心臟流出的大血管如主動脈與肺動脈，以及返回心臟的上下腔靜脈與肺靜脈。這些血管與心臟構成封閉式的循環系

統，負責將血液從心臟送至全身並返回，保持心臟正常的運作。




圖 2.1 心臟結構示意圖
資料來源：參考文獻 [10]

心臟各構造間需密切協調，才能完成完整的血液循環路徑。任何結構的異常，例如瓣膜鈣化、心室擴大或心房顫動，均可能對心臟功能造成重大影響。因此，在臨床心臟超音波影像判讀中，準確掌握各結構位置與功能至關重要，亦為後續疾病偵測與預後評估的基礎。

2.1.1 心臟切面影像

在經胸超音波（TTE）檢查中，醫師通常依探頭放置位置選擇固定的觀察角度（view），以便於比對與紀錄。下列 5 種切面為臨床最常用的影像 [11]。

- **胸骨旁長軸觀（Parasternal Long-Axis View, PLAX）**：胸骨旁長軸觀是經胸心臟超音波中最基本的切面之一，檢查時將探頭置於左胸第三至第四肋間處，朝向右肩方向。此切面可清楚顯示左心房、左心室、室中隔、主動脈根部與二尖瓣葉片等重要結構。臨床上常用於量測左心室的腔室大小與壁厚，並能觀察主動脈瓣是否有鈣化現象，或二尖瓣是否出現脫垂、逆流等病理徵象。搭配彩色都卜勒影像，可進一步評估瓣膜開合與血流動態。




圖 2.2 胸骨旁長軸觀 (PLAX) 示意圖

- **胸骨旁短軸觀 (Parasternal Short-Axis View, PSAX)**：胸骨旁短軸觀與 PLAX 取像位置相同，但需將探頭順時針旋轉約 90 度，以獲得橫斷式的心臟影像。視掃描深度不同，此切面可依序觀察主動脈瓣、右心室流出道、乳突肌平面與心尖平面等。PSAX 在臨床上有助於判讀主動脈瓣為三瓣或二瓣結構，亦常用於肺動脈壓的估算、右心室壓力變化的評估與心室同步性觀察。




圖 2.3 胸骨旁短軸觀 (PSAX) 示意圖

- **心尖四腔平面 (Apical Four-Chamber View, A4C)：**心尖四腔觀是評估左右心腔功能的重要視角，探頭置於心尖部位，通常為左側乳突下方，朝向右肩取得影像。此觀察角度能同時顯示左心房、右心房、左心室與右心室，並觀察二尖瓣與三尖瓣的開關動態。A4C 是評估心室收縮功能與瓣膜逆流的標準切面，亦有助於比較左右心室大小與收縮對稱性。
- **心尖二腔與三腔平面 (A2C / A3C)：**心尖二腔觀與三腔觀是由 A4C 基礎切面稍作順時針旋轉所取得。二腔觀 (A2C) 主要顯示左心房與左心室，三腔觀則可同時觀察左心室、左心房與主動脈瓣，並延伸至主動脈根部。臨床上，這些觀察角度常與 A4C 搭配使用，用於應用辛普森法 (Simpson's method) 計算左心室容積與 ejection fraction(EF，左心室射出分率)，或進一步評估主動脈瓣功能與逆流情況。
- **肋下四腔平面 (Subcostal Four-Chamber View)：**肋下四腔觀是經胸視窗受限（如肥胖、肺氣腫或胸外傷）時的重要替代方案。檢查時病人平躺並雙膝微彎，探頭放置於劍突下方朝向左肩。此切面能取得類似 A4C 的心腔影像，但需留意影像上下翻轉。因聲波會穿過肝臟，此切面能清晰呈現心包膜與心腔邊界，是觀察心包積水與心臟壓塞的重要角度，並可提供心室功能之補充資訊。

臨床檢查通常先以 PLAX 與 PSAX 建立解剖方向，再用 A4C 與 A2C 詳查左、右心室功能，必要時加做肋下或經食道視窗補足盲區。藉由固定切面，醫師可在追蹤檢查時迅速比對病灶變化，提高效率。

2.2 生物人工主動脈瓣膜

生物人工主動脈瓣膜 (Bioprosthetic Aortic Valve, BAV) 是一種以生物材料所製成的人工瓣膜，主要由牛心包膜 (bovine pericardium) 或豬主動脈瓣葉 (porcine aortic leaflet) 等動物組織經特殊處理與縫合後製成。由於生物瓣膜本身具有更接近人類原生瓣膜之血流動力學特性，且不需要患者終身服用抗凝血藥物，能有效降低因抗凝藥物治療所引起的出血風險，因此特別適合高齡患者及其他具有高出血風險的病患使用。

2.2.1 瓣膜置換術

瓣膜置換術（Valve Replacement Surgery）是一種心臟外科手術，用於治療因瓣膜狹窄（stenosis）或瓣膜閉鎖不全（regurgitation）所引起的嚴重瓣膜功能退化。心臟瓣膜負責控制心臟內血液流動的單向性，當瓣膜發生結構損壞或功能障礙時，會嚴重影響心臟功能與血液循環效率，進而導致患者出現呼吸困難、心律不整、心臟衰竭甚至猝死等嚴重症狀。瓣膜置換術的目的在於移除受損或功能失常的原生瓣膜，並植入新的人工瓣膜以恢復瓣膜正常功能，改善心臟血流動力學，提升病患生活品質與存活率，目前瓣膜置換術的手術方式有兩種：

- **傳統外科開胸手術（Surgical Aortic Valve Replacement, SAVR）**：SAVR 屬於侵入式手術，需要體外循環與全身麻醉，使用開胸的方式進行手術，但並不是所有病人皆適合此方式，有些病人經醫師評估，無法承受該手術，在經導管瓣膜置換術（transcatheter aortic valve replacement, TAVR）發展之前，只能使用藥物的方式治療，大大降低病人的平均壽命 [12]。
- **經導管瓣膜置換術（Transcatheter Aortic Valve Replacement, TAVR）** TAVR 則為微創方式，將生物人工主動脈瓣膜透過導管技術從股動脈或心尖處將瓣膜送入主動脈瓣位置，適用於不適合接受傳統開胸手術的高風險患者。

2.2.2 結構性瓣膜退化：

結構性瓣膜退化（Structural Valve Degeneration, SVD）指的是生物人工瓣膜植入後，隨著時間推移所發生的瓣膜結構性劣化現象，主要表現為瓣膜葉片鈣化（calcification）、撕裂（tearing）、穿孔（perforation）或其他結構損傷，導致瓣膜功能逐漸下降或失效 [13]。這些結構性改變會進一步造成瓣膜狹窄（stenosis）或瓣膜閉鎖不全（regurgitation），最終影響心臟的血液動力學表現，並降低患者的生活品質與長期存活率。

造成結構性瓣膜退化的原因包括瓣膜材料本身之生物特性、機械應力、血流動力學改變以及患者個體因素（如年齡、腎功能不佳、高血脂、高血糖及其他代謝異常等）。其中，瓣膜葉片的鈣化與退化為結構性瓣膜退化中最常見的表現形式，葉片內的鈣鹽沉積導致瓣膜逐漸變厚、僵硬，降低瓣膜開啟與關閉的靈活性，這種結構上的改變會逐漸加

重瓣膜狹窄或返流程度，甚至引起心臟功能衰退或心力衰竭[14]。

臨床上，SVD 被認為是生物瓣膜植入術後長期追蹤的重要監測項目，瓣膜植入後的 8 至 10 年內逐漸開始出現明顯退化跡象，尤其以年輕患者或代謝疾病患者更易加速退化。為及早發現瓣膜退化，醫學指引皆建議患者術後應進行定期超音波追蹤，尤其是彩色都卜勒心臟超音波，因其能快速且無創地提供瓣膜功能資訊，協助臨床醫師評估退化程度並適時介入治療，以減少併發症發生風險，提升患者的存活率與生活品質[11]。

2.3 心臟超音波影像

心臟超音波影像（Echocardiography）是一種利用高頻聲波對心臟結構與功能進行即時可視化檢查的醫學影像技術。藉由此技術，臨床醫師能夠無創地評估心臟各腔室、瓣膜結構及血流動力學，為心臟疾病的診斷、治療與追蹤提供重要依據。

2.3.1 超音波影像的類型

臨床心臟超音波影像並非只有一種顯示方式，而是依量測目的分成數種模式，彼此搭配才能完整評估結構與血流。下列五種類型是最常用、也是教科書與指引中必備的基礎工具。

- **二維超音波影像（2D echocardiography）**

二維超音波影像亦稱灰階模式（B-mode）。二維超音波影像為連續的掃描，透過點、線掃描讓醫師得以直接看到心房、心室、瓣膜與大血管的外形。透過停格或放慢速度，可以量出腔室直徑、壁厚，以及瓣膜開閉是否對稱。由於成像快速、不含輻射且解析度足以顯示細節，二維影像是後續所有都卜勒量測的「底圖」。

- **運動模式（M-mode, Motion mode）**

運動模式以單一超音波掃描線對組織進行連續追蹤，將時間軸與深度資訊合併成一條動態剖面圖。M-mode 具備極高的時間解析度，適合精確分析心臟壁厚變化、瓣膜運動幅度與收縮週期等動態參數。常用於輔助二維影像的結構與功能量測。

- **彩色都卜勒影像（Color Doppler Imaging）**

彩色都卜勒影像是將都卜勒效應與二維超音波影像作合併，在灰階影像上覆蓋紅、

藍兩色以標示血流方向，可以同時看到心臟組織及血流方向，通常血液朝向探頭顯示為紅色，遠離探頭則顯示為藍色；顏色愈鮮明代表速度愈快。醫師可依彩色都卜勒影像判斷是否發生退化狀況。

- **脈衝式都卜勒 (Pulsed-Wave Doppler, PW)**

脈衝式都卜勒是使用探頭以點為單位發射短脈衝，測量指定深度的血流速度與時間變化。因此可精確鎖定特定位置（例如二尖瓣口）來計算血流速率、決定心臟每搏輸出的血量，以此評估心臟功能。其缺點是速度上限約 2 m/s，若血流過快就會出現頻率混疊 (aliasing)。

- **連續波都卜勒 (Continuous-Wave Doppler, CW)**

與脈衝式都卜勒不同，連續波都卜勒讓探頭同時連續發射和接收超音波，能偵測高速血流而不受 aliasing 限制，適合量測如主動脈瓣狹窄或重度逆流噴射等高速射流。但因訊號來自整條掃描線，無法得知血流發生的確切深度，需結合彩色都卜勒或二維影像定位。

- **都卜勒組織影像 (Doppler Tissue Imaging, TDI)**

脈衝式都卜勒與連續波都卜勒主要看血流，而都卜勒組織影像把焦點放在心肌本身的移動速度。電腦會過濾掉高速血流訊號，只留下心肌緩慢的運動資訊，藉此判斷心室在收縮與放鬆階段的速度是否協調。如果 TDI 顯示心肌放鬆速度下降，通常代表早期的舒張功能不全，能及早發現潛在心臟衰竭風險。

2.3.2 二維超音波影像的優勢與劣勢

二維超音波影像 (B-mode, 二維灰階影像) 為心臟超音波的基礎模式，可即時動態顯示心臟各結構解剖，於臨床評估中扮演核心角色。其主要優勢包括：二維影像能夠直接呈現心臟腔室、瓣膜、心肌、心包膜等解剖構造 [15]，協助醫師精確評估心臟大小、壁厚、室間隔運動及瓣膜開閉情形，有助於發現先天性或後天性結構異常。此模式具備高時間解析度，可同步顯示心臟的收縮與舒張運動，利於即時觀察心肌運動異常，如心室壁運動不良 [16]。二維影像過程無輻射、無侵入性，可於床邊迅速操作，特別適合於加護病房、門診與急診重症患者的初步篩檢或追蹤。由於檢查儀器攜帶方便、成本低廉，因此適用於大量病患的例行健康檢查及長期追蹤。

然而，二維超音波影像亦存在若干技術侷限。最大限制為空間解析度受制於探頭頻率與穿透力，對於微小結構或深部組織易出現成像模糊。影像品質高度依賴檢查者技術、探頭定位及患者體型，如肥胖、胸廓畸形或慢性肺部疾病患者常因超音波阻隔或衰減，導致影像品質下降。此外，二維模式僅能提供靜態結構資訊，無法直接顯示血流方向與速度，對於血流動態或瓣膜逆流、狹窄等病變的診斷需仰賴彩色都卜勒或脈衝波模式輔助。影像判讀亦具有一定主觀性，易受操作者經驗影響，且對於部分特殊位置或小型病灶可能出現漏診。

綜上所述，二維超音波影像以其即時性、安全性與便利性，已成為臨床心臟檢查不可或缺的工具，但在定量分析與血流動態評估上，仍須結合其他超音波技術以完善臨床診斷流程。

2.3.3 彩色都卜勒影像的優勢與劣勢

彩色都卜勒影像結合二維灰階視野與都卜勒效應，可於單一畫面同步顯示心臟結構與血流動態，帶來多項臨床優勢。首先，紅、藍色編碼使血流方向與相對速度得以即時辨識，檢查者可於數秒內快速定位瓣膜閉鎖不全、射流方向異常、管腔狹窄或紊流等病灶 [3]。此外，彩色都卜勒檢查具備非侵入性、無輻射、儀器可攜等特性，適用於加護病房或術後床邊重複評估，亦有助於高齡與重症患者的長期追蹤管理 [11]。若搭配縮流頸寬度（vena contracta width）、逆流噴流面積等簡易量化指標，彩色都卜勒在初步判定瓣膜閉鎖不全或狹窄嚴重度時，通常能與心導管檢查結果呈現一致趨勢，提供治療決策之重要依據。

然而，彩色都卜勒亦存有數項技術限制。最主要的侷限為高度角度依賴性，當超音波波束與血流方向夾角過大時，影像上顏色編碼將低估實際流速，甚至錯誤顯示流向，臨床上經常需變換探頭位置以獲得可靠影像。其次，當血流速度超過尼奎斯特極限時，易出現混疊（Aliasing）現象，需改用連續波都卜勒以確保數據準確性。此外，彩色都卜勒僅能提供相對速度及面積資訊，若需精確量測跨瓣壓差或心輸出量，仍須結合脈衝波或連續波模式 [6]。影像品質亦受到檢查者經驗、探頭定位、患者體型等多重因素影響，例如肥胖或慢性肺病患者常因訊號雜訊比（SNR）降低，導致瓣膜逆流低估或偽影產生，增加誤判風險。最後，彩色影像的處理使得每秒影格數下降，高速噴流邊緣易顯模糊，臨床判讀時需注意時間解析度之侷限。




圖 2.4 彩色都卜勒混疊（aliasing）效應示意圖

在瓣膜疾病、先天性心臟病評估、術後監測等多種臨床情境下，彩色都卜勒已成為不可或缺的工具，但其技術侷限與定量不足，亦提示臨床醫師應結合多種超音波模式與臨床背景，以達最佳診斷與治療效果。

2.4 深度學習模型概述

近年來，深度學習（Deep Learning）技術因其優異的影像辨識能力與自動化特徵提取功能，逐漸被廣泛運用於醫學影像分析領域中。本研究旨在運用深度學習技術提升生物人工主動脈瓣膜早期退化偵測之準確性與效率。本節將詳細介紹本研究所使用的幾種深度學習模型與方法，包括卷積神經網路（CNN）、殘差網路（ResNet）、混合卷積神經網路（MC3）以及自監督對比學習框架（SimCLR）。此外，也會進一步詳述監督式學習與自監督式學習的基本概念。

2.4.1 卷積神經網路（Convolutional Neural Network, CNN）

卷積神經網路（CNN）是一種專為處理影像資料所設計的深度神經網路模型。CNN 的主要結構包含卷積層（Convolution Layer）、池化層（Pooling Layer）及全連接層（Fully Connected Layer）。

- **卷積層（Convolution layer）**：卷積層是 CNN 最核心的元件，用來在局部感受視窗內提取相關特徵，通過卷積核（Kernel Map）對輸入影像進行卷積運算，將每個元

素與輸入的影像相乘後相加成為一個卷積元素，當卷積核在整張影像上滑動時，最終會形成特徵圖（Feature Map）。由圖2.5所示。



圖 2.5 卷積運算示意圖

- **池化層 (Pooling layer)**：池化層分為最大池化 (Max Pooling) 和平均池化 (Average Pooling)，最大池化是抓特徵圖的最大值，平均池化是抓特徵圖的平均值。池化層的用途是降低空間維度，提升平移不變性並減少參數量。
- **全連接層 (Fully connected, FC)**：全連接層通常位於 CNN 的尾端，負責將最後的特徵圖通過映射的方式到輸出的類別，以輸出分類或回歸結果。

卷積神經網路 (CNN) 通常是由多重卷積層、池化層以及最末端的全連接層所串接而成。在整個流程中，最後一步的全連接層會把先前累積的特徵圖扁平化並轉換成機器可判斷的類別機率，達到分類或回歸輸出的目的。由於 CNN 能自動從影像中擷取局部紋理，並逐層組合成更抽象的表徵，它已被公認為影像處理領域中極具效能的深度學習模型。[17]。




圖 2.6 卷積神經網路 (CNN) 簡易架構示意圖

2.4.2 殘差網路 (Residual Network, ResNet)

殘差網路 (ResNet) 是針對 CNN 提出的改良方法，起因是在訓練神經網路時，常常會使用增加層數的方式來提高模型的表現，但隨著層數增加，模型的訓練變得越來越困難，準確率反而會下降，這是因為深度的神經網路在訓練過程中容易發生梯度消失的問題。ResNet 的主要創新在於引入了殘差塊 (Residual Block) 與跳躍連接 (Skip Connection) [18]。

- **殘差塊 (Residual Block)**：殘差塊的核心思想是將輸入信號與卷積層的輸出進行相加，形成一個殘差映射。這樣的設計使得網路可以學習到輸入與輸出之間的差異，而不是直接學習輸出本身。
- **跳躍連接 (Skip Connection)**：跳躍連接允許信號在網路中跳過一個或多個層，直接將淺層特徵傳遞到更深層，這樣可以減少梯度消失問題，並使得深度網路更容易訓練。

如圖2.7所示，圖左為常見的神經網路，右邊為改良後的 Resnet 架構圖。這種設計能將淺層特徵直接輸入到深層，使深層網路只需學習輸入與輸出間的殘差（即差異），從而有效地避免梯度消失問題，並使模型可以訓練至更深層的網路結構，讓深度學習模型能夠達到更高的準確率，並在許多影像辨識任務中取得了突破性的成果。




圖 2.7 殘差塊 (Residual Block) 示意圖

2.4.3 混合卷積神經網路 (Mixed Convolutional Network, MC3)

混合卷積神經網路 (Mixed Convolutional Network, MC3) 是一種結合二維與三維卷積操作的深度學習架構，最早由 Tran 等人於 2018 年提出 [19]，旨在兼顧時空特徵的學習效率與計算成本。傳統的三維卷積網路 (3D CNN) 雖能同時提取空間與時間資訊，但其高昂的參數量與運算成本限制了其在實際應用中的彈性與效能。

MC3 的核心設計理念在於：將影像序列，如影片或醫學影像的時間序列，分別以不同維度的卷積進行特徵學習。具體而言，MC3 (Mixed Convolutional Network) 透過「空間-時間解耦」的設計，僅在網路的初始層採用 3D 卷積來同時擷取空間與時間特徵，高層則僅用 2D 卷積以專注於抽象的空間特徵。這樣的架構能大幅降低計算量，卻仍能維持與 3D CNN 相當的時空建模能力。此外，MC3 還採用了殘差網路 (ResNet) 的設計，有效避免了深層網路的梯度消失問題，提升了訓練的穩定性。並提升模型的訓練穩定性。




圖 2.8 混合卷積神經網路（MC3）架構示意圖

2.4.4 監督式學習（Supervised Learning）

監督式學習（Supervised Learning）是深度學習中一種常見的訓練方式，其核心在於使用大量已標記資料來訓練模型。具體來說，每筆輸入資料都具備對應的正確標籤，模型在訓練過程中，根據預測結果與真實標籤間的差距，不斷進行參數的調整以降低誤差。

在監督式學習中，資料的數量與品質對於模型的準確性與泛化能力具有決定性影響。因此，前期需進行完整的資料收集、標註與預處理流程，以確保輸入樣本的代表性與一致性。常見的前處理步驟包括：影像格式轉換、尺寸統一、色彩正規化，以及資料增強等，藉此提升模型對於實際臨床應用中資料多樣性的適應能力。一旦完成資料準備，接下來需選擇適合任務需求的模型架構，如卷積神經網路（CNN）常被應用於影像分類任務中。訓練過程中，常使用交叉熵損失函數（Cross-Entropy Loss）作為目標函數，透過最佳化演算法（例如 Adam 或 SGD）持續更新模型參數，最小化預測結果與實際標籤之間的誤差。此過程使模型能逐步學習輸入與輸出之間的對應關係，並提升預測準確性。

模型訓練期間通常會使用驗證集（Validation Set）評估模型效能，作為監控訓練狀態與調整超參數的依據，進而降低過擬合風險。訓練結束後，則以獨立的測試資料集（Test Set）進行最終評估，測量模型在未見資料上的泛化能力，確保其在實際應用場景中的穩定性與準確性。如圖2.9所示。




圖 2.9 監督式學習（Supervised Learning）流程示意圖

2.4.5 自監督式學習（Self-Supervised Learning）

自監督式學習（Self-Supervised Learning）是一種介於監督式與無監督式學習之間的機器學習方法，其核心理念為：無須大量人工標註資料，即可進行有效的特徵學習。此方法透過利用資料本身的內在特徵與結構，設計特定的預測任務，讓模型從未標註的資料中自動學習有意義的特徵表示。自監督式學習的最大優勢是可顯著降低標註成本，並且提升模型的泛化能力與性能。常見的自監督式學習的方法包括：

- **生成式方法（Generative Approaches）**：生成式方法強調重建原始輸入資料，模型需學會在像素層級重建影像，例如補齊被遮蔽的區域或重現輸入樣本，藉此學得具語義意涵的特徵。
- **預測式方法（Predictive Approaches）**：預測式方法關注資料內部區塊之間的結構關係，例如要求模型預測圖像中兩個區塊的相對位置，或從一部分內容推測另一部分的性質，而非重建整體輸入。
- **對比式方法（Contrastive Approaches）**：對比式方法目前應用最為廣泛，核心概念為：模型應學會將來自相同樣本的不同轉換版本映射至相近的特徵空間，同時將來

自不同樣本的表徵區分開來。常見做法為對影像應用隨機資料增強策略產生多個視圖，並以相似性度量函數指引模型聚合正樣本對，遠離負樣本對。

2.4.6 對比學習 (Contrastive Learning)

對比學習 (Contrastive Learning) 是一種自監督式學習方法，旨在透過比較兩個樣本之間的相似性與差異性來學習有意義的特徵表示。

此方法的基本概念是：將同一資料樣本透過不同的資料增強操作產生兩個視圖 (views)，視為正樣本對 (positive pair)；而來自不同樣本的視圖則視為負樣本對 (negative pairs)。訓練過程中，模型學習將正樣本對映射至特徵空間中的鄰近位置，並同時拉開與負樣本對之間的距離 [20]。透過此種方式，模型可在無需標籤的前提下學習資料的結構性與語意資訊。

對比學習的訓練目標通常透過對比損失函數 (如 NT-Xent loss、InfoNCE loss) 實現，此類損失函數會根據特徵間的距離設計，使正樣本間相似度最大化、負樣本間相似度最小化。

近年來，對比式學習已廣泛應用於各種任務中，包括影像分類、語意分割、物件偵測與自然語言處理等領域。其學得之特徵表徵具有高度可遷移性與泛化能力，可作為下游監督式任務的良好初始化，有效提升模型效能與資料使用效率。




圖 2.10 對比學習 (Contrastive Learning) 示意圖

2.5 影像可解釋性

深度學習模型尤其是卷積神經網路 (CNN)，儘管在許多影像分類和醫學影像分析任務中展現出極佳的表現，但由於模型內部的計算過程相當複雜，模型的決策邏輯往往難以被人類直觀理解。為了提高模型決策的可解釋性，近年來視覺化分析技術受到廣泛的重視，其中梯度加權類別激活圖 (Gradient-weighted Class Activation Mapping, Grad-CAM) 便是最具代表性的方法之一。

Grad-CAM 由 Selvaraju 等人於 2017 年所提出，其主要概念是透過卷積層特徵圖 (feature map) 的梯度資訊，來呈現 CNN 模型在進行特定類別分類時關注影像的哪些區域 [21]。Grad-CAM 首先透過前向傳播獲得特徵圖，再透過反向傳播計算特徵圖相對於特定類別預測結果的梯度資訊，並將梯度資訊作為特徵圖的權重加以加權平均，生成視覺化的熱力圖 (heatmap)。熱力圖中顏色越鮮明，例如紅色區域，代表該區域對於分類決策的重要性越高，模型越關注該區域。

Grad-CAM 有以下幾點重要的優勢：

- **適用於任意 CNN 架構：**Grad-CAM 僅利用模型的梯度資訊與卷積層特徵圖，因此不受特定 CNN 架構限制，具有廣泛的適用性。
- **直觀的可解釋性：**透過視覺化熱力圖，使用者能清楚且直觀地理解模型進行預測時的關鍵區域，有助於驗證模型預測是否符合臨床邏輯。
- **不需改變模型結構：**Grad-CAM 並不需要修改模型原始結構，也不需要重新進行模型訓練，僅需在訓練後進行額外的後處理步驟即可完成。

在各類電腦視覺應用中，Grad-CAM 已被廣泛用於增進模型可解釋性，包括圖像分類、物件偵測與圖像分割等任務。透過該技術，研究者與使用者可以更清楚理解模型的行為，進一步提升其透明度與可信度，並作為模型驗證與除錯的重要輔助工具。如圖2.11所示。





圖 2.11 Grad-CAM 與原影像比較圖

2.6 評估指標與損失函數

在本研究中，主要任務為針對生物人工主動脈瓣膜置換術後的心臟超音波影像進行退化偵測，屬於二元分類問題。因此，除了訓練過程中所使用的損失函數外，亦需於模型驗證階段選用適當的評估指標，以量化模型在實際應用場景中的預測能力與穩定性。

本研究的效能評估主要依據四個基本分類指標進行計算與分析，如下所示：

- **True Positive (TP)**：實際為 Positive 的樣本被模型正確判斷為 Positive 的數量。
- **True Negative (TN)**：實際為 Negative 的樣本被模型正確判斷為 Negative 的數量。
- **False Positive (FP)**：實際為 Negative 的樣本卻被模型誤判為 Positive 的數量。
- **False Negative (FN)**：實際為 Positive 的樣本卻被模型誤判為 Negative 的數量。

2.6.1 常用分類評估指標

為評估模型對正常與異常瓣膜影像之區分能力，本研究採用下列多種二元分類常用評估指標：

- **Accuracy (準確率)**：整體預測正確的比例，計算公式為：

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

準確率 (Accuracy) 是最直觀且最常使用的分類效能指標之一，其定義為模型正確預測的樣本數與總樣本數之比。由於其計算方式簡單且易於理解，常被作為模型整體表現的初步評估指標。然而，在面對類別不平衡 (class imbalance) 問題時，準確率可能會產生誤導性的結果。例如，若某類別在資料中占絕大多數，模型僅透過偏向該類別進行預測，即使忽略其他類別，仍可能獲得較高的準確率，卻無法真正反映模型的辨識能力。

因此，僅以準確率作為模型優劣的依據往往不足，尤其在少數類別的重要性高於多數類別的應用情境下更為明顯，需與其他指標結合使用。

- **Sensitivity (靈敏度 / 真陽性率)**：衡量模型識別出實際異常個案的能力，公式為：

$$\text{Sensitivity} = \frac{TP}{TP + FN} \quad (2.1)$$

在實際應用中，尤其是臨床診斷場景中，模型的靈敏度（Sensitivity，又稱為召回率 Recall）具有關鍵性的重要性。靈敏度衡量的是模型正確識別出所有正類樣本的能力，亦即在所有實際為正的個體中，有多少比例被模型成功預測為正類。高靈敏度的模型能有效降低漏診（False Negative, FN）的風險，避免錯過潛在的異常或病變，對於需要早期偵測與介入的情境尤為重要。若模型靈敏度不足，即使整體準確率高，仍可能導致嚴重後果，例如延誤治療或錯失治癒時機。

- **Specificity (特異度 / 真負率)**：衡量模型對正常個案的識別能力，公式為：

$$\text{Specificity} = \frac{TN}{TN + FP} \quad (2.2)$$

特異度（Specificity）則反映模型對於負類樣本的識別能力，即在所有實際為負的個體中，有多少比例被正確預測為負類。高特異度的模型有助於減少誤報（False Positive, FP）情形，降低不必要的進一步檢查、資源浪費，甚至避免患者接受非必要或具風險性的醫療處置。這對於需要平衡診斷效益與成本、避免過度醫療的應用場景而言，具有實質價值。

總的來說，在評估模型效能時，除了關注整體準確率外，也應特別考量 Sensitivity 與 Specificity 的平衡。

2.6.2 損失函數 (Loss Function)

在機器學習與深度學習模型的訓練過程中，損失函數（Loss Function）扮演著核心角色。其主要功能為衡量模型預測結果與實際標籤之間的差異，並指導模型透過梯度下降等最佳化演算法進行參數調整，使損失逐步減少，進而提升預測準確性。

針對不同的任務性質與資料型態，所選用的損失函數亦有所差異。以二元分類問題為例，最常使用的是交叉熵損失函數（Binary Cross-Entropy Loss），其定義如下：

$$\mathcal{L}_{\text{BCE}} = -[y \cdot \log(\hat{y}) + (1 - y) \cdot \log(1 - \hat{y})] \quad (2.3)$$

其中， y 表示實際標籤（0 或 1）， $\hat{y}$ 為模型預測的機率輸出。交叉熵損失可有效處理機率預測問題，並對錯誤較高的預測給予較大懲罰，因此在分類任務中被廣泛採用。

此外，若任務涉及自監督學習或對比式學習等架構，則會使用不同型態的損失設計。對比學習（Contrastive Learning）中的典型損失函數為對比損失（Contrastive Loss），其目的在於將同類樣本的特徵距離拉近，並將異類樣本的距離推遠。其基本形式如下：

$$\mathcal{L}_{\text{contrastive}} = (1 - y) \cdot \frac{1}{2} D^2 + y \cdot \frac{1}{2} [\max(0, m - D)]^2 \quad (2.4)$$

其中， D 為兩筆樣本在特徵空間中的距離（如歐氏距離）， y 為樣本對的標籤（ $y = 0$ 表示正樣本對， $y = 1$ 表示負樣本對）， m 則為設定的邊界距離（margin），用以控制負樣本間的最小距離。此損失函數會懲罰正樣本對之間的距離過大，也會懲罰負樣本對之間的距離過小，從而強化模型的辨別能力。對比損失特別適用於資料無法明確分類、但可透過相似性關係學習嵌入表徵的情境。

損失函數的選擇與設計對模型訓練結果有重大影響，合適的損失函數能提升學習效率、穩定性及最終效能，因此為模型設計中不可忽略的重要環節。

2.6.3 最佳化器（Optimizer）

在深度學習模型的訓練過程中，最佳化器（Optimizer）負責根據損失函數的梯度資訊，調整模型參數以最小化損失，進而提升模型性能。不同的最佳化演算法對學習速率、收斂穩定性與模型表現有顯著影響，其中最常見的包括隨機梯度下降法（Stochastic Gradient Descent, SGD）與自適應矩估計法（Adaptive Moment Estimation, Adam）。

SGD 是最基礎且經典的最佳化方法，透過每次使用一小批資料（mini-batch）來估計梯度並更新參數，其更新公式如下：

$$\theta_{t+1} = \theta_t - \eta \cdot \nabla_{\theta} \mathcal{L}(\theta) \quad (2.5)$$

其中 θ 為模型參數， η 為學習率（learning rate）， $\nabla_{\theta}\mathcal{L}(\theta)$ 為損失函數對參數的梯度。SGD 儘管實作簡單，對學習率的敏感性高，收斂速度較慢，並容易受局部最小值與梯度震盪影響，因此常搭配動量法（Momentum）或學習率調整策略使用。

Adam 則是目前深度學習中最常用的自適應學習率演算法之一。Adam 結合了 RMSProp 與動量法的優點，透過追蹤一階與二階矩估計，自動調整每一參數的學習率。

Adam 無需手動調整每層參數的學習率，對初學者更為友善，且在大多數應用場景中能快速收斂，因此廣泛應用於影像識別、語音處理與自然語言處理等任務中。然而，在某些需高度泛化能力的任務中，Adam 可能導致模型落入次優解，故在特定研究中仍會採用 SGD 以追求更穩定的最終表現。

綜上所述，Adam 與 SGD 各具優劣，選擇何種最佳化器應依據資料特性、模型複雜度與應用需求進行調整。

2.7 Pytorch

PyTorch 是由 Facebook 人工智慧研究院（FAIR）於 2016 年所推出的開源深度學習框架，是目前最受學術界與工業界歡迎的深度學習平台之一。PyTorch 以其靈活性、高度模組化和動態運算圖的特性，廣泛應用於電腦視覺、自然語言處理、強化學習與醫學影像分析等領域 [22]。

相較於其他深度學習框架（如 TensorFlow、Keras），PyTorch 最大的特色在於其「動態計算圖」（Dynamic Computational Graph, 又稱 define-by-run）。這意味著網路結構可以在執行時動態建立與調整，極大地提升了程式的彈性、易於調試與實驗新想法。此外，PyTorch 擁有強大的自動微分（Autograd）引擎，使神經網路訓練與參數更新過程得以自動計算梯度，大幅簡化模型開發流程。

PyTorch 亦具備龐大的模組庫（如 torch.nn、torch.optim、torchvision 等），內建多種常用的神經網路層、優化器與資料增強工具，方便研究人員快速搭建、訓練與測試各式深度學習模型，且支援 GPU 加速運算與分布式訓練，有效提升大型模型的訓練效率。

在本研究中，所有深度學習實驗（包括模型構建、訓練、預測與自監督學習流程）皆基於 PyTorch 平台實現。透過 PyTorch 的高度彈性與便捷介面，能靈活設計各式卷積神經網路（如 CNN、ResNet、MC3）。

2.8 相關文獻探討

潘建蒼於其碩士論文中 [9]，針對彩色都卜勒影像於生物人工主動脈瓣膜異常的偵測進行深入研究。該研究提出一套完整的前處理與分類流程，透過深度學習模型對置換後瓣膜的超音波影像進行分析，以期提升異常辨識的準確率。研究中也強調了資料遮罩、血流資訊萃取與多階段影像處理的重要性，奠定本研究發展方向的重要基礎。

張維俊於其碩士論文中 [23] 探討了自我監督式學習 (Self-Supervised Learning, SSL) 在醫療影像分析中的應用潛力，特別聚焦於無需標記資料的學習策略如何輔助模型在影像分類、分割等任務上取得良好成效。其研究內容包含多種自我監督架構的實作與比較，為本研究採用對比式自監督學習提供實證與理論依據。

Ting Chen 等人於 2020 年提出的 SimCLR 框架 [20]，是自監督式學習領域的重要里程碑。SimCLR 不僅簡化了自監督學習的流程，更突顯了資料增強在對比學習中的核心價值。相關實驗進一步證明，該方法即使在極少量標註資料的情境下，依然能在下游分類任務中取得優異的表現，展現出其相較於傳統自監督與半監督學習方法的明顯優勢。

第三章 研究方法

本章節將詳細介紹本研究所使用的資料來源、資料前處理流程以及各項深度學習模型與訓練方法。首先將說明所採用之心臟超音波影像資料集之取得方式、基本結構與標註方式，並說明資料分割與增強技術。接著將闡述影像處理、特徵萃取與標準化等預處理步驟。隨後，將描述本研究所提出的兩大研究方法：影像增強策略的方法與自監督學習技術應用於動脈瓣膜退化偵測模型，以實現本論文的研究目標。

3.1 資料集

3.1.1 彩色都卜勒影像資料集

本論文中所使用之彩色都卜勒影像資料集來自北投振興醫院，均取自接受手術性主動脈瓣膜置換術（SAVR）後病患之生物人工瓣膜彩色都卜勒影像，涵蓋心臟長軸與短軸兩種掃描視角。接下來的章節將對這些影像資料集的來源與特性作詳細說明。

- **PLAX 資料集：**共收集 153 位接受檢查病患的彩色都卜勒長軸影像。其中，76 例經臨床標註為主動脈瓣功能異常，77 例判定為正常。由於少數案例存在影像缺損或標註不一致等問題，經嚴格篩檢後，最終納入 149 筆有效影像——包含 75 筆異常與 74 筆正常。

為了客觀評估模型效能，我們自有效影像中隨機抽出各 15 筆正常與 15 筆異常作為獨立測試集，其餘 119 筆（60 筆異常、59 筆正常）用於模型訓練與驗證。此分割策略可確保訓練集與測試集在類別分佈上維持平衡，從而提升實驗結果的可信度與泛化性。

- **PSAX 資料集：**共收集 149 例彩色都卜勒短軸影像。其中 74 例標註為主動脈瓣異常、75 例標註為正常。經剔除畫面缺損或標註不一致的個案後，最終留下 144 筆有效影像，正常與異常各 72 筆。

為公平評估模型表現，我們隨機抽出 15 筆正常與 15 筆異常影像組成獨立測試集，其餘 114 筆作為訓練／驗證資料。此分割方式可確保兩類樣本在訓練及測試階段比例均衡，

從而提升實驗結果的可信度。

3.1.1.1 彩色都卜勒影像資料集資料正、異常判斷：

在本研究中，「退化瓣膜」是指患者於人工主動脈瓣膜置換後，隨時間推移而出現的功能衰退或結構損毀現象，常見表現包含瓣膜狹窄、瓣膜反流，或兩者並存。根據文獻 [9] 中的方法，首先對：

- 人工主動脈瓣峰值射流速度 (Peak Prosthetic Aortic Jet Velocity) $> 3 \text{ m/s}$
- 平均壓力梯度 (Mean Pressure Gradient) $> 20 \text{ mmHg}$

進行判斷，接著進一步分析

- 多普勒速度指數 (Doppler Velocity Index, DVI) 所落區間，以推估瓣膜開口面積相對大小。
- 由醫師評估射流型態 (Jet Contour)，藉以判斷開口狀況及狹窄嚴重度。

若上述條件皆符合，且醫師排除其他影響因子後，該影像即歸類為退化瓣膜。

3.1.2 黑白心臟超音波資料集

除彩色都卜勒影像外，本研究亦納入公開黑白心臟超音波資料——RVENet 資料集 [24]。該資料集由 Semmelweis University 心血管中心釋出，旨在推動右心室功能 (Right-Ventricular Ejection Fraction, RVEF) 相關深度學習研究，其主要特色如下：

- **影像規模與型態**：收錄 3,583 段 2D 心尖四腔 (Apical 4-Chamber) 灰階影片，來源於 831 位受試者、共 944 次檢查。影片長度涵蓋完整心跳週期，畫質與臨床實務相符。
- **標註方式**：每段 2D 影片均配有 3D 經胸超音波計算之真實 RVEF 值，並以 CSV 檔集中管理相關人口統計與影像屬性。
- **去識別化與倫理**：所有 DICOM 影像均已移除可辨識個資，並通過 Semmelweis University 倫審 (編號 190/2020)。資料僅供非商業學術研究使用。

- **下載與使用：**研究團隊透過官方網站 (<https://rvenet.github.io/dataset/>) 提交申請後取得完整影像與標註，並遵守資料使用協議。

3.1.2.1 黑白心臟超音波資料集資料正、異常判斷：

本研究首先需要針對黑白心臟超音波資料集中之影像樣本進行正樣本（正常心臟）與負樣本（異常心臟）的分類與判定。由於此資料集已附帶官方標註標籤，我們選擇其中具有明確瓣膜病變的個案作為負樣本來源，具體包括：

- 主動脈瓣疾病（aortic valve disease）患者。
- 二尖瓣疾病（mitral valve disease）患者。

正樣本則選取無明顯瓣膜退化的健康個案，並確保其心臟結構完整、收縮與舒張運動規律。在本研究中，RVENet 影像用以驗證自監督式預訓練流程可行性：首先從 RVENet 資料集中取出上述的條件共 1402 個樣本（正、異常各 701 個）進行 SimCLR 對比預訓練，學習心臟收縮－舒張的時空特徵；隨後將預訓練權重遷移至彩色都卜勒資料集（PLAX／PSAX），藉以彌補自有資料量不足、幀率較低的限制，並觀察對瓣膜退化偵測準確度之影響。

3.2 訓練方法

本章說明兩條平行而互補的訓練流程**監督式模式**與**自監督模式**

3.2.1 應用資料增強之監督式學習

- **多階段前處理：**原始彩色都卜勒影像經遮罩去雜、血流資訊提取、灰階轉換、時間與空間插值、重縮放及心搏週期抽樣（詳 3.3 節）。
- **資料劃分：**前處理後的標記影像直接分成訓練集與獨立測試集，維持異常／正常比例平衡。
- **資料增強：**對訓練資料集進行隨機裁剪、旋轉、翻轉、色彩調整等資料增強操作，以擴充樣本多樣性（詳 3.4.2 節）。

- **模型訓練**：以 MC3 時空卷積網路從隨機初始化開始進行監督式學習，損失函數採 Binary Cross-Entropy。
- **模型評估**：完成訓練後，於測試集計算 Accuracy、Sensitivity、Specificity 等指標。




圖 3.1 應用資料增強之監督式學習流程

3.2.2 自監督模式

- **多階段前處理**：因 RVENet 資料集為黑白超音波影像，且已經為完整心跳週期，故僅需做遮罩處理以及縮放大小，無需血流資訊提取與時間插值。
- **資料劃分**：黑白超音波影像全部投入自監督預訓練；彩色超音波影像再劃分為訓練集與測試集。
- **自監督預訓練 (SimCLR)**：對未標記樣本進行資料增強，建立正負對比對；使用對比損失學習通用特徵表徵，獲得預訓練權重。
- **監督式線性評估訓練**：將預訓練權重遷移至 MC3 模型，再以彩色超音波影像訓練集進行監督式線性評估訓練。超參數設定與監督式模式保持一致。
- **模型評估**：在相同測試集上評估 Sensitivity、Specificity 等表現，並比較兩種模式之差異。




圖 3.2 自監督模式流程

以上兩條流程相互獨立，便於量化自監督策略對有限資料情境下模型效能與穩定度之增益。

3.3 資料前處理步驟

3.3.1 遮罩處理

不論是彩色或是黑白的超音波資料集，原始的資料皆為一段影像。因為畫面同時夾帶儀器參數（型號、MI 值…）與患者個資（姓名、ECG、心率…）等本研究不納入考量的資訊，在分析前必須先「只留超音波、去掉敏感資訊」，操作流程如下：

- **手動繪製遮罩：**使用小畫家，在影像中把需保留的超音波區域框選成白色，其餘填黑，得到 binary mask。
- **擷取白色區域：**以 OpenCV 設定白色閾值 RGB (200 -255)；讀入遮罩並定位白色像素。
- **套用遮罩：**將白色區域對應到原始影像，僅保留超音波內容，其他部分全部抹除。

如此即可產生不含任何個資或儀器資訊、專注於診斷區域的 masked image，供後續模型訓練與分析使用。




圖 3.3 遮罩處理示意圖

3.3.2 血流資訊提取

在彩色都卜勒影像中，血流資訊是關鍵診斷指標，因此需從遮罩後的影像中提取出血流區域。具體步驟如下：

- **色彩空間轉換：**將 RGB 影像轉換為 HSV 色彩空間，便於分離血流區域。
- **閾值設定：**根據血流顏色特徵，設定 H (Hue)、S (Saturation)、V (Value) 三個通道的閾值範圍，以提取出血流區域。
- **遮罩生成：**依上述 HSV 閾值，於每個畫面生成二值遮罩 (mask)，使目標色彩區域得以與背景區域分離，進而降低雜訊干擾。
- **遮罩應用：**利用遮罩將血流顏色區域抽取，保留血流區域，去除其他不相關資訊。




圖 3.4 血流資訊提取示意圖

3.3.3 灰階轉換

由於本研究主要關注瓣膜退化的時序特徵，彩色都卜勒影像中的色彩資訊對於退化檢測並非必要。因此，將彩色影像轉換為灰階影像以減少計算負擔，使用 openCV 的 'cv2.cvtColor()' 函數將 RGB 影像轉換為灰階（Grayscale）影像。這樣可以保留影像的亮度資訊，同時去除色彩資訊，便於後續處理。




圖 3.5 灰階轉換示意圖

3.3.4 時間插值

由於彩色都卜勒影像資料集的幀率較低，平均的 FPS（frames/sec）只有 14，為了提高週期影像數，本研究採用由 Yuki Sahashi 等人提出的方法 [25]，該方法的核心在於利用光流（optical flow）演算法進行影像間的插值，生成中間影像，以提高影像的時間解析度。具體而言，研究團隊建立了一個影像插值流程，透過計算相鄰幀之間的光流，預測並生成中間影像，從而實現任意時間的慢動作影像。

3.3.5 資料縮放

為了統一影像尺寸，所有影像均縮放至 224×224 像素。這一過程不僅有助於減少計算資源消耗，還能提高模型訓練的效率與穩定性。縮放操作使用 OpenCV 的 'cv2.resize()' 函數實現，確保所有輸入影像具有相同的尺寸。

3.3.6 資料取樣

資料取樣為本研究影像分析流程中的關鍵步驟。為確保後續模型訓練時，各筆資料皆具備一致的時間維度表示，本研究採用固定心跳週期取樣數 (x) 作為標準化依據。由於不同受試者的心率 (HR) 以及原始影片的幀率 (FPS) 皆不相同，因此需先計算單一心跳週期內所對應的影格數量，其計算公式如下：

$$L = \frac{60}{HR} \times FPS \quad (3.1)$$

其中， L 表示單一心跳週期內的影格總數， HR 為心率（每分鐘心跳次數）， FPS 則為影片的每秒影格數。完成 L 的計算後，將依據此結果自每個心跳週期內均勻抽取固定數量 x 的影格，以確保所有訓練樣本在時間維度上的一致性，有助於模型的有效學習與後續結果比較。

3.4 監督式學習模型架構與資料增強方法

在本節中，主要介紹本研究所採用的監督式學習使用的 MC3-18 模型架構與資料增強方法。

3.4.1 MC3-18 模型參數

本研究所使用的分類模型為基於 VideoResNet 架構的 MC3-18 模型，該模型設計融合了時間與空間卷積的特性，能夠有效擷取超音波影片中時間與空間上的重要特徵。為了將擾流區域或是 Grad CAM 的總面積和區域能加入一起訓練，本研究基於 Pan [9] 修改的模型進行改動，整體結構包含多個模組，分述如下：

- **輸入模組 (Stem Block)**：初始階段為一組三維卷積模組，輸入為單通道超音波影像（原始架構為三通道，已於本研究中修改），通過一個三維卷積層（核大小為 $3 \times 7 \times 7$ ，步長 $1 \times 2 \times 2$ ，padding 設為 $1 \times 3 \times 3$ ），搭配 Batch Normalization 與 ReLU 激活函數完成初步特徵提取。
- **第一層 (Layer 1)**：包含兩個殘差區塊，每個區塊皆由兩層三維卷積構成，使用 $(3, 3, 3)$ 的卷積核與單位步長，並加入殘差連接設計。輸入與輸出之間透過直接相加來保留低階特徵，達到資訊傳遞的效果。
- **第二層 (Layer 2)**：接續 Layer 1，該層將通道數由 64 擴展至 128，並在第一個區塊中引入下採樣操作，透過空間維度的壓縮提升感受野。本層的卷積運算針對時間軸不進行處理，主要針對空間維度提取特徵，卷積核大小為 $1 \times 3 \times 3$ 。
- **第三層 (Layer 3)**：重複第二層的結構設計，但將通道數再次擴增至 256，進一步提取更抽象的高階視覺特徵，同樣維持不處理時間維度的卷積策略。
- **第四層 (Layer 4)**：為最深層的殘差模組，輸出通道數擴充至 512。該層強調更大感受野的抽象特徵萃取，經歷最終的空間下採樣後，具備更強的全域表示能力。
- **全域池化層 (Global Average Pooling)**：經由 Adaptive Average Pooling 將整個三維特徵圖壓縮為 $(1, 1, 1)$ 尺寸的特徵向量，有效降低參數量並保留整體特徵分布。

- **全連接層 (Fully Connected Layers)**：在本研究中原有的全連接層已移除，並替換為額外設計的線性融合模組，結合影片特徵與額外結構性參數（例如病灶區域數與總面積），再經由線性變換與 Dropout、防過擬合操作後，接續一層輸出節點為 1 的全連接層進行二元分類。

綜上所述，MC3-18 模型能夠在處理影片型資料的同時，保留時間與空間訊息，並可靈活擴展結合結構性資料特徵，最終輸出分類結果用於瓣膜退化的判別任務。

3.4.2 資料增強方法

為了提高模型在有限資料下的泛化能力，本研究採用多種資料增強（Data Augmentation）技術，模擬不同變異以擴充訓練資料多樣性。以下介紹所使用的幾種增強方法：

- **透視變換 (Perspective Transform)**：利用隨機位移影像四個角點來改變影像的視角，模擬不同拍攝角度下的變形情況，有助於強化模型對視角變化的適應力。
- **隨機旋轉 (Random Rotation)**：將影像在 $-10^\circ \sim 10^\circ$ 的範圍內隨機旋轉，以避免模型對影像方向過度敏感。
- **翻轉 (Flip)**：包括水平與垂直翻轉，用以模擬器官左右或上下翻轉的情形，提高模型對空間對稱特徵的學習能力。
- **隨機裁切 (Random Cropping)**：隨機從影像邊緣裁去一部分內容後再重建成原大小，強化模型對影像中局部資訊的關注。
- **色彩變換 (Color Adjustment)**：調整亮度、對比度與飽和度，用以模擬光照條件的變化，避免模型對固定色彩特徵的過擬合。
- **高斯模糊 (Gaussian Blur)**：對影像施加隨機強度的高斯模糊，模擬影像失焦或運動模糊情況，強化模型的穩健性。

這些增強技術能夠有效擴充訓練資料集，提升模型對不同變異的適應能力。如圖 3.6 所示，上方為原始影像，下方為經過資料增強後的影像樣本。




圖 3.6 資料增強示意圖

3.4.3 Grad-CAM 和擾流區域判斷方法

本研究在監督式學習階段，採用 Grad-CAM 方法和擾流區域的總面積與區塊數量來訓練模型。

- **Grad-CAM 方法：**先採用 MC3-18 模型對資料集進行訓練，並計算每張影像的 Grad-CAM 熱力圖，以視覺化模型對影像特定區域的關注程度。此熱力圖能顯示模型在做出分類決策時，最關注的影像區域。接著使用程式計算熱力圖中紅色的區域




圖 3.7 提取擾流區域示意圖

面積和區塊數量，這些區域代表模型認為最重要的特徵區域。

- **擾流區域判斷方法**：將彩色都卜勒影像資料集中的擾流區域提取出來，並計算其總面積和區塊數量。如圖3.7所示，左側為原始圖像。

這些特徵將作為額外的輸入參數，與影像特徵一起進行模型訓練。

3.5 自監督式學習模型架構與資料增強方法

在本節中，主要介紹本研究所採用的自監督式學習使用的 SimCLR 模型架構與資料增強方法。

3.5.1 SimCLR 模型參數

本研究所採用之自監督式模型為 SimCLR 架構，核心由影像特徵提取特徵所組成，設計上專注於於無標記資料中自動學習潛在表示，以提升下游任務的辨識性能。各模組設計如下：

- **編碼器 (Encoder)**：本模型之主幹網路選用 ResNet-18 架構作為影像特徵萃取器，並將其最終分類層 (fully connected layer) 移除，以保留前段的卷積層與殘差結構來提取輸入圖片的高維表徵。原有的全連接層則被替換為恒等映射 (Identity)，使輸出為連續的特徵向量。
- **特徵投影模組 (Projection Head)**：為了讓模型能更清楚抓出不同圖片間的差別，在 encoder 輸出之後接上由兩層線性層構成的 MLP 模組。第一層將原始特徵轉換至

512 維度，並施加 ReLU 非線性轉換；第二層則將向量進一步壓縮至最終對比學習所需的 128 維度。此設計有助於投影至適合計算相似度的表示空間中。

- **前向傳播流程 (Forward Path)：**輸入圖像首先經由編碼器萃取空間特徵，接著將輸出送入投影頭中進行降維與特徵嵌入，最終生成可用於對比學習的嵌入表示向量。此向量隨後用於計算不同樣本之間的相似度或距離。

整體而言，SimCLRModel 的結構具備良好的模組化與擴展性，透過組合深度卷積編碼器與 MLP 投影頭，使模型能從未標記資料中學習具有語義區辨力的特徵表示，為後續監督式線性評估訓練提供有效初始化基礎。

3.5.2 資料增強方法

本研究採用 SimCLR 對比式自監督學習架構，因此每一張輸入影像均會隨機產生兩個增強後的視圖 (views)，作為正樣本對 (positive pair)。本實驗之資料增強流程設計如下：

- **隨機裁剪與縮放 (Random Resized Crop)：**

針對每張輸入影像，先進行隨機區域裁剪並縮放至 224×224 像素，裁剪比例隨機於 $[0.2, 1.0]$ 之間，用以模擬不同成像區域及視野的變化。

- **隨機水平翻轉 (Random Horizontal Flip)：**

以 50% 機率進行影像的左右翻轉，提升資料的多樣性與模型對結構對稱的容忍度。

- **隨機色彩擾動 (Random Color Jitter)：**

以 80% 機率對影像進行色彩抖動，包含亮度、對比度、飽和度與色相等隨機調整 (最大幅度均設為 0.8 或 0.2)。此步驟用以模擬不同臨床設備或掃描條件所產生的色彩變異。

- **隨機旋轉 (Random Rotation)：**將影像在的範圍內隨機旋轉，避免模型對影像方向過度敏感。

- **翻轉 (Flipping)：**包括水平與垂直翻轉，用以模擬器官左右或上下翻轉的情形，提高模型對空間對稱特徵的學習能力。

上述增強操作於每次訓練時均獨立隨機進行，使每張影像都能產生多樣化且具挑戰性的視圖，進一步提升自監督對比學習架構下特徵表徵的泛化能力。

3.5.3 自監督式學習與下游線性評估流程

本研究自監督式訓練與下游線性評估流程，完整反映於程式設計細節，說明如下：

- **自監督預訓練：**首先，於大量無標註的黑白（灰階）超音波影像上進行 SimCLR 自監督訓練。訓練資料由正負樣本資料夾組成，每張影像經隨機增強後產生兩個不同版本，作為正對（positive pair）進行對比式學習。模型主幹為移除分類層的 ResNet-18，於其後接兩層全連接投影頭，透過對比損失函數（contrastive loss）優化影像特徵表徵。
- **載入預訓練權重：**自監督訓練完成後，保存驗證集表現最佳的模型權重。下游任務將 encoder 之權重載入新模型，移除投影頭，僅保留特徵提取部分作為基礎。
- **分類架構設計與串接：**於已預訓練之 encoder 之後，接上一層全連接分類頭，用於下游瓣膜異常二分類。分類頭為單層線性層，輸入為 encoder 輸出特徵（維度 512），輸出為兩類機率（正常／異常）。
- **下游線性評估訓練策略：**下游線性評估階段以標註之彩色多普勒超音波影像資料集進行，僅訓練分類頭（線性層），而 encoder 參數保持凍結（不更新）。訓練時僅對分類頭設定學習率（ 10^{-3} ），使用交叉熵損失函數進行監督式學習，並於訓練與驗證階段持續追蹤分類準確率及損失值，動態儲存最佳模型權重。

綜合上述，本研究模型流程先以黑白無標註影像進行自監督預訓練，學習影像通用表徵，再將預訓練權重遷移至彩色多普勒標註影像的瓣膜退化分類任務，透過有限標註資料的線性評估訓練，有效提升模型於瓣膜退化偵測之泛化能力。

第四章 實驗結果與分析

本章將說明本研究所採用之實驗環境與資料集，並依據第三章所提出之各項方法，設計並實作相關實驗。所有實驗都已將資料集前處理為 224 x 224 像素的超音波影像進行。各項實驗內容與設定彙整如表 4.1 所示。

表 4.1 本論文主要實驗概述

編號	實驗名稱	實驗概述
一	資料增強對 MC3 模型效能的影響	設計多種資料增強策略（如旋轉、翻轉、仿射等），分別應用於彩色都卜勒長軸（PLAX）與短軸（PSAX）影像，訓練 MC3 模型，比較各種資料增強方法對模型分類效能之影響，篩選出最佳增強策略。
二	結合 Grad-CAM 與影像擾流區塊特徵	將 Grad-CAM 產生之關注區域與自動萃取的影像擾流區塊作為輔助特徵，輸入 MC3 模型進行訓練，分析這些結構化輔助特徵對瓣膜退化偵測準確率、敏感度、特異度之提升。
三	自監督學習於早期瓣膜退化偵測效能	先以 SimCLR 對比式自監督學習於黑白影像資料集預訓練，再以標註彩色都卜勒影像進行線性評估，與傳統監督式學習比較準確率、敏感度、特異度，探討自監督學習在不同資料集下之泛化能力。
四	混合資料集訓練之模型效能	將長軸（PLAX）及短軸（PSAX）資料集進行合併，於混合資料下訓練 MC3 及自監督模型，比較不同訓練策略在異質性資料集上的泛化能力與退化偵測成效。
五	長、短軸模型平均融合於多影像個案預測	對同時擁有長、短軸影像的患者，結合各增強及自監督方法下長、短軸模型之預測分數，採用平均融合法，分析融合模式下各方法的分類準確率與穩定性。

4.1 實驗環境與設備

本研究所有實驗均於同一台電腦上完成，詳細硬體設備如表 4.2 所示。表 4.3 整理了實驗所用深度學習框架及函式庫的版本。表 4.4 彙整本研究模型訓練的主要超參數設定。

表 4.2 實驗硬體設備

項目	規格
CPU	Intel Core i7-12700K 3.60GHz 12-Core Processor
GPU	NVIDIA GeForce RTX 4070 Ti SUPER
RAM	32GB DDR4-3200MHz
Storage	1TB NVMe SSD + 2TB SATA HDD
Operating System	Windows 11 Pro 64-bit

表 4.3 實驗所用深度學習框架及函式庫版本

項目	版本
PyTorch	2.0.1
torchvision	0.15.2
CUDA Toolkit	11.8
cuDNN	8700
NumPy	1.23.5
OpenCV	4.10.0
scikit-learn	1.5.1
Matplotlib	3.9.1
Pillow	9.5.0
PyYAML	6.0.1

表 4.4 模型訓練的主要超參數設定

超參數	設定值
批次大小 (Batch Size)	2
學習率 (Learning Rate)	1e-4
優化器 (Optimizer)	SGD
損失函數 (Loss Function)	CrossEntropyLoss
訓練輪數 (Epochs)	100
隨機種子 (Random Seed)	42
Momentum	0.9
Weight Decay	1e-4

4.2 實驗所用資料集

本研究使用的資料集包含兩個主要部分：來自振興醫院提供的彩色都卜勒資料集與 RVENet 的黑白超音波資料集，資料前處理的部分已於第三章說明，實驗所用資料集數量如表 4.5 所示，所示。

表 4.5 實驗所用資料集概述

資料集	影像數量	類別
PLAX (彩色都卜勒長軸)	149	74 正常、75 異常
PSAX (彩色都卜勒短軸)	144	72 正常、72 異常
RVENet (黑白超音波)	1402	701 正常、701 異常

表 4.6 所使用資料集數量

實驗編號	PLAX 資料集	PSAX 資料集	RVENet 資料集
一	✓	✓	×
二	✓	✓	×
三	✓	✓	✓
四	✓	✓	✓
五	✓	✓	✓

4.3 研究問題

本研究的核心問題是如何提升彩色都卜勒超音波影像分類模型的效能，特別是在異質性資料集上。具體研究問題包括：

- **RQ1.** 不同資料增強策略對 MC3 模型於 PLAX、PSAX 資料集的分類效能有何影響？
- **RQ2.** 融合 Grad-CAM 產生之關注區域與影像擾流區塊等結構化輔助特徵，是否能顯著提升瓣膜退化偵測之準確率？
- **RQ3.** 自監督學習（SimCLR 預訓練）結合監督式線性評估，能否提升模型在資料集上的泛化能力與退化偵測性能？其相對於傳統監督式學習有何優勢？
- **RQ4.** 不同訓練資料組合對模型泛化能力與穩定性有何影響？自監督學習模型在混合異質性資料下表現如何？
- **RQ5.** 採用平均融合法結合長、短軸模型預測結果，能否進一步提升多影像個案的分類準確率與模型穩定性？

4.4 實驗結果分析

本節將針對上述研究問題進行實驗結果的詳細分析，並提供各項實驗的具體數據與圖表支持。每個實驗將依據其設定與結果進行深入討論，並與相關文獻進行比較，以驗證本研究方法的有效性。

4.4.1 實驗一：資料增強對 MC3 模型效能的影響

實驗一主要是針對資料增強方式對 MC3 模型的影響，我們根據 Pan 等人於 2024 年提出的生物人工主動脈瓣膜異常偵測模型 [9]，並從長軸（PLAX）與短軸（PSAX）資料集中隨機抽取各 15 筆正、異常資料做為測試集，剩餘則為訓練集，並使用六種不同的資料增強方法進行訓練，因為考量到時間的問題，我們先使用在 PLAX 與 PSAX 資料集上各進行一次實驗，並挑選出 3 種較佳的資料增強的方法。而訓練資料的內插倍率皆為 8、取樣數皆為 32。




圖 4.1 六種資料增強方式於長軸資料集準確度之比較




圖 4.2 六種資料增強方式於短軸資料集準確度之比較

從圖 4.1與圖 4.2可以看出，使用 Perspective Transform、Rotation 與 Random Flip 這三種資料增強方式在 PLAX 與 PSAX 資料集上均表現出較高的準確率，在長軸資料集中，Rotation 是所有資料增強方法中表現最好的，準確率為 0.8666，而其他方法如 Random Crop、Gaussian Noise 與 Random color Transform 則表現較差，皆低於沒有資料增強的模型，這可能是因為這些方法可能直接破壞了醫學影像中重要特徵，且超音波影像對於顏色、雜訊本就較為敏感，不適合的資料增強方式會導致模型無法有效學習到有用的特徵，導致準確率不理想。

接下來，我們將這三種表現較好的資料增強方式應用於 MC3 模型的訓練六次，取名為 R0-R5，並比較其在 PLAX 與 PSAX 資料集上的效能。

表 4.7 Preprocessed PLAX 各資料增強方法之 MC3 模型測試正確率

Model	R0	R1	R2	R3	R4	R5	Average
BaseLine	0.8333	0.8	0.8333	0.7667	0.8	0.7667	0.8
Rotation	0.8667	0.8333	0.8667	0.9	0.8333	0.9	0.8667
Perspective	0.8333	0.8333	0.8	0.8	0.7667	0.8	0.8
Flip	0.8667	0.8333	0.8	0.7667	0.8	0.8333	0.8167

表 4.8 Preprocessed PSAX 各資料增強方法之 MC3 模型測試正確率

Model	R0	R1	R2	R3	R4	R5	Average
BaseLine	0.8	0.7	0.8	0.8	0.7	0.7667	0.7611
Rotation	0.8333	0.7667	0.8	0.7333	0.7667	0.8	0.7833
Perspective	0.7667	0.7667	0.7333	0.8	0.7667	0.7333	0.7611
Flip	0.7667	0.8333	0.7667	0.7667	0.7333	0.7667	0.7722

從表 4.7中，我們可以看到在 PLAX 資料集上，使用 Rotation 作為資料增強方法的訓練模型在所有中表現最佳，平均準確率達到 0.8667，比沒有使用資料增強的模型高出 6.67%，使用 Flip 方法的模型也比沒有使用資料增強的模型高出 1.67%，而 Perspective Transform 方法的平均準確率則與沒有資料增強相等。

從表 4.8中，我們可以看到在 PSAX 資料集上，表現最佳的資料增強方法是 Rotation，平均準確率為 0.7833，比沒有使用資料增強的模型高出 2.22%，而使用 Flip 方法的模型平均準確率為 0.7722，比沒有使用資料增強的模型高出 1.11%，而 Perspective Transform 方法的平均準確率則與沒有資料增強相等。




圖 4.3 各資料增強方法的平均準確率比較

從上述結果可以看出，部分的資料增強方法對於 MC3 模型是有助於提升準確性的，其中，Rotation 方法最為出色，我們推測是對於醫學超音波影像來說，在醫師操作時，為了更清楚顯示出影像，會進行探頭的微調，造成小角度的旋轉，因此對訓練資料進行小角度旋轉增強，是可以有效提升模型的學習能力，而 Flip 方法的提升較小，可能原因在於心臟結構具有明顯的左右或上下方向性，隨意翻轉可能造成結構的顛倒或不合臨床常規，使模型難以正確辨識關鍵特徵，進而影響其準確性。至於 Perspective transform 等其他增強方式，若與實際臨床影像的變異不符，甚至可能帶入非真實的雜訊，導致模型效能無明顯提升，甚至略低於 Baseline。整體而言，在長軸資料集上使用資料增強後，模型的準確率有明顯提升，而在短軸資料集上，雖然提升不如長軸資料集明顯，但仍有小幅度的提升，顯示資料增強對於 MC3 模型的效能提升是有幫助的。資料增強策略的選擇須考量醫學影像本身的特性與臨床實務操作，以避免引入過多不合理變異，影響模型學習效果。

4.4.2 實驗二：使用 Grad-CAM 與影像擾流區塊

實驗二主要是針對 Grad-CAM 與影像擾流區塊的結合對 MC3 模型效能的影響，我們將 Grad-CAM 產生的關注區域與自動萃取的影像擾流區塊作為輔助特徵，輸入 MC3 模型進行訓練，並比較此複合特徵對於瓣膜退化偵測效能之提升。

首先，我們使用 Grad-CAM 方法對由 Pan 等人於 2024 年提出的生物人工主動脈瓣膜退化偵測 MC3 模型 [9] 進行可視化，生成每張影像的關注區域，並計算出最關注區域的總面積與區塊數量，將數據與訓練及一起輸入 MC3 模型進行訓練。接著，我們使用影像擾流區塊方法，從每張影像中自動萃取出擾流區塊，並同樣計算擾流區塊的總面積與區塊數量，並將這些區塊與原始影像一起輸入 MC3 模型進行訓練。並比較兩種模式之間的準確度。




圖 4.4 Grad-CAM 與影像擾流區塊於長軸資料集準確度比較




圖 4.5 Grad-CAM 與影像擾流區塊於短軸資料集準確度比較

從圖 4.4和 4.5可以看出，在 PLAX 資料集上，無論是引入 Grad-CAM 關注區域或是

擾流區塊面積與數量，模型的測試準確率皆優於 Baseline，其中 Grad-CAM 與擾流區塊兩者的表現相近，準確率為 0.8333。在 PSAX 資料集上，僅有引入擾流區塊資訊的組別顯著優於 BaseLine，而 Grad-CAM 輔助組則與 BaseLine 成績一致。這說明在短軸影像中，直接量化與血流異常相關的區塊能提供額外且有效的判別訊息，相較於僅僅強化模型關注區域之可視化特徵更加有助於模型的預測準確率。綜合上述結果，可見結構化、與臨床意義相關的影像特徵（如擾流區塊資訊）對於提升模型效能具有一定幫助。而模型自身的可視化關注區域（如 Grad-CAM）雖可略為提升或持平，但效果受資料型態影響較大，未必在所有資料集下皆有效。

4.4.3 實驗三：自監督學習與傳統監督式學習之比較

實驗三主要是針對自監督學習（SSL）對早期偵測瓣膜退化的影響，詳細訓練過程見 3.5.3 節，我們採用 SimCLR 對比式自監督學習方法進行預訓練，再以已標註的彩色都卜普勒影像進行線性評估，並與監督式學習的 MC3 模型進行比較。

為了更完整分析自監督策略在早期偵測瓣膜退化的可行性，我們在探討準確度的同時，也加入了 Sensitivity（靈敏度 / 真陽性率）和 Specificity（特異度 / 真負率）來更完整的探討模型的表現。

表 4.9 自監督學習與監督學習模型在 PLAX 資料集上的比較

Model	Accuracy	Sensitivity	Specificity
MC3 (Supervised)	0.8±0.03	0.8333±0.03	0.7666±0.03
SimCLR (Self-supervised)	0.9±0	0.9333±0.06	0.8667±0.06

表 4.10 自監督學習與監督學習模型在 PSAX 資料集上的比較

Model	Accuracy	Sensitivity	Specificity
MC3 (Supervised)	0.7611±0.04	0.7111±0.03	0.8111±0.03
SimCLR (Self-supervised)	0.7611±0.02	0.8111±0.01	0.7111±0.01

從表 4.9 和表 4.10 可以看出，在 PLAX 資料集上，自監督學習的模型在準確度上優於監督學習的 MC3 模型，準確率達到 0.9，顯示出自監督學習在長軸資料集上的判斷能力是優於監督學習的。相比之下，PSAX 資料集上，兩者的準確率相同，皆為 0.7611。

接下來評估 Sensitivity 和 Specificity 方面，在 PLAX 資料集方面，自監督學習模型的 Sensitivity 達到 0.9333，而監督學習模型則為 0.8333，顯示出自監督學習模型在早期偵測瓣膜退化的識別能力是優於監督式模型的，而在 Specificity 部分，自監督模型亦較監督式模型高，達到 0.8667，代表其在排除正常樣本時也有更佳的判斷力。整體而言，在長軸資料集上，自監督學習不僅準確率提升，且對於異常個案的敏感度與正常個案的特異度皆表現優異，展現出較傳統監督式學習更強的泛化能力。至於 PSAX 資料集，雖兩種方法準確率相同，皆為 0.7611，但兩者在 Sensitivity 及 Specificity 上呈現互補關係。監督式模型的 Specificity 為 0.8111，表示監督式模型在判別正常個案表現較佳，而自監督模型的 Sensitivity 為 0.8111，顯示出自監督模型在偵測退化方面較突出。綜合以上分析可知，採用自監督對比學習（SimCLR）進行特徵預訓練，有助於提升模型於異質化彩色都卜勒資料上的泛化能力，特別是在退化偵測敏感度方面帶來明顯增益。此結果證明，在醫學影像標註有限、異質性高的情境下，自監督學習為一具潛力的先導策略。

4.4.4 實驗四：混合資料集於自監督學習與監督學習模型的比較

在本實驗中，我的想要知道若是將 PLAX 及 PSAX 資料集進行合併，形成混合資料集，各個模型在混合資料集下的表現，因此我們將先前實驗中的長軸與短軸資料集 R0-R5 進行融合，作法為照著編號進行合併，形成新的混合資料集 R0-R5，進行 6 次實驗，將結果平均，並分析各模型的表現。

表 4.11 自監督學習與監督學習模型在混合資料集上的比較

Model	Accuracy	Sensitivity	Specificity
BaseLine	0.7529	0.7944	0.7111
Rotation (Supervised)	0.77	0.7944	0.7333
Perspective Transform (Supervised)	0.7111	0.7111	0.7111
Flip (Supervised)	0.8	0.7333	0.8667
SimCLR (Self-supervised)	0.8333	0.9	0.7667

從表 4.11 可以看出，在混合資料集上，使用自監督學習（SimCLR）之模型的準確率為 0.8333，明顯高於各種監督學習方法，其中 Flip 方法準確率為 0.8、Rotation 方法

為 0.77、Baseline 的 MC3 模型則為 0.7529，而 Perspective Transform 方法最低，僅達到 0.7111。這顯示出，自監督學習模型在混合資料集上所具備的判斷能力，優於所有納入實驗之監督學習模型。接下來進一步評估各模型在 Sensitivity 和 Specificity 方面的表現，其中自監督學習模型的 Sensitivity 高達 0.9，顯著優於所有監督式模型，MC3 模型和 Rotation 方法的 Sensitivity 均為 0.7944，Flip 方法則為 0.7333，Perspective Transform 方法最低，僅達 0.7111。此結果表明自監督學習策略能夠更有效地識別出真正具瓣膜退化的病例，對臨床上的病症偵測提供明顯助益。在 Specificity 方面，自監督學習模型的表現為 0.7667，而 Flip 方法在特異度表現上最佳，達到 0.8667，優於其他所有模型，顯示 Flip 方法在辨別正常病例方面表現最為優秀。其他監督式方法方面，Rotation 方法特異度為 0.7333，Baseline 的 MC3 模型為 0.7111，Perspective Transform 方法同樣最低，僅有 0.7111。此結果凸顯出雖然自監督學習在特異度方面略遜於 Flip 方法，但仍保持良好的正常樣本判別能力，且在靈敏度方面的優勢更加明顯，綜合表現仍最為突出。

整體而言，本實驗的分析清楚表明，透過 SimCLR 自監督學習預訓練的模型，不僅在混合的異質性資料集中具有較佳的準確率，更能顯著提升對退化樣本之識別能力 (Sensitivity)，同時兼具穩定的正常樣本排除能力 (Specificity)。此結果進一步驗證了自監督學習作為醫學影像分析預訓練策略的價值，特別是在樣本異質性高、資料複雜且標註受限的實務情境下，展現出極大的潛力及臨床適用性。

4.4.5 實驗五：簡單平均融合法結合長、短軸模型於同時具長、短軸患者之評估

本實驗的目標是探討若是同時使用長軸與短軸模型來判斷同時擁有長、短軸影像的患者，資料增強與自監督學習的效果是否會更好。

為了達成此目標，我們將先前實驗的資料集 R0-R5 進行訓練，得到長、短軸的模型。接著將 R0-R5 測試集剔除掉並不同時擁有長軸與短軸影像的患者資料，分別載入各組模型，針對每位患者的測試資料進行預測，分別得到長、短軸模型的預測分數，平均預測分數後得到預測結果。

從表 4.12 可以看出，在使用平均融合法結合長軸和短軸模型下，四種方法於六個資料集上的模型表現存在一定差異。其中，自監督學習 (SSL) 方法在各資料集的表現最為

表 4.12 不同方法於 R0-R5 子集的準確率比較

	R0	R1	R2	R3	R4	R5	Avg.
BaseLine	0.7391	0.7391	0.7391	1	0.913	0.913	0.8405
Flip	0.8	0.87	0.9	1	0.913	0.913	0.8993
Rotation	0.85	0.83	0.9	1	0.913	0.913	0.901
Perspective	0.83	0.81	0.85	1	0.913	0.87	0.8788
SSL	0.8	0.9	0.913	1	0.9	0.95	0.9105

突出，平均準確率（Avg.）達到 0.9105，顯示使用 SSL 方法結合長、短軸在判斷瓣膜退化方面有很明顯的效果。

進一步觀察資料增強策略，Rotation 與 Flip 方法同樣表現優異，平均準確率分別為 0.901 與 0.8993，顯示這兩種資料增強方式能夠有效提升模型在不同資料切分下的穩健性。Perspective transform 方法在部分子集（如 R3、R4）也能達到 1 與 0.913 的高分，但在 R5 略低於其他資料增強方法，整體平均準確率為 0.8788。這也再度表明，雖然 Perspective transform 在某些情況下能夠提升模型效能，但其穩定性較其他資料增強方法稍遜。整體而言，不論是自監督學習或是資料增強策略，在結合長、短軸的模式下，皆能有效提升模型效能。尤其是自監督學習（SSL）方法，其不僅於多數子集取得最佳準確率，平均表現也明顯優於傳統監督式學習與單一資料增強方法，展現出優異的泛化能力和穩定性。此外，資料增強（如 rotation、flip）亦能展現較佳的分類效果。




圖 4.6 不同方法於 R0-R5 子集的平均準確率比較圖

4.5 研究問題回應

根據上述五組實驗結果，現對本研究之各項研究問題（RQ）逐一進行回應與討論：

RQ1. 不同資料增強策略對 MC3 模型於 PLAX、PSAX 資料集的分類效能有何影響？

根據實驗一結果（表 4.7、4.8 與圖 4.1、4.2），Rotation、Flip 與 Perspective Transform 等資料增強策略普遍優於 Baseline 模型，其中 Rotation 在 PLAX 與 PSAX 資料集中皆達到最高準確率（平均 0.8667），顯示旋轉式變化較能貼近實際臨床探頭操作的變化。Flip 亦具穩定提升效果，但因心臟構造具方向性，應避免過度使用。整體而言，Rotation 為本研究中表現最佳之增強策略。

RQ2. 融合 Grad-CAM 產生之關注區域與影像擾流區塊等結構化輔助特徵，是否能顯著提升瓣膜退化偵測之準確率？

如圖 4.4 與 4.5 所示，導入 Grad-CAM 與影像擾流區塊的結構化輔助特徵能小幅提升模型效能。在 PLAX 資料中，兩者皆提升準確率至 0.8333，高於 Baseline；而在 PSAX 資料中，僅擾流區塊輔助明顯提升模型表現。這說明相較於模型內部特徵（Grad-CAM），擾流區塊對提升退化偵測準確性的幫助更大。

RQ3. 自監督學習（SimCLR 預訓練）結合監督式線性評估，能否提升模型在單一及混合資料集上的泛化能力與退化偵測性能？其相對於傳統監督式學習有何優勢？

從表 4.9、4.10 與 4.11 可知，SimCLR 自監督學習在 PLAX 資料集上達到準確率 0.9，明顯優於監督式 MC3 模型（0.8），在 Sensitivity 與 Specificity 亦皆提升。在混合資料集上，自監督學習達成最高準確率 0.8333，Sensitivity 高達 0.9，顯示其對退化個案具有極佳識別能力。由此證明 SimCLR 能有效彌補資料標註不足之問題，並顯著提升模型泛化性能。

RQ4. 不同訓練資料組合對模型泛化能力與穩定性有何影響？自監督學習模型在混合異質性資料下表現如何？

本研究將 PLAX 與 PSAX 資料集進行融合，並在表 4.11 中分析模型在混合資料下的表現。結果顯示，自監督模型在 Accuracy、Sensitivity 與 Specificity 均優於各種監督學習

方式，證明 SimCLR 具備處理異質性資料的能力與強泛化穩定性。而部分資料增強策略如 Flip 雖在 Specificity 上表現出色 (0.8667)，但整體平均準確率仍不如 SimCLR，說明其效果有限。整體而言，融合資料集能強化訓練樣本的多樣性，自監督模型在此情境下尤具優勢。

RQ5. 採用平均融合法結合長、短軸模型預測結果，能否進一步提升多影像個案的分類準確率與模型穩定性？

根據表 4.12，使用平均融合策略將 PLAX 與 PSAX 模型結合後，整體模型效能顯著提升。其中 SimCLR 模型在六組資料中取得最高平均準確率 (0.9105)，展現出極佳之穩定性與準確性。其他增強方法如 Rotation 與 Flip 亦提升至 0.901 與 0.8993。這顯示長短軸模型融合策略有助於綜合不同視角之特徵訊息，提升分類準確度，且自監督模型在此策略下可進一步放大其效能優勢。



第五章 結論與未來展望

5.1 結論

本論文針對彩色都卜勒超音波影像於生物人工主動脈瓣膜退化之早期偵測問題，系統性地整合資料增強技術、自監督學習（SimCLR），並比較不同深度學習模型於多種影像切面（長軸、短軸）及混合資料集下之效能表現。研究結果顯示，適當的資料增強方法（如 rotation、flip）可顯著提升模型在不同資料切分下的準確率與穩健性，在長軸資料集上，Rotation 方法最為出色，準確率達 86%，優於未增強的 80%；而在短軸資料集上，Rotation 方法同樣表現最佳，準確率達 78%，較未增強的 76% 有小幅提升。自監督學習策略（SimCLR）展現優越的泛化能力，除了在單獨短軸資料集上表現沒有提升外，在其餘多個實驗條件下，皆獲得最高平均準確率，在使用平均融合法結合長軸和短軸模型下，準確率達到 91%，優於其他所有模型，在長軸資料集方面，準確率也高於未使用資料增強的監督式模型 10%。同時，本論文進一步證實融合多切面資訊，配合進階學習策略，有助於提升模型對瓣膜退化的識別效能，為未來臨床輔助診斷系統之開發提供了有力的技術基礎。

5.2 研究限制

本研究雖成功建構出自監督學習瓣膜退化早期偵測模型與使用資料增強提升 MC3 模型之準確率，但在實作過程中仍存在若干限制。首先，資料來源主要來自單一醫療院所，影像格式與儀器參數較為一致，導致模型可能對其他院所或不同機型的影像泛化能力不足。其次，本研究使用之影像樣本數量有限，尤其在彩色都卜勒超音波影像數量上，雖然已經進行了資料增強，但仍可能無法充分代表臨床實際情況中的多樣性。此外，本研究之彩色都卜勒超音波影像類型剖面幾乎都為長軸與短軸，但用來訓練之黑白超音波資料集則以心尖四腔影像為主，可能影響自監督模型的識別能力。

最後，模型的解釋性與臨床應用性仍需進一步驗證，後續研究可針對多來源資料、多模型比較以及臨床驗證等方向進一步探討與優化。

5.3 未來展望

本研究驗證了以自監督學習瓣膜退化早期偵測模型與使用資料增強提升 MC3 模型之準確率的可行性，未來仍有多項發展方向值得進一步探討，包含資料面、模型架構面與訓練策略面，詳述如下：

- **擴充資料來源與剖面類型：**目前彩色都卜勒超音波影像類型以 PLAX 及 PSAX 剖面為主，未來可整合更多臨床常用剖面（如 A4C、A2C）與病患資料，以提升模型於多視角資料上的泛化能力。此外，若能引入來自不同醫療院所或超音波設備的資料，有助於評估模型對資料的適應能力。
- **跨器官拓展與多病灶應用：**雖本研究聚焦於心臟瓣膜退化之辨識，但該模型與訓練流程具高度可移植性，未來可應用於其他器官或疾病類型之影像分析，以驗證模型的廣泛適用性。
- **導入其餘的自監督學習方法：**目前採用 SimCLR 架構進行預訓練，未來可嘗試導入更進階的自監督方法，如：BYOL（Bootstrap Your Own Latent）、DINO（Self-Distillation with No Labels）等，探索出更多的可能性。
- **多模態與結構化特徵整合：**本研究初步結合 Grad-CAM 關注區域與結構性特徵，未來可進一步納入病患臨床資訊或都卜勒訊號波形等數據，提升整體預測能力與解釋性。
- **臨床應用性：**本研究所提出之模型若能進一步臨床驗證，預期將有助於實現瓣膜功能退化的初步自動化診斷。此一技術可望減輕醫療人力負擔，提高診斷效率，特別是在醫療資源有限或專業心臟醫師人力短缺之地區，提供即時且可靠的輔助工具，促進心血管疾病之早期發現與治療，擴大其臨床價值與社會影響力。

參考文獻

- [1] Nadera N. Bismee, Niloofar Javadi, Ahmed Khedr, et al. “Bioprosthetic Aortic Valve Degeneration After TAVR and SAVR: Incidence, Diagnosis, Predictors, and Management”. In: *Journal of Cardiovascular Development and Disease* 11.12 (2024), p. 384. DOI: 10.3390/jcdd11120384.
- [2] John B. Chambers et al. “Indications for echocardiography of replacement heart valves: a joint statement from the British Heart Valve Society and British Society of Echocardiography”. In: *Echo Research & Practice* 6.1 (2019), G10–G16. DOI: 10.1530/ERP-18-0079.
- [3] R. Omoto et al. “The development of real-time two-dimensional Doppler echocardiography and its clinical significance in acquired valvular diseases: with special reference to the evaluation of valvular regurgitation”. In: *Japanese Heart Journal* 25.3 (1984), pp. 325–340. DOI: 10.1536/ihj.25.325.
- [4] Yukina Hirata et al. “Reducing echocardiographic examination time through routine use of fully automated software: a comparative study of measurement and report creation time”. In: *Journal of Echocardiography* 22.2 (2024), pp. 162–170. DOI: 10.1007/s12574-023-00636-6.
- [5] L. Garcia-Elcano et al. “Accurate estimation of interobserver variability in echocardiography segmentation measured from 35 experts and impact on derived clinical metrics”. In: *European Heart Journal - Cardiovascular Imaging* 26.Supplement₁ (2025), jeae333.044. DOI: 10.1093/ehjci/jeae333.044.
- [6] Jia Zhou et al. “Artificial intelligence in echocardiography: detection, functional evaluation, and disease diagnosis”. In: *Cardiovascular Ultrasound* 19.1 (2021), p. 29. DOI: 10.1186/s12947-021-00261-2.
- [7] Ashish Singh Chauhan et al. “Unleashing the Power of Advanced Technologies for Revolutionary Medical Imaging: Pioneering the Healthcare Frontier with Artificial Intelligence”. In: *Discover Artificial Intelligence* 4 (2024), p. 58. DOI: 10.1007/s44163-024-00161-0.

- [8] Borui Chen et al. “Trends and hotspots in research on medical images with deep learning: a bibliometric analysis from 2013 to 2023”. In: *Frontiers in Artificial Intelligence* 6 (2023), pp. 1–23. DOI: 10.3389/frai.2023.1289669.
- [9] 潘建蒼. “應用彩色都卜勒影像於生物人工主動脈瓣膜異常偵測之研究”. 碩士論文. 國立臺北科技大學資訊工程系, 2024, pp. 30–40.
- [10] Wikimedia Commons contributors. *Diagram of the human heart (cropped)*. CC BY-SA 4.0. 2020. URL: [https://commons.wikimedia.org/wiki/File:Diagram_of_the_human_heart_\(cropped\).svg](https://commons.wikimedia.org/wiki/File:Diagram_of_the_human_heart_(cropped).svg).
- [11] Catherine M. Otto et al. “2020 ACC/AHA Guideline for the Management of Patients With Valvular Heart Disease”. In: *Circulation* 143.5 (2021), e72–e227. DOI: 10.1161/CIR.0000000000000923.
- [12] Qian Zhao et al. “Comparison of outcomes after transcatheter aortic valve replacement vs medical therapy in inoperable severe aortic stenosis: a meta-analysis”. In: *Medicine* 101.10 (2022), e28912. DOI: 10.1097/MD.00000000000028912.
- [13] Danny Dvir et al. “Standardized Definition of Structural Valve Degeneration for Surgical and Transcatheter Bioprosthetic Aortic Valves”. In: *Circulation* 137.4 (2018), pp. 388–399. DOI: 10.1161/CIRCULATIONAHA.117.030729.
- [14] Davide Capodanno et al. “Degeneration of Bioprosthetic Heart Valves: Update 2020”. In: *Journal of the American Heart Association* 9.19 (2020), e018506. DOI: 10.1161/JAHA.120.018506.
- [15] I. Ahmed and N. Sasikumar. “Echocardiography Imaging Techniques”. In: *StatPearls*. Updated 2023 Jul 30. Available from: <https://www.ncbi.nlm.nih.gov/books/NBK572130/>. Treasure Island (FL): StatPearls Publishing, 2025.
- [16] Iveta Simova. “Coronary Flow Velocity Reserve Assessment with Transthoracic Doppler Echocardiography”. In: *European Cardiology Review* 10.1 (July 2015), pp. 12–18. DOI: 10.15420/ecr.2015.10.01.12.

- [17] Yann LeCun et al. “Gradient-based learning applied to document recognition”. In: *Proceedings of the IEEE* 86.11 (1998), pp. 2278–2324. DOI: 10.1109/5.726791.
- [18] Kaiming He et al. “Deep Residual Learning for Image Recognition”. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2016, pp. 770–778. DOI: 10.1109/CVPR.2016.90.
- [19] Du Tran et al. “A Closer Look at Spatiotemporal Convolutions for Action Recognition”. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2018, pp. 6450–6459. DOI: 10.1109/CVPR.2018.00675.
- [20] Ting Chen et al. “A Simple Framework for Contrastive Learning of Visual Representations”. In: *Proceedings of the International Conference on Machine Learning (ICML)*. 2020, pp. 1597–1607.
- [21] Ramprasaath R. Selvaraju et al. “Grad-CAM: Visual Explanations from Deep Networks via Gradient-Based Localization”. In: *Proceedings of the IEEE International Conference on Computer Vision (ICCV)* 2017.10 (2017), pp. 618–626. DOI: 10.1109/ICCV.2017.74.
- [22] Adam Paszke et al. “PyTorch: An Imperative Style, High-Performance Deep Learning Library”. In: *Advances in Neural Information Processing Systems* 32 (2019).
- [23] 張維俊. “自我監督式學習應用於醫療影像之研究”. 碩士論文. 國立臺北科技大學資訊工程系, 2024.
- [24] László Csányi et al. “RVENet: A Large Echocardiographic Dataset for the Deep Learning-Based Assessment of Right Ventricular Function”. In: *Proceedings of the International Conference on Medical Image Computing and Computer-Assisted Intervention (MICCAI)*. 2023.
- [25] Y. Sahashi et al. “Development of artificial intelligence-based slow-motion echocardiography and clinical usefulness for evaluating regional wall motion abnormalities”. In: *International Journal of Cardiovascular Imaging* 40.2 (Feb. 2024), pp. 385–395. DOI: 10.1007/s10554-023-02997-6.