



國立臺北科技大學

資訊工程系碩士班

碩士學位論文

主動脈剝離術後 ICU 停留時間預測之研究

**A Study on the Prediction of Postoperative ICU
Length of Stay after Aortic Dissection Surgery**

研究生：陳俞安

指導教授：尤信程博士

中華民國一百一十五年七月



國立臺北科技大學

資訊工程系碩士班

碩士學位論文

主動脈剝離術後 ICU 停留時間預測之研究

**A Study on the Prediction of Postoperative ICU
Length of Stay after Aortic Dissection Surgery**

研究生：陳俞安

指導教授：尤信程博士

中華民國一百一十五年七月

「學位論文口試委員會審定書」掃描檔

審定書填寫方式以系所規定為準，但檢附在電子論文內的掃描檔須具備以下條件：

1. 含指導教授、口試委員及系所主管的完整簽名。
2. 口試委員人數正確，碩士口試委員至少 3 人、博士口試委員至少 5 人。
3. 若此頁有論文題目，題目應和書背、封面、書名頁、摘要頁的題目相符。
4. 此頁有無浮水印皆可。

摘要

關鍵詞：A 型主動脈剝離、加護病房停留時長預測、自監督式學習、不確定性量化、集成學習、MambaVision

A 型主動脈剝離為一種高死亡率之急性主動脈疾病，即便患者及時接受手術治療，術後恢復情況仍存在顯著個體差異。若能有效預測患者術後加護病房（ICU）停留時間，將有助於醫療資源配置與規劃。然而基於術前 CT 影像預測 ICU 停留時間之研究仍相對有限，且真實醫學影像資料普遍存在樣本不足與類別不平衡問題，容易導致模型對少數類別辨識能力不足。此外現有方法多僅著重於分類結果，缺乏對模型預測可信度之評估。因此本研究提出一套結合 ROI 為輔的資料平衡策略、自監督式學習與不確定性量化之 3D 醫學影像分析流程，以預測 TAAD 患者術後 ICU 停留時間。在資料平衡方面，本研究透過主動脈 ROI 切割與少類影像隨機替換策略改善少數類別過擬合問題；模型架構則採用 Swin-UNETR v2 作為主要骨幹模型，並實作 3D MambaVision 架構進行比較。此外本研究亦導入 MC Dropout 與 Block Zooming Qualities (BZQ) 評估模型預測之不確定性。

本研究部分 A 型主動脈剝離患者的相關資料由振興醫院提供，實驗結果顯示本研究提出之方法於 10-fold 交叉驗證下，以 3 模型硬投票取得最佳效能，準確率達 0.8500 ± 0.0946 ，F1 分數達 0.7300 ± 0.1590 ，明顯優於臨床七項指標基準方法（Accuracy 0.45、F1 0.30）。此外，BZQ 於不確定性量化中亦優於 MC Dropout，顯示其具有較佳之校準能力與預測可信度。綜合實驗結果，本研究所提出之框架能有效提升小樣本不平衡醫學影像分類任務之穩定性與辨識能力，並具備作為 TAAD 術後 ICU 停留時間輔助評估工具之潛力。

ABSTRACT

Keyword: Type A Aortic Dissection, ICU Length of Stay Prediction, Self-Supervised Learning, Uncertainty Quantification, Ensemble Learning, MambaVision

Type A Aortic Dissection (TAAD) is a life-threatening cardiovascular disease requiring immediate surgical intervention. While surgical techniques have advanced, postoperative ICU length of stay (LOS) varies significantly among patients, making early resource allocation difficult. This study proposes a deep learning framework to predict ICU LOS (above or below 7 days) solely from preoperative CT images, supplemented by uncertainty quantification (UQ) to support reliable clinical decision-making.

The framework consists of two components. First, a self-supervised contrastive learning upstream model is trained to enhance the encoder’s representation of aortic features. The downstream task is formulated as binary classification with a 7-day threshold. To address class imbalance (majority-to-minority ratio of 2:1), we propose a ROI-guided class balancing strategy that randomly replaces minority-class samples with ROI-cropped counterparts. Both Swin-UNETR v2 and a 3D-adapted MambaVision serve as backbone architectures, further improved via multi-model ensemble voting. Second, two uncertainty quantification methods—MC Dropout and BZQ (a sliding-mask-based approach)—are applied to evaluate the model’s predictive confidence.

The best classification performance is achieved by a 3-model hard-voting ensemble with the ROI-based balancing strategy, yielding an accuracy of 0.8500 ± 0.0946 and an F1 score of 0.7300 ± 0.1590 —representing improvements of over 40% in accuracy and 43% in F1 compared to the clinical 7-indicator baseline. In the UQ experiments, BZQ achieves an AUC of 0.694 and an ECE of 0.203, outperforming MC Dropout (AUC 0.679, ECE 0.239), demonstrating that input-perturbation-based uncertainty estimation provides better-calibrated confidence scores for this task.

誌謝

所有對於研究提供協助之人或機構，作者都可在誌謝中表達感謝之意。




目錄

摘要	i
ABSTRACT	ii
誌謝	iii
目錄	iv
圖目錄	v
表目錄	vi
第一章 緒論	1
1.1 研究背景	1
1.2 研究動機與目的	1
1.3 論文架構	2
第二章 相關研究	3
2.1 深度學習於醫學影像之應用	3
2.2 Swin-UNETR v2 網路架構	3
2.3 狀態空間模型與 Mamba	4
2.3.1 長短期記憶網路 (LSTM)	5
2.3.2 狀態空間模型 (SSM) 與 S4	5
2.3.3 Mamba：選擇性狀態空間模型	6
2.4 MambaVision 混合視覺架構	7
2.5 TAP-CT 通用基礎模型	7
2.6 自監督式學習	8
2.7 集成學習策略	8
2.8 損失函數設計	9
2.8.1 Cross Entropy Loss (交叉熵損失)	9
2.8.2 Contrastive Loss	9
2.9 不確定性量化	10
2.9.1 Monte Carlo Dropout (MC Dropout)	10
2.9.2 BZQ (Block-Zone Quantification)	10

2.10	預測效能與評估指標	11
2.10.1	分類評估指標	11
2.10.2	不確定性與校準評估指標	11
2.10.3	K-fold 交叉驗證 (Cross-Validation)	12
第三章	實驗方法	13
3.1	資料預處理與擴增	13
3.1.1	影像正規化與空間重採樣	13
3.1.2	資料增強 (Data Augmentation)	14
3.2	模型設計	14
3.2.1	Swin-UNETR v2	14
3.2.2	MambaVision 3D	14
3.2.3	TAP-CT 特徵融合設計	16
3.3	資料平衡	17
3.3.1	類別平衡	17
3.3.2	ROI 切割替換	18
3.4	自監督式學習預訓練	18
3.5	不確定性量化	19
3.5.1	Monte Carlo Dropout	19
3.5.2	BZQ	19
3.6	集成學習	19
3.7	臨床指標 Baseline	20
第四章	實驗結果	21
4.1	實驗硬體設備與軟體環境	21
4.2	資料集與病歷篩選	22
4.2.1	振興醫院 A 型主動脈剝離資料集	22
4.2.2	ImageTAAD	22
4.2.3	ImageTBAD	23
4.3	實驗一：自監督式預訓練對 ICU LOS 分類影響	23
4.4	實驗二：僅以 ROI 影像對 ICU LOS 分類影響	24

4.5	實驗三：資料平衡策略對 ICU LOS 分類影響	25
4.6	實驗四：Swin-UNETR v2 與 MambaVision 3D 架構比較	26
4.7	實驗五：不確定性量化比較	28
4.8	實驗六：集成學習對 ICU LOS 分類影響	30
4.9	實驗七：TAP-CT 特徵對 ICU LOS 分類影響	32
第五章	結論與未來方向	34
5.1	結論	34
5.2	未來研究方向	34
參考文獻		36



圖目錄

2.1	Swin-UNETR v2 架構示意圖	4
2.2	Mamba 選擇性狀態空間模型 (SSM) 架構示意圖	6
2.3	MambaVision 混合架構示意圖	7
2.4	TAP-CT 架構概念與下游遷移示意圖	8
2.5	MC Dropout 不確定性衍生決策示意圖	10
2.6	K-fold 交叉驗證流程示意圖	12
3.1	整體流程示意圖	13
3.2	本研究提出之 MambaVision 3D 模型架構流程圖	15
3.3	TAP-CT 特徵融合架構示意圖	17
4.1	Swin-UNETR v2 搭配 MC Dropout 之 ROC 曲線	29
4.2	Swin-UNETR v2 搭配 BZQ 之 ROC 曲線	29

表目錄

3.1	自監督式預訓練超參數設置	18
3.2	臨床七項指標基準線效能	20
4.1	實驗硬體設備規格	21
4.2	自監督式預訓練對分類結果的影響	24
4.3	ROI 切割策略對分類結果的影響	25
4.4	資料平衡—方法 A (少類全用, 多類隨機採樣)	26
4.5	資料平衡—方法 B (少類 ROI 隨機替換, 多類隨機採樣)	26
4.6	Swin-UNETR v2 與 MambaVision 3D 比較	27
4.7	MambaVision 3D 不同增強倍數結果	27
4.8	BZQ 不確定性量化參數	28
4.9	MC Dropout 不確定性量化參數	28
4.10	不確定性量化模型校準方法預期比較 (ECE)	29
4.11	Swin-UNETR v2 集成學習—軟投票結果	31
4.12	Swin-UNETR v2 集成學習—硬投票結果	31
4.13	MambaVision 3D 集成學習—軟投票結果 (12x 增強)	31
4.14	MambaVision 3D 集成學習—硬投票結果 (12x 增強)	31
4.15	TAP-CT 特徵融合結果	32

第一章 緒論

1.1 研究背景

近年來，醫療資源配置與管理議題在全球公共衛生領域中日益受到重視。其中加護病房（Intensive Care Unit, ICU）作為醫院中重症照護的重要資源之一，其床位、設備分配以及醫護人力的安排更需經過審慎規劃與細緻管理。若能透過客觀的分析工具，有效且精準地預測患者術後於 ICU 的停留時間（Length of Stay, LOS），不僅有助於醫護人員預先進行床位與資源的有效分配，亦能為第一線臨床醫護人員在擬定風險控管與決策時，提供強而有力的量化依據。

A 型主動脈剝離（Type A Aortic Dissection, TAAD）為一種病情發展極度迅速、高致死率且極具急迫性的心急症。其主要的病理機制為主動脈內膜發生撕裂後，大量的血流壓力迫使血液灌入血管壁的中層，從而形成所謂的「假腔（false lumen）」。隨著病程的惡化，假腔的擴張極可能壓迫並阻斷原始的「真腔（true lumen）」，進而造成全身重要器官組織的灌流不足與缺血性壞死，甚至是導致心包膜填塞性心臟壓迫等危及生命的嚴重併發症。同時 A 型主動脈剝離患者在經歷緊急外科手術後，其術後狀況仍相當不穩定，往往需要入住 ICU 進一步觀察其生理狀態。

綜上所述，若能精準預測 A 型主動脈剝離患者之 ICU 停留時間，將有助於提升加護病房病床的使用效率並提前識別高風險之長留病患，進而降低整體醫療照護與人力負擔。然而現有關於重症預後的相關預測研究，多半高度仰賴病患入院時的電子病歷（EHR）或臨床生理數值，鮮少深度結合富含立體解剖結構資訊的醫學影像（如 3D 電腦斷層掃描 CT）。此外現行深度模型對於醫學領域可解釋性的相關研究仍相對不足，若能提供預測可信度及結果不確定性供臨床醫師參考亦能參與醫療決策，作為其中一項重要的參考依據。

1.2 研究動機與目的

考量到上述問題與現有技術之不足，本研究以黃鈺婷（2025）[1] 所提出之基於自監督式學習分析 A 型主動脈剝離患者 CT 影像的初期研究架構為基礎，進一步針對不同

模型、資料不平衡與模型可信度等問題進行研究與討論。

在醫療影像訓練常遭遇的類別極度不平衡問題上，本研究設計了以主動脈感興趣區域（Region of Interest, ROI）切割為輔助的「少數類影像隨機替換策略」，期望在提升少數類（高危險病患）預測準確度的同時，有效緩解深度神經網路面對樣本不足所產生的過擬合（Overfitting）現象。在神經網路架構方面，本研究採用了具備強大層次化空間特徵提取能力的 Swin-UNETR v2 作為主要分類骨幹，並同步實作且引入了近期的狀態空間模型 3D MambaVision 架構進行比較。

此外為了彌補標註資料稀缺的劣勢，本研究導入了自監督式對比學習（Contrastive Learning）機制進行大規模無標註影像的預訓練，以期望預先強化模型對於複雜主動脈病灶的表徵理解能力。最後本研究深入採用了 Monte Carlo (MC) Dropout 與 Block Zooming Qualities (BZQ) 兩種不確定性量化方法，評估模型對於每一筆推論結果的統計可信程度，期盼能為臨床醫師提供一份精準又具備風險感知能力的輔助決策工具。

1.3 論文架構

本論文共分為五章，其內容架構概述如下：第二章為文獻回顧與相關研究，詳細介紹本研究所應用之各項核心技術背景，涵蓋先進深度學習基礎架構（Swin Transformer、Swin-UNETR v2、MambaVision 等）、監督式與自監督式學習理論、集成學習機制、損失函數之設計考量、不確定性量化原理（包含 MC Dropout 與 BZQ），以及各項演算法效能評估指標之定義。第三章詳細說明實驗方法與核心模型設計，章節涵蓋資料集之來源與特性、影像預處理與正規化流程、兩大主幹模型之建構細節、資料平衡擴增策略之邏輯、自監督式對比學習之實作機制、不確定性量化之應用流程，以及模型集成策略。第四章具體呈現本研究一系列之實驗結果與比較分析，驗證各項提出之模組設計對於 ICU LOS 預測效能的變化。第五章總結本研究之各項實驗發現，並具體提出現行框架的侷限性與未來可能的研究發展方向。

第二章 相關研究

本章將回顧與本研究密切相關之核心技術與過往文獻。首先介紹深度學習於醫學影像分析的發展脈絡，接著深入探討本研究所採用的兩大網路架構：奠基於注意力機制的 Swin-UNETR v2，以及新興的狀態空間模型 Mamba 與其後續相關研究 MambaVision。同時介紹 TAP-CT 特徵提取技術與自監督式對比學習架構。最後本章亦涵蓋了能提升模型預測穩定性之集成學習策略，以及用於模型信賴度評估之不確定性量化方法與各項數學評估指標。

2.1 深度學習於醫學影像之應用

深度學習 (Deep Learning, DL) 是機器學習領域中發展最為迅速的技術之一，其核心思維在於運用多層結構的人工神經網路 (Deep Neural Networks) 來模仿人類大腦神經元的連結與資訊傳遞方式。在複雜多層的網路架構中，每一層的神經元都會接收前一層的特徵輸出並透過非線性激活函數 (如 ReLU 或 GELU) 進行加權轉換。隨著反向傳播 (Backpropagation) 演算法在訓練過程中的反覆修正權重，網路便能從原始數據中逐層萃取出重要語意特徵 (Semantic Features)。

在現代醫學影像分析領域，深度學習更進一步地被廣泛應用於器官與病灶分割、病情分類與術後預後預測等相關醫療領域。其中在醫療影像上，3D 電腦斷層掃描 (CT) 影像蘊含了龐大的空間立體解剖資訊，深度模型對於其理解能力仍具有相當大的潛力。

2.2 Swin-UNETR v2 網路架構

Swin-UNETR (Swin Transformer-based U-shape Network for Encoder-Decoder) 最初由 Hatamizadeh et al. (2021) [2] 提出，是一種結合了 Swin Transformer 與 U-Net 的醫學影像分割架構，專門針對 3D 影像任務所設計。過去模型通常採用 Transformer 的全注意力架構，但這樣的架構在運算成本上相當龐大，尤其是應用在 3D 影像上時過去的設計難以在合理的時間內完成訓練。因此在 Swin Transformer 架構中放棄了傳統全局注意力的

設計，改採用基於「局部移動視窗 (Shifted Window)」的自注意力機制 (Self-Attention) 來逐層計算特徵，透過視窗可以讓不同區塊間的資訊在計算時可以一併考慮，同時在計算注意力時也大幅降低了計算複雜度。Unet 的部分同樣保留完整的跳躍連接 (Skip Connection) 將各尺度的空間特徵進行連接與還原，這種多尺度資訊的融合設計相當適合需要一定精細像素的切割任務。

後續研究為解決初始版本在深層特徵丟失的侷限，Tang et al. (2022) [3] 進一步提出了 Swin-UNETR v2。此版本主要修改為在每一個 stage 前加入殘差卷積塊 (Residual Convolution Block)，在計算前透過殘差卷積塊先融合鄰近區域的特徵，以供後續模型在訓練任務時能更好的捕捉局部特徵，強化對於局部的理解性。




圖 2.1: Swin-UNETR v2 架構示意圖

2.3 狀態空間模型與 Mamba

在自然語言中常常需要考慮上下語句間的意義及關係，循環神經網路 (Recurrent Neural Network, RNN) 便是因應而生的設計之一，當前的 output 不僅考慮了輸入同時也考慮了前一個的 output，這樣的設計可以使得模型可以考慮前後文提出更進一步的理解。

2.3.1 長短期記憶網路 (LSTM)

但是在傳統的 RNN 設計中隨著計算序列的增長距離越遠的語句對於當前的結果影響力越低甚至為零，為了解決當前的缺陷 Hochreiter & Schmidhuber (1997) [4] 發明了長短期記憶網路 (Long Short-Term Memory, LSTM)，透過設計專屬的記憶單元 (Cell State) 以及輸入閘 (Input Gate)、遺忘閘 (Forget Gate) 與輸出閘 (Output Gate) 來進行記憶的儲存與使用。其中遺忘閘作為最主要的設計之一，通常是以 Sigmoid 作為主要函數，透過計算兩個向量間的相似度來決定記憶的去留。

LSTM 大幅延長了網路的記憶跨度但仍存在部分缺點：運算必須嚴格依賴「循序」特性及無法充分使用 GPU 的平行加速優勢。且面對動輒數萬單位的超長序列（如高解析度醫療影像壓平後的像素序列）時，LSTM 仍會陷入遺忘與難以捕捉首尾特徵對齊的困境。

2.3.2 狀態空間模型 (SSM) 與 S4

為突破先前設計限制，狀態空間模型 (State Space Model, SSM) 的概念引入至深度學習。SSM 使用了一組連續時間的微分方程來描述輸入訊號 $u(t)$ 與輸出訊號 $y(t)$ 間的動態映射轉換：

$$x'(t) = \mathbf{A}x(t) + \mathbf{B}u(t), \quad y(t) = \mathbf{C}x(t) + \mathbf{D}u(t) \quad (2.1)$$

其中 $x(t) \in \mathbb{R}^N$ 為高維度隱藏狀態矩陣，而 $\mathbf{A}$ 、 $\mathbf{B}$ 、 $\mathbf{C}$ 、 $\mathbf{D}$ 皆為網路在訓練階段可學習的參數矩陣。若要讓演算法能夠處理離散化的資料庫，SSM 必須經由零階保持機制 (Zero-Order Hold, ZOH) 離散轉換為類似遞迴形式之數列：

$$x_k = \bar{\mathbf{A}}x_{k-1} + \bar{\mathbf{B}}u_k, \quad y_k = \mathbf{C}x_k \quad (2.2)$$

基於此數學定義，Gu et al. (2021) 提出的架構 S4 (Structured State Space Sequence Model) [5] 在狀態轉移矩陣 $\mathbf{A}$ 上強制施加了特殊的結構化約束（如對角矩陣與低秩分解），這使得原本遞迴的計算可以轉換為「全局線性卷積 (Global Convolution)」形式進行求解。此舉將模型應對長序列的時間複雜度大幅降低至 $O(n \log n)$ 並解放了平行計算

潛力。不過，S4 中的參數矩陣為靜態常數（Linear Time-Invariant, LTI），對於當下輸入的資料內容並不具備動態選擇（挑選關鍵字或略過雜訊）的能力，進而限制了其語意表達的靈活性。

2.3.3 Mamba：選擇性狀態空間模型

為了達成類似 Transformer 具有動態關注核心資訊能力的目標，Gu & Dao（2023）[6] 針對 S4 進行了重新設計並提出 Mamba。將「選擇性機制（Selective Mechanism）」引入 SSM 中，使 $\mathbf{B}$ 、 $\mathbf{C}$ 矩陣以及時間離散化步長 Δ 脫離常數限制，轉為根據每個輸入脈衝 u_k 動態生成的計算結果：

$$\mathbf{B}_k = s_B(u_k), \quad \mathbf{C}_k = s_C(u_k), \quad \Delta_k = s_\Delta(u_k) \quad (2.3)$$

其中 s_B 、 s_C 、 s_Δ 為針對特定特徵的線性投影（Linear Projection）。這種設計使得 Mamba 模型在掃描到關鍵資料時能夠決定儲存與使用。此外 Mamba 透過底層 CUDA 硬體感知的平行掃描（Parallel Scan）演算法以及內存重算技術（Kernel Fusion / Recomputation），在保持具有媲美注意力機制的資訊選擇過濾能力的同時，運算複雜度仍維持在線性增長 $O(n)$ 。




圖 2.2: Mamba 選擇性狀態空間模型（SSM）架構示意圖

2.4 MambaVision 混合視覺架構

MambaVision (Hatamizadeh & Kautz, 2024) [7] 為了避免 SSM 難以萃取影像邊界局佈紋理的缺點，提出了一套分層混合 (Hierarchical Hybrid) 的運算架構：在影像解析度較高的前兩個網路淺層，模型採用卷積層 (CNN) 來進行高效率的邊緣與局部紋理提取；而在解析度被降散至深層後，網路才交替疊加 MambaVision Mixer 與多頭自注意力機制 (Multi-head Self-Attention, MHSA) 模組來整合遠距離特徵的分佈資訊。透過混合的設計層次，使得模型訓練上與其他模型相比運算表現相當快速。此外除了計算時間上模型準確率也顯示其具有相當良好的特徵理解能力。




圖 2.3: MambaVision 混合架構示意圖

2.5 TAP-CT 通用基礎模型

在現今的大部分研究中，為了解決當前樣本不足或是增加任務多樣性，往往會採用預訓練模型來作為提升模型表現的手法之一，其中 TAP-CT (Task-Agnostic Pretraining of CT foundation models) [8] 是由 Veenboer 等人 (2025) 全新提出之專注於 3D CT 掃描的基礎底層模型。其宗旨為透過巨量且無需病理標注的開放 CT 掃描進行預先訓練，萃取出可以幾乎「零成本 (Zero-shot)」或「低成本 (Few-shot)」遷移至各種器官分割、疾病檢測與分類醫療預測任務上的通用空間特徵。TAP-CT 使用了 Vision Transformer 架構 (ViT-Base) 作為運算主幹，為適應人體掃描特性，它將傳統 2D Patch 修改為體素嵌入 (Volumetric Patch Embedding, 大小為 $4 \times 8 \times 8$)，並提出了「深度感知位置編碼 (Depth-aware Positional Encoding)」，使網路能夠清楚體認到當下切片正位於病患胸腔之深淺位置。同時搭配基於 DINOv2 [9] 的強大自監督學習對比框架，TAP-CT 在高達 105,000 例之 CT 體積影像上完成訓練。透過預先理解大量的 CT 影像特徵後，其結果

顯示對於如切割、分類等任務具有一定程度上的提升。




圖 2.4: TAP-CT 架構概念與下游遷移示意圖

2.6 自監督式學習

自監督式學習 (Self-Supervised Learning, SSL) 為一種完全不依賴人工介入標記病灶，而是利用輸入資料本身的結構或視角變異來建構監督目標學習任務。對比學習 (Contrastive Learning) 為 SSL 其中之一分支。其核心思想為：對每一筆 CT 影像樣本引入隨機的空間擾動或裁切遮罩以生成兩種「視圖 (View)」。網路必須學會將同一病患來源變異出的兩種視圖認定為「正對 (Positive Pair)」，並於特徵空間中將兩者點距極大化拉近；反之來自不同病患身上的視圖視為「負對 (Negative Pair)」，兩者在空間上的距離應是越遠越好。經由如此周而復始的對比學習，模型得以理解核心特徵並進一步提升對於下游任務的理解能力。

2.7 集成學習策略

集成學習 (Ensemble Learning) 是一種將多個獨立訓練的模型結合起來以提升預測性能的技術。常見的集成方法包括投票、袋裝、提升等方法。集成學習能夠有效降低單一模型可能帶來的不穩定性，並且在面對高變異性的臨床資料時提供更穩健的預測結果。

- **投票**：投票又可分為軟投票與硬投票，本質上來說都是將多個模型的預測結果進行統計，選擇出最終的預測結果。
- **袋裝**：袋裝是通過對訓練資料進行重複抽樣來訓練多個模型，最終將這些模型的預測結果進行平均或投票來得到最終預測。
- **提升**：提升方法通過逐步訓練模型，每一個新的模型都試圖修正前一個模型的錯誤，最終將這些模型的預測結果進行加權平均來得到最終預測。

2.8 損失函數設計

2.8.1 Cross Entropy Loss (交叉熵損失)

交叉熵損失函數為神經網路分類任務時最為普及的數值懲罰機制，目的在衡量模型輸出之機率分布與病患真實標籤分布之間的對數差異。對於 C 個類別的真實標籤 one-hot 編碼向量 $\mathbf{y}$ ，與模型最終層輸出的機率分布 $\hat{\mathbf{p}}$ ，交叉熵定義為：

$$\mathcal{L}_{CE} = - \sum_{c=1}^C y_c \log \hat{p}_c \quad (2.4)$$

在下游 ICU 停留時長分類任務之微調 (Fine-tuning) 階段，本研究皆採用此損失來逼近與真實情況的最佳切合。

2.8.2 Contrastive Loss

用於自監督式對比學習階段。給定一個批次中的 N 個樣本，每個樣本生成兩個增強視圖，共 $2N$ 個特徵向量。對於第 i 個樣本的視圖 $\mathbf{z}_i$ ，其與同一樣本另一視圖 $\mathbf{z}_j$ 構成正對，損失定義為：

$$\mathcal{L}_{contrast} = - \log \frac{\exp(\text{sim}(\mathbf{z}_i, \mathbf{z}_j)/\tau)}{\sum_{k=1, k \neq i}^{2N} \exp(\text{sim}(\mathbf{z}_i, \mathbf{z}_k)/\tau)} \quad (2.5)$$

其中 $\text{sim}(\cdot, \cdot)$ 為餘弦相似度 (cosine similarity)， τ 為溫度超參數，用於控制特徵分布的尖銳程度，值越小代表對負對之間的區別越敏感。

2.9 不確定性量化

不確定性量化指的是模型對於同一測試資料展現出來的準確可信度，透過對同樣的測試資料進行多次預測，最終分析其信心分數以判斷模型在具有高信心時是否仍具有高度準確率。

2.9.1 Monte Carlo Dropout (MC Dropout)

MC Dropout (Monte Carlo Dropout) 由 Gal & Ghahramani (2016) [10] 提出，是一種將 Dropout 正則化詮釋為貝葉斯近似推論的不確定性量化方法。傳統 Dropout 僅在訓練階段隨機停用神經元以防止過擬合，而 MC Dropout 在推論階段同樣保持 Dropout 的啟用狀態，對同一輸入進行 T 次隨機前向傳播，得到 T 個預測結果 $\{\hat{y}^{(t)}\}_{t=1}^T$ 。模型最終信賴機率定義如下：

$$\bar{p}^c(\mathbf{x}) = \frac{1}{T} \sum_{t=1}^T p^{c,(t)}(\mathbf{x}) \quad (2.6)$$




圖 2.5: MC Dropout 不確定性衍生決策示意圖

2.9.2 BZQ (Block-Zone Quantification)

BZQ 為王派軒 (2025) [11] 提出的量化方法，與 MC Dropout 同樣採用遮蔽策略來產生多次變異推論，但兩者的遮蔽對象不同：MC Dropout 作用於模型的神經元連接，而 BZQ 直接對輸入測試資料施加空間遮罩。

BZQ 主要操作為，按預設計算步幅 (Stride) 滑動定大小的遮罩視窗 (Mask Window)，對每個遮蔽位置生成一個變異推論，從而形成多個變異分支。透過分析這些

分支預測的一致性，即可估計模型對不同空間區域的敏感程度，進而量化其不確定性。

2.10 預測效能與評估指標

2.10.1 分類評估指標

本研究分類任務為二元分類，因此透過比較常見評估指標：

準確率 (Accuracy, ACC)：衡量正負類別推算完全正確的比率

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (2.7)$$

敏感度 (Sensitivity)，亦即召回率 (Recall)：衡量所有真實正樣本被正確識別的比例，在本研究中主要作為反映模型對於少數類別的判別能力。

$$\text{Sensitivity} = \frac{TP}{TP + FN} \quad (2.8)$$

特異度 (Specificity)：衡量所有真實負樣本被正確識別的比例，對於評估模型在多數類別上的表現同樣重要。

$$\text{Specificity} = \frac{TN}{TN + FP} \quad (2.9)$$

F1 分數 (F1 Score)：精確率 (Precision) 與敏感度的調和平均數，適合在資料不平衡的情境下評估整體分類效能

$$\text{Precision} = \frac{TP}{TP + FP}, \quad \text{F1} = \frac{2 \times \text{Precision} \times \text{Sensitivity}}{\text{Precision} + \text{Sensitivity}} \quad (2.10)$$

2.10.2 不確定性與校準評估指標

ROC 曲線 (Receiver Operating Characteristic Curve) 以偽陽性率 (False Positive Rate, $\text{FPR} = \text{FP} / (\text{FP} + \text{TN})$) 為橫軸、真陽性率 (True Positive Rate, TPR ，即敏感度) 為縱軸，在不同決策閾值下描繪分類模型的效能軌跡。曲線越靠近左上角，代表模型在

各閾值下均能同時維持高敏感度與低偽陽性率，整體分類能力越佳；對角線（FPR = TPR）對應隨機猜測的基準。在不確定性量化場景中，以信心分數作為決策閾值繪製 ROC 曲線，可直觀呈現模型在不同信心切點下的辨別能力。

預期校準誤差（Expected Calibration Error, ECE） 衡量模型輸出信心分數與實際準確率之間的一致程度。將所有測試樣本的預測信心分數分成 B 個等距區間，對第 b 個區間計算區間內樣本的平均信心 $\overline{\text{conf}}_b$ 與實際準確率 acc_b ，ECE 定義為加權平均偏差：

$$\text{ECE} = \sum_{b=1}^B \frac{|B_b|}{n} |\text{acc}_b - \overline{\text{conf}}_b| \quad (2.11)$$

其中 $|B_b|$ 為第 b 個區間的樣本數， n 為總樣本數。ECE 越小代表模型的信心分數與實際準確率越吻合，即模型具有更好的校準性（calibration）。

2.10.3 K-fold 交叉驗證（Cross-Validation）

為了獲得更為準確的實驗結果評估，本研究採用 K-fold 交叉驗證方法。流程上將整體資料集平均分成 K 個子集，依次將每個子集作為驗證集，其餘子集作為訓練集，進行 K 次訓練與驗證，最後將 K 次驗證結果的平均值作為模型效能的評估指標。此方法能有效減少因資料分割偶然性帶來的評估偏差，特別適用於資料量有限的分析任務。




圖 2.6: K-fold 交叉驗證流程示意圖

第三章 實驗方法

本章將系統性地闡述本研究所設計之實驗方法與核心模組。為了精準預測 A 型主動脈剝離患者之術後 ICU 停留時間 (Length of Stay, LOS)，我們設計了一套影像分類處理流程。本章節的編排依序為：第一節介紹影像預處理流程；第二節闡述使用的分類模型（包含 Swin-UNETR v2、3D MambaVision 以及 TAP-CT 特徵融合架構）；第三節與第四節探討為解決資料與特徵稀缺所設計之資料平衡策略與自監督式預訓練；最後於第五至第七節介紹不確定性量化機制、集成學習流程以及作為評量基準之傳統臨床指標 Baseline。影像分類之訓練流程巨觀架構如圖 3.1 所示。




圖 3.1: 整體流程示意圖

3.1 資料預處理與擴增

3.1.1 影像正規化與空間重採樣

原始 DICOM 或 NIFTI 檔案在 Z 軸上經常存在明顯的物理空間解析度差異。本研究遵循黃鈺婷 (2025) [1] 之預處理流程，首步採用雙線性插值演算法 (Bilinear Interpolation) 針對所有影像重採樣 (Resampling)，將三維空間之體素像素間距 (Voxel Spacing) 強迫對齊統一至 $1.0 \times 1.0 \times 1.0 \text{ mm}^3$ 的物理等距網格。最後影像統一縮放為 $128 \times 128 \times 64$ 供後續模型進行相關訓練。

3.1.2 資料增強 (Data Augmentation)

資料增強同樣沿用 [1] 的資料增強做法，以 80% 機率在 x 、 z 軸做 90 度旋轉，50% 機率在 x 、 y 、 z 軸進行鏡像反轉，以增強模型在不同情形下的適應能力。

3.2 模型設計

3.2.1 Swin-UNETR v2

3.2.1.1 病灶 ROI 分割任務

分割模型主要用於產生少類對應的 ROI 圖像並用來在資料平衡時替換少類影像。使用帶有主動脈剝離標記的影像先縮放成 $96 \times 96 \times 64$ 大小並輸入預訓練模型進行 ROI 切割訓練。取得切割結果後，ROI 提取流程分為以下三個步驟：

1. 以切割模型於縮小影像上取得病灶 ROI 位置
2. 將切割結果的尺寸與位置資訊回推至原始 $512 \times 512 \times N$ 影像上的實際座標
3. 依照回推座標對原始影像進行裁切得到最終 ROI 影像

3.2.1.2 ICU LOS 分類任務

採用與 [1] 相同的模型架構移除 decoder 結構，僅保留 encoder 用來提取影像特徵。在 encoder 第四層輸出後依序接入一層卷積層 (Convolutional layer)、全域平均池化層 (Global Average Pooling)、線性全連接層 (Fully Connected Layer) 作為主要模型架構。

3.2.2 MambaVision 3D

原始 MambaVision 為設計於 2D 影像的架構，為了應用在 3D CT 影像上，本研究對模型進行了對應的結構修改。整體架構由 Stem、四個 Stage 以及分類組成，正規化層統一從原本 Batch Normalization 改成 Instance Normalization (InstanceNorm3d) 以適應小批次訓練場景。架構各階段設計如下：




圖 3.2: 本研究提出之 MambaVision 3D 模型架構流程圖

- **輸入模組 Stem**：3D 卷積（Conv3d，核心大小為 3，步幅為 2，輸出通道數為 80），後接 InstanceNorm3d 與 GELU，輸入 $(B, 1, 128, 128, 64)$ 降採樣為 $(B, 80, 64, 64, 32)$ 。
- **Stage 0**：純卷積階段（ConvStage3D），包含 1 層 Conv3d-InstanceNorm-GELU，並以步幅 2 降採樣，通道數從 80 升至 160，輸出 $(B, 160, 32, 32, 16)$ 。
- **Stage 1**：純卷積階段，包含 3 層 Conv3d-InstanceNorm-GELU，並以步幅 2 降採樣，通道數從 160 升至 320，輸出 $(B, 320, 16, 16, 8)$ 。
- **Stage 2**：混合階段（MambaVisionHybridStage3D），前 4 個區塊為 MambaVision-Mixer3D、後 4 個區塊為 AttentionBlock3D，並以步幅 2 降採樣，通道數從 320 升至 640，輸出 $(B, 640, 8, 8, 4)$ 。
- **Stage 3**：混合階段，前 2 個區塊為 MambaVisionMixer3D、後 2 個區塊為 Attention-Block3D，無降採樣，通道數維持 640，輸出 $(B, 640, 8, 8, 4)$ 。
- **分類**：AdaptiveAvgPool3d(1) 全域平均池化後展平，接 Linear(640, 2) 輸出二元分類 Logits。

3.2.3 TAP-CT 特徵融合設計

本研究在 Swin-UNETR v2 與 MambaVision 3D 兩種主幹模型上均採用相同的 TAP-CT [8] 特徵融合策略：於主幹完成全域池化後、進入分類層前，結合凍結的 TAP-CT 所抽取的通用 CT 語意特徵。整體架構由兩條並行路徑組成，融合後送入線性分類。期望結合 TAP-CT 的影像特徵後能加強模型在小樣本場景下的特徵理解能力並進一步提升分類效能。

1. **主幹特徵路徑**：輸入 $(B, 1, 128, 128, 64)$ ，經主幹網路逐層提取深層特徵後，以全域平均池化（AdaptiveAvgPool3d）並展平，得到主幹特徵向量 $\mathbf{f}_{\text{backbone}} \in \mathbb{R}^d$ 。Swin-UNETR v2 的 $d = \text{feature_size} \times 16$ ；MambaVision 3D 的 $d = \text{dim} \times 8 = 640$ 。
2. **TAP-CT 路徑（凍結）**：TAP-CT（fomofo/tap-ct-b-3d，ViT-Base）採用 3D Patch Embedding（patch size $4 \times 8 \times 8$ ）以 3D 體積塊為處理單元。經過預訓練 PAT-CT 擷取影像特徵後得到 $\mathbf{f}_{\text{tap}} \in \mathbb{R}^d$ 。

兩路徑特徵相加後送入線性分類，計算如下：

$$\hat{y} = W(\mathbf{f}_{\text{backbone}} + \mathbf{f}_{\text{tap}}) + b \quad (3.1)$$




圖 3.3: TAP-CT 特徵融合架構示意圖

3.3 資料平衡

檢視前文提及之 60 筆存活留院個案，以 ICU LOS 7 天作為切分點時，多類（ ≤ 7 天）與少類（ > 7 天）的比例約為 2:1，存在明顯的資料不平衡現象（data imbalance）。此時模型預測可能偏向多類從而失去對少類的判別能力。

3.3.1 類別平衡

為了改善多類與少類間的數量差距，在每一個訓練週期（epoch）中隨機選擇與少類同樣數量的多類影像加入訓練，同時優先挑選尚未被選擇的多類影像，若所有多類

影像皆被選擇則重新納入可選範圍。這樣可以使得訓練時兩類間的數量保持一致且所有多類影像至少加入過訓練週期一次。

3.3.2 ROI 切割替換

應用類別平衡後雖可改善資料不平衡對於模型的影響，但對於少類而言，因為每個 epoch 都會加入訓練可能導致模型對少類判斷過擬合，使得模型在預測從未見過的少類影像時失去判別能力。因此本研究訓練了用於 A 型主動脈剝離的切割模型，產生少類對應的 ROI 切割圖像以供替換。在每個 epoch 隨機於原始少類圖像與切割 ROI 後的少類圖像間進行選擇，期望透過這樣的隨機替換機制使模型具有更好的泛化性能並減少過擬合的可能。

3.4 自監督式學習預訓練

對比學習是透過比較資料之間的相似性，使模型將相似的樣本映射到接近的特徵空間，並將不相似的樣本映射到較遠的位置。方法沿用 [1] 的 Inner-cutout 與 Outer-cutout 設定，Inner-cutout 專注於影像內部的隨機剪裁與加噪，Outer-cutout 則專注於影像邊緣的隨機剪裁與加噪。兩個 cutout 各做六次後，兩者影像輸入模型進行影像重建並計算 contrastive loss。最終損失定義如下：

$$\mathcal{L}_{total} = \mathcal{L}_{recon} + \mathcal{L}_{contrast} \cdot \mathcal{L}_{recon} \quad (3.2)$$

自監督預訓練階段的超參數設置如表 3.1 所示。

表 3.1: 自監督式預訓練超參數設置

超參數	設置值
訓練回合數 (Epochs)	500
學習率 (Learning Rate)	1×10^{-4}
優化器 (Optimizer)	AdamW
批次大小 (Batch Size)	1

3.5 不確定性量化

不確定性量化指的是模型對於同一測試資料展現出來的準確可信度。本研究主要使用兩個方法—MC Dropout [12] 與 BZQ [11]—對同樣的測試資料做多次預測，最終分析信心分數與測試結果，以判斷模型在具有高信心時是否同樣具有高度準確率。量化指標採用 ROC 曲線與預期校準誤差（ECE）。

3.5.1 Monte Carlo Dropout

MC Dropout 為 Ovadia et al. (2019) [12] 所提出的方法，旨在預測階段透過隨機停用神經元來產生多次變異推論，以模型輸出分布的離散程度估計不確定性。

3.5.2 BZQ

BZQ 為王派軒 (2025) [11] 提出的量化方法，與 MC Dropout 同樣採用遮蔽方法，差異在於 MC Dropout 作用於模型結構上，而 BZQ 為對輸入測試資料作隨機遮罩，並以統一步幅逐步移動遮罩，產生多個變異推論以量測模型的不確定性。

原始 BZQ 為應用在 2D 模型上的方法，為將其應用在 3D 模型上本研究產生一個 $n \times n$ 的隨機遮罩，在 x 軸、 y 軸位置不變的前提下進行 z 軸全軸遮罩，使遮罩能夠覆蓋整個體積影像的深度方向。

3.6 集成學習

為了提高模型泛化及準確率，我們將多個獨立預測模型對同樣資料進行投票以產生最終結果。在投票決策上採用軟投票（Soft Voting）與硬投票（Hard Voting）兩種方法。軟投票為平均模型各類別的輸出機率，最後取最高機率一類作為最終結果；硬投票為對模型輸出結果採多數決，較多模型傾向的一類作為最終結果。

本研究保持上游模型不變，僅對下游模型使用不同初始權重重新訓練，採用 3、5、7、9 個模型加入投票，期望在多個模型的投票下使預測結果更加穩定、精確。

3.7 臨床指標 Baseline

鑒於當前基於影像預測 A 型主動脈剝離 ICU LOS 的研究仍較為稀少，本研究沿用 [1] 採用的七項指標評分標準作為比較的基準，其為基於影像畫面上的主動脈病理結構作為評分依據，主要涵蓋以下七項影像特徵：

1. 連接主動脈的頸動脈是否具有明顯夾層膜（dissection flap）結構。
2. 主動脈弓是否具有明顯夾層膜結構。
3. 降主動脈是否具有明顯夾層膜結構。
4. 腹腔區域主動脈是否具有明顯夾層膜結構。
5. 是否存在心包積液。
6. 主動脈直徑是否大於 40 mm。
7. 假腔直徑是否大於 20 mm。

若影像符合以上任一特徵則加計 1 分，以總分 4 分以下作為低風險組，高於則計為高風險組，其臨床基準線效能如表 3.2 所示。

表 3.2: 臨床七項指標基準線效能

方法	Accuracy	Sensitivity	Specificity	F1
統一判斷 (≤ 7 天)	0.667	—	—	0.800
統一判斷 (> 7 天)	0.333	—	—	0.500
七項臨床指標	0.450	0.260	0.610	0.300

第四章 實驗結果

本章將詳細呈現與分析本研究所提出之各項模組與演算法的實驗結果。第一節與第二節將說明本研究所使用的實驗環境配置及資料集分佈與處理方式。第三節至第九節則逐步探討各項實驗設計策略之有效性，探討範疇涵蓋：自監督式預訓練、感興趣區域（ROI）影像提取、資料集不平衡之擴增策略、不同深度學習架構（Swin-UNETR v2 與 MambaVision 3D）的效能評估、不確定性量化方法之比較、集成學習策略之探討，以及外部基礎模型（TAP-CT）深層特徵融合之影響。透過嚴謹的實驗設計，以期全面驗證本研究所提方法在預測 A 型主動脈剝離患者術後加護病房停留天數（ICU LOS）上的準確性與穩定性。

4.1 實驗硬體設備與軟體環境

本研究中涵蓋之所有模型訓練、參數微調與評估推論，均於統一的硬體設備上進行，詳細之硬體規格與軟體版本如表 4.1 所示。

自監督式學習模型訓練週期（epochs）配置如下：上游之自監督預訓練階段（SSL）設定為 500 epochs；下游 ICU LOS 主任務分類模型訓練 30 epochs；而用於輔助提取病灶之 ROI 影像切割模型同樣訓練 30 epochs。此外為降低資料樣本較少與患者個體差異所帶來的隨機偏差，本研究中所有評估分類效能的實驗環節，均嚴格採用 10 次交叉驗證（10-fold cross-validation）。最終實驗結果之各項評估指標（如準確率、敏感度、特異度及 F1 分數等）皆為 10 次驗證測試結果之平均值與標準差，以合理地反映模型面對未知資料的真實泛化能力。

表 4.1: 實驗硬體設備規格

項目	規格
CPU	Intel Core i9-9900X @ 3.50GHz
GPU	NVIDIA GeForce GTX 1080 Ti
RAM	32 GB
OS	Ubuntu 20.04.6 LTS
Python	3.9.19
PyTorch	2.4.1
CUDA	12.2
MONAI	1.3.0

4.2 資料集與病歷篩選

4.2.1 振興醫院 A 型主動脈剝離資料集

本研究所採用之首要臨床醫療影像由台北振興醫院提供。該資料集共收錄 91 位經診斷為 A 型主動脈剝離並接受緊急外科修補手術前的患者之 3D 胸腔電腦斷層掃描 (CT) 影像。為確保空間立體資訊的一致性，所有原始影像的長寬截面維度皆為 $512 \times 512 \times N$ (其中 N 為切片深度，依病患差異浮動)。

以下是此資料集的組成：

- **ROI 切割任務標注組**：由醫師針對其中 20 位患者的 CT 影像進行了病灶邊界標記，標記內容聚焦於主動脈之真腔與假腔撕裂範圍。此 20 筆將用於訓練病灶區域 (ROI) 切割模型。
- **預後 LOS 分類任務篩選組**：對於剩餘無標注分割圖的 71 位患者的 CT 影像 (蒐集年份涵蓋 2020 年至 2024 年) 皆由同一位資深心臟外科醫師親自執刀，其中有 2 筆資料因術後資料不完全而被排除。剩餘 69 筆中有 9 筆案例在 ICU 停留期間不幸去世或中途轉院，最終保留 60 筆具備完整影像與明確術後停留天數的紀錄，作為訓練下游 ICU LOS 二元分類模型與驗證效能之核心資料集。

4.2.2 ImageTAAD

ImageTAAD [13] 為 120 位來自廣東省人民醫院 A 型主動脈剝離患者的影像資料並包含 36 個類別的標籤，影像大小為 $512 \times 512 \times N$ 。此資料集主要作用於兩個訓練階段。其一為「自監督式預訓練階段」：此階段不使用任何標記標籤，僅將這 120 組無標籤的 3D 影像輸入網路進行空間對比學習，期望模型學習胸腔之病理特徵；其二為「ROI 切割模型訓練階段」：我們對 ImageTAAD 繁複的 36 類標籤進行了部分融合並將所有非主動脈及非剝離的區域抹除，僅保留與振興醫院資料集定義一致的標記類別。

4.2.3 ImageTBAD

ImageTBAD [14] 為 100 位來自廣東省人民醫院 B 型主動脈剝離患者的影像資料，包含真腔、假腔以及撕裂點類別的標籤，影像大小為 $512 \times 512 \times N$ 。此資料集作為實驗二用於比較對於 A 型病人以及 B 型病人在模型切割上的準確度以及對於後續做 A 型病人 ICU LOS 分類時的影像。

4.3 實驗一：自監督式預訓練對 ICU LOS 分類影響

在醫學影像深度學習領域中取得特定資料相當不易。因此本實驗旨在評估透過外部大型資料集（ImageTAAD）進行對比學習（Contrastive Learning）之自監督式預訓練，是否能夠促使模型學習更具代表性的主動脈解剖特徵，進而提升下游小樣本 ICU LOS 預測任務的效能。無預訓練基線與引入自監督預訓練之分預測果比較如表 4.2 所示。實驗架構分為上游預訓練與下游分類兩個連續階段，具體設定如下：

上游任務（自監督式對比學習預訓練）

- **預訓練資料集：**ImageTAAD（120 筆 A 型主動脈剝離 CT 影像，剝除原始類別標籤，僅以無監督方式學習空間特徵）。
- **預訓練方法：**採用 Inner-cutout / Outer-cutout 空間遮罩對比學習。

下游任務（ICU LOS 分類）

- **分類資料集：**振興醫院 60 位患者。
- **任務定義：**ICU 停留時間 ≤ 7 天歸類為 Class 0（短期停留）； > 7 天歸類為 Class 1（長期停留）。
- **模型：**Swin-UNETR v2。
- **資料增強：**採用 12 倍。

分析實驗數據可發現套用自監督式對比學習預訓練後，儘管模型整體的分類準確率（Accuracy）略有下降（由 0.7333 降至 0.6833）且特異度出現退步，但對於敏感度（Sensitivity，對長期停留患者之召回率）而言從 0.2500 提升至 0.4000，F1 綜合分數也由 0.2833 進步至 0.3967。推測在無預訓練狀況下，模型嚴重偏向預測樣本較多的「短

表 4.2: 自監督式預訓練對分類結果的影響

預訓練	Accuracy	Sensitivity	Specificity	F1
無	0.7333 $\pm$ 0.1165	0.2500 $\pm$ 0.3536	0.9750 $\pm$ 0.0791	0.2833 $\pm$ 0.3853
對比學習	0.6833 $\pm$ 0.1657	0.4000 $\pm$ 0.3944	0.8250 $\pm$ 0.2058	0.3967 $\pm$ 0.3487

期停留 (Class 0)」，導致看似較高的準確率實則對少類的識別能力低下。而自監督預訓練有效引導模型習得主動脈病灶的通用特徵，使其對少類具備更高的敏感度。雖然犧牲了部分特異度，但卻為後續配合資料平衡策略提供了更佳的模型權重初始化起點。

4.4 實驗二：僅以 ROI 影像對 ICU LOS 分類影響

臨床判讀上，主動脈的局部異常結構（如真假腔形態與位置）通常是術後復原的關鍵指標。本實驗旨在探討若透過分割模型裁剪出感興趣區域 (Region of Interest, ROI)，隨後單純依賴 ROI 裁剪後影像進行分類，是否能過濾其他背景無關的病理部位從而提升分類效能。ROI 座標擷取邏輯已於第三章詳述。實驗具體設定如下：

上游任務（自監督式對比學習預訓練）

- 預訓練資料集：ImageTAAD
- 預訓練方法：採用 Inner-cutout / Outer-cutout 空間遮罩對比學習。

下游任務（切割 ROI）

- 任務定義：僅訓練用於切割真、假腔部分。
- 模型：Swin-UNETR v2。
- 資料增強：無。

下游任務（ICU LOS 分類）

- 分類資料集：振興醫院 60 位患者。
- 任務定義：患者 ICU 停留時間 ≤ 7 天歸類為 Class 0； > 7 天歸類為 Class 1。
- 模型：Swin-UNETR v2。
- 資料增強：採用 12 倍。

表 4.3: ROI 切割策略對分類結果的影響

切割模型訓練資料集	Accuracy	Sensitivity	Specificity	F1
資料集 ImageTBAD	0.6833 ± 0.2144	0.5000 ± 0.2357	0.7750 ± 0.2789	0.5333 ± 0.2460
資料集 ImageTAAD	0.617 ± 0.137	0.35 ± 0.337	0.750 ± 0.167	0.340 ± 0.305

如表 4.3 所示，採用 ImageTBAD 資料集訓練的 ROI 切割模型所裁剪出的影像，能夠在下游分類任務中達到較高的準確率（0.6833）與敏感度（0.5000）。推測 ROI 引導確實有助於模型聚焦於病灶相關區域，惟僅以 ROI 區域作為分類依據仍存在資訊不完整的問題。

4.5 實驗三：資料平衡策略對 ICU LOS 分類影響

鑑於上述實驗中少數類樣本稀缺所帶來的識別困難，本實驗進一步針對資料集類別不平衡現象，探討並比較兩種不同資料平衡機制的效能幫助。實驗額外探討不同增強倍數（4x、8x、12x）對此現象之影響，兩種方法效能分別詳列於表 4.4 及表 4.5。詳細實驗設定如下：

上游任務（自監督式對比學習預訓練）

- 預訓練資料集：ImageTAAD
- 預訓練方法：採用 Inner-cutout / Outer-cutout 空間遮罩對比學習。

下游任務（ICU LOS 分類）

- 分類資料集：振興醫院 60 位患者。
- 任務定義：患者 ICU 停留時間 ≤ 7 天歸類為 Class 0； > 7 天歸類為 Class 1。
- 模型：Swin-UNETR v2。
- 資料增強：採用 12 倍。

實驗方法

- 方法 A（傳統上採樣）：在每個訓練 epoch 中，系統將強制取用所有「少類樣本（長期停留）」，並僅透過隨機採樣同等數量的「多類樣本」來達到數量 1:1 的平衡。

- **方法 B (ROI 隨機替換)**：在針對少類樣本進行抽樣擴充時，有一定機率將原本的完整影像替換為該患者切割過後的影像，以此產生更具空間變異性的少類樣態。

表 4.4: 資料平衡—方法 A (少類全用，多類隨機採樣)

增強數	Accuracy	Sensitivity	Specificity	F1
4x	0.7500 ± 0.1416	0.5500 ± 0.4378	0.8500 ± 0.1748	0.5100 ± 0.3745
8x	0.6833 ± 0.1459	0.6000 ± 0.3162	0.7250 ± 0.2189	0.5300 ± 0.2570
12x	0.6833 ± 0.1657	0.4000 ± 0.3944	0.8250 ± 0.2058	0.3967 ± 0.3487

表 4.5: 資料平衡—方法 B (少類 ROI 隨機替換，多類隨機採樣)

增強數	Accuracy	Sensitivity	Specificity	F1
4x	0.7833 ± 0.1125	0.5000 ± 0.4714	0.9250 ± 0.1208	0.4733 ± 0.4175
8x	0.7667 ± 0.1405	0.5000 ± 0.4082	0.9000 ± 0.1748	0.5000 ± 0.3849
12x	0.8000 ± 0.1315	0.6500 ± 0.3375	0.8750 ± 0.1768	0.6467 ± 0.2860

從結果中可明顯觀察到，方法 A 在增加增強倍數（由 4x 擴充至 12x）時，整體效能不但未獲改善，反而出現準確率退步及 F1 顯著下滑的衰退現象。此趨勢揭示了傳統的上採樣方法在樣本極度貧乏的情境下，對有限之少數類樣本做過度重複運算導致神經網路對於少類過度擬合，削弱了對於數據的泛化能力。

相比之下，引入 ROI 替換機制的方法 B 在高倍數增強下（12x）取得了最傑出的整體績效，達到 0.8000 的準確率與 0.6467 的 F1 分數，甚至使敏感度突破達到 0.6500。推測在替換少類的方法上，不僅保留了對於少類的病理特徵同時隨機抽換的機制使得模型得以觀察到不同區域上的少類結構，大幅提升模型對於少類的理解性。

4.6 實驗四：Swin-UNETR v2 與 MambaVision 3D 架構比較

傳統基於 Transformer 架構的模型（如 Swin-UNETR）在處理 3D 醫學影像時常受限於自注意力機制的運算複雜度，近年的 Mamba 架構憑藉狀態空間模型（SSM）嘗試在保持全局感受野的同時降低複雜度。本實驗旨在比較自監督式學習後 Swin-UNETR v2 與本研究修改引入之 3D MambaVision 在 ICU 停留分類上的表現潛力。實驗中 Swin-UNETR 設定如下：

上游任務（自監督式對比學習預訓練）

- 預訓練資料集：ImageTAAD
- 預訓練方法：採用 Inner-cutout / Outer-cutout 空間遮罩對比學習。

下游任務（ICU LOS 分類）

- 分類資料集：振興醫院 60 位患者。
- 任務定義：患者 ICU 停留時間 ≤ 7 天歸類為 Class 0； > 7 天歸類為 Class 1。
- 資料平衡：ROI 隨機替換。
- 資料增強：採用 12 倍。

此實驗中 MambaVision 3D 未載入任何預訓練權重，詳細設定如下：分類任務（ICU LOS 分類）

- 分類資料集：振興醫院 60 位患者。
- 任務定義：患者 ICU 停留時間 ≤ 7 天歸類為 Class 0； > 7 天歸類為 Class 1。
- 資料平衡：ROI 隨機替換。
- 資料增強：採用 12 倍。

比較結果見表 4.6，此外針對 Mamba 擴展不同增強倍數之測試結果詳列於表 4.7。

表 4.6: Swin-UNETR v2 與 MambaVision 3D 比較

模型	Accuracy	Sensitivity	Specificity	F1
Swin-UNETR v2	0.8000 $\pm$ 0.1315	0.5500 $\pm$ 0.3689	0.9250 $\pm$ 0.1687	0.5433 $\pm$ 0.4037
MambaVision 3D	0.7833 $\pm$ 0.1125	0.5500 $\pm$ 0.3689	0.9000 $\pm$ 0.1748	0.5633 $\pm$ 0.3230

表 4.7: MambaVision 3D 不同增強倍數結果

增強數	Accuracy	Sensitivity	Specificity	F1
6x	0.7500 $\pm$ 0.1179	0.6500 $\pm$ 0.3375	0.8000 $\pm$ 0.1972	0.5967 $\pm$ 0.2598
12x	0.7833 $\pm$ 0.1125	0.5500 $\pm$ 0.3689	0.9000 $\pm$ 0.1748	0.5633 $\pm$ 0.3230
24x	0.8167 $\pm$ 0.0527	0.5500 $\pm$ 0.2838	0.9500 $\pm$ 0.1054	0.6267 $\pm$ 0.2271

由表 4.6 可知，即使小資料樣本的情形下，MambaVision 3D 仍表現出了與 Swin-UNETR v2 極為相近的效能（F1 甚至略高達到 0.5633）。這印證了 SSM 架構在處理具

有大量連續像素之立體醫學影像時，確實擁有足夠深度的特徵承载力與良好的收斂性。更進一步可以從表 4.7 可以看出，當資料增強被極端放大至 24 倍時，MambaVision 3D 準確率更進一步推升至 0.8167，並且模型效能波動的標準差縮小到 0.0527 之間。整體而言，MambaVision 3D 架構在未使用自監督預訓練的情況下即展現出與 Swin-UNETR v2 相當的潛力，值得進一步結合預訓練策略進行探索。

4.7 實驗五：不確定性量化比較

除了預測準確，我們仍期望模型對於其預測結果仍具有一定解釋性。本實驗比較 MC Dropout 與 BZQ 兩種不確定性量化方法在本研究分類模型上的表現，評估模型是否能在高信心預測時同時保持高準確率。本節採用實驗三表現較好的方法 B 作為實驗基底，模型設定如下：

上游任務（自監督式對比學習預訓練）

- 預訓練資料集：ImageTAAD
- 預訓練方法：採用 Inner-cutout / Outer-cutout 空間遮罩對比學習。

下游任務（ICU LOS 分類）

- 分類資料集：振興醫院 60 位患者。
- 任務定義：患者 ICU 停留時間 ≤ 7 天歸類為 Class 0； > 7 天歸類為 Class 1。
- 模型：Swin-UNETR v2。
- 資料平衡：ROI 隨機替換。
- 資料增強：採用 12 倍。

各方法精細之超參數載於表 4.8 與 4.9，並於圖 4.1 與圖 4.2 繪製相對應之 ROC（Receiver Operating Characteristic）評估曲線，綜合校準準確率表現詳見表 4.10。

表 4.8: BZQ 不確定性量化參數

參數	設定值
遮罩大小	5×5
滑動步幅	5×5

表 4.9: MC Dropout 不確定性量化參數

參數	設定值
Dropout Rate	0.001
推論次數	100

表 4.10: 不確定性量化模型校準方法預期比較 (ECE)

方法	Expected Calibration Error (ECE) ↓
MC Dropout	0.239
BZQ	0.203




圖 4.1: Swin-UNETR v2 搭配 MC Dropout 之 ROC 曲線




圖 4.2: Swin-UNETR v2 搭配 BZQ 之 ROC 曲線

作為評量模型預測信賴水準與實際正確率適配度的重要指標，Expected Calibration Error (ECE) 越低，顯示模型的輸出機率越等同於真實置信度。成果顯示，BZQ 在涵蓋校準度 (ECE: 0.203) 與曲線下面積 (AUC: 0.691) 上全面超越了傳統的 MC Dropout (ECE: 0.239, AUC: 0.679)。推測為 MC Dropout 屬於模型權重層級的認知型不確定量化擾動，在深度神經網路的深層傳播中，隨機屏蔽隱藏層權重容易導致已習得的 3D 全域空間視野與病理理解關聯產生破壞；相對地，BZQ 採用的是針對輸入影像的「空間遮蔽」。此做法迫使網路在推論當下，需仰賴那些未被遮住的病灶邊緣訊息來進行預測。這本質上與醫療診斷上高度依賴病灶位置與局部特異性相當符合，提供更穩定的統計量化指標與更精確的臨床可解釋性。

4.8 實驗六：集成學習對 ICU LOS 分類影響

在樣本有限或變異性過大導致模型預測不穩定的問題中，集成學習 (Ensemble Learning) 策略已被證明能有效進行結合，減少模型間的差異。本實驗分別對最佳條件下產出之多個模型存檔，組合 39 個子模型構成評議集群，比較基於預測機率平均的「軟投票 (Soft Voting)」與基於最終預測類別多數決的「硬投票 (Hard Voting)」對最終預測輸出的效能比較。實驗所採用之模型囊括 Swin-UNETR v2 (搭載預訓練權重) 與未預訓練之 MambaVision 3D。詳細投票結果如表 4.11 至 4.14 所示。實驗設定如下：

Swin-UNETR 上游任務 (自監督式對比學習預訓練)

- 預訓練資料集：ImageTAAD
- 預訓練方法：採用 Inner-cutout / Outer-cutout 空間遮罩對比學習。

ICU LOS 分類

- 分類資料集：振興醫院 60 位患者。
- 任務定義：患者 ICU 停留時間 ≤ 7 天歸類為 Class 0； > 7 天歸類為 Class 1。
- 資料平衡：ROI 隨機替換。
- 資料增強：採用 12 倍。

綜合數據走勢，硬投票的表現優於軟投票。Swin-UNETR v2 以 3 模型硬投票取

表 4.11: Swin-UNETR v2 集成學習—軟投票結果

模型數量	Accuracy	Sensitivity	Specificity	F1
3	0.7833 ± 0.0805	0.5000 ± 0.2357	0.9250 ± 0.1208	0.5800 ± 0.2218
5	0.7667 ± 0.0861	0.4500 ± 0.2838	0.9250 ± 0.1208	0.5133 ± 0.2842
7	0.8167 ± 0.0946	0.5500 ± 0.2838	0.9500 ± 0.1054	0.6300 ± 0.2555
9	0.8000 ± 0.1315	0.5000 ± 0.3333	0.9500 ± 0.1054	0.5800 ± 0.3236

表 4.12: Swin-UNETR v2 集成學習—硬投票結果

模型數量	Accuracy	Sensitivity	Specificity	F1
3	0.8500 ± 0.0946	0.6500 ± 0.2415	0.9500 ± 0.1054	0.7300 ± 0.1590
5	0.8167 ± 0.0946	0.5500 ± 0.2838	0.9500 ± 0.1054	0.6300 ± 0.2555
7	0.8333 ± 0.0786	0.5500 ± 0.2838	0.9750 ± 0.0791	0.6467 ± 0.2515
9	0.8500 ± 0.0946	0.6000 ± 0.3162	0.9750 ± 0.0791	0.6800 ± 0.2754

表 4.13: MambaVision 3D 集成學習—軟投票結果（12x 增強）

模型數量	Accuracy	Sensitivity	Specificity	F1
3	0.7667 ± 0.0861	0.4500 ± 0.2838	0.9250 ± 0.1687	0.5167 ± 0.2772
5	0.7667 ± 0.0861	0.5000 ± 0.3333	0.9000 ± 0.1748	0.5300 ± 0.2882

表 4.14: MambaVision 3D 集成學習—硬投票結果（12x 增強）

模型數量	Accuracy	Sensitivity	Specificity	F1
3	0.8333 ± 0.1361	0.6000 ± 0.3944	0.9500 ± 0.1581	0.6333 ± 0.3668
5	0.8167 ± 0.1230	0.6000 ± 0.3944	0.9250 ± 0.1687	0.6133 ± 0.3497

得最佳結果 (Accuracy: 0.8500, F1: 0.7300)，增加模型數量至 5、7 時準確率略有起伏，推測是因少數類別的訓練樣本有限，過多模型投票時少類的偏好票數被稀釋。MambaVision 3D 的集成結果同樣顯示硬投票優於軟投票，3 模型硬投票達到最佳結果 (Accuracy: 0.8333, F1: 0.6333)，增加至 5 模型後效能略微下降，趨勢與 Swin-UNETR v2 一致。整體而言，集成學習策略確實在提升模型穩定性與整體效能上展現出顯著優勢，尤其在樣本有限的醫療影像任務中，適度的模型組合能夠有效緩解單一模型過擬合或偏差的問題。

4.9 實驗七：TAP-CT 特徵對 ICU LOS 分類影響

本實驗探討將通用 CT 基礎模型 TAP-CT 所抽取的語意特徵分別融合 Swin-UNETR v2 與 MambaVision 3D 的後段分類層，成效整理為表 4.15。實驗設定如下：

Swin-UNETR 上游任務（自監督式對比學習預訓練）

- **預訓練資料集：**ImageTAAD
- **預訓練方法：**採用 Inner-cutout / Outer-cutout 空間遮罩對比學習。

ICU LOS 分類

- **分類資料集：**振興醫院 60 位患者。
- **任務定義：**患者 ICU 停留時間 ≤ 7 天歸類為 Class 0； > 7 天歸類為 Class 1。
- **資料平衡：**ROI 隨機替換。
- **資料增強：**採用 12 倍。

表 4.15: TAP-CT 特徵融合結果

融合模型	Accuracy	Sensitivity	Specificity	F1
TAPSwinUNETR	0.7667 $\pm$ 0.1405	0.4500 $\pm$ 0.4378	0.9250 $\pm$ 0.1687	0.4500 $\pm$ 0.4161
TAPMambaVision3D	0.8167 $\pm$ 0.1230	0.6500 $\pm$ 0.3375	0.9000 $\pm$ 0.1748	0.6633 $\pm$ 0.2813

對比未融合前之獨立模型數據（參考表 4.6），將 TAP-CT 特徵混入 Swin-UNETR v2（TAPSwinUNETR）後，不僅準確率（0.7667）未提升，代表綜合鑑別度的 F1 亦銳減至 0.4500。推測由於 Swin-UNETR v2 內部自身已設計具備密集多層次的局部特徵傳遞途

徑，凍結 TAP-CT 所引入的影像特徵可能對分類結果造成干擾，反而掩蓋了有用的心血管資訊。

TAPMambaVision3D 的表現較 MambaVision 3D 單一模型的差距較小，F1 達 0.6633，且敏感度從 0.6000 提升至 0.6500，顯示 TAP-CT 通用語意特徵在 MambaVision 架構上具有一定的互補性並有助於少類的識別。整體而言 TAP-CT 特徵融合在 MambaVision 3D 上的效果優於 Swin-UNETR v2，兩者的差異可能源自各主幹特徵空間的差異性。



第五章 結論與未來方向

5.1 結論

本研究針對 A 型主動脈剝離患者術後加護病房停留時間（ICU LOS）的預測問題，提出了一套結合影像分割、自監督預訓練、模型集成與不確定性量化的三維深度學習綜合評估框架。在類別嚴重不平衡的挑戰下，本研究提出的「以 ROI 切割影像替換為基礎之資料平衡策略」，成功在增加少數類資料多樣性的同時避免了過度依賴背景特徵的過擬合現象，賦予了模型更為強健的病灶鑑別能力。

此外其他近一步的實驗表明：採用 Swin-UNETR v2 搭配 3 組模型進行「硬投票（Hard Voting）」的集成學習策略取得了最佳的綜合表現，其準確率達到 0.85，且 F1 分數躍升至 0.7300，證明了多重決策邊界在處理模糊邊緣個案時的穩健性。然而實驗中亦觀察到，若單純僅依賴切割後的主動脈 ROI 區域作為預測輸入，整體的準確率反而出現明顯下滑。這透露出兩項潛在的醫學影像特性：其一為自動切割模型之邊緣刻畫可能仍存在微小偏差；其二為患者術後的總體 ICU 停留時間，不僅僅受限於主動脈假腔擴張的局部區域，全身性的解剖特徵如心包膜周邊狀態或胸腔積液等未被劃入 ROI 的區域，亦蘊含了不可忽視的判斷線索。

而在極為關鍵的模型不信任度評估方面，本研究引入的 BZQ 不確定性量化空間遮蔽方法，相較於傳統擾動神經網路權重的 MC Dropout，能更為精確且穩定地捕捉模型預測的統計信心。儘管 BZQ 已將預期校準誤差（ECE）壓低至 0.203，但在追求絕對安全與高可信度的臨床決策標準而言，該校準能力依舊存在著進階改良與技術擴展的進步空間。

5.2 未來研究方向

總結本研究過程所遭遇之限制與未探索之層面，特提出以下三個維度的未來研究方向，期盼能推進該領域技術朝向實際臨床落地邁進：

- 1. Mamba 預訓練任務：**從本研究的架構比較中可明顯看出，3D MambaVision 在完全缺乏上游對比學習預訓練的前提下，仍展現出不亞於 Swin-UNETR v2 的強勢分類能

力，甚至在 24 倍的極端資料增強中仍有標準差極低的穩定準確率。考量其在序列映射與長距離資訊傳遞上的低記憶體損耗優勢，後續若能針對 MambaVision 架構量身打造專屬的自監督學習訓練計畫（如 Masked Autoencoder, MAE 等），有望使進一步提升其對大規模醫療影像的底層病理空間結構具備更深度的理解。

2. 融合 ROI 語意特徵與全域影像：有鑑於「僅輸入 ROI 影像」將損失全局重要特徵，而「僅輸入全域影像」又容易被雜亂背景誤導。可在進入深層分類層前，同時引入「全域原影像」與「分割模型所產出之 ROI 遮罩預測標籤」，透過特殊的注意力相加融合機制（Attention Mechanism），讓模型自主學習要在何時關注焦點病灶（主動脈真假腔），這種多個特徵的融合，有極大潛力同時兼顧細節局部特徵與全局穩定性。

3. 整合多元臨床數據：純粹透過 3D CT 影像來推論複雜患者的預後恢復天數往往有所侷限。若能夠結合電子病歷（EHR）、入院血液生化檢查數據、年齡及過往病史等一維時序性指標，設計多模態融合網路。這樣的架構不僅能從影像中抽取病灶特徵，還能從結構化數據中捕捉患者的生理狀態與潛在風險因素，進一步提升預測的準確性與臨床實用性。

參考文獻

- [1] 黃鈺婷. “基於自監督式學習分析 A 型主動脈剝離患者的 CT 影像以預測其住院情況”. 臺灣博碩士論文知識加值系統。 <https://hdl.handle.net/11296/xu78xb>. 碩士論文. 國立臺北科技大學, 2025.
- [2] A. Hatamizadeh et al. “Swin UNETR: Swin Transformers for Semantic Segmentation of Brain Tumors in MRI Images”. In: *International MICCAI Brainlesion Workshop*. 2021.
- [3] Y. Tang et al. “Self-supervised pre-training of Swin transformers for 3D medical image analysis”. In: *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2022.
- [4] S. Hochreiter and J. Schmidhuber. “Long short-term memory”. In: *Neural Computation* 9.8 (1997), pp. 1735–1780.
- [5] A. Gu, K. Goel, and C. Ré. “Efficiently modeling long sequences with structured state spaces”. In: *International Conference on Learning Representations (ICLR)*. 2022.
- [6] A. Gu and T. Dao. “Mamba: Linear-time sequence modeling with selective state spaces”. In: *arXiv preprint arXiv:2312.00752* (2023).
- [7] A. Hatamizadeh and J. Kautz. “MambaVision: A hybrid Mamba-Transformer vision backbone”. In: *arXiv preprint arXiv:2407.08083* (2024).
- [8] T. Veenboer et al. “TAP-CT: 3D task-agnostic pretraining of computed tomography foundation models”. In: *arXiv preprint arXiv:2512.00872* (2025).
- [9] M. Oquab et al. “DINOv2: Learning robust visual features without supervision”. In: *Transactions on Machine Learning Research (TMLR)* (2024).
- [10] Y. Gal and Z. Ghahramani. “Dropout as a Bayesian approximation: Representing model uncertainty in deep learning”. In: *International Conference on Machine Learning (ICML)*. 2016.
- [11] 王派軒. “基於測試資料遮罩之不確定量化模型之研究”. 臺灣博碩士論文知識加值系統。 <https://hdl.handle.net/11296/4t5uzn>. 碩士論文. 國立臺北科技大學, 2025.
- [12] Y. Ovadia et al. “Can you trust your model’s uncertainty? Evaluating predictive uncertainty under dataset shift”. In: *Advances in Neural Information Processing Systems (NeurIPS)*. 2019.
- [13] S. Song et al. “Domain knowledge based comprehensive segmentation of Type-A aortic dissection with clinically-oriented evaluation”. In: *Medical Image Analysis* 102 (2025), p. 103512.

- [14] J. Zhang Y. Dong H. Qiu H. Yuan Q. Jia T. Wang Y. Shi J. Zhuang L. Que X. Xu Z. Yao W. Xie and M. Huang. “ImageTBAD: A 3D Computed Tomography Angiography Image Dataset for Automatic Segmentation of Type-B Aortic Dissection”. In: *Frontiers in Physiology* 12 (2021).

