

國立臺灣
科技大學
資訊工程
系碩士班

碩

士

論

文

○ 基於自監督式學習分析
「」 影像以預測其主動脈剝離
患者
住院
情況

研究生：
黃鈺婷



國立臺北科技大學

資訊工程系碩士班

碩士學位論文

**基於自監督式學習分析 A 型主動脈剝離患
者的 CT 影像以預測其住院情況**

**Using Self-Supervised Learning to Predict
Hospitalization Outcomes from CT Images of
Patients with Type A Aortic Dissection**

研究生：黃鈺婷

指導教授：尤信程 博士

共同指導教授：劉建宏 博士

中華民國一百一十四年七月

(預留空白頁)



國立臺北科技大學

資訊工程系碩士班

碩士學位論文

基於自監督式學習分析 A 型主動脈剝離患
者的 CT 影像以預測其住院情況

Using Self-Supervised Learning to Predict
Hospitalization Outcomes from CT Images of
Patients with Type A Aortic Dissection

研究生：黃鈺婷

指導教授：尤信程 博士

共同指導教授：劉建宏 博士

中華民國一百一十四年七月

國立臺北科技大學
研究所碩士學位論文口試委員會審定書

本校資訊工程系研究所黃鈺婷君

所提論文，經本委員會審定通過，合於碩士資格，特此證明。

學位考試委員會

委

員：

尤信程

殷修賢

李國樞

劉建宏

指導教授：

尤信程 劉建宏

所

長：

劉建宏

中華民國 114 年 7 月 2 日

摘要

關鍵詞：自監督式學習、深度學習、主動脈剝離

本研究旨在預測 A 型主動脈剝離患者於接受手術治療後的住院情況，藉以協助醫師進行更精確的手術風險評估與臨床決策。A 型主動脈剝離是一種高死亡率的急性主動脈疾病，患者常需緊急手術治療，但術後恢復狀況存在個體差異，對醫療資源分配與臨床照護造成挑戰。因此，若能夠在早期階段準確預測其住院情況，對於臨床決策與病患風險評估具有重要意義。本研究所有 A 型主動脈剝離患者的相關資料由振興醫院提供，所有胸部 CT 影像經匿名化處理後輸入深度學習模型進行分析。我們透過自監督式學習進行預訓練任務以強化主動脈結構辨識能力，而下游網路任務設計包含二元分類、多類別分類與回歸三種形式來預測患者的住院情況。實驗結果顯示，在多模型進行投票的方法中可達到 0.77 的準確率，顯示了影像特徵與術後住院情況之間可能有潛在的關聯性，未來可整合更多臨床資料、優化模型設計與擴充資料規模，進一步提升模型的預測能力與臨床應用價值。

ABSTRACT

Keywords: Self-supervised Learning, Deep Learning, Aortic Dissection

This study aims to predict the hospitalization outcomes of patients with type A aortic dissection following surgical treatment, in order to assist physicians in performing more accurate surgical risk assessments and clinical decision-making. Type A aortic dissection is a life-threatening acute aortic condition with high mortality, often requiring emergency surgical intervention. However, postoperative recovery varies among individuals, posing challenges to medical resource allocation and clinical care. Therefore, accurately predicting hospitalization outcomes at an early stage is of significant importance for clinical decision-making and patient risk assessment. All relevant data of type A aortic dissection patients in this study were provided by Cheng Hsin General Hospital. Chest CT images were anonymized before being analyzed using a deep learning model. A self-supervised learning approach was employed as a pretraining task to enhance the model's ability to recognize aortic structures. The downstream tasks included binary classification, multiclass classification, and regression to predict hospitalization outcomes. Experimental results showed that a model ensemble using voting achieved an accuracy of 0.77, suggesting a potential correlation between imaging features and postoperative hospitalization outcomes. In the future, integrating more clinical data, optimizing model design, and expanding the dataset may further improve prediction performance and clinical applicability.

誌謝

首先，要特別感謝我的指導老師尤信程教授與劉建宏教授，在整個研究過程中不僅耐心地提供指導，更在研究設計、數據分析與論文撰寫等各個階段給予我建議，引導我釐清問題脈絡。

感謝振興醫院的陳威廷醫師提供寶貴的研究資料，並對資料內容進行詳細說明，讓我能更精確地掌握資料特性與研究脈絡。同時，也非常感謝李永在醫師在影像判讀上所給予的專業意見與協助。

謝謝實驗室的同學，在整個研究歷程中，大家總是在討論中給我啟發，無論是技術問題、研究想法或資料處理，大家總是樂於分享經驗與資源。彼此間互相幫忙、提醒，在許多實驗操作、數據處理與論文修改的過程中提供了實質的協助，也營造了良好的合作與學習氛圍。


最後，感謝我的家人一直以來的支持。在我專注研究、繁忙撰寫的時期，總是默默包容與鼓勵，是我能夠全心投入研究的堅實後盾。謝謝你們一路上的支持與陪伴，使我得以順利完成這段具有挑戰性的學習旅程。

目錄

摘要.....	i
ABSTRACT.....	ii
誌謝.....	iii
目錄.....	iv
表目錄.....	vii
圖目錄.....	viii
第一章 緒論.....	1
1.1 研究背景.....	1
1.2 研究目的.....	1
1.3 論文架構.....	1
第二章 相關研究.....	2
2.1 深度學習.....	2
2.2 Transformer 架構.....	2
2.3 Vision Transformer 架構.....	3
2.4 Swin Transformer 架構.....	4
2.5 SwinUNETR 與 SwinUNETR-V2.....	5
2.6 監督式學習.....	7
2.7 自監督式學習.....	7
2.8 集成學習.....	8
2.9 損失函數.....	8
2.9.1 Cross Entropy Loss.....	8
2.9.2 L1 Loss.....	9
2.9.3 Contrastive Loss.....	9
2.10 評估指標.....	10

2.10.1 Sensitivity.....	10
2.10.2 Specificity.....	10
2.10.3 Accuracy.....	10
2.10.4 Mean Absolute Error	11
2.11 3D Slicer.....	11
2.12 MONAI	12
第三章 研究方法	13
3.1 資料預處理	13
3.2 資料增強方法	13
3.3 自監督式學習方法	14
3.3.1 對比學習	14
3.3.2 影像重建.....	15
3.3.3 遮蓋區域重建.....	15
3.4 將 SwinUNETR 和 SwinUNETR-V2 用於下游分類任務與回歸任務.....	16
3.4.1 應用於分類任務	17
3.4.2 應用於回歸任務	19
3.5 下游任務的驗證方法	20
3.6 用 Voting 整合多個模型的預測	20
3.7 針對二元分類任務 Baseline 設計方法	20
第四章 實驗結果和討論.....	22
4.1 實驗所用硬體設備	22
4.2 資料集	22
4.2.1 A 型主動脈剝離資料集	22
4.2.2 B 型主動脈剝離資料集	23
4.3 實驗一：測試不同資料增強倍率對二元分類任務的影響	23

4.4 實驗二：比較 SwinUNETR 與 SwinUNETR-V2 對二元分類任務的影響.....	24
4.5 實驗三：添加線性層以控制全連接層輸入維度對二元分類任務的影響	26
4.6 實驗四：比較不同自監督式學習方法對預測住院天數的影響	27
4.7 實驗五：使用 Soft Voting 與 Hard Voting 融合多個模型的二元分類結果	28
4.8 實驗六：重新劃分住院天數區間以進行多類別分類任務	30
第五章 結論和未來方向	32
5.1 結論	32
5.2 未來方向	32
參考文獻	33
附錄 A	35
附錄 B	36



表目錄

表 3.1 自監督學習階段超參數.....	14
表 3.2 人工判別結果.....	21
表 4.1 實驗用硬體設備與軟體環境.....	22
表 4.2 不同資料增強倍率的實驗結果.....	24
表 4.3 SwinUNETR 和 SwinUNETR-V2 實驗結果.....	25
表 4.4 不同全連階層輸入維度的實驗結果.....	26
表 4.5 不同自監督學習方法的實驗結果.....	28
表 4.6 硬投票結果.....	29
表 4.7 軟投票結果.....	30
表 4.8 各類別分類標準.....	31
表 4.9 多分類任務結果.....	31
表 B.1 以總分大於 3 分作為分類門檻之結果.....	36
表 B.2 以總分大於 5 分作為分類門檻之結果.....	36
表 B.3 以總分大於 6 分作為分類門檻之結果.....	36
表 B.4 總分為 7 分病患之住院天數.....	36

圖目錄

圖 2.1 Transformer 架構圖	3
圖 2.2 Vision Transformer 架構圖	4
圖 2.3 Swin Transformer 架構圖	5
圖 2.4 SwinUNETR 架構圖	6
圖 2.5 SwinUNETR-V2 架構圖	7
圖 3.1 Inner-cutout 和 Outer-cutout 範例圖	15
圖 3.2 隨機像素遮蔽 75% 前後對比圖	16
圖 3.3 應用於分類任務的 SwinUNETR 架構圖（版本一）	18
圖 3.4 應用於分類任務的 SwinUNETR 架構圖（版本二）	19
圖 4.1 A 型主動脈剝離病人住院天數分佈箱型圖	28
圖 A.1 七項影像特徵相關性熱圖	35



第一章 緒論

1.1 研究背景

在現代醫療體系中，住院天數是評估醫療品質、資源配置效率以及病人康復狀況的重要指標，若能準確預測患者的住院天數，就能夠提升臨床決策的效率並減少醫療資源的浪費。住院天數的預測多依賴患者的病歷紀錄，然而這可能會面臨資料格式不一致或內容缺失等問題。根據相關研究[1]，醫療影像中包含大量可用於疾病嚴重程度評估、併發症風險辨識與整體健康狀況判斷的資訊，透過深度學習技術進行特徵擷取與分析，已被證實在疾病預測與診斷任務中具顯著潛力。

A 型主動脈剝離是一種高死亡率且需緊急手術處置的重大心血管急症，依據史丹福分類法（Stanford Classification）其病理特徵為升主動脈內膜破裂，血液進入中層造成真腔與假腔分離，其病情變化劇烈且術後住院天數差異極大。因此，若能在初期透過影像資料預測住院情況，將有助於照護資源配置與預後評估。

1.2 研究目的

本研究希望能應用自監督式學習技術，從醫療影像中擷取出有助於預測的關鍵特徵，並建立一套以胸部 CT 影像為基礎的預測模型。模型首先透過自監督學習進行預訓練，以強化對主動脈結構的辨識能力，接著利用深度神經網路架構萃取影像特徵，進一步估計 A 型主動脈剝離患者的住院情況。

1.3 論文架構

論文整體架構主要分為以下幾個部分：在第二章的部分主要介紹用到的模型架構、評估指標、套件工具；而第三部分介紹自監督式學習方法和下游網路的架構設計；第四章為實驗部分，主要呈現不同架構和方法對於住院天數分類和預測的結果；最後第五章的部分為結論和未來研究方向。

第二章 相關研究

2.1 深度學習

深度學習 (Deep Learning) 是一種使用多層神經網路進行資料學習與分析的技術。它借鑒人類大腦中神經元的結構與連結方式，其核心在於運用深度神經網路 (Deep Neural Networks)。這些網路由多個隱藏層構成，每一層都包含大量的神經元。每個神經元會接收前一層的輸出訊號，並透過運算進行處理。接著隨著訓練過程中不斷調整權重參數，神經網路能逐漸學會資料中的重要特徵，最終具備強大的預測與判別能力。

2.2 Transformer 架構

Transformer 由 Google 團隊在 2017 年提出後[2]，Transformer 架構迅速成為自然語言處理領域的核心技術，並延伸到電腦視覺、語音處理等眾多領域。傳統的序列模型在處理長序列資料時，容易遇到梯度消失或計算效率低的問題。而 Transformer 改用了自注意力機制 (Self-Attention) 來捕捉序列中不同位置間的關聯，使其能夠更好地捕捉長距離依賴，且能夠同時計算很多資料，提高了計算效率。

圖 2.1 為 Transformer 架構，圖中的左半部和右半部分別由 Encoder 和 Decoder 組成，兩者都是堆疊多層相似的模組，每一層都包含了多頭自注意力機制 (Multi-Head Self-Attention) 和前饋神經網路 (Feed-Forward Neural Network)。在整體流程中，首先將輸入序列轉換為嵌入向量，並加上位置編碼，此操作可以讓模型提高對序列順序的感知能力，接著，這些帶有位置資訊的向量會被送入 Encoder 中，透過多頭自注意力機制與前饋神經網路，不斷提取與整合特徵。完成 Encoder 的操作後，Decoder 會根據 Encoder 輸出的特徵，以及自身先前已生成的資料，利用遮蔽的多頭自注意力機制 (Masked Multi-Head Self-Attention)，逐步地生成目標序列。在每一步的生成過程中，Decoder 僅能依賴已知的部分資訊，不能預先看到未來的詞，確保輸出符合自然生成的邏輯。最終，經過線性變換與 softmax 層，模型會輸出每個步驟的預測結果，完成整個

序列的生成。




圖 2.1 Transformer 架構圖

圖片來源：參考文獻[2]

2.3 Vision Transformer 架構

Vision Transformer (ViT) 是一種將 Transformer 用在電腦視覺上的創新方法，它最早在 2020 年由 Google Research 的團隊提出[3]。傳統上，電腦視覺領域主要使用卷積神經網路 (CNN) 來處理圖像任務，而 Vision Transformer 則是將圖像進行切分後，組成一個序列來進行特徵學習，圖 2.2 為其架構圖。

在 Vision Transformer 中，首先會將輸入切分成多個固定大小的 patches，接著，每個切分後的 patch 被攤平成一個向量，並通過 Linear Layer 投影到一個固定維度的

空間中，形成對應的 patch embedding，為了讓模型能夠保留圖像中各個 patch 的位置信息，ViT 會在這些 patch embeddings 上加上位置編碼（Positional Encoding），以彌補 Transformer 缺乏順序感知能力的特性。加上位置編碼後，這些序列化的 patch embeddings 會被送入 Transformer Encoder 和 Linear Head 進行最終的分類預測。




圖 2.2 Vision Transformer 架構圖

圖片來源：參考文獻[3]

2.4 Swin Transformer 架構

Swin Transformer（Shifted Window Transformer）是 2021 年由微軟研究院提出[4]，主要是為了解決 Vision Transformer 在處理高解析度影像時計算量過大、缺乏層次結構等問題，圖 2.3 為其架構圖。

首先，Swin Transformer 通過 Patch Partition 操作將影像切割成小的 patch，並在每個 patch 內部進行 Self-Attention 計算，這樣可以有效減少計算量，但是會限制不同區域之間的訊息交流，為了克服這個問題，Swin Transformer 引入了 Shifted Window 的概念，讓每一層的 Attention Window 可以進行平移，因此相鄰 window 的區域能夠進行訊息交換，這樣的設計讓不同區域間的訊息可以進行交流，同時維持了良好的計算效率。

除此之外，為了解決 Vision Transformer 缺乏層次結構的問題，Swin Transformer 在

每一層中進行 patch merging 操作，將相鄰的 patch 合併成一個新的 patch，從而達到降低解析度和增加特徵維度的效果，幫助模型學到更多的特徵並提高了處理不同解析度影像的能力。




圖 2.3 Swin Transformer 架構圖

圖片來源：參考文獻[4]

2.5 SwinUNETR 與 SwinUNETR-V2

SwinUNETR [5] 是由 Hatamizadeh 等人所提出，是一種專為 3D 醫學影像分割任務設計的深度學習模型，其採用了 Encoder-Decoder 架構，如圖 2.4 表示。

SwinUNETR 的 Encoder 架構是由多個 stage 堆疊而成，總共有 4 個 stage，每 stage 包含了 2 個 Swin Transformer Block 和 Patch Merging。接下來會依序介紹 Encoder 部分，首先，輸入的 3D 醫學影像會進入 Patch Partition，會將輸入的影像切成 $2 \times 2 \times 2$ 且不重疊的 patch，然後進入第一個 stage 中的 Linear embedding block 將 patch 映射到指定維度，轉換成可供 Transformer 處理的 3D Token，以便後續 Swin Transformer Block 中的 self-attention 計算，每個 stage 最後還有一層 Patch Merging Layer，在此層中每組相鄰的 token 會被視為一個整體進行處理，將局部特徵按照空間位置切分出來，接著，將切分出來的部分拼接在一起，此時尺寸縮小為原來的一半而通道數變為原來的 2 倍，完成了下採樣的動作。

Decoder 的部分，由五個上採樣區塊以及一個輸出區塊組成。首先，對編碼器最深層的輸出結果進行一次卷積處理，然後依序通過五個上採樣區塊，每一層都對特徵圖進

行上採樣，將尺寸放大為原來的 2 倍，通道數變為原來的一半，且對應 Encoder 的 Feature Map 會透過 Skip Connections 傳至 Decoder，最後輸出區塊使用 $1 \times 1 \times 1$ 的卷積層，生成最後的分割結果。

SwinUNETR-V2 [6] 則是在 SwinUNETR 的基礎上進行的改良版本，架構圖可參考圖 2.5，SwinUNETR-V2 最主要的變化在於每個 stage 的開頭都增加了一個殘差卷積塊（Residual Convolution Block），透過殘差卷積塊，模型能夠在進行 Self-Attention 計算前，先讓每個 patch 融合了附近區域的特徵。此設計有助於增強模型對局部特徵的感知能力，進一步提升訓練的穩定性。




圖 2.4 SwinUNETR 架構圖

圖片來源：參考文獻[5]




圖 2.5 SwinUNETR-V2 架構圖

圖片來源：參考文獻[6]

2.6 監督式學習

監督式學習（Supervised Learning）是機器學習領域中，最常見且應用最廣的一種學習方式。監督式學習是一種透過已知資料標籤來訓練模型的方法。在過程中，模型會接收到一組已經標示好答案的資料，模型會比對標籤和預測結果的差異來進行改正，由於模型能夠在明確的指導下學習輸入與輸出之間的對應關係，因此在同類型任務上通常能達到較高的準確率，但它同時也存在一些限制與缺點，監督式學習必須依賴有標籤的資料，但這種資料通常需要大量的人工標記，通常花費的成本較高，耗時也較久，尤其是在醫療影像等方面的資料。

2.7 自監督式學習

自監督式學習（Self-Supervised Learning）是一種讓模型自己產生訓練所需的標籤，而不依賴人工標記。它會在大量沒有人工標籤的資料中，依照設計的前置任務（Pretext Task）與偽標籤（Pseudo Labels）來進行訓練，常見的前置任務包含對比學習、遮罩預

測等。相較於監督式學習，自監督式學習不需要大量的手動標記，減少了標記的成本，較適合應用於醫療影像方面。

2.8 集成學習

集成學習（Ensemble Learning）是一種機器學習策略，透過結合多個模型的預測結果，以提升整體模型的準確性與穩定性。由於單一模型可能存在偏差或過擬合等問題，集成多個模型能夠相互補強、彌補各自的誤差，從而產生更穩健且可靠的預測效果。常見的方法包括：

- 投票法（Voting）：讓多個模型進行投票決定最終結果，又細分為硬投票和軟投票。
- 堆疊（Stacking）：結合多個不同模型的預測當作輸入，再由另一個模型做最終判斷。
- 裝袋法（Bagging）：將訓練資料隨機分成多個子集，並各自訓練模型，最後平均或投票整合所有預測結果。

2.9 損失函數

損失函數（Loss Function）是用來衡量模型預測結果與真實標籤之間的差距。透過損失函數計算出的差值，模型會根據差值進行參數的調整與優化，逐步學習更準確的預測方式。接下來會介紹本論文中會使用到的損失函數。

2.9.1 Cross Entropy Loss

Cross Entropy Loss 是分類任務中常見的損失函數，適用於多類別的分類問題或二元分類問題。它的主要目的是衡量模型預測的機率分布與真實標籤分布之間的差異。以下為其計算公式：

$$\mathcal{L} = - \sum_{i=1}^C y_i \log(\hat{y}_i) \quad (2.1)$$

其中 C 為類別總數， $\hat{y}_i$ 為模型對每一類的預測機率， y_i 為實際標籤。Cross Entropy Loss 會針對每個類別計算預測機率的對數，並與真實標籤相乘後求和，再取負號。若 Cross Entropy Loss 結果數值越小，表示模型預測越準確；數值越大，表示預測和實際結果偏差越大。

2.9.2 L1 Loss

L1 損失函數 (L1 Loss)，常用於回歸任務與影像重建任務中，用於評估模型預測值與實際值之間的誤差大小，具有對離群值不敏感的特性，讓模型不會被少數極端值影響，適合用於資料中含有異常值的情況。其公式如下：

$$\text{L1 Loss} = \sum_{i=1}^N |y_i - \hat{y}_i| \quad (2.2)$$

其中， N 為樣本數， $\hat{y}_i$ 為資料的標籤， y_i 為模型預測結果。

2.9.3 Contrastive Loss

Contrastive Loss 常用於自監督式學習 (self-supervised learning)，目的是讓模型學會將相似的樣本拉到空間中相近的位置，並將不相似的樣本推離至較遠的距離。一對正樣本 $(\mathbf{z}_i, \mathbf{z}_j)$ 的 Contrastive Loss 可表示為：

$$\mathcal{L}_{i,j} = -\log \frac{\exp(\text{sim}(\mathbf{z}_i, \mathbf{z}_j)/\tau)}{\sum_{k=1}^{2N} \mathbb{1}_{[k \neq i]} \exp(\text{sim}(\mathbf{z}_i, \mathbf{z}_k)/\tau)} \quad (2.3)$$

其中， τ 為參數，用來控制相似度分數的敏感度，若 τ 小則分數差會拉大，代表模型會更在意相似與不相似的差距。而 N 代表正樣本對的數量。 $\mathbf{z}_i$ 和 $\mathbf{z}_j$ 為同個原始影像以兩個不同資料增強產生的樣本，又稱為正樣本對 (positive pair)，而負樣本對 (Negative pairs) 則是兩個不同原始影像產生的樣本。 $\text{sim}(\mathbf{z}_i, \mathbf{z}_j)$ 使用到了餘弦相似度，公式如下：

$$\text{sim}(z_i, z_j) = \frac{z_i^T z_j}{|z_i| \cdot |z_j|} \quad (2.4)$$

若想降低 Contrastive Loss，模型必須學會最大化正樣本對的相似度，同時最小化負樣本對的相似度。

2.10 評估指標

本章節會介紹論文實驗階段使用到的評估指標。

2.10.1 Sensitivity

靈敏度（Sensitivity），是評估分類模型效能的指標之一，用於衡量模型在預測正類樣本的能力。其公式為：

$$\text{Sensitivity} = \frac{TP}{TP + FN} \quad (2.5)$$

其中 True Positives（TP）代表實際分類為正類，且模型也預測為正類的樣本數；而 False Negatives（FN）代表實際為正類，但模型誤判為負類的樣本數。

2.10.2 Specificity

特異度（Specificity）是用來評估模型在辨識負類樣本時的準確程度，其公式為：

$$\text{Specificity} = \frac{TN}{TN + FP} \quad (2.6)$$

其中 True Negatives（TN）代表樣本實際為負類，且模型正確預測其為負類的樣本數；而 False Positives（FP）代表樣本實際為負類，但卻被模型誤判為正類的樣本數。

2.10.3 Accuracy

準確率（Accuracy）是用於評估模型在所有預測中，正確預測的比例。其定義為模型預測正類與負類分類正確的樣本數占總樣本數的比值，公式如下：

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (2.7)$$

2.10.4 Mean Absolute Error

Mean Absolute Error (MAE) 是迴歸任務中常用的評估指標，用於衡量模型預測值與實際值之間的平均差異程度。其計算方式為所有預測誤差的絕對值的平均數，公式如下：

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (2.8)$$

2.11 3D Slicer

3D Slicer [7] 是一款開源的醫學影像處理工具，廣泛應用於醫學圖像視覺化以及人工智慧模型開發等領域，並支援多種醫學影像格式。在資料預處理方面，3D Slicer 提供多種實用功能，協助使用者在進行影像分析或訓練深度學習模型前，先對醫學影像進行必要的轉換與標準化處理。常見的功能包括：

- 格式轉換：將 DICOM 影像轉換為 NIfTI 或其他分析常用格式，簡化影像管理與運算流程。
- 影像重採樣 (Resampling)：統一影像的體素間距 (voxel spacing)，確保來自不同來源的資料具有一致的空間解析度。
- 影像裁切與補邊 (Cropping / Padding)：調整影像尺寸，使其符合特定模型的輸入需求。
- 配準 (Registration)：將不同時間點或不同模態的影像對齊至相同的空間座標系，有助於進行後續的比較、融合或分析。
- 去除雜訊與強度正規化 (Normalization)：提升影像品質，使輸入資料更穩定、更適合模型學習。

這些功能使 3D Slicer 能有效支援深度學習的資料前處理，確保影像的一致性與品質。

此外，3D Slicer 還提供豐富的模組化功能，包括影像分割、三維重建等，還允許使用者透過 Python 撰寫腳本，協助深度學習模型進行影像的預處理。

2.12 MONAI

MONAI (Medical Open Network for AI) [8] 是由 NVIDIA 與多家醫療機構合作開發的開源深度學習框架，專為醫學影像分析所設計。MONAI 建立在 PyTorch 之上，整合了醫療影像處理所需的多種功能，包括資料預處理、資料增強、模型訓練、評估與部署。



第三章 研究方法

3.1 資料預處理

在本研究中，為了統一所有醫學影像的資料維度與格式，我們採用 3D Slicer 和 dcm2niix 工具來進行。首先，使用 3D Slicer 載入每位患者的 DICOM 資料後，可瀏覽所有影像 series，並根據影像描述與顯影品質，選擇有施打顯影劑的影像 series 作為訓練資料。完成選擇後，透過 dcm2niix 工具將原始的 DICOM 影像轉換為 NIfTI(.nii.gz) 格式，相較於 DICOM，NIfTI 結構較為簡潔，僅保留影像資料本身，不保留任何病患訊息，因此更適合做為輸入資料。

在完成影像格式的統一後，我們採用 MONAI (Medical Open Network for AI) 套件進行資料預處理。首先將所有影像重新採樣 (resample) 讓每方向上的體積像素間距 (voxel spacing) 為 1.0 mm，避免不同機器拍出來 CT 影像解析度有所落差。在重新採樣的過程中使用了雙線性插值 (bilinear interpolation)，此方法會根據鄰近像素的值進行加權平均，來估算新的像素，這樣可以讓影像邊緣看起來較為平滑，減少因為尺寸變化而出現的失真或鋸齒狀問題。接著，為了配合深度學習模型的輸入需求，我們將所有影像統一調整大小為 (128, 128, 64) 的三維影像。

3.2 資料增強方法

資料增強 (Data Augmentation) 是用來增加訓練資料的多樣性，避免過擬合 (overfitting) 的發生，特別是在資料量有限的情況下。在本研究中，我們使用兩種資料增強方法來提升模型的學習能力，說明如下：

1. 旋轉 (Rotation): 以 80% 的機率，對影像在 x 軸與 z 軸方向隨機進行 90 度旋轉，模擬不同掃描方向。
2. 翻轉 (Flip): 以 50% 的機率在 x、y、z 軸上進行鏡像翻轉。

3.3 自監督式學習方法

本研究採用了三種不同的自監督式學習方法來進行比較，這三種策略分別為：對比學習 (Contrastive Learning)、重建影像 (Image Reconstruction)，以及遮蓋區域預測 (Mask sampling strategy)。三者皆基於 SwinViT AutoEncoder 架構進行自監督式學習，並使用 B 型主動脈剝離病人的影像當作輸入，SwinViT AutoEncoder 與 SwinUNETR 都是基於 Swin Transformer 所構建的 Encoder-Decoder 架構，但針對不同任務所設計，SwinViT AutoEncoder 主要應用於自監督學習任務，透過 Swin Transformer Block 將輸入影像轉換為特徵向量，再經由 Decoder 上採樣還原回與原圖同樣大小的影像，經過自監督學習訓練後，該 encoder 學得的權重可作為下游任務的初始化權重 (pretrained weights)。

3.3.1 對比學習

對比學習參考了論文[9]中的方法來進行，使用了 Inner-cutout 以及 Outer-cutout，施加不同類型的增強操作來進行對比學習，Inner-cutout 的方式著重於在影像內部進行隨機裁剪與加噪，在影像中隨機選取大小介於 5 至 32 之間的區塊進行裁剪，並添加噪點，每張影像會進行六次此操作，而 Outer-cutout 則聚焦於影像邊緣的區域，裁剪尺寸介於 20 至 64，並在此範圍內隨機添加噪點，同樣也執行六次，可參考圖 3.1。接著，Inner-cutout 和 Outer-cutout 的輸出影像會進入 SwinViT AutoEncoder 模型中進行影像重建，最終產生兩種輸出，並計算這兩種輸出的 Contrastive Loss，以及計算 Outer-cutout 重建影像和原始圖片的 L1 Loss。綜上所述，總損失函數定義如下：

$$\mathcal{L}_{total} = \mathcal{L}_{recon} + \mathcal{L}_{contrast} \cdot \mathcal{L}_{recon} \quad (3.1)$$

其中， $\mathcal{L}_{recon}$ 表示 L1 Loss， $\mathcal{L}_{contrast}$ 為 Contrastive Loss，其餘超參數可參考表 3.1

表 3.1 自監督學習階段超參數

Epochs	500
Learning rate	1e-4

Optimizer	Adam
Batch Size	1




圖 3.1 Inner-cutout 和 Outer-cutout 範例圖

3.3.2 影像重建

影像重建 (Image Reconstruction) 是指讓模型學習從經過壓縮處理過後的影像資料中，重新還原出原本的影像。

在這個過程中，首先會使用 SwinViT 這個模型的編碼器 (Encoder)，來處理輸入影像。模型會把影像切成很多小區塊 (patches)，再透過 Transformer 的注意力機制 (self-attention)，抓出影像中的重要特徵。經過編碼器後，原始影像就會被壓縮成特徵向量。

接著，這些特徵向量會被送進解碼器 (Decoder)，把壓縮過的資料一步步放大還原成原本的影像，最後會輸出一張跟原圖大小一樣的影像。

為了讓模型提高準確率，我們使用 L1 Loss 做為損失函數來訓練模型並比較重建後的影像和原圖的相似程度。

3.3.3 遮蓋區域重建

遮蓋區域重建的具體做法參考了 [10] 中提出的方法並進行微調，採用隨機像素遮

蓋輸入影像 75% 的區域，如圖 3.2 所示，此方法訓練模型根據可見區域特徵，推測並重建被遮蓋的部分，讓模型學會從不完整的資料中恢復出完整的影像，學習整體影像結構與局部細節之間的關聯。

在訓練過程中，首先對輸入影像中的每張切片進行遮蔽，被遮蓋的區域之像素的值會被設為 1，未被遮蔽區域的值設為 0。隨後，將這些遮蔽後的影像輸入到模型來得到預測結果。

為了訓練模型重建被遮蔽的區域，在計算損失函數時，我們只對遮蔽區域進行比較，忽略未遮蔽的區域。利用 L1 Loss 來計算重建損失，具體的計算公式為：

$$loss = \frac{1}{N} |m \odot (\hat{x} - x)|_1 \quad (3.1)$$

其中 $\odot$ 為逐元素乘法 (Hadamard product)， $|\cdot|_1$ 為絕對值總和， $m \in \{0,1\}$ 分別代表遮蔽和未遮蔽。




圖 3.2 隨機像素遮蔽 75% 前後對比圖

3.4 將 SwinUNETR 和 SwinUNETR-V2 用於下游分類任務與回歸任務

在自監督學習預訓練階段完成後，下游網路需針對實際任務調整網路結構，因此本

章節將介紹下游任務網路的具體架構。

3.4.1 應用於分類任務

在本研究中，為了能夠有效分類病人住院情況，我們對原始的 SwinUNETR 架構進行了修改，使其能應用於三維醫學影像的分類任務。原始的 SwinUNETR 模型主要被設計用於醫學影像的分割問題，其架構已於 2.5 小節進行介紹。

在第一種架構設計中，我們保留了 SwinUNETR 中的 Encoder 部分，並刪除了 Decoder 結構，只使用 Encoder 部分提取有助於分類的影像特徵，接著在 Encoder 輸出端加入一層卷積層 (Convolutional Layer)，在其後加入全域平均池化層 (Global Average Pooling)，再透過一個線性全連接層 (Fully Connected Layer)，實現對病患住院情況的分類，最後使用 Cross Entropy Loss 作為 Loss function，圖 3.3 為架構圖，圖中的 Encoder 部分可替換成 SwinUNETR-V2 的 Encoder。

在第二種架構設計中，於全域平均池化層 (Global Average Pooling) 後額外增加兩層線性層，逐步將特徵向量從 384 維壓縮至 128 維，最後變成 40 維，最後以一層全連接層進行分類輸出，SwinUNETR-V2 也以同樣方式進行調整，整體可查看圖 3.4

對結構進行調整後，我們將其應用於自監督學習後的下游分類任務，只提取預訓練網路中的 Encoder 權重到我們的下游網路為初始權重，為了確保模型能持續學習並適應分類任務，我們未凍結任何參數，允許其進行微調 (fine-tuning)。




圖 3.3 應用於分類任務的 SwinUNETR 架構圖（版本一）




圖 3.4 應用於分類任務的 SwinUNETR 架構圖（版本二）

3.4.2 應用於回歸任務

為了能夠預估手術後病人住院天數，本研究將 SwinUNETR 架構再次進行修改，使其能夠適配回歸任務。回歸模型在整體架構上與分類任務類似，主要差異在於最後全連階層輸出結果的數量。分類模型輸出的是各類別的機率分布而回歸模型的部分則改為輸出一個連續值。在訓練之前我們對住院天數進行了對數轉換（log transformation），來穩定標籤的分布並提升預測穩定性與準確度，並降低極值對模型訓練的影響，最後我們使用 L1 Loss 作為損失函數。

3.5 下游任務的驗證方法

本研究分別採用 10 折交叉驗證 (10-fold cross-validation) 與 逐一交叉驗證法 (Leave-One-Out Cross-Validation, LOOCV) 進行實驗。在 10 折交叉驗證中，將所有資料平均分成 10 個子集合，每次輪流以其中一個子集作為測試資料，其餘 9 個子集作為訓練資料，重複進行 10 次以取得模型整體的平均表現。為確保分類任務的公平性與穩定性，資料在分折時採用分層抽樣 (stratified sampling)，使每個 fold 中均包含所有分類標籤，避免樣本分布不均，平衡模型在訓練與測試階段所見資料。而逐一交叉驗證法 (LOOCV) 則是在每次訓練時將僅保留一筆資料作為測試，其餘所有資料用於訓練，並重複進行與樣本數相同次數的實驗。

3.6 用 Voting 整合多個模型的預測

在本研究中，為提升模型預測的準確性與穩定性，我們採用了集成學習 (Ensemble Learning) 策略，分別實作了軟投票 (Soft Voting) 與硬投票 (Hard Voting) 兩種方法。軟投票透過平均各模型對各類別的預測機率，選擇平均機率最高的類別作為最終預測結果，而硬投票則是根據各模型所預測的類別進行多數決，選出出現次數最多的類別作為最終結果。

我們分別融合了三種、五種與七種具有不同初始權重的預訓練任務與下游模型的輸出，來進行軟投票與硬投票。

3.7 針對二元分類任務 Baseline 設計方法

為提供可對照的 Baseline，本研究設計一套基於人工影像評分方法來去對 A 型主動脈剝離患者進行分類，但由於目前缺乏能夠直接從 CT 影像預測患者住院天數的明確標準，我們以主動脈剝離的範圍與影像中可見的異常結構作為替代依據，因此評分規則主要反映病灶嚴重程度與潛在手術難度，可能無法全面涵蓋影響住院天數的其他重要因素。本方法依據七項影像特徵進行判讀，包括：

- 連接主動脈的頸動脈是否具有明顯夾層膜（dissection flap）結構。
- 主動脈弓是否具有明顯夾層膜結構。
- 降主動脈是否具有明顯夾層膜結構。
- 腹腔區域主動脈是否具有明顯夾層膜結構。
- 是否存在心包積液。
- 主動脈直徑是否大於 40 mm。
- 假腔直徑是否大於 20 mm。

每項條件若符合即記 1 分，否則記 0 分，總分範圍為 0 至 7 分，七項標準之間的相關性可參考附錄 A。我們根據總分進行風險分類：總分大於 4 分者歸為高風險組（class 1），其餘則歸為低風險組（class 0），結果可查看表 3.2，以不同分數進行分類結果可參考附錄 B。使用此方法作為一種模擬臨床判讀的基準模型，並用以對照本研究所提出的深度學習方法的效能表現。

表 3.2 人工判別結果

Accuracy	0.52
Sensitivity	0.46
Specificity	0.56

第四章 實驗結果和討論

4.1 實驗所用硬體設備

表 4.1 詳列本實驗所使用的主要硬體與軟體環境。

表 4.1 實驗用硬體設備與軟體環境

CPU	Intel(R) Core(TM) i9-9900X CPU @ 3.50GHz	12th Gen Intel(R) Core(TM) i7- 12700
GPU	NVIDIA GeForce GTX 1080 Ti	NVIDIA RTX A2000 12GB
RAM	32 GB	32 GB
OS	Ubuntu 20.04.6 LT	Windows 11
Python	3.9.19	
Pytorch	2.4.1	
CUDA	12.2	
MONAI	1.3.0	

4.2 資料集

本章節會介紹本實驗所使用到的資料集，包含其來源與數量。

4.2.1 A 型主動脈剝離資料集

本研究中使用到的 A 型主動脈剝離影像資料由振興醫院所提供，資料來源皆經匿名化處理，共有 71 例患者的影像資料，這些患者皆由同一位醫師進行開刀，手術年份分布為 2020 年至 2024 年，其主要用於下游任務網路階段之輸入資料。

4.2.2 B 型主動脈剝離資料集

本研究於自監督式學習階段採用 ImageTBAD 資料集[11]，該資料集收錄從 2013 年至 2019 這段期間在廣東省人民醫院收集的 100 例病患手術前的三維 CT 影像，這些影像涵蓋完整胸主動脈區域，且資料集結構複雜，較能促使模型學習處理具有高變異性與不規則形狀的病理結構。在預訓練階段中，僅使用 ImageTBAD 中 100 例原始 CT 影像進行學習，不使用任何人工標註資訊，預訓練所得之模型權重，將作為後續下游任務的初始化參數。

4.3 實驗一：測試不同資料增強倍率對二元分類任務的影響

在資料量有限的情況下，提高資料增強倍率，可以模擬更豐富的輸入樣本，讓模型對不同情況具有更強的適應能力。本實驗旨在探討資料增強（Data Augmentation）倍率對模型進行二元分類準確率之影響，進而確定後續實驗流程中最合適的超參數設定。實驗分為兩個主要階段，自監督學習預訓練階段與下游分類任務階段，分別說明如下：

- 自監督學習預訓練階段

- 輸入資料：4.2.2 小節提到的 100 例 B 型主動脈剝離病患影像。
- 自監督學習方法：3.3.1 小節提到的對比學習。
- 資料增強倍率：使用資料增強方法將輸入資料數量擴增至原本的 8 倍、12 倍與 16 倍。
- 增強方法：使用旋轉（Rotation）與翻轉（Flipping）進行資料增強。

- 下游分類任務階段

在下游任務中，我們選用可執行分類任務的 SwinUNETR 架構，實驗設定如下：

- 輸入資料：40 位 Type A 主動脈剝離病患。
- 任務目標：預測病患自手術日至出院日之住院天數是否超過 30 天，若手術後至出院前的住院天數 ≤ 30 屬於 class 0，而手術後至出院前的住院天數 > 30 或死亡屬於 class 1。

- 模型架構：使用 3.4.1 小節提到的 SwinUNETR（版本一）。
- 資料增強倍率：將輸入資料數量擴增至原本的 8 倍、12 倍、16 倍與 24 倍。
- 增強方法：輸入資料同樣以旋轉（Rotation）與翻轉（Flipping）進行資料增強。
- 訓練策略：採用 Leave-One-Out 交叉驗證（Leave-One-Out Cross-Validation, LOOCV）。

● 實驗結果

實驗重點在於比較不同資料增強倍率對分類模型效能的影響，以分類準確率（Accuracy）作為主要評估指標。根據實驗結果，當對比學習階段與下游分類任務皆使用 12 倍資料增強時，模型表現最佳，詳細數據請參見表 4.2，縱軸代表下游網路所使用的資料增強倍率，橫軸代表自監督學習預訓練階段所使用的資料增強倍率。

表 4.2 不同資料增強倍率的實驗結果

	8 倍 SSL	12 倍 SSL	16 倍 SSL
8 倍下游網路	0.4	0.6	0.4
12 倍下游網路	0.45	0.75	0.55
16 倍下游網路	0.4	0.7	0.4
24 倍下游網路	0.65	0.65	0.65

4.4 實驗二：比較 SwinUNETR 與 SwinUNETR-V2 對二元分類任務的影響

本實驗比較了 SwinUNETR 與 SwinUNETR-V2 兩種模型於手術後至出院期間是否超過 30 天的二元分類任務準確率，以便後續實驗能夠選擇最佳效果的模型架構。自監督學習預訓練階段與下游分類任務階段說明如下：

● 自監督學習預訓練階段

- 輸入資料：100 例 B 型主動脈剝離病患影像。

- 自監督學習方法：對比學習。
- 資料增強倍率：12 倍。
- 增強方法：旋轉（Rotation）與翻轉（Flipping）進行資料增強。

● 下游分類任務階段

在下游任務中，比較版本一 SwinUNETR 和 SwinUNETR-V2 的分類準確率，實驗設定如下：

- 輸入資料：71 位 Type A 主動脈剝離病患。
- 任務目標：分類病患自手術日至出院日之住院天數是否超過 30 天。
- 資料增強倍率：12 倍。
- 增強方法：旋轉（Rotation）與翻轉（Flipping）進行資料增強。
- 訓練策略：採用 10 折交叉驗證（10-Fold Cross-Validation）。

● 實驗結果

我們使用 2.10 小節介紹的三種評估指標進行評估，我們將 class 1 設定為正類，而 class 0 設定為負類，來計算靈敏度(Sensitivity)和特異度(Specificity)，SwinUNETR-V2 於 10-fold 交叉驗證下達到 0.73 ± 0.17 的準確率，其中 ± 0.17 為標準差，透過 10-fold cross-validation 所得結果計算而得。實驗結果顯示 SwinUNETR-V2 添加的殘差捲積能在特徵擷取過程中保留更多細節資訊，使模型在訓練時能學習到與住院天數相關的特徵，提升住院天數分類任務中的判別能力。詳細數據請參見表 4.3。根據以上結果，後續實驗將以 SwinUNETR-V2 作為主要分類模型。

表 4.3 SwinUNETR 和 SwinUNETR-V2 實驗結果

評估指標	SwinUNETR	SwinUNETR-V2
Accuracy	0.68 ± 0.15	0.73 ± 0.17
Sensitivity	0.50 ± 0.22	0.67 ± 0.27
Specificity	0.79 ± 0.17	0.79 ± 0.20

4.5 實驗三：添加線性層以控制全連接層輸入維度對二元分類任務的影響

在 3.4.1 小節中提到第二種架構設計，讓最後進入到全連階層的輸入控制在 40 維，目的是為了進一步壓縮特徵圖並減少進入全連階層的輸入維度。我們想知道是否能透過這樣的設計提升模型分類能力。

● 自監督學習預訓練階段

- 輸入資料：100 例 B 型主動脈剝離病患影像。
- 自監督學習方法：對比學習。
- 資料增強倍率：12 倍。
- 增強方法：旋轉（Rotation）與翻轉（Flipping）。

● 下游分類任務階段

- 使用資料：71 位 A 型主動脈剝離病患影像。
- 任務目標：二元分類患者的住院天數是否大於 30 天。
- 模型架構：比較版本一和版本二的 SwinUNETR-V2。
- 資料增強倍率：12 倍。
- 資料增強：以旋轉（Rotation）與翻轉（Flipping）進行。
- 訓練策略：採用 10 折交叉驗證。

● 實驗結果

實驗結果可查看表 4.4，結果顯示在降低全連階層的輸入維度後，模型於住院天數分類任務上的平均準確率為 0.68 ± 0.20 ，略低於未進行降低輸入維度模型，造成準確率下降的可能原因為，降維過程中遺失了部分具有辨識力的特徵，使模型在分類住院天數時表現受限。

表 4.4 不同全連階層輸入維度的實驗結果

評估指標	未添加線性層（版本一）	添加線性層（版本二）
------	-------------	------------

Accuracy	0.73 ± 0.17	0.68 ± 0.20
Sensitivity	0.67 ± 0.27	0.63 ± 0.28
Specificity	0.79 ± 0.20	0.71 ± 0.24

4.6 實驗四：比較不同自監督式學習方法對預測住院天數的影響

本實驗比較了 3.3 小節提到的自監督式學習方法在回歸任務中的表現，目的是了解不同預訓練方式對模型預測能力的影響。整個實驗流程分為兩個階段，分別是自監督學習預訓練階段和下游任務階段，說明如下。

- 自監督學習預訓練階段

- 輸入資料：100 例 B 型主動脈剝離病患影像。
- 自監督學習方法：使用 3.3 小節提到所有方法，並進行比較。
- 資料增強：未使用。

- 下游回歸任務階段

本階段改為進行預測住院天數的回歸任務，模型輸出為連續數值，因此以 MAE 作為主要評估指標。實驗設置如下：

- 使用資料：移除死亡的病患影像，並將大於 180 天的個案設為 180 天，共有 58 位病患，圖 4.1 顯示所有病人住院天數大致分布情況。
- 任務目標：預測患者住院天數。
- 模型架構：統一使用 SwinUNETR-V2（版本一）。
- 資料增強：以旋轉（Rotation）與翻轉（Flipping）進行，擴增倍率為 12 倍。
- 訓練策略：採用 10 折交叉驗證。




圖 4.1 A 型主動脈剝離病人住院天數分佈箱型圖

● 實驗結果

根據表 4.5 實驗結果顯示，雖然三種自監督學習方法在預測住院天數的平均絕對誤差上有所差異，但整體而言，預測表現仍有進步空間。為建立基準以評估模型效能，我們計算了這 58 位患者的平均住院天數為 32.05 天以及住院天數中位數 20 天，並使用這兩個數值作為預測值來計算 MAE，結果分別為 17.95 與 21.98。與此相比，三種自監督學習方法的 MAE 分別為 19.82、31.72 及 18.75。對比學習與遮蓋區域預測結果表現略優於平均數基準，但仍未優於中位數基準，顯示模型雖能學習部分與住院天數相關的資訊，但預測能力仍有限。

表 4.5 不同自監督學習方法的實驗結果

方法	平均絕對誤差(天)
隨機遮蓋 75% 區域	19.82 ± 12.02
影像重建	31.72 ± 18.58
對比學習	18.75 ± 10.73
以中位數作為預測值	17.95
以平均數作為預測值	21.98

4.7 實驗五：使用 Soft Voting 與 Hard Voting 融合多個模型的二元分類結果

為了進一步提升分類模型在住院天數預測任務中的準確率，本實驗採用了軟投票（Soft Voting）與硬投票（Hard Voting）兩種方式融合多個模型的預測結果。

- 自監督學習預訓練階段

本實驗延續前述最佳設定，採用對比學習為主要模型架構，自監督階段固定資料增強倍率為 12 倍。我們分別使用不同的隨機初始化種子訓練出多組自監督模型，確保每組模型具備不同的權重起始條件，以增加多樣性。

- 下游分類任務階段

在此階段固定使用 SwinUNETR-V2，使用 71 位 Type A 主動脈剝離資料集來分類患者是否住院超過 30 天，並採用 10 折交叉驗證進行訓練與測試，並選用多個以不同初始權重訓練出的分類模型進行集成，設計如下三種模型數量組合：

- 三模型融合
- 五模型融合
- 七模型融合

其中，軟投票（Soft Voting）方式會將多個模型預測出的類別機率進行平均，再選擇機率最高的類別作為最終輸出；硬投票（Hard Voting）則是根據每個模型的預測結果進行多數決，票數最多的類別即為最終結果。

- 實驗結果

實驗結果如表 4.6 和表 4.7 所示，結果顯示，軟投票五模型融合的設定下，達到最高的準確率 0.77，和 4.4 小節的實驗結果 0.73 相比，顯示出適度的模型數與機率平均融合方式有助於提升預測性能。

表 4.6 硬投票結果

評估指標	3 models	5 models	7 models
Accuracy	0.76 ± 0.14	0.74 ± 0.13	0.76 ± 0.14
Sensitivity	0.62 ± 0.29	0.53 ± 0.32	0.53 ± 0.32
Specificity	0.87 ± 0.19	0.89 ± 0.15	0.91 ± 0.12

表 4.7 軟投票結果

評估指標	3 models	5 models	7 models
Accuracy	0.76 ± 0.15	0.77 ± 0.12	0.72 ± 0.14
Sensitivity	0.53 ± 0.36	0.58 ± 0.26	0.53 ± 0.32
Specificity	0.91 ± 0.12	0.91 ± 0.12	0.84 ± 0.19

4.8 實驗六：重新劃分住院天數區間以進行多類別分類任務

本實驗進一步將住院天數進行三類別分類，以查看模型是否能有效辨識出住院時間的細微差異，具體分類情況可查看表 4.8。

● 自監督學習預訓練階段

- 輸入資料：100 例 B 型主動脈剝離病患影像。
- 自監督學習方法：對比學習。
- 資料增強倍率：12 倍。
- 增強方法：旋轉（Rotation）與翻轉（Flipping）進行資料增強。

● 下游回歸任務階段

- 使用資料：71 位 A 型主動脈剝離病患影像。
- 模型架構：SwinUNETR-V2。
- 資料增強：以旋轉（Rotation）與翻轉（Flipping）進行，擴增倍率皆為 12。
- 訓練策略：10 折交叉驗證。

在模型輸出得到三個類別各自機率後，本研究嘗試以不同臨界值來劃分預測結果，臨界值調整如下：

- Class 0 預測機率 > 0.4 則歸類為 Class 0。
- Class 2 機率 > 0.35 則歸為 Class 2。
- 其餘歸為 Class 1。

- 實驗結果

模型於多分類任務中之表現如表 4.9 所示。整體準確率為 0.35，顯示在三類別的判別上仍具挑戰，特別是在中間區段 Class 1 中表現較弱，這可能與其影像特徵與其他兩類別之間不明顯有關，造成模型學習到的特徵無法明確區分中間類別與相鄰類別。

表 4.8 各類別分類標準

Class 0	住院天數 ≤ 20 天，共 30 人。
Class 1	住院天數介於 21 至 60 天之間，共 21 人。
Class 2	住院天數 > 60 天，或住院期間死亡者，共 20 人。

表 4.9 多分類任務結果

評估指標	Class 0	Class 1	Class 2
Sensitivity	0.63 ± 0.33	0.10 ± 0.21	0.2 ± 0.35
Specificity	0.45 ± 0.28	0.72 ± 0.29	0.82 ± 0.18
Accuracy	0.35 ± 0.10		

第五章 結論和未來方向

5.1 結論

在本研究中，我們針對住院天數預測進行了一系列以影像為基礎的深度學習實驗，於所有二元分類的實驗當中，表現最佳的準確率為 0.77，和 3.7 小節提到的 Baseline 準確率 0.52 相比表現較好。此結果顯示，深度學習模型具備從醫療影像中提取與住院時間相關特徵的能力，並能有效辨識病患是否有長期住院的風險。但當任務轉為三分類或回歸任務時，模型的表現則未如預期。此一結果可能與住院天數本身作為病情嚴重程度指標的局限性有關，該指標可能受到健保給付規範、病床資源分配等非病情因素影響，進而降低模型預測的準確性與一致性。

5.2 未來方向

未來可以在資料處理的階段加入 bounding box，來圈出主動脈剝離的位置，並計算剝離在主動脈中擴散的範圍或體積。這樣的資訊除了可以提供模型更多輸入特徵，也能幫助模型學習病灶嚴重程度與住院天數之間的關係。

除了影像資訊外，未來可嘗試整合患者的臨床病歷資料，如臨床症狀表現、慢性病史等非影像特徵。這類資料與影像資訊互補，可進一步提升模型對住院天數的預測能力。特別是在資料不平衡或某些病例影像特徵不明顯時，非影像資訊可能提供關鍵輔助，有助於提高整體預測準確性與模型穩定性。

在模型預測目標上，未來研究可考慮將住院天數替換為更具臨床意義且相對客觀的指標，例如：改以病患脫離呼吸器的時間點作為預測目標，以更準確地反映病情嚴重程度與恢復進展。除此之外，也可延伸模型任務，使其能夠比較病人術前與術後半年主動脈的影像差異，判斷是否因主動脈剝離導致血管直徑擴大，進一步提供醫師快速判斷病情變化與發展趨勢的輔助工具。這些目標均能提升模型在臨床實務中的應用價值，並加強其在病情監測與決策支援上的實用性。

參考文獻

- [1] A. S. Lundervold and A. Lundervold, "An overview of deep learning in medical imaging focusing on MRI," *Z. Med. Phys.*, vol. 29, no. 2, pp. 102–127, 2019.
- [2] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin, "Attention is all you need," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017.
- [3] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani *et al.*, "An image is worth 16×16 words: Transformers for image recognition at scale," *arXiv preprint arXiv:2010.11929*, 2020.
- [4] Z. Liu, Y. Lin, Y. Cao, H. Hu, Y. Wei, Z. Zhang, S. Lin, and B. Guo, "Swin Transformer: Hierarchical vision transformer using shifted windows," in *Proc. IEEE/CVF Int. Conf. Comput. Vis. (ICCV)*, Montreal, QC, Canada, 2021, pp. 10012–10022.
- [5] A. Hatamizadeh, V. Nath, Y. Tang, D. Yang, H. R. Roth, and D. Xu, "Swin UNETR: Swin transformers for semantic segmentation of brain tumors in MRI images," in *Proc. Int. MICCAI BrainLes Workshop*, Springer, 2021, pp. 272–284.
- [6] Y. He, V. Nath, D. Yang, Y. Tang, A. Myronenko, and D. Xu, "SwinUNETR-V2: Stronger Swin Transformers with Stagewise Convolutions for 3D Medical Image Segmentation," in *Proc. Int. Conf. Med. Image Comput. Comput.-Assist. Interv. (MICCAI)*, Vancouver, BC, Canada, 2023, pp. 416–426.
- [7] "3D Slicer," [Online]. Available: <https://www.slicer.org/>.
- [8] "MONAI," [Online]. Available: <https://monai.io/>.
- [9] 張維俊, "自我監督式學習應用於醫療影像之研究," 碩士, 資訊工程系, 國立臺北科技大學, 台北市, 2023. [Online]. Available: <https://hdl.handle.net/11296/8ds62m>

- [10] K. He, X. Chen, S. Xie, Y. Li, P. Dollár, and R. Girshick, "Masked autoencoders are scalable vision learners," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, New Orleans, LA, USA, 2022, pp. 16000–16009.
- [11] Z. Yao, W. Xie, J. Zhang, Y. Dong, H. Qiu, H. Yuan, Q. Jia, T. Wang, Y. Shi, J. Zhuang, L. Que, X. Xu, and M. Huang, "ImageTBAD: A 3D computed tomography angiography image dataset for automatic segmentation of Type-B aortic dissection," *Frontiers in Physiology*, vol. 12, article 732711, 2021.



附錄 A




圖 A.1 七項影像特徵相關性熱圖

附錄 B

表 B.1 以總分大於 3 分作為分類門檻之結果

總分大於 3 分者歸為 class 1，其餘則歸為 class 0	
Accuracy	0.44
Sensitivity	0.71
Specificity	0.26

表 B.2 以總分大於 5 分作為分類門檻之結果

總分大於 5 分者歸為 class 1，其餘則歸為 class 0	
Accuracy	0.58
Sensitivity	0.25
Specificity	0.79

表 B.3 以總分大於 6 分作為分類門檻之結果

總分大於 6 分者歸為 class 1，其餘則歸為 class 0	
Accuracy	0.62
Sensitivity	0.11
Specificity	0.95

表 B.4 總分為 7 分病患之住院天數

編號	住院天數（手術日期至出院日期）	是否死亡
1	22 天	否
2	15 天	否
3	78 天	是

4	1 天	是
5	61 天	否

